

Luiz Henrique Monteiro Silva Lima

**SOLUÇÃO PARA EXTRAÇÃO E
CLASSIFICAÇÃO EM FATURAS DE CARTÃO
DE CRÉDITO UTILIZANDO FERRAMENTAS
DE INTELIGÊNCIA ARTIFICIAL**

Itaquaquecetuba, SP

2025

Luiz Henrique Monteiro Silva Lima

SOLUÇÃO PARA EXTRAÇÃO E CLASSIFICAÇÃO EM FATURAS DE CARTÃO DE CRÉDITO UTILIZANDO FERRAMENTAS DE INTELIGÊNCIA ARTIFICIAL

Projeto de monografia apresentado como requisito parcial para obtenção do título de especialista.

Universidade de São Paulo – USP
MBA em Inteligência Artificial e Big Data

Itaquaquecetuba, SP
2025

Lista de ilustrações

Figura 1 – Exemplo de fatura de cartão de crédito.	11
Figura 2 – Pipeline de processamento OCR	34
Figura 3 – Pipelines de transformação e classificação	36
Figura 4 – Fluxo de Experimentação e operação de modelos	39
Figura 5 – Arquitetura de Data Lakehouse Orientada a Eventos com MLOps . . .	58

Lista de tabelas

Tabela 1 – Características dos trabalhos correlatos e relação com a presente pesquisa 48

Sumário

1	INTRODUÇÃO	10
1.1	Objetivos	12
2	FUNDAMENTAÇÃO TEÓRICA	15
2.1	Aprendizado Supervisionado	15
2.1.1	Features (Atributos) vs. Labels (Rótulos)	17
2.1.2	Classificação vs Regressão	17
2.1.3	Trade-off Viés-Variância (Bias-Variance Tradeoff)	18
2.1.4	Preparação e Divisão dos Dados	18
2.1.5	Cross-Validation (Validação Cruzada / K-Fold)	18
2.1.6	Lidando com Classes Desbalanceadas	18
2.2	Os Algoritmos (Modelos Clássicos)	19
2.3	Métricas de Avaliação	20
2.3.1	Otimização e Diagnóstico	21
2.4	Mineração de Dados	21
2.4.1	A Ponte entre Mineração de Textos e a Geração de Ground-Truth	23
2.5	Processamento de Visão Computacional e Extração	24
2.5.1	Técnicas de OCR	25
2.5.2	O Papel das Bounding Boxes na Estruturação do OCR	26
2.5.3	Pré-Processamento de imagem	27
2.5.4	Medidas de avaliação da Qualidade do OCR	28
2.5.5	Pós-processamento de OCR e a Eficiência de Modelos de Linguagem em Textos Curtos e Financeiros	30
2.5.6	A Ineficiência de LLMs Generativos neste Domínio	31
2.5.7	Finalização de limpeza de dados	32
2.6	Processamento de Linguagem Natural Aplicado à Classificação Fi- nanceira	33
2.6.1	Pré-processamento Léxico e Morfológico em Textos Ruidosos	34
2.6.2	Estratégias de Tokenização	34
2.6.3	Vetorização e Representação Semântica	35
2.6.4	A transição para o Estado da Arte	35
2.6.5	Discussão: papel do pipeline clássico na era dos LLMs	36
2.6.6	Pipeline de Pré-Processamento e Extração (OCR)	36
2.6.7	Saneamento Pós-OCR: A Higienização do Dado	37
2.6.8	Modelagem e Classificação Semântica	37

2.6.9	Viabilidade Prática e Ciclo de Manutenção Contínua	37
2.6.10	Ciclo de Vida do Modelo e Práticas de MLOps	38
2.6.11	Ciclo de Vida de Modelos e Aprendizagem Ativa em Ambientes Dinâmicos .	41
3	TRABALHOS RELACIONADOS	43
3.1	String de Busca	43
3.1.1	Justificativa dos termos	43
3.1.2	Trabalhos Fracamente Relacionados (Problemas similares ou próximos) . . .	44
3.1.3	Correção e pós-processamento de erros de OCR via modelos de linguagem .	44
3.1.4	Aplicação de LLMs e Transformers para saneamento e categorização de dados desestruturados	44
3.2	Critérios para escolha e exclusão de trabalhos relacionados	45
3.3	Descrição dos estudos selecionados	45
3.3.1	Dhingra et al. (2016) e Zhang et al. (2021)	45
3.3.2	Participantes da Competição ICDAR (2019) e Modelo CCC	45
3.3.3	Santos (2023)	46
3.3.4	Araújo et al. (2024)	46
3.3.5	Souza (2025)	47
3.4	Características dos estudos selecionados e Conclusão da Seção . . .	47
3.5	Conclusão do Capítulo	49
4	PROCEDIMENTOS METODOLÓGICOS	51
4.1	Classificação da Pesquisa	51
4.2	Framework de Desenvolvimento (CRISP-DM Adaptado)	51
4.2.1	Coleta e Compreensão dos Dados	52
4.2.2	Preparação e Saneamento	52
4.2.3	Modelagem Comparativa	52
4.2.4	Avaliação e Métricas Quantitativas	53
4.2.5	Implantação e Ciclo de Vida (MLOps)	53
4.3	Desenvolvimento da Solução/Proposta	54
4.3.1	Arquitetura Geral da Solução e Stack Tecnológico	54
4.3.2	Módulo de Ingestão e Extração (OCR)	54
4.3.3	Pipeline de Saneamento e Processamento de Dados	55
4.3.4	Implementação do Baseline Científico	55
4.3.5	Implementação do Estado da Arte (Transformers e LLMs Abertos)	55
4.3.6	Encapsulamento e Deploy (MLOps)	56
4.4	Estratégia de Garantia de Qualidade e Testes	56
4.4.1	Testes Unitários e Simulações (Mocks)	56
4.4.2	Testes de Integração com <i>Testcontainers</i>	57
4.4.3	Validação de Dados e Testes de <i>Machine Learning</i>	57

4.4.4	Testes Fim-a-Fim (E2E) e de Carga	57
	REFERÊNCIAS	59

Lista de abreviaturas e siglas

USP	Universidade de São Paulo
USPSC	Campus USP de São Carlos
IA	Inteligencia artificial
OCR	Reconhecimento Óptico de Caracteres
ABCS	Associação Brasileira das Empresas de Cartões de Crédito e Serviços
SPC	Serviço de Proteção ao Crédito

IA Inteligencia artificial

PLN Processamento de Linguagem Natural

OCR Reconhecimento Óptico de Caracteres

Regex Expressões Regulares

TF-IDF Term Frequency-Inverse Document Frequency

ML Machine Learning

Todo list

■ Fechar o escopo para diminuir saneamento léxico	13
■ REFAZER ESSE PONTO - PRECISO REESCREVER COM BASE NO QUE FOI CONVERSADO EM REUNIÃO SOBRE O USUÁRIO DIZER AS CLASSES QUE O MODELO NÃO CONSEGUIU CLASSIFICAR	23
■ Revisar esse ponto(detectei que esse pre-processamento pode ou não acontecer) .	27
■ Modificar essa parte do TCC na questao do uso de regex	34
■ escrever sobre técnicas de LGPD	54
■ concluir referencias	57

1 Introdução

Com a popularização do cartão de crédito como principal meio de pagamento no Brasil trouxe consigo um desafio crescente: a dificuldade de compreender e organizar os próprios gastos. Em 2024, as compras com cartão de crédito, débito e pré-pagos somaram por volta de 4,1 trilhões, segundo a Abecs (Panorama Abecs, 2024). Ao mesmo tempo, dados da Serasa indicam que o país possui cerca de 200 milhões de cartões de crédito ativos e que, aproximadamente 29,37% dos brasileiros inadimplentes tinham dívidas ligadas ao cartão de crédito (Serasa, 2024). Nesse contexto, surge a necessidade de ferramentas que auxiliem o usuário a visualizar, categorizar e compreender seus padrões de consumo de forma automática e inteligente.

Este trabalho propõe desenvolvimento de um classificador automático de gastos de cartão de crédito baseado em técnicas de inteligência artificial, que seja capaz de atribuir categorias de despesas (como alimentação, transporte, lazer, assinaturas, saúde, etc.) a partir da descrição presente nas faturas. A solução busca aproximar conceitos de linguagem de máquina, processamento de linguagem natural e análise de dados das pessoas, oferecendo uma ferramenta para o controle financeiro pessoal.

O uso de cartão tornou-se parte essencial na vida financeira dos brasileiros, representa uma principal forma de pagamento tanto no comércio físico quanto digital. Segundo o relatório de hábitos de consumo da Elo, os gastos com cartão cresceram 8% no final de 2024 em relação ao ano anterior, que foi impulsionado pelo consumo de alta renda e compras digitais, tiveram aumento de 15% (poder 360, 2025). Esse crescimento reflete tanto a conveniência do meio de pagamento quanto também a expansão do comércio eletrônico e a digitalização da nossa gestão financeira.

No entanto facilitar o uso do cartão de crédito trouxe consigo um desafio significativo: a falta de controle nos gastos. Muitos consumidores recebem mensalmente faturas extensas, por descrições e abreviações, códigos alfanuméricos e nomes de estabelecimento pouco claros, o que dificulta a identificação rápida de onde o dinheiro está sendo gasto. Essa falta na visibilidade favorece o gasto impulsivo, o endividamento tornando mais trabalhoso o uso de planilhas ou aplicativos de gestão financeira que dependem, em grande parte, de classificação/categorização manual. Nesse cenário, as soluções baseadas em IA surgem como alternativa promissora para automatizar a organização e análise de despesas, permitindo que usuário compreenda melhor seus gastos e tome decisões financeiras mais conscientes.

A categorização automática coloca no campo da análise de dados financeiros. Técnicas de aprendizado supervisionado são fundamentais para interpretar descrições e atribuir categorias (MITCHELL, 1997). O uso de dados transacionais nos permite a construção de modelos que aprendem com o histórico dos usuários, mitigando a necessidade de inserção

manual de dados em planilhas ou aplicativos.

O problema central é a falta de padronização nas descrições das faturas, que frequentemente utilizam códigos e abreviações, na figura 1 é demonstrado claramente a falta de padronização. Segundo o Serviço de Proteção ao Crédito (SPC BRASIL, 2024), a maioria dos brasileiros não possui um bom controle de seus gastos mensais. A relevância deste projeto esta na capacidade de oferecer visibilidade imediata sobre os padrões de consumo, auxiliando na prevenção da inadimplência e promovendo a educação financeira/ gestão financeira.

Figura 1 – Exemplo de fatura de cartão de crédito.

MARIA OLIVEIRA COSTA			R\$ 2.450,15
05 FEB	1234	Livraria Cultura - São Paulo	R\$ 145,50
08 FEB	5678	Academia SmartFit - Parcela 3/12	R\$ 99,90
11 FEB	9012	Netshoes - Parcela 2/3	R\$ 110,33
14 FEB	3456	Café Do Ponto - Ipanema	R\$ 22,80
16 FEB	7890	Papelaria Grafite - Curitiba	R\$ 48,20
18 FEB	1122	Padaria Pão de Queijo - Belo Horizonte	R\$ 15,90
21 FEB	4455	Supermercado Pão de Açúcar - Recife	R\$ 299,75
24 FEB	6677	Farmácia Drogasil - Salvador	R\$ 81,10
26 FEB	8899	Restaurante Mocotó - São Paulo	R\$ 195,40
28 FEB	1010	Cinema Kinoplex - Shopping Morumbi	R\$ 68,00
02 MAR	2020	Gasolina Posto Shell	R\$ 210,00
05 MAR	3030	Petshop Cão Fiel	R\$ 74,50
08 MAR	4040	Loja Zara - Parcela 1/2	R\$ 125,00
11 MAR	5050	Uber - Viagem Local	R\$ 18,90
14 MAR	6060	Mercado Livre	R\$ 89,90
19 MAR	8080	Padaria Dona Deôla	R\$ 12,50
21 MAR	9090	Barbearia Corleone	R\$ 55,00
23 MAR	1133	Restaurante Bráz Pizzaria	R\$ 138,00
25 MAR	2244	Assinatura Netflix	R\$ 44,90

Fonte: Minha fatura adaptada com IA

Ademais, a automação desse processo mitiga substancialmente a carga de tempo e o esforço cognitivo exigidos para a atualização contínua de sistemas de gestão financeira, conferindo maior acessibilidade e sustentabilidade metodológica à prática no longo prazo.

A estruturação de um classificador automatizado de despesas, contudo, pressupõe a superação de obstáculos intrínsecos a esse domínio de dados. Entre os principais desafios, destacam-se: (i) a **variabilidade e falta de padronização** nas descrições transacionais, frequentemente repletas de abreviações, códigos alfanuméricos, sufixos de autorização e heterogeneidade na nomenclatura de um mesmo fornecedor; (ii) a **necessidade de dados rotulados** para o treinamento de modelos supervisionados, o que impõe uma etapa exaustiva de curadoria manual inicial; (iii) a **manutenção contínua do modelo**, justificada pela constante inserção de novos estabelecimentos no mercado e pela fluidez dos padrões de consumo humano; e, por fim, (iv) a garantia da **privacidade e segurança**

dos dados financeiros, que exige tratamento ético e arquiteturas rigorosas para mitigar riscos de exposição e uso indevido de informações sensíveis.

A despeito dessas barreiras, a aplicação conjunta de técnicas de aprendizado de máquina e processamento de linguagem natural consolida-se como uma solução não apenas viável, mas altamente escalável. Trata-se de uma abordagem com potencial para gerar um impacto transformador na governança e na saúde financeira dos indivíduos.

1.1 Objetivos

O **objetivo geral** deste trabalho é desenvolver e avaliar um classificador de gastos de cartão de crédito baseado em Inteligência Artificial, capaz de categorizar automaticamente as transações a partir da descrição textual presente na fatura, auxiliando o usuário a entender seus padrões de consumo e apoiar decisões de planejamento financeiro.

Para alcançar esse objetivo geral, foram definidos os seguintes objetivos específicos:

1. **Extração e Digitalização de Dados (OCR):** Implementar um módulo de visão computacional capaz de processar documentos financeiros (em formato PDF e imagem) e extrair os dados textuais brutos relativos às transações.
2. **Pré-processamento e Saneamento Léxico:** Desenvolver heurísticas e expressões regulares (Regex) avançadas para a limpeza de ruídos gerados pelo OCR, removendo sufixos bancários, códigos alfanuméricos e stopwords específicas do domínio financeiro.
3. **Estabelecimento de um Baseline Científico:** Treinar e avaliar algoritmos de Machine Learning clássico (como Naive Bayes e Random Forest) acoplados a técnicas de vetorização tradicionais (TF-IDF), estabelecendo uma métrica base de desempenho.
4. **Implementação do Estado da Arte (Transformers):** Explorar e implementar modelos de linguagem avançados (como a arquitetura ByT5, focada na tokenização ao nível do caractere/byte) para a classificação semântica, visando uma maior resiliência aos erros ortográficos e abreviações das faturas.
5. **Análise Comparativa de Desempenho:** Comparar empiricamente os resultados obtidos pelo modelo clássico (baseline) e pelo modelo Transformer, utilizando métricas estatísticas robustas como a Acurácia, Precisão, Recall e, primordialmente, o F1-Score, além da análise visual via Matriz de Confusão.
6. **Arquitetura e Encapsulamento (MLOps):** Desenhar a arquitetura de software da solução, encapsulando os modelos treinados e o motor de extração em um microserviço escalável e pronto para integração em ambientes cloud.

O escopo deste trabalho está limitado à classificação de transações em categorias predefinidas (classificação multiclasse), utilizando como entrada principal a descrição textual presente na fatura, eventualmente combinada com informações auxiliares como valor e data da transação. Não faz parte do escopo deste trabalho a integração com sistemas bancários ou APIs de Open Finance, embora essas extensões sejam discutidas como trabalhos futuros.

Os requisitos do sistema incluem: (i) capacidade de processar descrições textuais variadas e pouco padronizadas; (ii) tempo de resposta adequado para uso em aplicações interativas (classificação em tempo real ou quase real); (iii) interpretabilidade mínima, permitindo ao usuário entender por que uma transação foi classificada em determinada categoria; e (iv) facilidade de retreinamento e atualização do modelo conforme novos dados se tornam disponíveis.

As restrições do trabalho incluem: (i) ausência de ferramentas CASE ou plataformas comerciais de apoio à modelagem, sendo todo o desenvolvimento realizado com bibliotecas open-source em Python; (ii) limitação de dados reais disponíveis, exigindo o uso de dados sintéticos ou anonimizados para complementar o conjunto de treinamento; e (iii) foco em transações de cartão de crédito no contexto brasileiro, com descrições em português.

O domínio de aplicação é o de finanças pessoais, especificamente o controle de gastos de cartão de crédito. Os dados utilizados consistem em transações reais (anonimizadas) e/ou sintéticas, contendo campos como: descrição do estabelecimento, valor da transação, data, e categoria de despesa (rótulo).

As principais questões de pesquisa que orientam este trabalho são:

- **Q1:** Quais técnicas de representação textual e algoritmos de classificação são mais eficazes para categorizar transações de cartão de crédito a partir de descrições pouco padronizadas?
- **Q2:** Qual é o nível de acurácia alcançável por um classificador automático de gastos, considerando a variabilidade das descrições e o número de categorias?
- **Q3:** Quais são os principais tipos de erro cometidos pelo classificador e como eles podem ser mitigados?
- **Q4:** Em que medida a inclusão de informações auxiliares (como valor e data) melhora o desempenho do modelo?
- **Q5:** Qual é a viabilidade prática de manter e atualizar o modelo ao longo do tempo, considerando a entrada de novos estabelecimentos e mudanças no comportamento de consumo?

A hipótese central deste trabalho é que técnicas de aprendizado de máquina supervisionado, combinadas com representações textuais adequadas, são capazes de classificar

Fechar
o es-
copo
para
dimi-
nuir
sanea-
mento
léxico

transações de cartão de crédito em categorias de despesa com acurácia superior a 85% para um conjunto de 10 a 20 categorias, oferecendo uma solução viável e prática para o problema de organização de gastos pessoais.

2 Fundamentação Teórica

2.1 Aprendizado Supervisionado

O aprendizado de máquina supervisionado (Supervised Machine Learning) é uma vertente da Inteligência Artificial em que os algoritmos constroem seu conhecimento a partir de um conjunto de dados preteritamente rotulados. O paradigma é fundamentado na busca por uma função matemática capaz de mapear assertivamente variáveis independentes (os atributos, características ou features) para variáveis dependentes (os rótulos, classes ou labels). A nomenclatura "supervisionada" faz uma analogia à figura de um "professor" ou especialista humano, que detém o conhecimento prévio e oferta ao sistema os gabaritos (as respostas corretas) durante a fase de treinamento, guiando assim as inferências do modelo.

A base dessa metodologia consiste em separar o acervo de informações em diferentes subconjuntos: treinamento, validação e teste. O algoritmo consome primeiro o conjunto de treinamento para ajustar seus padrões internos. Posteriormente, tem sua capacidade de generalização posta à prova com o conjunto de teste, que contém cenários inéditos para assegurar que o sistema aprendeu as regras inerentes aos dados, em vez de apenas memorizá-los (fenômeno conhecido como sobreajuste ou overfitting).

A arquitetura supervisionada é aplicada essencialmente na resolução de dois grandes tipos de problemas:

- **Classificação:** Envolve prever alocações em categorias discretas. Pode ser uma tarefa binária (duas classes) ou multiclasse, em que estratégias de divisão como "Um-contra-Um" (OvO) e "Um-contra-Todos" (OvR) são empregadas para decompor o problema central.
- **Regressão** Neste cenário, a saída buscada é numérica e contínua. O modelo tenta prever uma grandeza escalar (por exemplo, prever tendências ou valores de grandezas físicas) estimando a distância entre a saída prevista e o alvo real.

Uma extensa variedade de algoritmos atende a esse formato de aprendizado, variando em complexidade e formulação estatística:

- **Naïve Bayes:** Classificador probabilístico alicerçado no Teorema de Bayes. É considerado "ingênuo" por partir do pressuposto de que as características de entrada são completamente independentes umas das outras. É reconhecido por sua eficiência e velocidade, sendo muito usado em análises de textos curtos.
- **Máquinas de Vetores de Suporte (SVM):** Buscam delimitar o espaço de dados traçando o melhor hiperplano que promova a maior margem de distância

possível entre classes distintas. São poderosas no tratamento de problemas altamente dimensionais.

- **Árvores de Decisão (Decision Trees):** Estruturam o conhecimento em ramificações hierárquicas, particionando os dados sucessivamente utilizando critérios como entropia ou ganho de informação. Como tendem ao sobreajuste, muitas vezes exigem podas (pruning) estruturais.
- **K-Vizinhos Mais Próximos (K-NN):** Abordagem baseada em instâncias que julga e classifica um novo objeto a partir do "voto da maioria" dos 'k' vizinhos mais próximos no espaço dimensional do conjunto de treino.
- **Métodos de Conjunto (Ensembles):** Trata-se da união de múltiplos algoritmos para criar um preditor superior. Exemplos notáveis incluem estratégias de Bagging, como o Random Forest (que extrai a média de várias árvores de decisão para trazer mais estabilidade), e técnicas de Boosting (AdaBoost, XGBoost, CatBoost), que melhoram sequencialmente a acurácia ao forçar os novos preditores a corrigirem as falhas dos antecessores.
- **Redes Neurais e Deep Learning:** Utilizam múltiplas camadas de neurônios artificiais (ex: Perceptrons Multicamadas, Redes Convolucionais e Transformers) capazes de identificar relações não-lineares muito complexas.

Compreender se a aprendizagem foi bem-sucedida requer ferramentas rigorosas de aferição. Na classificação, utiliza-se constantemente a Matriz de Confusão, uma tabela que confronta os verdadeiros e falsos positivos/negativos previstos pelo sistema. A partir dessa matriz derivam-se indicadores como a Acurácia (percentual absoluto de acertos), a Precisão (fração de predições positivas que estavam corretas), o Recall/Sensibilidade (capacidade do modelo identificar as ocorrências reais) e o F1-Score (uma média harmônica que pondera precisão e recall). A literatura adverte que basear-se apenas na Acurácia pode mascarar o mau desempenho do modelo em dados desbalanceados (o paradoxo da acurácia), tornando indicadores como o F1-Score e o Coeficiente de Correlação de Matthews (MCC) escolhas metodológicas bem mais confiáveis.

Já para tarefas de regressão, usam-se métricas focadas na magnitude do erro, como o Erro Absoluto Médio (MAE), Raiz do Erro Quadrático Médio (RMSE) e o Coeficiente de Determinação (R^2), que traduz o grau de variância explicada pelo modelo. A comunidade científica também salienta o desafio da interpretabilidade (caixa-preta dos algoritmos), fomentando estudos focados em IA explicável e modelos substitutos (surrogates) para tornar inteligíveis as deliberações das redes neurais.

O fluxo metodológico do Aprendizado Supervisionado é estruturado nas seguintes etapas encadeadas:

1. **Estruturação do Conhecimento Prévio (Dados):** O processo inicia-se com a coleta e curadoria de uma vasta base histórica contendo os atributos de entrada associados invariavelmente aos seus respectivos resultados reais (rótulos).
2. **Engenharia de Atributos e Vetorização:** Extraem-se os dados em seu formato bruto (ex: descrições textuais) e as informações são normalizadas em valores numéricos (através de táticas como TF-IDF ou Embeddings) para que os algoritmos consigam processá-las matematicamente.
3. **Fase de Aprendizado (Treinamento):** O algoritmo analisa os dados de treino de forma massiva e iterativa. Nesse momento, ele realiza otimizações internas (ajuste de pesos ou delineamento de regras de ramificação) com a meta de penalizar e reduzir a sua margem de erro perante as respostas fornecidas pelo supervisor.
4. **Otimização Generalista (Validação):** Utilizando processos como a validação cruzada, afina-se os hiper parâmetros do modelo, barrando o overfitting (a simples "decoreba" dos dados) e atestando que a máquina adquiriu inteligência genuína para atuar frente ao desconhecido.
5. **Aferição Final (Teste):** Por fim, o modelo congelado é alimentado com o "conjunto de teste" contendo inputs cegos. Suas previsões são mensuradas com o uso da Matriz de Confusão, calculando F1-Score (se for classificação) ou R^2 (se regressão), provando sua validade como inteligência preditiva viável e não enviesada.

2.1.1 Features (Atributos) vs. Labels (Rótulos)

O aprendizado de máquina supervisionado visa estimar uma função matemática que mapeia um conjunto de variáveis independentes para uma variável dependente. Formalmente, o sistema é alimentado por um **conjunto de dados de treinamento** $\mathcal{D} = \{(x_1, y_1), \dots, (x_n, y_n)\}$, onde cada $x_i \in \mathbb{R}^d$ representa um vetor de dimensão d de **atributos (features)**, e y_i representa o **rótulo (label)** ou alvo (target) correspondente àquela observação. O objetivo do algoritmo é aproximar uma função ótima $h^*(x) = y$ para prever rótulos de novos vetores x .

2.1.2 Classificação vs Regressão

A natureza da variável dependente y define a taxonomia do problema de aprendizado: **Classificação:** Ocorre quando o alvo y pertence a um conjunto discreto e finito de categorias ou classes (ex: $y \in \{0, 1\}$ ou $y \in \{-1, 1\}$ na classificação binária). **Regressão:** Configura-se quando o rótulo y é uma variável escalar contínua ($y \in \mathbb{R}$). O modelo de regressão estima a magnitude de uma grandeza baseando-se na minimização do erro, como o erro quadrático $(h(x) - y)^2$.

2.1.3 Trade-off Viés-Variância (Bias-Variance Tradeoff)

A teoria do aprendizado estatístico estabelece que o erro de generalização de qualquer modelo preditivo pode ser decomposto em duas fontes primárias: **viés (bias)** e **variância (variance)**, formando um balanço indissociável. A formulação clássica para o erro quadrático médio (MSE) sobre os conjuntos de dados de treinamento expressa que:

$$Learning_Error = Bias + Variance$$

Viés (Bias): Expressa o erro introduzido por aproximações incorretas do modelo. Matematicamente, é o quadrado da diferença entre a probabilidade real $P(c|d)$ e o valor médio das predições do modelo $\mathbb{E}_{\mathcal{D}}[\Gamma_{\mathcal{D}}(d)]$ em diferentes conjuntos de treino: $Bias = [P(c|d) - \mathbb{E}_{\mathcal{D}}\Gamma_{\mathcal{D}}(d)]^2$. **Variância (Variance):** Mede a sensibilidade do modelo às flutuações da amostra de treino. Uma variância alta indica que o modelo se ajustou até mesmo aos ruídos aleatórios: $Variance = \mathbb{E}_{\mathcal{D}}[\Gamma_{\mathcal{D}}(d) - \mathbb{E}_{\mathcal{D}}\Gamma_{\mathcal{D}}(d)]^2$. Geralmente, ao se reduzir a variância (ex: aplicando suavização ou regularização), penaliza-se o modelo com um aumento em seu viés, e vice-versa.

2.1.4 Preparação e Divisão dos Dados

Data Splitting (Treino, Validação e Teste) A inferência estatística sólida exige que um modelo não seja testado com os mesmos dados em que foi otimizado. Para tanto, reparte-se o conjunto inicial de observações, de modo a formar os subconjuntos de treinamento (Tr), validação (Va) e teste (Te). O conjunto de validação é utilizado para a otimização de hiperparâmetros (ajuste fino), e o conjunto de teste provê uma estimativa impoluta do erro de generalização.

2.1.5 Cross-Validation (Validação Cruzada / K-Fold)

A abordagem tradicional **hold-out** (uma única divisão) é sensível à maneira randômica em que os dados foram separados. O método de **validação cruzada k-fold** mitiga essa dependência ao fracionar o corpus em k partições mutuamente exclusivas e de tamanho similar. Iterativamente, o modelo é treinado em $k - 1$ partições e testado na partição remanescente. O resultado final é a média do desempenho apurado nestas k iterações, oferecendo uma estimativa estatisticamente mais robusta da capacidade preditiva.

2.1.6 Lidando com Classes Desbalanceadas

Em múltiplos domínios (como detecção de fraudes ou diagnósticos médicos), o número de amostras da classe de interesse é significativamente inferior ao da classe majoritária. Se

esta discrepância não for endereçada, o classificador tende a ser enviesado em direção à classe dominante, manifestando o chamado "paradoxo da acurácia". Estratégias mitigadoras incluem a ponderação assimétrica na função de perda ou metodologias de superamostragem (oversampling), como a técnica **SMOTE**, que sintetiza novas observações interpelando as características da classe minoritária sub-representada.

2.2 Os Algoritmos (Modelos Clássicos)

Naive Bayes: Trata-se de um classificador probabilístico amparado pelo Teorema de Bayes, com a pressuposição ("ingênua") de forte independência condicional entre os atributos. Seu treinamento envolve a contagem de ocorrências para inferir as probabilidades da classe. Para evitar que atributos ausentes no treino forcem a probabilidade a zero, a **suavização de Laplace** é matematicamente aplicada:

$$\phi_{y,j} = \frac{\alpha + \text{count}(y, j)}{V\alpha + \sum_{j'=1}^V \text{count}(y, j')}$$

Regressão Logística (Logistic Regression): Um modelo discriminativo largamente empregado em problemas cujos alvos são probabilísticos. Ele pondera a matriz de features estimando diretamente a probabilidade da variável dependente $P(Y|X)$ ao transformar uma combinação linear usando a função **sigmoide** (para problemas binários) ou **softmax** (para cenários multiclasse):

$$P(y^{(i)} = 1|x, \theta) = \frac{\exp(\theta_{(i)}^T x)}{\sum_{j=1}^m \exp(\theta_{(j)}^T x)}$$

Support Vector Machines (SVM): Metodologia cuja formulação analítica tem como premissa traçar um hiperplano no espaço vetorial que maximize a "margem" geométrica entre exemplos de diferentes classes. O equacionamento visa minimizar $\|\theta\|_2$, simultaneamente isolando os dados perante a função de restrição $y_i(\theta^T x_i + b) \geq 1$. Na etapa de inferência, um modelo SVM classifica pontos a partir do sinal da combinação de seus vetores de suporte $\vec{x}_i$ ponderados pelo coeficiente de Lagrange α_i :

$$f(\vec{x}) = \text{sign} \left(\sum_i \alpha_i y_i \vec{x}_i^T \vec{x} + b \right)$$

Árvores de Decisão (Decision Trees): Realizam o particionamento hierárquico e ortogonal do espaço dimensional. Na fase de aprendizagem de árvore, nós internos avaliam os atributos testando limiares sob heurísticas focadas no decréscimo da entropia ou impuridade (como o índice de Gini, tipicamente implementado pelo CART).

Ensembles - Random Forest: Uma arquitetura estocástica que orquestra e agrega múltiplas Árvores de Decisão. Baseia-se no princípio de Bagging, onde sucessivas sub-amostras do dado são criadas para edificar preditores disjuntos, cujas predições são combinadas através de "votação da maioria". Isso quebra correlações e reduz fortemente o viés de sobreajuste comum em árvores isoladas.

Ensembles - XGBoost / LightGBM: Modelos baseados no paradigma Gradient Boosting. Ao contrário da construção independente das árvores no Random Forest, aqui, as predições são ajustadas sequencial e aditivamente. Cada novo modelo (tipicamente também árvores) foca em aprender os "erros residuais" do preditor anterior (baseados em cálculos complexos de gradiente descendente), proporcionando as mais robustas métricas em competições e dados tabulares.

2.3 Métricas de Avaliação

O crivo metodológico de classificação exige ultrapassar a análise simplória de exatidão do modelo, decompondo sua performance com as seguintes medidas empíricas estruturadas com base na Matriz de Confusão (que sumariza Verdadeiros Positivos - TP , Verdadeiros Negativos - TN , Falsos Positivos - FP e Falsos Negativos - FN):

Precisão (Precision): Relaciona a fração dos instantes classificados como classe alvo que estavam efetivamente corretos:

$$Precision = \frac{TP}{TP + FP}$$

Revocação (Recall / Sensitivity): Capacidade matemática que o preditor tem de identificar o total dos elementos que perfeitamente compunham aquela classe:

$$Recall = \frac{TP}{TP + FN}$$

F1-Score: Definida como a média harmônica englobando a intersecção de perdas entre Precisão e Revocação. É a métrica mais fiável perante amostras desbalanceadas:

$$F_1 = \frac{2 \cdot TP}{2 \cdot TP + FP + FN} = 2 \cdot \frac{Precision \times Recall}{Precision + Recall}$$

Curva ROC e AUC: A Receiver Operating Characteristic (ROC) projeta de forma gráfica o "True Positive Rate" em face ao "False Positive Rate" na variação do threshold operacional. A Área Abaixo da Curva (AUC - Area Under Curve) traduz em uma métrica unificada (de 0,0 a 1,0) a capacidade discriminatória probabilística de toda a classificação. Na literatura pontua-se que se os dados são muito assimétricos/desbalanceados, a medição AUC-PR (Precision-Recall) serve como um corretivo pragmático à otimista ROC-AUC.

2.3.1 Otimização e Diagnóstico

Para assegurar que o modelo adquiriu **inteligência** estatística ao invés de mera "memorização", torna-se necessário diagnosticar sua capacidade de adequação:

- **Overfitting (Sobreajuste):** Ocorre quando um preditor é exposto a altíssima complexidade arquitetural, resultando em um erro residual ilusório no treino, com péssimo balanço generalista nos dados de teste. Na validação experimental, uma das maneiras de se quantificar ativamente esse viés é utilizando a Taxa Logarítmica de Sobreajuste (LOR - *Logarithmic Overfitting Ratio*), onde:

$$LOR = \log \left(\frac{MAE_{train}}{MAE_{test}} \right)$$

Valores muito distintos de 0 inferem severo grau de distorção (**overfitting** se o teste é muito superior ao treino).

- **Underfitting (Subajuste):** Manifesta-se diametralmente em um modelo brando ou insuficientemente treinado, cujas aproximações lineares generalizam pouco os meandros estatísticos subjacentes tanto no treino como na base cega.
- **Hyperparameter Tuning:** Os coeficientes extrínsecos dos classificadores (como profundidade máxima das árvores em Random Forest, ou o custo regulador de complacência C no SVM) não são treináveis nativamente, necessitando manipulações iterativas conhecidas como hiper-parametrização. A sintonia costuma ser conduzida de modo empírico na fase particionada (validação) explorando um espaço vetorial de busca por grade (Grid Search ou Optuna) a fim de encontrar as variáveis que otimizem os f-scores antes de transitar à amostragem de Teste.

2.4 Mineração de Dados

A mineração de dados e de textos, intrinsecamente ligada à Inteligência Artificial (IA), tem como objetivo auxiliar os computadores a entender, interpretar e manipular a linguagem humana por meio do Processamento de Linguagem Natural (PLN) (ANCHIÊTA et al., 2021). No contexto de transações financeiras, como a análise de descrições de compras em faturas, o grande desafio da mineração reside na desestruturação dos dados originais, uma vez que os campos de descrição costumam ser de livre preenchimento, resultando em uma enorme variedade de formas de descrever um mesmo item, incluindo erros ortográficos, abreviações e divergências de representação (SANTOS, 2023).

Para processar essa base de informações desestruturadas e realizar a mineração de forma adequada, os algoritmos de Aprendizagem de Máquina (Machine Learning) apresentam-se como a abordagem metodológica mais indicada, especialmente quando não se conhece com

profundidade o que se está buscando inicialmente nos dados (RAJARAMAN; ULLMAN, 2011). A aprendizagem adotada para o agrupamento e a classificação das compras costuma ser a supervisionada, buscando encontrar um modelo computacional que relacione as observações de dados com categorias previamente associadas, com o intuito de treinar a máquina para prever respostas de observações futuras (SANTOS, 2023).

No processo de mineração de textos a nível de palavras, uma das estratégias matemáticas clássicas utilizadas para a seleção e ponderação de características é a medida TF-IDF (**Term Frequency–Inverse Document Frequency**) (RAJARAMAN; ULLMAN, 2011). Essa técnica calcula a frequência dos termos e permite identificar as palavras que melhor caracterizam o tópico de um documento e o diferenciam dentro de uma grande base de dados (RAJARAMAN; ULLMAN, 2011). Frequentemente, o algoritmo TF-IDF atua em conjunto com classificadores como a Máquina de Vetores de Suporte (SVM), que mapeia os dados minerados em um espaço n-dimensional para buscar a separabilidade das classes, lidando tanto com dados lineares quanto não lineares por meio de funções kernel (FEI; ZHANG, 2020).

Contudo, abordagens tradicionais de mineração baseadas em palavras inteiras podem se mostrar ineficientes ao lidar com textos curtos e que contêm vocabulário despadronizado (DHINGRA et al., 2016). Nesses cenários de maior complexidade textual, a mineração de dados avança para a utilização de Redes Neurais Artificiais (ANN), as quais são constituídas para possuir capacidades de processamento e de aprendizado de padrões de forma análoga ao cérebro humano (OSORIO; BITTENCOURT, 2000). Dentro desse escopo tecnológico, destacam-se as Redes Neurais Recorrentes (RNN), que utilizam sequências de texto como entrada, e suas sub-arquiteturas desenvolvidas para mitigar problemas de perda de informações a longo prazo, como a **Long Short-Term Memory** (LSTM) (HOCHREITER; SCHMIDHUBER, 1997) e a **Gated Recurrent Unit** (GRU) (CHO et al., 2014; CHUNG et al., 2014).

Para superar definitivamente a incidência de ruídos, símbolos e abreviações excessivas nas descrições de faturas, a mineração de texto no estado da arte adota modelos baseados em redes recorrentes bidirecionais (Bi-GRU) a nível de caracteres, a exemplo da arquitetura do **tweet2vec** (DHINGRA et al., 2016). Esse modelo de mineração combina as informações da sequência de entrada simultaneamente nas direções para frente e para trás (**forward** e **backward**), demonstrando superioridade na classificação e na captura de dependências não locais em textos informais (ZHANG et al., 2021). Essa abordagem computacional a nível de caracteres é significativamente mais precisa quando a entrada de dados engloba palavras fora do vocabulário padrão, garantindo alta eficácia na extração, classificação e organização de grandes volumes de faturas e notas de cartão (SANTOS, 2023).

2.4.1 A Ponte entre Mineração de Textos e a Geração de Ground-Truth

A construção de um modelo supervisionado de Aprendizagem de Máquina (Machine Learning) depende intrinsecamente da qualidade dos dados de treinamento, os quais compõem o que se denomina Ground Truth (dados de referência ou "verdade terrestre"). O processo de estruturação do Ground Truth consiste em associar corretamente as observações de entrada (como trechos de texto ou faturas) a uma variável alvo ou rótulo correspondente, permitindo que o algoritmo aprenda as semelhanças e padrões implícitos para, posteriormente, generalizar e prever novas instâncias. Na prática, a literatura aponta que o maior desafio no desenvolvimento de soluções de Inteligência Artificial do mundo real não reside na arquitetura dos algoritmos em si, mas sim na ausência de conjuntos de dados diversificados, extensos e devidamente rotulados.

A abordagem metodológica basilar para a formação de um Ground Truth é a **Rotulação Manual** por especialistas. Para treinar classificadores de texto, é necessário criar um conjunto de pares que vinculem o texto original à sua respectiva classe. Esse procedimento humano requer o estabelecimento de critérios rigorosos de padronização para evitar ambiguidades que possam confundir o modelo. A exemplo da classificação de Notas Fiscais Eletrônicas (NFEs), a criação dos dados de referência exigiu que os anotadores padronizassem abreviações divergentes (como "PCT" e "PACOTE" para uma única classe) e aplicassem regras de negócio estritas, como rotular sempre a menor unidade comercial em casos de descrições complexas com múltiplos volumes.

Em projetos de maior envergadura e complexidade, a criação do Ground Truth deixa de ser uma etapa única e passa a ser compreendida como um processo iterativo e colaborativo. A literatura sugere a utilização de aplicações web dedicadas onde especialistas do domínio da aplicação e cientistas de dados trabalham em conjunto na anotação. Nesse ciclo, as previsões iniciais do modelo são aplicadas em dados fora da amostra e reutilizadas para análise de erros. A partir dessa análise, novas instâncias são estrategicamente rotuladas para complementar os cenários específicos onde o modelo obteve um desempenho insuficiente, repetindo-se o ciclo iterativo até que resultados satisfatórios sejam alcançados. Para mitigar a exaustão do trabalho humano e otimizar a criação desses dados de referência, destaca-se duas técnicas computacionais avançadas:

- **Aprendizagem Ativa (Active Learning):** Tem como objetivo minimizar a quantidade de rotulação manual necessária. O modelo é treinado inicialmente com um pequeno conjunto de dados supervisionados. Em vez de selecionar novas amostras de forma aleatória para anotação humana, o algoritmo seleciona estrategicamente as instâncias mais "valiosas" ou incertas — geralmente aquelas que se encontram muito próximas ao limite de decisão do modelo. Com isso, a máquina aprende os padrões com um volume muito menor de dados, poupando tempo e esforço dos especialistas.

- **Aprendizagem de Confiança (Confident Learning):** Enquanto o foco de muitos métodos está em avaliar a previsão do algoritmo, essa técnica foca estritamente na validação e qualidade dos rótulos manuais que formam o Ground Truth. Ela tem como objetivo caracterizar e identificar erros humanos de anotação nos conjuntos de dados, filtrando exemplos incorretos ou duvidosos. Essa limpeza protege o processo de treinamento, garantindo que o modelo não incorpore falhas decorrentes de imprecisões humanas durante a criação das bases de referência.

Por fim, a preparação da base de referência costuma estar associada à aplicação de **Módulos Redutores de Ruído**. Baseado em regras definidas por especialistas do negócio, esse mecanismo identifica e exclui automaticamente passagens ou trechos irrelevantes dos documentos originais (como cabeçalhos, marcadores ou preâmbulos) antes mesmo da rotulação. Isso reduz drasticamente o volume de informações submetidas à análise humana, mitigando o desequilíbrio das classes e garantindo que o esforço manual de criação do Ground Truth seja direcionado exclusivamente aos dados de real valor analítico.

2.5 Processamento de Visão Computacional e Extração

A **visão computacional** consolida-se como um proeminente campo da inteligência artificial (IA) e da ciência da computação que tem como principal objetivo capacitar as máquinas a processar, compreender e interpretar o mundo visual, replicando as capacidades do sistema visual humano. No cenário do processamento informacional, a intersecção entre a visão computacional e o Processamento de Linguagem Natural (PLN) deu origem à área de Inteligência de Documentos (Document Intelligence ou Document AI). Com a contínua digitalização e o uso massivo de formatos como o PDF, o desenvolvimento de soluções autônomas tornou-se mandatório para entender estruturas documentais complexas que não fornecem nativamente metadados estruturados.

Uma etapa primordial para a extração bem-sucedida da informação é a Análise de Layout de Documentos (Document Layout Analysis - DLA). Esta tarefa consiste em segmentar a imagem do documento descobrindo seus diversos objetos de interesse (como parágrafos, tabelas, figuras e linhas) e classificá-los em categorias lógicas ou funcionais predefinidas. A extração da estrutura hierárquica do layout geralmente envolve localizar entidades visuais através de caixas delimitadoras (bounding boxes) e aplicar metodologias baseadas em regras ou em aprendizado de máquina para modelar e prever a ordem de leitura humana e a topologia da página. A exatidão da análise de layout é essencial, visto que erros nesta fase propagam-se para todas as demais etapas de extração.

Em seguida, o processamento direciona-se à extração da informação textual propriamente dita, estruturada tipicamente em quatro subsistemas: a localização das regiões candidatas a texto, a seleção e filtragem, a extração (que inclui a binarização para separar

os caracteres de fundos complexos) e o reconhecimento do texto. Enquanto os sistemas convencionais enfrentam dificuldades substanciais em imagens complexas com variações de iluminação e fundos texturizados, a adoção moderna de Redes Neurais Convolucionais (CNNs) e modelos baseados na arquitetura Transformer tem estabelecido novos paradigmas de acurácia através da fusão multimodal de características visuais, textuais e de layout espacial.

2.5.1 Técnicas de OCR

As abordagens e técnicas de Reconhecimento Óptico de Caracteres (OCR) evoluíram significativamente, e a literatura aponta que os melhores resultados não dependem apenas do algoritmo de reconhecimento final, mas da combinação de tecnologias modernas com um pipeline robusto de pré e pós-processamento. Destacam-se as seguintes técnicas e ferramentas fundamentais para este domínio:

1. **Modelos Modernos de Deep Learning** As técnicas mais avançadas baseiam-se em Redes Neurais Recorrentes (RNNs) e arquiteturas baseadas em Transformers, capazes de aprender hierarquias de características complexas e realizar a fusão multimodal (visão, texto e layout) na extração dos dados.
2. **Tesseract OCR** Entre as soluções convencionais e de código aberto, o Tesseract (mantido pela Google) é amplamente considerado o mecanismo de OCR livre mais preciso existente. Apesar de sua precisão local e garantia de privacidade a baixo custo, ele necessita que as imagens sejam rigorosamente tratadas, pois seu desempenho se degrada severamente diante de fundos complexos, ruídos e variações no ângulo de rotação do texto.
3. **Técnicas de Preparação e Pipeline (Otimização para o OCR)** Para mitigar falhas em imagens distorcidas, implementam-se métodos como o MSER (Maximally Stable Extremal Regions) integrado com Detecção de Bordas (Canny) para localizar regiões de texto; a Transformada de Hough para retificação automática de inclinações de perspectiva; e a Transformada de Distância e Largura do Traçado (Stroke Width) para remover falsos positivos e ruídos locais.
4. **Abordagem Iterativa com Múltiplos Limiares:** Uma técnica eficaz envolve aumentar a resolução da região de interesse para 300 DPI e utilizar um algoritmo iterativo que gera diversas versões da mesma imagem com variações de brilho, contraste e binarização. Ao final, o sistema usa dicionários léxicos e os valores de confiabilidade (confidence score) do próprio OCR para escolher o melhor resultado por palavra.

5. **Ferramentas para PDFs Nativos** Se o objetivo for puramente extrair dados de documentos PDF digitais já consolidados com variação de layout estrutural, a literatura determina que a biblioteca MuPDF é a que apresenta a maior consistência e melhor desempenho médio (validado pela métrica ROUGE) em manter a estrutura e preservar as informações, superando alternativas como PDFBox, PDFMiner e Slate3k.

Em contrapartida às soluções locais de código aberto, motores comerciais em nuvem como o Google Cloud Vision e o Amazon Textract entregam resultados substancialmente superiores por utilizarem redes profundas para realizar fusão multimodal de texto e layout. O Google Cloud Vision demonstra robustez contundente contra distorções geométricas, enquanto o Amazon Textract destaca-se por ser otimizado para extrair pares de chave-valor e compreender a estrutura espacial de faturas. As limitações dessas APIs em nuvem residem nos custos operacionais recorrentes, exigência de conectividade constante e restrições de limites de requisição (rate limits).

2.5.2 O Papel das Bounding Boxes na Estruturação do OCR

Outro fator determinante para o sucesso da extração é a utilização de Bounding Boxes (caixas delimitadoras). Conceitualmente, uma bounding box é definida como o menor polígono ou retângulo orientado que circunscreve um objeto de interesse ou componente conexo na imagem — neste caso, os caracteres ou palavras isoladas,. Durante a etapa de localização, o algoritmo traça essas caixas ao redor do texto detectado para isolá-lo do plano de fundo, reduzindo o ruído e a complexidade visual para que o reconhecedor processe as regiões de forma independente.

Enquanto motores de OCR mais antigos (ou em configurações padrão, como certas versões do Tesseract) limitavam-se a fornecer retângulos estritos (upright rectangles) que falhavam ao capturar textos inclinados, as abordagens modernas adotam caixas delimitadoras quadrilaterais ou poligonais. Esses formatos são altamente adaptáveis a textos curvos, rotacionados ou com disposições não lineares, frequentemente presentes em faturas amassadas ou fotografadas com perspectiva.

A importância das bounding boxes vai muito além do simples recorte da imagem: elas extraem métricas quantitativas cruciais, fornecendo as coordenadas espaciais exatas (posição, largura e altura em pixels) de cada entidade de texto identificada. Essas coordenadas são o pilar da Análise de Layout de Documentos (DLA), pois fornecem ao sistema as propriedades geométricas necessárias para modelar a topologia da página, fundir caixas delimitadoras sobrepostas, agrupar caracteres adjacentes em blocos semânticos e prever a ordem lógica de leitura humana. Em documentos transacionais despadronizados como faturas e notas fiscais, preservar essa hierarquia espacial é vital. A relação geométrica entre os blocos — como a proximidade e o alinhamento entre o nome de um estabelecimento

comercial e o seu respectivo valor transaccional — carrega a semântica necessária para que o modelo consiga categorizar e compreender os dados extraídos, mesmo sem a presença de marcações estruturais estritas.

2.5.3 Pré-Processamento de imagem

A etapa de pré-processamento de imagens consiste em um funil técnico fundamental que antecede a extração de texto, sendo responsável por adequar as características visuais do documento para maximizar a precisão dos sistemas de Reconhecimento Óptico de Caracteres (OCR). Em domínios transaccionais e complexos, como o processamento de faturas e notas fiscais, os documentos originais frequentemente sofrem com condições adversas de captura, incluindo iluminação inadequada, distorções de perspectiva, fundos texturizados e artefactos de digitalização advindos de câmeras de dispositivos móveis. A literatura demonstra que o aprimoramento da qualidade da imagem de entrada por meio de técnicas robustas de pré-processamento pode aumentar a acurácia geral do OCR em 15% a 30% em documentos desafiadores. Para atingir esse nível de eficácia, o pipeline de preparação da imagem estrutura-se, primordialmente, em três fases operacionais: remoção de ruídos, binarização e correção geométrica.

- 1. Remoção de Ruídos (Denoising e Filtragem Gaussiana)** Durante o processo de digitalização ou captura fotográfica, as imagens adquirem defeitos e degradações, como manchas, ruídos de sensores, fundos complexos, sombras e desfoques, que caracterizam o ruído visual. A etapa de denoising tem o objetivo de detectar e eliminar esses pixels ruidosos ou espúrios, sendo um procedimento que, isoladamente, pode melhorar a precisão do OCR em 3% a 8%. Para mitigar variações abruptas e remover ruídos de alta frequência, aplica-se frequentemente a filtragem Gaussiana, que atua suavizando a imagem de forma leve (ex: utilizando um fator σ apropriado) enquanto preserva a integridade de detalhes estruturais importantes, como os contornos das letras. Diferente de filtros lineares simples que podem borrar a imagem em excesso, a combinação de filtros de suavização com máscaras de nitidez (unsharp mask) reduz as interferências locais e realça o contraste das bordas dos caracteres, preparando uma base limpa para a separação do texto.
- 2. Binarização da Imagem (Thresholding)** Após a atenuação morfológica dos ruídos, a imagem em tons de cinza ou colorida deve ser convertida para uma representação estrita de dois níveis (preto e branco), processo este denominado binarização. O objetivo primário desta operação é maximizar o contraste, separando inequivocamente os objetos de interesse (o texto em primeiro plano, atribuído ao valor 1 ou 0) do fundo do documento (background), com base em um valor de limiar predefinido (threshold). Em faturas de cartão de crédito e recibos comerciais, a

Revisar
esse
ponto (de
que
esse
pre-
processar
pode
ou
não
acon-
tecer)

iluminação sobre o papel raramente é homogênea, fazendo com que abordagens de limiarização global — como o clássico método de Otsu, que calcula um limiar único para toda a imagem — falhem e causem perda de informação textual em áreas sombreadas. Nessas condições, métodos de limiarização local ou adaptativa tornam-se imperativos, pois calculam múltiplos valores de limiar dinâmicos e regionalizados, adaptando-se perfeitamente às mudanças graduais de iluminação e aos fundos não uniformes que degradam as faturas.

3. Correção de Rotação e Inclinação (Deskewing) e Normalização de DPI

Variações no posicionamento físico do papel ou na angulação da câmera durante a captura invariavelmente resultam em inclinações (skew) e na perda de ortogonalidade do conteúdo da página. A etapa de retificação (deskewing) detecta e corrige o ângulo de desvio do documento em relação ao eixo horizontal, um alinhamento que pode melhorar a precisão da leitura do OCR em 5% a 15%. Técnicas puramente matemáticas, como a Transformada de Hough, são frequentemente empregadas neste estágio preliminar para identificar padrões de linhas retas e calcular o ângulo exato de inclinação, permitindo que a imagem seja rotacionada no sentido oposto de forma algorítmica. Aliada estritamente à correção geométrica, a normalização de DPI (Dots Per Inch) atua padronizando a resolução espacial da imagem submetida. A literatura estabelece que a resolução de 300 DPI é o padrão mínimo aceitável e ideal para que as ferramentas modernas de OCR processem textos contendo tamanhos de fonte normais de forma satisfatória.

Em suma, a aplicação rigorosa deste funil técnico na etapa de pré-processamento assegura que as irregularidades visuais e topológicas inerentes às faturas financeiras sejam contornadas. A mitigação combinada de imperfeições lumínicas, de contraste e de inclinação transforma uma imagem originalmente caótica em uma matriz textualmente límpida, estabelecendo os alicerces críticos para que a arquitetura do OCR extraia os dados com excelência.

2.5.4 Medidas de avaliação da Qualidade do OCR

A avaliação da qualidade do desempenho de sistemas de Reconhecimento Óptico de Caracteres (OCR) é uma etapa crítica para determinar a eficácia da extração de dados textuais e identificar deficiências nos modelos computacionais. Para mensurar de maneira objetiva o quão próximo o texto predito pela máquina está de sua transcrição correta — comumente chamada de "verdade fundamental" ou ground truth —, a literatura científica baseia-se em métricas que calculam a similaridade entre strings. O alicerce matemático para o cálculo dessas métricas é a Distância de Levenshtein (também conhecida como distância de edição), que quantifica o número mínimo de operações unitárias de edição

necessárias para transformar o texto gerado pelo OCR no texto de referência original. O cálculo dessas taxas de erro avalia, essencialmente, três classes de falhas que ocorrem durante o processo de reconhecimento:

- **Erro de Substituição (S):** Quando caracteres ou palavras são lidos e classificados de forma incorreta (por exemplo, confundir a letra "c" com a letra "e").
- **Erro de Deleção/Exclusão (D):** Quando há perda ou omissão de caracteres ou palavras que estavam presentes na imagem original, mas que o OCR falhou em capturar.
- **Erro de Inserção (I):** Quando o sistema, geralmente induzido por ruídos no plano de fundo, insere caracteres ou palavras inexistentes no texto de referência.

Neste contexto, a métrica mais fundamental para a avaliação técnica é a Taxa de Erro de Caracteres (CER - Character Error Rate). O CER calcula a porcentagem exata de caracteres reconhecidos incorretamente pelo motor e é obtido por meio da fórmula: $CER = (S + D + I)/N$, onde N representa o número total de caracteres contidos na verdade fundamental. Quanto mais próximo de zero for o resultado numérico, melhor será considerado o desempenho do sistema. Em avaliações acadêmicas, sistemas que apresentam um valor de CER igual ou inferior a 10% já são considerados muito eficientes, e resultados iguais ou menores que 5% são classificados como excelentes. Sob condições mercadológicas modernas e com documentos de alta qualidade, tecnologias de ponta alcançam de forma rotineira um CER inferior a 1%. É importante ressaltar uma particularidade do CER: devido à possibilidade de o OCR gerar uma quantidade excessiva de "inserções indevidas" em imagens muito ruidosas, o valor bruto da equação pode ultrapassar a marca dos 100%. Como artifício metodológico para fins comparativos, é comum aplicar uma normalização na métrica, dividindo o montante de erros pela soma dos erros mais os caracteres corretos (C). Isso garante que a taxa permaneça aprisionada em um intervalo normalizado de 0 a 100%. Avaliando o problema sob uma perspectiva semântica e gramatical superior, utiliza-se a Taxa de Erro de Palavras (WER - Word Error Rate). Esta métrica opera seguindo exatamente o mesmo conceito e arquitetura matemática do CER, porém utilizando palavras inteiras como base da unidade de medição em vez de letras individuais. Sua formulação é $WER = (S_w + D_w + I_w)/N_w$ (onde a variável w delimita os eventos ao escopo das palavras). O WER é a métrica mais apropriada em cenários de transcrição de frases longas ou parágrafos documentais estruturados. Em aplicações comerciais com textos ideais, espera-se que o índice WER seja inferior a 2%. Vale destacar que o rigor do WER é consideravelmente superior ao do CER. Nesta métrica, caso apenas um único caractere que componha uma palavra longa seja predito de forma errada, toda a palavra será integralmente classificada como incorreta — gerando assim um erro de substituição de palavra. Consequentemente, as taxas computadas pelo WER tendem a ser naturalmente

mais altas do que as de CER. E, de forma idêntica ao que ocorre no cálculo dos caracteres, uma profusão de inserções indevidas pelo algoritmo OCR pode facilmente fazer com que o valor final do WER extrapole o limite percentual de 100% em relação ao texto de referência.

2.5.5 Pós-processamento de OCR e a Eficiência de Modelos de Linguagem em Textos Curtos e Financeiros

A etapa de pós-processamento de textos extraídos por Sistemas de Reconhecimento Óptico de Caracteres (OCR) consolidou-se como um componente crítico no fluxo de extração de dados. A presença de ruídos derivados de erros de segmentação, má qualidade da imagem original e distorções tipográficas afeta substancialmente o desempenho de tarefas a jusante, como Recuperação da Informação (IR) e Reconhecimento de Entidades Nomeadas (NER). O impacto é severo: enquanto o processamento da informação mantém certa resiliência a altas taxas de erro em textos longos, a literatura indica que seu desempenho cai de forma dramática quando se trata de textos curtos.

Neste âmbito de textos curtos – onde se inserem diretamente os documentos financeiros e transacionais, tais como faturas e recibos de compras (shopping receipts) –, a precisão na correção de ruídos é estritamente necessária. A literatura contemporânea aborda esse desafio modelando a correção de OCR como uma tarefa de tradução sequence-to-sequence (tradução de um texto ruidoso para um texto limpo no mesmo idioma) ou de remoção de ruído (denoising).

Com base na análise do estado da arte, a arquitetura baseada em Transformers destaca-se na tarefa, mas nem todos os modelos de linguagem são eficientes para este propósito. Para responder de forma incisiva à questão central, os modelos menores e específicos, ajustados finamente (fine-tuned) e baseados em tokenização no nível do caractere ou do byte, são comprovadamente mais eficientes que Grandes Modelos de Linguagem (LLMs) generalistas (como LLaMA, GPT-3.5 e GPT-4) para corrigir ruídos de OCR, especialmente em fragmentos curtos.

Abaixo, fundamentam-se os modelos de linguagem arquitetonicamente mais recomendados:

1. **ByT5 e Tokenização em Nível de Byte** O ByT5 é apontado como uma das soluções mais eficientes e escaláveis. Ao operar na tokenização em nível do byte (ou caractere), o modelo adquire a granularidade ideal para detectar modificações isoladas em strings, um padrão clássico de erro do OCR. Além disso, experimentos revelam que modelos de linguagem perdem precisão e sofrem de severas "alucinações" ao processar páginas inteiras de texto. O ByT5 atingiu sua eficiência máxima (redução de 56% na taxa de erro de caracteres) processando blocos de texto limitados a janelas de contexto extremamente curtas, entre 25 e 50 caracteres. Essa restrição técnica

torna-o nativamente otimizado e altamente eficiente para corrigir dados tabulares e campos isolados comuns em documentos financeiros.

2. **BERT e Modelos Vencedores (Tratamento de Recibos/Textos Financeiros)**

O modelo BERT (incluindo suas derivações) representa a espinha dorsal de métodos vencedores no estado da arte. No âmbito da competição internacional ICDAR 2019 – cujo conjunto de dados incluiu explicitamente a correção de **recibos de compras** (shopping receipts) em diversos idiomas –, a abordagem vencedora (denominada CCC) consistiu num modelo baseado no BERT. Este sistema passa por ajuste fino utilizando camadas convolucionais para detectar a exata posição dos erros de OCR e utiliza uma rede de atenção Sequence-to-Sequence para realizar a correção direta. Essa validação empírica comprova a proeminência das representações baseadas no BERT para textos de natureza financeira-transacional.

3. **BART** O BART foi nativamente pré-treinado com um objetivo de remoção de ruídos corrompidos (text denoising), englobando transformações muito similares aos erros introduzidos pelo OCR, como a deleção de tokens e o preenchimento de texto. Por possuir este viés arquitetônico, o BART corrige erros de segmentação e alucinações de caracteres em uma única etapa e sem precisar de dados explicitamente alinhados no nível do caractere durante seu treinamento, demandando taxas muito baixas de fine-tuning.
4. **mT5** O Text-to-Text Transfer Transformer multilíngue (mT5) é extensamente validado por sua capacidade de retificar erros de OCR de forma agnóstica a diferentes domínios e idiomas. Quando ajustado para as especificidades morfológicas dos ruídos, apresenta reduções consistentes nas taxas de erro de palavra (WER) e caractere (CER) do material extraído.

2.5.6 A Ineficiência de LLMs Generativos neste Domínio

A fundamentação bibliográfica rejeita fortemente o uso de grandes LLMs generativos (como LLaMA ou modelos off-the-shelf da família GPT) para o pós-processamento de OCR. Abordagens baseadas em zero-shot ou few-shot nesses modelos falham em preservar a originalidade do texto. LLMs generalistas, quando deparados com ruídos tipográficos atípicos, tendem a ignorar o papel de correção e introduzem vastas porções de texto inventado (alucinações) ou descartam a sequência original da sentença. Ademais, eles demandam recursos computacionais excessivos (memória de GPU e latência de inferência), tornando-se insustentáveis e ineficientes para tarefas automatizadas de correção textual quando comparados a modelos menores e precisos na escala de 100 a 500 milhões de parâmetros.

Conclui-se que o uso de modelos especializados em nível de subpalavra/caractere — especificamente ByT5, BERT (conforme metodologia do ICDAR 2019 aplicada a recibos), BART e mT5 — constitui o estado da arte para correção de OCR. O uso obrigatório de janelas curtas de contexto (10 a 50 caracteres) não apenas afasta o problema da alucinação como se sobrepõe estruturalmente à tarefa de processar e normalizar entidades curtas, como aquelas frequentemente recuperadas em faturas, certidões e textos financeiros.

2.5.7 Finalização de limpeza de dados

Para finalizar a base do OCR antes da etapa de Processamento de Linguagem Natural (PLN), a limpeza morfológica e estrutural dos documentos atua como o estágio definitivo de consolidação da informação. Após a localização inicial e a binarização, a imagem ainda pode apresentar ruídos residuais, caracteres fragmentados ou aglutinados, e uma topologia desordenada que inviabiliza a interpretação semântica. A resolução desses problemas divide-se em duas frentes: a aplicação de operações de morfologia matemática para o refinamento tipográfico e a estruturação geométrica do layout para garantir a coerência sequencial do texto.

Limpeza Morfológica: Refinamento Tipográfico A Morfologia Matemática é uma ferramenta baseada na teoria dos conjuntos, amplamente utilizada para extrair e modificar estruturas geométricas da imagem, atuando na representação e descrição da forma de uma região (VALIENTE ROMERO, 2018). As formas e traços dos caracteres são avaliados e ajustados por meio de comparações com um "elemento estruturante". Quatro operações fundamentais são aplicadas nesta etapa para melhorar a continuidade das formas:

- **Erosão** Atua reduzindo as proporções da imagem, fazendo desaparecer componentes de tamanho inferior ao elemento estruturante. O efeito prático da erosão é o aumento do espaço entre os caracteres, o que evita sombras indesejadas e elimina pequenos artefatos (VALIENTE ROMERO, 2018).
- **Dilatação** Realiza o processo inverso, expandindo a imagem para "engordar" as partículas e preencher pequenos buracos. Em textos com falhas de impressão ou baixa densidade, a dilatação é crucial para reconectar traços separados, garantindo que fragmentos de uma mesma letra voltem a se fundir.
- **Abertura** Consiste na aplicação da erosão seguida imediatamente pela dilatação. No processamento Pós-OCR, a abertura é empregada especificamente para realizar a separação de caracteres indevidamente emendados ou aglutinados (VALIENTE ROMERO, 2018).
- **Fechamento** Consiste na aplicação da dilatação seguida pela erosão. Essa operação é utilizada para tratar caracteres quebrados (ruídos internos de digitalização),

preenchendo as falhas e garantindo a continuidade estrutural do traçado antes que a imagem seja submetida ao reconhecimento do caractere (VALIENTE ROMERO, 2018).

Limpeza Estrutural: Tratamento de Layout e Coerência Uma vez que os caracteres individuais possuam continuidade morfológica, o sistema deve lidar com a estruturação dos dados. Nesta fase, os resultados são formados por letras ou fragmentos isolados que, sozinhos, não carregam valor semântico. Torna-se imperativo fundi-los em palavras ou linhas de texto, processo realizado por meio do cálculo de distância, altura e sobreposição das caixas delimitadoras (bounding boxes) (VALIENTE ROMERO, 2018). O sistema aumenta progressivamente as margens das caixas delimitadoras de cada caractere até que elas se sobreponham no eixo horizontal. Essas caixas sobrepostas são então mescladas para formar uma cadeia unificada (palavras ou linhas), enquanto caixas solitárias que contêm apenas uma região de texto isolada são suprimidas do processamento por se tratarem, provavelmente, de falsos positivos ou ruídos (VALIENTE ROMERO, 2018).

Entretanto, formar linhas isoladas não garante um texto estruturado, visto que faturas e notas fiscais frequentemente possuem disposições complexas. Para que o texto final seja coerente, aplica-se a Análise de Layout de Documentos (DLA). Esta etapa consolida os fragmentos, identificando e segmentando os conteúdos físicos da página para agrupá-los funcionalmente (DRUMOND, 2023). Os blocos textuais fundidos pelas caixas delimitadoras são rigorosamente ordenados e agrupados em colunas de página coerentes, respeitando sua centralização geométrica e proximidade (DRUMOND, 2023).

O pilar final desta estruturação é a Determinação da Ordem de Leitura, responsável por recuperar a sequência exata em que um leitor humano percorreria as diferentes seções da fatura (DRUMOND, 2023). A aplicação desta organização previne que o OCR misture valores financeiros e nomes de estabelecimentos que estejam alinhados paralelamente em colunas distintas, preservando as relações hierárquicas das informações originais.

Em suma, a combinação do refinamento morfológico com a rígida Análise de Layout (DLA) garante que a matriz de dados transacionais fragmentados se consolide em um texto coeso, contínuo e ordenado. Somente após esta higienização estrutural, o pipeline entrega os dados com a qualidade e a coerência necessárias para que os algoritmos semânticos de Processamento de Linguagem Natural (PLN) procedam com a classificação exata das faturas financeiras.

2.6 Processamento de Linguagem Natural Aplicado à Classificação Financeira

O Processamento de Linguagem Natural (PLN) é uma subárea da Inteligência artificial (IA) dedicada a investigar, desenvolver e propor modelos capazes de compreender,


analisar e manipular a linguagem humana (ANCHIÊTA et al., 2021; CASELI; NUNES, 2024b). No escopo do tratamento de documentos transacionais, o PLN atua como ferramenta para a transição de dados desestruturados, oriundos da extração via Reconhecimento Óptico de Caracteres (OCR) – para matrizes numéricas computáveis. A aplicação de técnicas em descrições de faturas viabiliza a limpeza estrutural do texto, permitindo a extração de informações semânticas e a depois a categorização preditiva dos gastos (CHOWDHURY, 2003; MATOS, 2010)

2.6.1 Pré-processamento Léxico e Morfológico em Textos Ruidosos

A etapa léxica e morfológica de pré-processamento é essencial para assegurar a qualidade da análise dos modelos, possuindo a finalidade de reduzir a alta dimensionalidade do vocabulário e padronizar a entrada de dados (CASELI; NUNES, 2024b). Esse funil inicia envolve operações de normalização morfológica e como a conversão de toda a sentença para letras de caixa baixa, e a aplicação rigorosa de Expressões Regulares (Regex) para a filtragem de pontuação, caracteres especiais e anomalias tipográfica inerentes às falhas de leitura do OCR como descrito na figura (2) (CASELI; NUNES, 2024b). Adicionalmente, a remoção de stopwords - palavras de alta frequência e com função meramente conectiva, como artigos e preposições - é uma prática de otimização consolidada. Contudo, em domínios transacionais, o uso exclusivo de listas universais de stopwords mostra-se falho e insuficiente. A literatura afirma que o trabalho com documentos financeiros exige a criação de listas de exclusão baseadas em regras específicas do negócio sendo necessário a remoção de abreviações e jargões de natureza corporativa (por exemplo, "LTDA", "S/A", "CIA" e "ME"). Tais termos são ruídos que diminuem a precisão da representação do estabelecimento comercial pelo classificador (SANTOS, 2023)

Modificar
essa
parte
do
TCC
na
questão
do
uso de
regex

Figura 2 – Pipeline de pré-processamento OCR



2.6.2 Estratégias de Tokenização

A tokenização consiste em fragmentação e separação do texto contínuo em unidades mínimas e processáveis pela máquina, denominadas tokens (CASELI; NUNES, 2024b). A tokenização é fundamentada no nível de palavras, utilizando espaços em branco e sinais de pontuação como delimitadores estritos. No entanto, essa abordagem demonstra-se muito frágil diante dos elementos textuais das faturas de cartão, que é composta por contrações sistêmicas e descrição unidas. Para mitigar esse problema, a tokenização no nível de

subpalavra (subword) e de caractere se torna indispensável. Essa fragmentação eficaz contra termos anômalos que orbitam fora do vocabulário padrão (Out-Of-Vocabulary). A apresentação a nível de caractere permite que o sistema capture conexões informais e reconstrua a lógica de abreviações comerciais extremas, tornando-a uma estratégia de extração consideravelmente superior para solucionar o problema de sentenças curtas e ruidosas (CASELI; NUNES, 2024b; DHINGRA et al., 2016; SANTOS, 2023).

2.6.3 Vetorização e Representação Semântica


Para que os tokens fragmentados sejam consumidos pelos algoritmos de classificação, é necessário que sua conversão para representações numéricas por meio de processos de vetorização. Inicialmente essa modelagem ocorre através de matrizes de vetorização esparsas, com destaque para o cálculo estatístico de Term Frequency-Inverse Document Frequency (TF-IDF) (SANTOS, 2023). O TF-IDF atua penalizando palavras frequentes e valorizando termos singulares e discriminativos em um documento. Essa técnica persiste na literatura como um baseline científico interessante devido ao seu baixo custo computacional, alta interpretabilidade e solidez empírica em arquiteturas clássicas de Machine Learning (ML) (MATOS, 2010). Apesar da tentativa de sanar a principal debilidade das representações esparsas - a incapacidade de mapear a proximidade contextual e o ordenamento das palavras, a disciplina evoluiu para adoção de semântica distribucional. Através de Embeddings estáticos em espaços densos (como Word2Vec e o FastText), tornou-se possível mapear o texto em um espaço contínuo, conferindo ao modelo a habilidade elementar de aproximar matematicamente termos sinônimos ou de ocorrência análoga dentro do contexto sintagmático (CASELI; NUNES, 2024b)

2.6.4 A transição para o Estado da Arte

A concepção da representação semântica e do processamento textual foi disruptivamente transformada com a introdução das arquiteturas baseadas em Transformers e seus mecanismos de autoatenção (self-attention) (VASWANI et al., 2017; CASELI; NUNES, 2024b). Diferente de modelagens que analisam os termos de forma isolada ou puramente sequencial, o mecanismo de atenção permite que o modelo analise, de maneira bidirecional e paralela, toda a extensão da frase extratada. Ele atribui pesos dinâmicos de relevância a cada token, fundamentando-se nas interações complexas com as suas subpalavras adjacentes (CASELI; NUNES, 2024b). Essa capacidade de gerar representações densas profundamente contextualizadas justifica de maneira categórica a superioridade dessa arquitetura sobre as abordagens clássicas de frequência do baseline (vide Figura 3). Diante de faturas com corrupção óptica severa, em que o nome de um estabelecimento é cortado ou alterado semanticamente por artefatos visuais (ex: "UBER BR" ou "PAGMCDONALDS"), Transformers compactos e em nível de caractere capturam de forma robusta o sentido

contextual oculto pela falha de OCR, fixando-se, desta forma, como a metodologia no estado da arte para sanear, estruturar e classificar com excelência as transações financeiras desestruturadas (ARAÚJO et al., 2024; ZHANG et al., 2021).

Figura 3 – Pipelines de transformação e classificação



2.6.5 Discussão: papel do pipeline clássico na era dos LLMs

A literatura recente sobre text mining e machine learning coloca os métodos clássicos em perspectiva com as abordagens modernas de deep learning e LLMs. A revisão de 2024 sobre text mining argumenta que, apesar do avanço rápido dos modelos de linguagem, técnicas baseadas em frequência e PLN tradicional continuam importantes, seja como baselines, seja em aplicações em que transparência, reprodutibilidade e baixo custo computacional são prioritários. Do mesmo modo, a análise histórica de machine learning conclui que algoritmos clássicos permanecem essenciais e abrem espaço para modelos híbridos que combinam suas vantagens com redes neurais profundas.

Do ponto de vista prático, diversos autores sugerem que projetos envolvendo texto devem iniciar com um pipeline clássico — texto bruto → pré-processamento → TF-IDF → modelo clássico — para estabelecer uma linha de base clara e facilmente reprodutível, antes de investir na adoção de arquiteturas mais complexas. Além de servir como referência quantitativa, esse pipeline oferece maior interpretabilidade, o que é particularmente relevante em contextos regulados (como saúde, direito e administração pública), nos quais a justificativa das decisões do modelo é tão importante quanto sua acurácia.

2.6.6 Pipeline de Pré-Processamento e Extração (OCR)

A porta de entrada do sistema lida com o desafio físico do documento. Visto que faturas frequentemente apresentam fundos texturizados, sombras e distorções de captura, a imagem bruta passa por um funil de limpeza visual. Aplicou-se a binarização adaptativa para separar o texto do fundo sob condições desiguais de luz, conjugada com a filtragem Gaussiana para suavização de ruídos. Adicionalmente, empregou-se a correção geométrica (deskewing) para garantir o alinhamento horizontal das linhas de compra.

Com a imagem estabilizada, a extração dos dados é delegada ao motor Tesseract OCR. O algoritmo atua desenhando caixas delimitadoras (bounding boxes) flexíveis, isolando

especialmente os valores financeiros e as descrições dos estabelecimentos para extrair o texto bruto.

2.6.7 Saneamento Pós-OCR: A Higienização do Dado

O texto que emerge do OCR é naturalmente falho, apresentando frequentes erros de substituição e aglutinação de caracteres. Apoiando-se na fundamentação teórica que rejeita o uso de Grandes Modelos de Linguagem (LLMs generativos) para este fim devido ao altíssimo custo de hardware e incidência de "alucinações", a arquitetura propõe uma camada de higienização cirúrgica.

Foi adotado o modelo de linguagem ByT5, que atua com tokenização em nível de byte. Ao processar os dados em janelas curtas de contexto (ideal para descrições fragmentadas de faturas), o modelo consegue restaurar a integridade ortográfica dos nomes dos estabelecimentos comerciais, alcançando a redução das métricas de erro (CER e WER) sem esgotar os recursos locais da máquina.

2.6.8 Modelagem e Classificação Semântica

Na última milha da arquitetura, o dado anonimizado e higienizado é submetido aos modelos de aprendizado de máquina para a devida categorização em classes de despesa. Para assegurar a validade empírica do estudo, a modelagem foi dividida em duas frentes de experimentação:

Primeiramente, construiu-se uma linha de base (baseline) clássica, combinando a etapa de mineração de texto via vetorização TF-IDF com classificadores tradicionais.

Em contrapartida, para lidar de forma mais profunda com o jargão e as abreviações financeiras extremas, implementou-se uma rede neural amparada no estado da arte. Utilizando a arquitetura de Redes Neurais Recorrentes bidirecionais (como a Bi-GRU), o sistema analisa as palavras a nível de caracteres. Essa tática permite contornar palavras desconhecidas (fora do vocabulário padrão) e extrair o padrão semântico oculto, lidando com eficácia frente ao natural desbalanceamento das categorias de gastos pessoais.

2.6.9 Viabilidade Prática e Ciclo de Manutenção Contínua

A manutenção a longo prazo de um classificador de faturas financeiras impõe o desafio de mitigar os efeitos do desvio de dados (*Data Drift*) e do desvio de conceito (*Concept Drift*), causados pelo surgimento diário de novas empresas e pelas mudanças sazonais nos hábitos de consumo dos usuários (QUINONERO-CANDELA et al., 2008). Para garantir que o sistema mantenha os requisitos de tempo de resposta adequado e facilidade de atualização (KREUZBERGER; KÜHL; HIRSCHL, 2022), a arquitetura prevê um ciclo de


sustentabilidade estruturado em três pilares baseados em técnicas locais de baixo custo computacional:

1. **Gatilhos de Retreinamento Periódico e por Desempenho:** Valendo-se do fato de que a linha de base clássica (TF-IDF) e as abordagens neurais compactas propostas exigem baixa infraestrutura de hardware (ARAÚJO et al., 2024), o processo de retreinamento não exige janelas de manutenção complexas. Propõe-se um modelo híbrido de atualização: (i) cronológico, executado mensalmente de forma automatizada em segundo plano; e (ii) reativo, disparado caso a métrica de *F1-Score* local apresente uma degradação superior a um limiar tolerável pré-estabelecido durante o uso real.
2. **Alimentação por Aprendizagem Ativa (*Active Learning*):** Para contornar a exaustão da rotulação manual de novas faturas despadronizadas (REN et al., 2021), o pipeline adota a Aprendizagem Ativa como mecanismo contínuo. Quando o classificador se depara com a descrição de um estabelecimento comercial inédito e a camada de inteligência emite uma predição com baixo índice de confiança (NORTHCUTT; JIANG; CHUANG, 2021), essa transação é isolada e enviada para uma fila de curadoria. O esforço humano de anotação torna-se cirúrgico, concentrando-se apenas nos dados de real valor analítico para expandir o *Ground Truth* (REN et al., 2021).
3. **Mecanismo de *Fallback* Semântico:** Diante de novos estabelecimentos que ainda não foram incorporados ao modelo pelo retreinamento, o sistema implementa uma camada de contingência. Em vez de classificar a transação erroneamente ou enviá-la para uma categoria genérica, o pipeline utiliza a granularidade do modelo a nível de caracteres (como o ByT5 ou algoritmos morfológicos locais) (REN et al., 2021) para realizar um pareamento aproximado (*Fuzzy Matching*) ou buscar radicais textuais comuns a categorias existentes, garantindo uma experiência preditiva estável mesmo diante do desconhecido.

2.6.10 Ciclo de Vida do Modelo e Práticas de MLOps

A implantação de um classificador de aprendizado de máquina em domínios financeiros não se encerra na obtenção de boas métricas na etapa de teste. Na prática, modelos estáticos sofrem uma degradação preditiva natural e contínua ao longo do tempo. Esse declínio ocorre devido ao constante surgimento de novos estabelecimentos comerciais, mudanças de marca e alterações sazonais nos padrões de consumo, fenômenos formalmente definidos na literatura como *Data Drift* (Dataversity, 2026) e *Concept Drift* (LU et al., 2019).

Figura 4 – Fluxo de Experimentação e operação de modelos



Fonte: Adaptado de Amaral (2026).

Para mitigar essa obsolescência e endereçar a manutenção contínua do sistema, este trabalho propõe a adoção de diretrizes baseadas em *Machine Learning Operations* (MLOps). O MLOps consiste na padronização e automação do ciclo de vida dos modelos, unindo o desenvolvimento da Inteligência Artificial com as práticas de engenharia de software contínua (SCHUMACHER et al., 2023).

Embora o estado da arte e a indústria frequentemente apliquem o MLOps através de orquestrações complexas em nuvem, as restrições de infraestrutura (processamento local e escassez de VRAM) que norteiam este projeto exigem uma adaptação metodológica. Dessa forma, propõe-se uma esteira de MLOps pragmática e enxuta, focada estritamente no monitoramento do modelo e na eficiência do retreinamento.

A sustentabilidade do classificador é garantida através de um ciclo estruturado nos seguintes pilares:

1. **Pilar de monitoramento Contínuo (Observabilidade de IA)** Não basta apenas expor o modelo; é preciso monitorar o comportamento das predições em tempo real.
 - **Detecção de Data Drift:** O sistema deve alertar se a natureza dos textos de entrada mudar repentinamente (por exemplo, se o motor de OCR for atualizado e começar a gerar um padrão de caracteres diferente).
 - **Análise de Confiança (Confidence Score):** O pilar baseia-se em registrar a probabilidade (o score de saída do Transformer) de cada predição. Uma queda

na média de confiança geral do modelo indica que ele está a deparar-se com faturas que não sabe classificar.

2. **Pilar de Aprendizado Ativo (Human-in-the-Loop)** A IA não deve operar de forma 100% autônoma se não tiver certeza, sob o risco de poluir a base de dados do usuário com erros.

- **Roteamento Inteligente:** Predições com um score de confiança alto (ex: > 90%) seguem automaticamente para a base. Predições com baixa confiança são interceptadas pelo sistema.
- **Curadoria:** Essas faturas difíceis ou ambíguas são enviadas para uma fila de revisão humana. A resposta fornecida pelo curador humano gera um novo dado de Ground-Truth de altíssimo valor, pois foca exatamente naquilo que o modelo não sabia.

3. **Pilar de Treinamento Contínuo (Continuous Training - CT)** A base de dados cresce a cada correção humana, mas o modelo não aprende sozinho em tempo real. É necessário orquestrar o retreinamento.

- **Gatilhos Automatizados:** O sistema deve possuir regras de negócio para disparar o treinamento de uma nova versão do ByT5/Random Forest. Estes gatilhos podem ser por volume (ex: retreinar a cada 5.000 novas faturas anotadas) ou por tempo (retreinar a cada 15 dias).
- **Automação do Pipeline:** O fluxo de extração, limpeza (Regex) e vetorização deve ser codificado de ponta a ponta, permitindo que a nova compilação do modelo ocorra sem intervenção manual na engenharia de dados.

4. **Pilar de Engenharia e Implantação Contínua (Continuous Deployment - CD)** Substituir um modelo de IA em produção não pode causar indisponibilidade no serviço de classificação.

- **Arquitetura Desacoplada:** Para que este ciclo rode sem interrupções, a arquitetura exige um isolamento claro das responsabilidades. O encapsulamento do motor de inferência através de um backend robusto, orientado a microsserviços, separa as regras financeiras do processamento matemático.
- **Orquestração e Atualização Invisível:** A containerização da solução permite que a nova versão do modelo treinado suba para o cluster em nuvem de forma transparente (utilizando estratégias como Blue-Green Deployment). Se a nova versão apresentar falhas, a orquestração reverte automaticamente para a versão anterior, garantindo a resiliência do classificador.

2.6.11 Ciclo de Vida de Modelos e Aprendizagem Ativa em Ambientes Dinâmicos

A implantação de modelos de aprendizado de máquina em ambientes de produção não representa o fim do ciclo de desenvolvimento, mas sim o início de uma rigorosa fase contínua de monitoramento e adaptação. Em domínios transacionais altamente dinâmicos, como o setor financeiro e a classificação de faturas, a evolução natural dos dados afeta severamente a capacidade preditiva de modelos estáticos, um fenômeno teoricamente fundamentado e conhecido como desvio de dados (Data Drift) e desvio de conceito (Concept Drift) (QUIÑONERO-CANDELA et al., 2008). O Data Drift ocorre quando a distribuição estatística das variáveis de entrada sofre alterações consistentes ao longo do tempo - impulsionada pelo surgimento diário de novos fornecedores, pelas variações constantes nas abreviações capturadas via OCR e pelas alterações nos padrões de formatação e fatura comercial. Por sua vez, o Concept Drift se manifesta quando a relação subjacente entre os dados de entrada e a variável alvo é alterada, refletindo, por exemplo novos hábitos de consumo. Como a validade estatística de um modelo depende do contexto no qual os dados foram coletados, fatores externos e novas abordagens tornam a manutenção necessária, exigindo ajustes constantes para mitigar a degradação que o modelo sofre com o tempo (ROCHA, 2025; QUIÑONERO-CANDELA et al., 2008).

Para lidar com a exaustão operacional e o alto custo associados à rotulação manual em grande escala de novos dados na criação e atualização do Ground-Truth, a literatura técnica recomenda a adoção da Aprendizagem Ativa (Active Learning) em conjunto com o paradigma Human-in-the-Loop (humano no ciclo de controle). Essa metodologia parte da premissa de que os algoritmos podem escolher, de maneira autônoma, as amostras mais informativas, desafiadoras e ruidosas para serem submetidas à curadoria manual (REN et al., 2021). Utilizando técnicas de aprendizagem confiante e estimação matemática da incerteza, o modelo avalia constantemente o nível de confiança de suas próprias previsões. Quando o classificador encontra a descrição de um novo estabelecimento comercial ou um que esteja seriamente fragmentado que resulta em um limiar de confiança extremamente baixo, essa situação é tratada de forma isolada (NORTHCUTT; JIANG; CHUANG, 2021). Esse esforço de anotação se torna, portanto, estritamente cirúrgico, assegurando que especialistas humanos dediquem seu tempo apenas aos dados que realmente agregam valor analítico ao classificador. Isso expande de forma robusta a "verdade terrestre" (Ground Truth) de maneira robusta e permite a adaptação do algoritmo sem necessidade de rotular grandes volumes de dados triviais ou redundantes (REN et al., 2021).

Em última análise, a conexão estrutural entre a captura contínua de novos dados e o retreinamento eficaz do modelo é formalmente teorizada por meio da disciplina de Operações de Aprendizado de Máquina (Machine Learning Operations - MLOps). O MLOps se estabelece como uma cultura metodológica que harmoniza o desenvolvimento

conceitual, unindo de maneira integrada as práticas de engenharia de software e ciência de dados, com o objetivo de englobar a implementação, implantação, monitoramento e escalabilidade dos produtos de inteligência artificial de ponta a ponta (KREUZBERGER; KÜHL; HIRSCHL, 2022).

Ao incorporar as diretrizes de MLOps no ecossistema financeiro, a arquitetura estabelece rotinas automatizadas de Treinamento Contínuo (Continuous Training), permitindo que a solução integre ciclicamente as amostras corrigidas pela Aprendizagem Ativa ao conjunto de treinamento. Esse acoplamento sistêmico garante que o modelo reaja às mudanças orgânicas do ambiente, combatendo a degradação algorítmica de forma eficaz e promovendo um ciclo de vida preditivo confiável, escalável e duradouro para mitigar instabilidades e ruídos (KREUZBERGER; KÜHL; HIRSCHL, 2022; ROCHA, 2025).

3 Trabalhos Relacionados

Neste capítulo, são abordados os trabalhos que se encontram no estado da arte e possuem relação com esta pesquisa. Tais trabalhos são referentes à classificação de textos curtos e ruidosos, correção de erros de Reconhecimento Óptico de Caracteres (OCR) e uso de arquiteturas de Aprendizado Profundo em hardware limitado.

3.1 String de Busca

Para a busca de trabalhos relacionados a esta pesquisa, foram construídas strings otimizadas utilizando os operadores lógicos AND e OR. O objetivo foi encontrar estudos que tentaram resolver exatamente a classificação de transações financeiras, cruzando o uso de inteligência artificial e processamento Pós-OCR. As sintaxes de busca aplicadas em bases como Scopus, IEEE Xplore e Web of Science foram as seguintes:

```
("financial transaction*"OR "credit card"OR invoice* OR receipt*  
OR "nota fiscal") AND (classification OR categorization) AND (OCR)  
AND ("natural language processing"OR transformer* OR LLM*)
```

•

```
("post-OCR"OR "OCR error correction") AND ("language model*"OR  
transformer* OR LLM*)
```

•

3.1.1 Justificativa dos termos

- **Domínio:** Utilizei "financial transaction*", "credit card", invoice*, receipt* e "bank statement*" para cobrir todas as variações de faturas, recibos e extratos. Incluí o termo regional "nota fiscal" pois trabalhos de relevância técnica costumam utilizar esse termo mesmo escrevendo o artigo em inglês
- **Tarefa:** classification, categorization e "information extraction" capturam os objetivos diretos de saneamento e rotulagem do seu projeto
- **Extração:** OCR e sua forma por extenso garantem que os textos sejam provenientes de leitura de imagens
- **Tecnologia:** A inclusão de transformer* e LLM* garante a recuperação de métodos no estado da arte atual para lidar com dados textuais.

3.1.2 Trabalhos Fracamente Relacionados (Problemas similares ou próximos)

Para resolver seus desafios técnicos de forma isolada, dividi esta categoria em três buscas especializadas.

Classificação de textos curtos e ruidosos Esta string foca estritamente na natureza do dado (curto e com ruído), independentemente de ser um documento financeiro ou não.

String de busca:

("short text*"OR "noisy text*"OR "noisy short text*") AND (classification OR categorization OR representation) AND ("natural language processing"OR NLP OR transformer* OR LLM*)

Justificativa dos termos:

- Textos provenientes de OCR, redes sociais (como tweets investigados em ferramentas textuais) ou registros administrativos frequentemente sofrem com escassez de contexto e erros ortográficos . O termo "noisy text*"abrange diretamente os ruídos que afetam a vetorização clássica, atraindo soluções que utilizam embeddings e Transformers para contornar esse problema

3.1.3 Correção e pós-processamento de erros de OCR via modelos de linguagem

Esta string busca trabalhos focados em limpar e arrumar os erros gerados pelas falhas inerentes de ferramentas como Tesseract ou Google Vision antes da classificação

Justificativa dos termos:

- A literatura aponta que a correção de erros residuais de OCR tem tido resultados no estado da arte ao utilizar Modelos de Linguagem (LMs) e arquiteturas baseadas em tradução de máquina (Neural Machine Translation) no processamento Pós-OCR . Os termos isolam pesquisas que modelam o problema de correção de erros de digitalização de documentos como uma tarefa de tradução texto-a-texto via LLMs/Transformers

3.1.4 Aplicação de LLMs e Transformers para saneamento e categorização de dados desestruturados

Esta string almeja estudos focados em organizar o caos textual.

String de busca:

("unstructured data"OR "unstructured text*") AND (sanitization OR cleaning OR classification OR categorization) AND (transformer* OR LLM* OR "large language model*"OR "deep learning")

Justificativa dos termos:

- Campos extraídos por OCR em faturas raramente chegam organizados; eles são caracterizados como dados não-estruturados que necessitam de forte pré-processamento . A inclusão de sanitization e cleaning junto a LLM* e transformer* vai mapear o uso destas redes complexas não apenas para classificar, mas atuar também como agentes higienizadores da informação bruta

3.2 Critérios para escolha e exclusão de trabalhos relacionados

A quantidade de pesquisas sobre processamento de linguagem natural (PLN) e visão computacional é vasta. Sendo assim, como requisitos para inclusão de trabalhos com melhor exatidão e qualidade para o tema, foram adotados filtros temáticos rigorosos. Foram incluídos estudos que detalham a metodologia de treinamento de redes neurais e que avaliam o desempenho ou a viabilidade do treinamento em computadores com recursos limitados (escassez de VRAM). Como critérios de exclusão, foram eliminados trabalhos que utilizam Grandes Modelos de Linguagem (LLMs) de forma puramente generativa sem avaliar os custos computacionais, ou abordagens que não detalham o tratamento do desbalanceamento de classes, por não refletirem as restrições práticas deste TCC.

3.3 Descrição dos estudos selecionados

3.3.1 Dhingra et al. (2016) e Zhang et al. (2021)

Dhingra et al. (2016) e Zhang et al. (2021) descrevem um trabalho o qual concentrou-se na mineração de textos curtos e informais provenientes de transações e redes sociais, utilizando arquiteturas de Redes Neurais Recorrentes (Bi-GRU e LSTM) de natureza bidirecional. A metodologia comprovou que as linhas de base (baselines) compostas por modelos clássicos de processamento de linguagem falham agressivamente diante de palavras fora do vocabulário padrão da língua (fenômeno conhecido como Out-Of-Vocabulary). Essas conclusões sustentam a arquitetura proposta para o meu TCC, evidenciando a necessidade de utilizar uma visão textual bidirecional e granular para conseguir capturar o sentido de nomes de lojas e estabelecimentos que frequentemente aparecem cortados, abreviados ou aglutinados na leitura do OCR da fatura (como, por exemplo, o termo "UBER BR").

3.3.2 Participantes da Competição ICDAR (2019) e Modelo CCC

Participantes da Competição ICDAR (2019) e Modelo CCC descrevem um trabalho o qual objetivou realizar a correção de falhas de OCR voltada especificamente para o

domínio comercial de recibos de compras (shopping receipts), implementando arquiteturas de aprendizado profundo focadas em tradução texto-a-texto (Sequence-to-Sequence), amparadas em modelos BERT modificados com redes convolucionais. A grande limitação desse e de outros modelos apresentados no torneio reside na exigência de uma infraestrutura de hardware altamente onerosa, inviabilizando aplicações de correção na borda do dispositivo do usuário (edge computing). Isso confirma as escolhas estruturais do meu TCC, evidenciando que limpar o OCR financeiro exige o uso de Transformers menores focados em sub-palavras, capazes de processar e reconstruir a sentença inteira com baixo custo computacional e superando as abordagens ingênuas baseadas apenas em regras de substituição manual (Regex).

3.3.3 Santos (2023)

Santos (2023) descrevem um trabalho o qual foi selecionado para este projeto por fundamentar a superioridade do processamento a nível de caracteres no trato de dados financeiros desestruturados e desbalanceados. Os autores avaliaram a viabilidade do uso de algoritmos de aprendizado de máquina para a classificação de produtos em Notas Fiscais Eletrônicas (NFE) a partir de descrições textuais curtas e ruidosas. Em sua síntese, o estudo implementou e comparou um classificador tradicional (baseline) a nível de palavras contra uma Rede Neural Recorrente (arquitetura LSTM) a nível de caracteres, mitigando falhas da vetorização clássica (TF-IDF) diante de jargões. Na metodologia de treinamento, a rede LSTM otimizou seus pesos através de retropropagação, utilizando portas lógicas (gates) para evitar o problema da dissipação do gradiente (vanishing gradient) em sequências mais complexas. Contudo, os autores relataram expressiva dificuldade em treinar arquiteturas recorrentes em computadores menos potentes; a complexidade da rede exigiu rigoroso controle do tamanho do lote (batch size) na memória, visto que a natureza sequencial da RNN impede a paralelização eficiente de cálculos, esgotando rapidamente a memória de vídeo (VRAM). A principal limitação reportada foi a acentuada degradação na precisão preditiva ao lidar com dados altamente desbalanceados, especialmente devido à presença massiva da classe "indefinido" nas notas fiscais.

3.3.4 Araújo et al. (2024)

Araújo et al. (2024) descrevem um trabalho o qual é central para o presente TCC por justificar tecnicamente a escolha de pequenos Transformers sub-palavra em detrimento de Grandes Modelos de Linguagem (LLMs) para o saneamento de erros textuais originários de OCR. Os pesquisadores propuseram uma abordagem geral de correção ortográfica Pós-OCR avaliando dois modelos de linguagem compactos (BART e ByT5) contra dois LLMs massivos (LLaMA 1 e LLaMA 2). Como contribuição, demonstraram que o ByT5 (com tokenização em nível de byte) superou os modelos de bilhões de parâmetros na redução

das Taxas de Erro de Caractere (CER) e Palavra (WER) em textos altamente ruidosos. A metodologia de treinamento revelou dicotomias severas: os modelos menores passaram por um fine-tuning completo otimizando todos os pesos, ao passo que a dificuldade em treinar LLMs em computadores menos potentes forçou o uso de técnicas de quantização. Devido à severa escassez de hardware (utilizou-se uma GPU de apenas 16 GB de VRAM), o treinamento do LLaMA exigiu a técnica Q-LoRA em 4-bits para reduzir o uso de memória, provando que arquiteturas massivas possuem custos proibitivos e menor eficácia para atuar como higienizadores de fragmentos textuais. Como limitação, o estudo aponta a necessidade de conduzir treinamentos futuros que capturem o contexto em níveis mais amplos, como parágrafos inteiros, para refinar a ambiguidade semântica residual.

3.3.5 Souza (2025)

Souza (2025) descrevem um trabalho o qual fundamenta a necessidade de etapas rigorosas de pré-processamento de imagens e delineia os custos computacionais da visão computacional que este TCC contorna ao focar no texto. O estudo propôs uma metodologia automatizada focada na extração de informações em imagens de faturas de energia elétrica, utilizando Redes Neurais Convolucionais (CNNs da família EfficientNet) para classificação de layout, seguidas pelo serviço de OCR ajustado Amazon Textract. A metodologia de treinamento da CNN adotou a transferência de aprendizado (Transfer Learning) com funções de perda orientadas por Fuzzy Matching para extrair entidades específicas das faturas. No que tange aos desafios de infraestrutura, os autores enfrentaram fortes restrições ao treinar modelos pesados em hardwares limitados. A rede EfficientNetB7, por sua profunda arquitetura, demonstrou-se inviável para inferência ágil e treinamento em CPUs/GPUs comuns de baixo custo, obrigando os autores a adotar o modelo mais leve (EfficientNetB0) e a terceirizar o processamento multimodal (texto e visão espacial) para servidores remotos em nuvem via API, aliviando o consumo de VRAM local. A limitação principal constatada foi que a generalização espacial falha; o sistema restringe-se a funcionar como um "especialista" atrelado apenas aos layouts previamente treinados, exigindo a reconstrução dos adaptadores sempre que uma concessionária altera a formatação da sua nota.

3.4 Características dos estudos selecionados e Conclusão da Seção

As características extraídas dos estudos selecionados elucidam que o processamento e a categorização de documentos financeiros dependem intrinsecamente da qualidade da extração óptica, do balanço das classes de treinamento e da infraestrutura computacional disponível. Trabalhos como os de Souza (2025) demonstram que, embora a incorporação do layout visual gere sistemas precisos para faturas estruturadas, o peso computacional

das arquiteturas convolucionais exige terceirização para a nuvem e falha em generalizar fora de gabaritos rígidos. Paralelamente, os estudos de Araújo et al. (2024) e Santos (2023) estabelecem que as imperfeições da leitura ótica (ruídos de OCR) são superadas com máxima eficiência e baixo custo de hardware ao se aplicar o aprendizado em nível de byte ou caractere com rigorosos controles de batch size e quantização de memória, sendo técnica e computacionalmente inviável a aplicação de grandes LLMs generativos em ambientes restritos. O presente projeto de TCC preenche uma lacuna prática ao conectar esses achados metodológicos para resolver a categorização despadronizada de faturas pessoais de cartão de crédito. Diferente de Souza (2025), cuja abordagem depende do layout estático (exigindo alto poder gráfico), este trabalho propõe independência espacial, baseando-se unicamente nas descrições curtas e informais das compras. Absorvendo e expandindo os rigorosos métodos de treinamento de Santos (2023) e Araújo et al. (2024), o projeto utilizará representações sub-word devidamente dimensionadas para viabilizar treinamentos ágeis em computadores locais com VRAM limitada. Por fim, focará em tratar o desafio crítico das classes desbalanceadas nativas do consumo financeiro pessoal, ofertando um pipeline que higieniza o OCR localmente e categoriza os gastos do usuário com alta precisão (comprovada pela métrica F1-score) e extrema sustentabilidade computacional.

Diante disso, a tabela 4 exibe as características referentes aos trabalhos relacionados e a esta pesquisa

Tabela 1 – Características dos trabalhos correlatos e relação com a presente pesquisa

Trabalho (Ref)	Objetivo	Abordagem	Limitações	Lacuna
Araújo et al. (2024)	Saneamento de erros Pós-OCR em textos curtos com ruído extremo.	Comparação entre modelos compactos (ByT5/BART) vs LLMs (LLaMA).	Custo de VRAM e inferência em hardware comum; alucinações semânticas.	Descarte de APIs externas. Uso de modelos ágeis (ByT5) locais, rápidos e baratos.
Santos (2023)	Classificação de produtos em NFE.	Classificador clássico (TF-IDF) vs Rede Recorrente (tweet2vec).	Queda de precisão em dados altamente des- balanceados.	Fundamenta o processamento a nível de caracteres para lidar com abreviações.

Continua na próxima página...

Tabela 1 – continuação da página anterior

Trabalho (Ref)	Objetivo	Abordagem	Limitações	Lacuna
Souza (2025)	Extração e classificação em notas de energia.	CNNs (EfficientNet) e OCR Amazon Textract.	Falha de generalização em layouts desconhecidos.	Justifica o foco em extração semântica independente de layout visual.
Dhingra et al. (2016)	Mineração de textos informais.	Redes Recorrentes Bidirecionais (Bi-GRU).	Falha diante de ruídos e palavras fora do vocabulário.	Base teórica para capturar dependências em textos ruidosos.
ICDAR (2019)	Correção de OCR em recibos.	BERT modificado + rede Seq2Seq.	Modelos generalistas são excessivamente onerosos.	Comprova que a correção deve ser modelada como tradução Seq2Seq.
Vaswani et al. (2017)	Otimização de processamento.	Transformadores e autoatenção (BERT).	Custo computacional altíssimo de LLMs.	Embase a decisão por pequenos Transformers de by-tes/subpalavras.

3.5 Conclusão do Capítulo

A revisão do estado da arte evidencia que as soluções mais sofisticadas voltadas à extração e classificação de documentos comerciais frequentemente esbarram em gargalos severos de custo computacional e engessamento estrutural. Abordagens multimodais baseadas em layouts visuais estritos e a utilização indiscriminada de modelos de linguagem generativos massivos provaram-se onerosas e limitadas frente à alta despadronização das faturas de cartão de crédito. O presente Trabalho de Conclusão de Curso contorna ativamente esses obstáculos ao focar na semântica puramente textual em nível de caractere, descartando a dependência geométrica e o uso de APIs pesadas, o que viabiliza um

processamento local, ágil e computacionalmente sustentável para a organização dos gastos.

Em paralelo às barreiras de infraestrutura, a literatura destaca as lacunas no processamento de vocabulários informais e no tratamento de classes severamente desbalanceadas — um fenômeno crônico na categorização de despesas pessoais, que tradicionalmente compromete o acerto nas classes minoritárias. Com a adoção de técnicas de mineração que superam o problema das palavras fora do vocabulário e a aplicação sistemática de métricas rigorosas como o F1-Score Macro, este TCC propõe um pipeline analítico unificado. Ele assegura que mesmo os nomes de estabelecimentos abreviados ou danificados pelo OCR sejam corretamente higienizados e categorizados, promovendo uma solução de baixo custo e alta precisão diretamente alinhada às necessidades do controle financeiro pessoal moderno.

4 PROCEDIMENTOS METODOLÓGICOS

Este capítulo detalha a arquitetura tecnológica e os procedimentos técnicos adotados para a construção e validação de um classificador inteligente de faturas de cartão de crédito. Todo o percurso metodológico foi estruturado com o propósito de solucionar a extração e a categorização de textos curtos e altamente ruidosos provenientes de processos de digitalização. Para isso, empregou-se exclusivamente ferramentas, bibliotecas e modelos de código aberto (*Open Source*), de forma a garantir a reprodutibilidade da pesquisa, a privacidade dos dados e a viabilidade computacional.

4.1 Classificação da Pesquisa

Do ponto de vista de sua natureza, o presente trabalho define-se como uma pesquisa aplicada, uma vez que objetiva gerar conhecimentos para aplicações práticas dirigidas à solução de problemas específicos, mitigando a falta de padronização nas descrições de transações financeiras (GERHARDT; SILVEIRA, 2009). Quanto aos procedimentos técnicos e abordagem, classifica-se como uma pesquisa de natureza experimental e quantitativa (GIL, 2019).

O delineamento experimental justifica-se pelo controle e pela manipulação de variáveis computacionais em um ambiente de simulação, com o intuito de comparar rigorosamente o desempenho preditivo de diferentes abordagens arquiteturais (modelos clássicos estatísticos versus redes neurais profundas) no tratamento de ruídos originários de Reconhecimento Óptico de Caracteres (OCR).

4.2 Framework de Desenvolvimento (CRISP-DM Adaptado)

Para orientar a execução lógica da pesquisa, adotou-se o ciclo de vida *Cross-Industry Standard Process for Data Mining* (CRISP-DM). Contudo, devido às exigências da Inteligência Artificial contemporânea e à necessidade de sustentabilidade do modelo em produção, o *framework* tradicional foi adaptado e integrado às diretrizes de Operações de Aprendizado de Máquina (*Machine Learning Operations - MLOps*) (KREUZBERGER; KÜHL; HIRSCHL, 2022). As etapas da metodologia foram estruturadas conforme os tópicos a seguir.

4.2.1 Coleta e Compreensão dos Dados

A etapa primária da esteira de processamento consistiu na ingestão das faturas digitalizadas (em formato PDF ou imagem) e na extração de seus dados brutos. Para essa tarefa, instituiu-se o uso do motor Tesseract OCR, integrado ao ambiente Python. O Tesseract atua mapeando o documento por meio de caixas delimitadoras (*bounding boxes*), isolando espacialmente os valores financeiros e as descrições literais para realizar a extração textual.

A escolha do Tesseract fundamenta-se na necessidade de adotar a alternativa *open source* mais madura e consolidada da literatura, permitindo o processamento estritamente local e assegurando o sigilo das informações financeiras, descartando o uso de APIs comerciais de terceiros.

4.2.2 Preparação e Saneamento

O texto emergente do processo de OCR é invariavelmente ruidoso, apresentando caracteres fragmentados, símbolos aglutinados e distorções ortográficas que inviabilizam a modelagem semântica imediata. O processo de saneamento foi estabelecido sobre táticas de higienização léxica. Inicialmente, empregou-se o uso de Expressões Regulares (Regex) para a supressão algorítmica de anomalias tipográficas e pontuações indesejadas (CASELI; NUNES, 2024a).

Em sequência, aplicou-se a tokenização clássica associada à filtragem de *stopwords*. Neste domínio transacional específico, as *stopwords* universais mostraram-se insuficientes; portanto, injetaram-se heurísticas de negócio para remover termos e sufixos corporativos (como “LTDA”, “S/A” e “ME”) que figuram como ruídos genéricos e não agregam valor preditivo para a identificação do estabelecimento comercial (SANTOS, 2023).

4.2.3 Modelagem Comparativa

A fase central do experimento alicerça-se na condução de um comparativo arquitetural, testando duas frentes de modelagem preditiva sobre os dados higienizados:

- **Linha de Base Científica (*Baseline*):** Como régua de desempenho mínimo, codificou-se um *pipeline* de aprendizado de máquina clássico utilizando a biblioteca Scikit-Learn. Os textos foram submetidos à vetorização esparsa por meio da técnica TF-IDF (*Term Frequency-Inverse Document Frequency*). As matrizes numéricas geradas alimentaram algoritmos estatísticos tradicionais, notadamente o *Random Forest*, estabelecendo os limites de precisão da contagem estrita de palavras diante de vocabulários informais.
- **Estado da Arte (*Transformers*):** Para superar o *baseline* e contornar a corrupção severa do OCR (que gera o problema de *Out-Of-Vocabulary*), implementou-se o

modelo estado da arte ByT5 (cedido pelo Google e orquestrado no ecossistema aberto da Hugging Face). O ByT5 foi submetido a um ajuste fino (*fine-tuning*) e selecionado especificamente por sua arquitetura de tokenização atuar em nível de caractere/byte. Tal granularidade capacita o modelo a processar textos altamente fragmentados e reconstruir o sentido de transações ilegíveis (ex: “UBER*BR”), atuando de forma simultânea como corretor ortográfico e classificador denso, com baixo impacto no *hardware* local (ARAÚJO et al., 2024).

4.2.4 Avaliação e Métricas Quantitativas

Para validar a hipótese de superioridade da rede neural baseada em caracteres sobre os modelos de frequência, o desempenho foi mensurado quantitativamente. As previsões dos classificadores foram confrontadas com o conjunto de teste de anotação humana (*Ground-Truth*), calculando-se as métricas estatísticas de Acurácia, Precisão e *Recall* (Revocação).

Contudo, devido à natureza intrínseca do consumo humano, as categorias de despesas em faturas apresentam-se massivamente desbalanceadas. Por conseguinte, estabeleceu-se a métrica do F1-Score Macro como o principal validador de diagnóstico algorítmico, por ser uma medida harmônica que penaliza o modelo caso este foque apenas na classe majoritária, garantindo a avaliação justa da assertividade nas categorias transacionais minoritárias (SANTOS, 2023).

4.2.5 Implantação e Ciclo de Vida (MLOps)

Finalizada a avaliação, a sustentabilidade da pesquisa em um ambiente dinâmico foi assegurada mediante práticas de engenharia de *software* e MLOps. A solução inteira foi encapsulada em contêineres Docker, garantindo a padronização das dependências de sistema (Hugging Face, PyTorch e Tesseract) e facilitando a portabilidade. A orquestração das requisições foi delegada a um *backend* desenvolvido em linguagem Java, apoiado pelo *framework* Spring Boot.

Para combatendo a degradação preditiva temporal (*Concept Drift*), instituiu-se uma rotina de Aprendizado Ativo (*Active Learning*). Essa abordagem metodológica utiliza o grau de incerteza estocástica do modelo como curador autônomo: inferências geradas com baixa confiança (frente a novos fornecedores ou falhas extremas de OCR) são enviadas para intervenção de um humano no ciclo (*Human-in-the-Loop*), expandindo cirurgicamente os dados de treinamento e disparando gatilhos de retreinamento contínuo sem prejudicar a disponibilidade do sistema (NORTHCUTT; JIANG; CHUANG, 2021; REN et al., 2021).

4.3 Desenvolvimento da Solução/Proposta

Neste capítulo, detalha-se a arquitetura tecnológica e a implementação prática do pipeline de extração e classificação de faturas de cartão de crédito. Afastando-se das discussões puramente teóricas, esta seção assume um caráter estritamente metodológico e aplicado, detalhando como a esteira de dados foi efetivamente construída. Toda a concepção do sistema foi guiada por uma premissa pragmática: desenvolver uma ferramenta viável para processamento local, garantindo a privacidade dos dados transacionais, contornando limitações de infraestrutura e utilizando exclusivamente bibliotecas, frameworks e modelos de código aberto (Open Source) e gratuitos.

4.3.1 Arquitetura Geral da Solução e Stack Tecnológico

A arquitetura geral da solução foi concebida de forma modular e sequencial, dividida em microsserviços para isolar as responsabilidades de extração visual, higienização textual e categorização preditiva.

O stack tecnológico foi segmentado de acordo com as forças de cada ecossistema computacional. A linguagem Python foi definida como a base fundamental para a ciência de dados, análise exploratória e treinamento dos modelos de Machine Learning e Deep Learning, devido ao seu vasto ecossistema de bibliotecas orientadas à inteligência artificial. Por outro lado, para garantir robustez, escalabilidade e integração comercial, a linguagem Java, operando sob o framework Spring Boot, foi eleita para o backend. O Java atua como a camada orquestradora (API), responsável por receber as requisições dos usuários (imagens das faturas), gerenciar a comunicação assíncrona com os motores em Python e encapsular os serviços em um ambiente de produção maduro.

escrever
sobre
técni-
cas de
LGPD

4.3.2 Módulo de Ingestão e Extração (OCR)

Para a conversão das faturas digitalizadas (imagens ou PDFs escaneados) em matrizes de texto estruturado, implementou-se o módulo de Reconhecimento Óptico de Caracteres utilizando o motor Tesseract OCR, integrado nativamente ao código através da biblioteca Python pytesseract.

A escolha do Tesseract como espinha dorsal da extração justifica-se por ser a alternativa de código aberto mais madura, documentada e amplamente utilizada na literatura acadêmica e industrial. Ao dispensar o uso de modernas APIs comerciais pagas baseadas em nuvem, o Tesseract garante não apenas o custo zero de operação, mas fundamentalmente a privacidade absoluta dos dados sensíveis do usuário, já que todo o processamento computacional ocorre localmente. Para maximizar a eficácia do Tesseract na localização das palavras e caracteres (Bounding Boxes), a imagem bruta enviada pelo backend Java passa por um pré-processamento digital antes da extração.

4.3.3 Pipeline de Saneamento e Processamento de Dados

O texto bruto resultante da extração óptica é invariavelmente ruidoso. Para estruturá-lo, o pipeline de processamento faz uso ostensivo da biblioteca Pandas, que aloca as saídas do Tesseract em DataFrames estruturados, viabilizando a manipulação vetorial rápida das colunas e transação.

A higienização léxica opera em múltiplas camadas. Inicialmente, utiliza-se a biblioteca padrão re (Expressões Regulares) do Python para a aplicação de Regex, realizando a exclusão algorítmica de caracteres especiais, pontuações indesejadas e anomalias tipográficas grotescas geradas pela leitura da imagem . Em seguida, para a tokenização e o tratamento do vocabulário, implementou-se o uso das bibliotecas NLTK (Natural Language Toolkit) e spaCy . Optou-se por não utilizar as listas universais genéricas de remoção de stopwords destas bibliotecas, pois, no domínio financeiro, faz-se necessário remover ruídos corporativos. Através do NLTK/spaCy, injetou-se uma lista customizada de stopwords contendo termos como "LTDA", "S/A", "ME" e "CIA", que não agregam valor semântico e confundem o classificador.

4.3.4 Implementação do Baseline Científico

Para garantir o rigor acadêmico, antes de empregar arquiteturas neurais complexas, desenvolveu-se uma linha de base (baseline) focada em Machine Learning clássico . Toda a codificação estatística deste módulo foi executada utilizando exclusivamente a biblioteca Scikit-Learn (sklearn).

Através do módulo TfidfVectorizer do scikit-learn, as descrições limpas dos estabelecimentos comerciais foram convertidas em matrizes esparsas (Term Frequency-Inverse Document Frequency), penalizando termos demasiadamente comuns e valorizando descrições discriminativas . As matrizes resultantes alimentaram algoritmos classificadores tradicionais e de baixo custo computacional instanciados pelo próprio sklearn, notadamente o Random Forest e o Naive Bayes . Este baseline atua como a régua mínima de performance e tempo de inferência a ser batida pelo modelo no estado da arte.

4.3.5 Implementação do Estado da Arte (Transformers e LLMs Abertos)

Para mitigar a severa corrupção ortográfica proveniente do Tesseract, implementou-se a modelagem avançada utilizando o ecossistema da Hugging Face (biblioteca transformers), suportado nos bastidores pelo processamento tensorial do framework PyTorch.

Descartou-se a utilização de Grandes Modelos de Linguagem (LLMs generativos gigantes) devido ao seu altíssimo consumo de VRAM e à latência impraticável em computadores comuns . A solução adotada consistiu na instanciamento do modelo ByT5 (desenvolvido pelo Google e disponível de forma gratuita e aberta no Hub da Hugging Face) . A arquitetura

do ByT5 processa a linguagem estritamente em nível de bytes (byte-level), o que lhe confere uma capacidade exímia para restaurar palavras fragmentadas ou aglutinadas por erros do Tesseract ("UBERBR", "PAGMCDONALDS") . Foi realizado um fine-tuning (ajuste fino) deste modelo para atuar como um corretor texto-a-texto e vetorizador semântico profundo, capaz de compreender o sentido do gasto independentemente do ruído ou do vocabulário informal, fornecendo aos embeddings a capacidade de classificar as classes minoritárias da fatura.

4.3.6 Encapsulamento e Deploy (MLOps)

Por fim, o ciclo de vida do desenvolvimento de Machine Learning (MLOps) exigiu o empacotamento da solução para garantir total independência de ambiente e portabilidade.

A infraestrutura foi containerizada utilizando Docker. Foram criadas imagens isoladas: um contêiner carregando as dependências pesadas do sistema operacional necessárias para o Tesseract OCR e as bibliotecas do PyTorch/Hugging Face com o modelo treinado; e um contêiner secundário rodando a aplicação Java (Spring Boot).

A aplicação Spring Boot expõe uma API REST. O fluxo final de deploy ocorre da seguinte maneira: o cliente faz um POST enviando o arquivo da fatura em imagem/PDF para o endpoint do Spring Boot. O Java gerencia o arquivo e aciona o microserviço Python via requisição interna. O Python executa a leitura Tesseract (4.2), o saneamento via Pandas/NLTK (4.3) e a correção/categorização via Hugging Face/ByT5 (4.5). Em milissegundos, o backend devolve ao usuário um objeto JSON estruturado, contendo a descrição real do estabelecimento comercial e a categoria do gasto predita com sucesso.

4.4 Estratégia de Garantia de Qualidade e Testes

Devido à natureza distribuída, assíncrona e poliglota da arquitetura proposta, a estratégia de testes foi fundamentada na Pirâmide de Testes, garantindo validações em diferentes níveis de granularidade. A abordagem assegura não apenas a correção lógica do código, mas também a integridade do fluxo de dados e a precisão do modelo de Inteligência Artificial.

4.4.1 Testes Unitários e Simulações (Mocks)

Na camada de ingestão, desenvolvida sob o paradigma reativo, os testes unitários utilizam *JUnit 5* em conjunto com a classe utilitária *StepVerifier*. Esta abordagem permite subscrever publicadores reativos (*Flux* e *Mono*) e avaliar os sinais emitidos assincronamente, simulando as integrações externas através do *Mockito*. Nos microserviços de processamento, o *framework* *pytest* foi adotado, utilizando a biblioteca *moto* para

interceptar e emular em memória as requisições ao armazenamento de objetos (compatível com S3), isolando a lógica de negócio de dependências de rede.

4.4.2 Testes de Integração com *Testcontainers*

Para validar as fronteiras de comunicação entre os serviços, implementou-se o uso de *Testcontainers*. Esta ferramenta instancia de forma efêmera, via *Docker*, os serviços de mensageria (*Apache Kafka*) e o *Data Lakehouse* (*MinIO*), permitindo a execução de testes contra infraestruturas reais e garantindo que o contrato de mensagens e formatos de gravação (*Apache Iceberg*) estejam corretos antes da promoção do código.

4.4.3 Validação de Dados e Testes de *Machine Learning*


Uma esteira de dados baseada em *Machine Learning* exige validação contínua da sua saída. Foi implementada uma bateria de testes focada no modelo *ByT5*, onde a inferência é validada contra um *dataset* dourado de referência. O pipeline falha ativamente caso as métricas de acurácia regridam. Adicionalmente, as tabelas da camada *Silver* são auditadas para garantir a conformidade dos esquemas e a tipagem estrita das entidades estruturadas.

4.4.4 Testes Fim-a-Fim (E2E) e de Carga

A validação de topo da pirâmide engloba testes Fim-a-Fim, orquestrados para submeter um documento de teste na API e consultar, via motor SQL, a sua correta chegada e formatação na camada *Silver*, comprovando a eficácia do processamento assíncrono. Por fim, a validação de vazão do fluxo reativo é conduzida pela ferramenta de injeção de carga *k6*, demonstrando a resiliência do barramento de eventos sob estresse simulado de concorrência massiva.

concluir
refe-
ren-
cias

Figura 5 – Arquitetura de Data Lakehouse Orientada a Eventos com MLOps



Fonte: Elaborado pelo autor (2026).

Referências

- AMARAL, F. *Automatize a criação de modelos: aprenda Operações de ML com Python e MLFlow*. 2026. Curso online. Udemy. Disponível em: <<https://brq.udemy.com/course/mlops-mlflow-operacao-de-machine-learning/learn/lecture/24761294#overview>>. Acesso em: 24 maio 2026.
- ANCHIÊTA, R. et al. Processamento de linguagem natural: Fundamentos e aplicações. In: *Anais do Simpósio Brasileiro de Tecnologia da Informação e da Linguagem Humana (STIL)*. Brasil: SBC, 2021.
- ARAÚJO, S. S. et al. Saneamento pós-ocr de textos ruidosos avaliando modelos sub-palavra contra llms massivos. 2024.
- CASELI, H. M.; NUNES, M. d. G. V. (Ed.). *Processamento de Linguagem Natural: Conceitos, Técnicas e Aplicações em Português*. 2. ed. Brasil: BPLN, 2024.
- CASELI, H. M.; NUNES, M. G. V. (Ed.). *Processamento de Linguagem Natural: Conceitos, Técnicas e Aplicações em Português*. 2. ed. BPLN, 2024. ISBN 978-65-00-95750-1. Disponível em: <<https://brasileiraspln.com/livro-pln/2a-edicao/>>.
- CHOWDHURY, G. G. Natural language processing. *Annual Review of Information Science and Technology*, Wiley Online Library, v. 37, n. 1, p. 51–89, 2003.
- Dataversity. *Data Drift vs. Concept Drift: What Is the Difference?* 2026. <<https://www.dataversity.net/articles/data-drift-vs-concept-drift-what-is-the-difference/>>. Accessed: 2026-05-24.
- DHINGRA, B. et al. Tweet2vec: Character-based distributed representations for social media. *arXiv preprint arXiv:1605.03481*, 2016.
- GERHARDT, T. E.; SILVEIRA, D. T. *Métodos de pesquisa*. Porto Alegre, RS: Editora da UFRGS, 2009.
- GIL, A. C. *Métodos e Técnicas de Pesquisa Social*. 7. ed. São Paulo: Atlas, 2019.
- KREUZBERGER, D.; KÜHL, N.; HIRSCHL, S. Machine learning operations (mlops): Overview, definition, and architecture. *IEEE Access*, IEEE, v. 10, p. 31866–31879, 2022.
- LU, J. et al. Learning under Concept Drift: A Review . *IEEE Transactions on Knowledge & Data Engineering*, IEEE Computer Society, Los Alamitos, CA, USA, v. 31, n. 12, p. 2346–2363, dez. 2019. ISSN 1558-2191. Disponível em: <<https://doi.ieeecomputersociety.org/10.1109/TKDE.2018.2876857>>.
- MATOS, P. F. *Metodologia de pré-processamento textual para extração de informação sobre efeitos de doenças em artigos científicos do domínio biomédico*. Dissertação (Dissertação (Mestrado em Ciência da Computação)) — Universidade Federal de São Carlos (UFSCar), São Carlos, SP, 2010.

NORTHCUTT, C. G.; JIANG, L.; CHUANG, I. L. Aprendizagem confiante: Estimando a incerteza em rótulos de conjuntos de dados. *Journal of Artificial Intelligence Research*, v. 70, p. 1373–1411, abril 2021. Disponível em: <<https://doi.org/10.48550/arxiv.1911.00068>>.

QUIÑONERO-CANDELA, J. et al. *Dataset Shift in Machine Learning*. Cambridge, MA: The MIT Press, 2008.

RAJARAMAN, A.; ULLMAN, J. D. *Mining of Massive Datasets*. [S.l.]: Cambridge University Press, 2011.

REN, P. et al. Uma pesquisa de aprendizagem ativa profunda (a survey of deep active learning). *Inquéritos Computacionais ACM (CSUR)*, v. 54, n. 9, 2021. Disponível em: <<https://doi.org/10.1145/3472291>>.

ROCHA, T. K. P. *Avaliação de modelos preditivos de aprendizado de máquina como suporte na tomada de decisão gerencial: a predição de risco de mortalidade por COVID-19 no estado de São Paulo*. Dissertação (Dissertação (Mestrado em Ciências)) — Faculdade de Medicina da Universidade de São Paulo (USP), Programa de Saúde Coletiva, São Paulo, 2025.

SANTOS, M. T. M. d. *Classificação de produtos em Notas Fiscais Eletrônicas usando Descrições Textuais não estruturadas*. Dissertação (Trabalho de Conclusão de Curso (Engenharia de Computação)) — Universidade Federal de Alagoas (UFAL), Instituto de Computação, Maceió, AL, 2023.

SCHUMACHER, J. et al. Machine learning operations (mlops): Overview, definition, and architecture. *IEEE Software*, 2023. Disponível em: <<https://ieeexplore.ieee.org/document/10081336>>.

VASWANI, A. et al. Attention is all you need. In: *Advances in Neural Information Processing Systems*. [S.l.: s.n.], 2017. v. 30.

ZHANG, Y. et al. Mineração de textos curtos e informais provenientes de redes sociais e transações. 2021.