

Relatório de revisão de monografia

MBA em Inteligência Artificial e Big Data — ICMC/USP

Item	Descrição
Título da monografia	Solução para extração e classificação em faturas de cartão de crédito utilizando ferramentas de inteligência artificial
Autor	Luiz Henrique Monteiro Silva de Lima
Orientador	Prof. Dr. Ricardo Rodrigues Ciferri
Versão revisada	TCC.pdf — 121 páginas, gerado em 18/09/2026 (LaTeX/abnTeX2)
Normativa de referência	TCC_Modelo.docx (instruções de apresentação e normas ABNT)
Estrutura verificada	6 capítulos + 5 apêndices + 1 anexo

1. Escopo e método desta revisão

A revisão considerou exclusivamente a versão anexa da monografia (TCC.pdf). As instruções de apresentação seguidas são as descritas no modelo de TCC anexo (TCC_Modelo.docx); as seções de exemplo daquele modelo e a ficha catalográfica foram desconsideradas, conforme orientado.

Foram verificados: (i) a aderência da estrutura de capítulos ao padrão exigido; (ii) a completude de conteúdo de cada capítulo frente aos requisitos definidos para Introdução, Fundamentação Teórica, Trabalhos Relacionados, Solução Proposta, Validação e Conclusões; (iii) o rigor metodológico e a coerência interna da parte experimental, com recomputação independente das tabelas numéricas; (iv) a conformidade das citações e referências com a ABNT; e (v) a qualidade da escrita — ortografia, sintaxe, impessoalidade, estrangeirismos, redundância, prolixidade, padronização numérica e legendas.

Sugestões que já constam da lista de trabalhos futuros do Capítulo 6 (Seção 6.6) e os itens da Seção 6.5 explicitamente rotulados pelo autor como "trabalho futuro" — a saber, validação manual independente do subconjunto de rótulos, comparação de OCR sobre documentos genuinamente escaneados e varredura sistemática de hiperparâmetros — foram deliberadamente omitidas do relatório, para não duplicar o que a própria monografia já registra.

1.1 Marcadores de severidade

Marcador	Significado
CRÍTICO	Compromete a qualidade ou a aprovação; deve ser corrigido antes do depósito.
MODERADO	Recomenda-se fortemente corrigir.
LEVE	Ajuste fino / opcional.
POSITIVO	Ponto de mérito identificado, registrado para preservação na revisão.

2. Sumário executivo

A monografia está, em linhas gerais, acima da média esperada para um TCC de MBA. A estrutura de capítulos corresponde exatamente ao padrão exigido; o protocolo experimental é incomumente rigoroso para o nível (teste cego por estabelecimento, intervalos de confiança por reamostragem, teste de McNemar, estudo de ablação, rastreamento em MLflow); e o autor demonstra honestidade intelectual pouco frequente, refutando a própria hipótese central e catalogando onze limitações do trabalho. As tabelas numéricas foram recomputadas de forma independente nesta revisão e mostraram-se aritmeticamente consistentes.

Os problemas críticos identificados não são de execução, mas de leitura dos próprios resultados e de consistência interna: uma das três conclusões de destaque não se sustenta quando cada arquitetura é comparada em sua melhor configuração; o Capítulo 3 é apresentado como revisão sistemática da literatura, o que o Apêndice A desmente; o trabalho correlato mais próximo de todos os citados na monografia não figura no capítulo de trabalhos relacionados; há uma contradição factual sobre o tamanho do conjunto de treinamento; e uma tabela apresenta quatro arquiteturas distintas com métricas idênticas até a casa decimal, sem verificação nem explicação.

Nenhum desses pontos exige novos experimentos. Todos são resolvíveis por reanálise, reescrita e verificação de planilha.

2.1 Distribuição dos achados

Bloco temático	Achados	Concentração de severidade
Conformidade com o modelo de TCC	9	2 moderados, 4 leves, 3 positivos
Capítulo 1 — Introdução	11	3 leves, 8 positivos
Capítulo 2 — Fundamentação Teórica	9	4 moderados, 2 leves, 3 positivos
Capítulo 3 — Trabalhos Relacionados	11	2 críticos, 5 moderados, 1 leve, 3 positivos
Capítulo 4 — Solução Proposta	10	4 moderados, 3 leves, 3 positivos
Capítulo 5 — Validação e Resultados	14	3 críticos, 5 moderados, 2 leves, 4 positivos
Capítulo 6 — Conclusões	8	2 moderados, 2 leves, 4 positivos
Citações e referências (ABNT)	10	4 moderados, 3 leves, 3 positivos
Escrita, estilo e terminologia	13	4 moderados, 7 leves, 2 positivos
Legendas, equações e elementos gráficos	8	2 moderados, 4 leves, 2 positivos

2.2 Os cinco achados críticos

Id	Achado	Onde corrigir
C1	A conclusão "representações esparsas superaram embeddings densos" não se sustenta quando cada arquitetura é comparada em sua melhor configuração (69,3% contra 66,8%).	Seções 5.6, 5.8 (Q1), 5.9 e 6.4 (conclusão 3)
C2	O Capítulo 3 declara seguir protocolo de revisão sistemática, mas o Apêndice A revela ausência de leitura integral; o funil da Tabela 13 é internamente implausível.	Seções 3.1, 3.2 e Apêndice A
C3	Ta, Saad e Oh (2023) — classificação de transações de Open Banking, o trabalho mais fortemente relacionado de toda a bibliografia — está ausente do Capítulo 3 e do Quadro 3.	Seções 3.6 e 3.7

Id	Achado	Onde corrigir
C4	Contradição factual sobre o tamanho do conjunto de treinamento: 1.150 na Seção 5.6 contra 1.326 implícitos na Seção 5.4.2.	Seções 5.4.2 e 5.6
C5	Tabela 9: quatro arquiteturas distintas apresentam acurácia e F1-Macro idênticos (98,0% / 36,2%) no subconjunto Nubank, sem verificação nem explicação.	Seção 5.6.2 e Tabela 9

3. Conformidade com o modelo de TCC e formato dos títulos

3.1 Estrutura de capítulos

[POSITIVO] E1 — A estrutura de capítulos corresponde exatamente ao padrão exigido

A monografia apresenta Capítulo 1 Introdução, Capítulo 2 Fundamentação Teórica, Capítulo 3 Trabalhos Relacionados, Capítulo 4 Solução Proposta, Capítulo 5 Validação Experimental e Resultados e Capítulo 6 Conclusões e Trabalhos Futuros. O Capítulo 3 foi mantido como capítulo próprio (alternativa válida à sua incorporação como seção do Capítulo 2) e o Capítulo 4 conservou o rótulo "Solução Proposta", pertinente ao objeto pesquisado. Não há desvio estrutural a corrigir.

[POSITIVO] E2 — Considerações iniciais e finais presentes em todos os capítulos exigidos

Os Capítulos 2, 3, 4 e 5 abrem com "Considerações Iniciais" e encerram com "Considerações Finais do Capítulo". Mais relevante: todas as quatro seções de encerramento fazem a ligação explícita com o capítulo seguinte ("O capítulo seguinte revisa os trabalhos correlatos...", "...traduzidas em decisões arquiteturais concretas no capítulo seguinte...", "...para a validação empírica detalhada no capítulo seguinte...", "...são discutidas no Capítulo 6"). Esse encadeamento é exatamente o que se pede e frequentemente falta. O Capítulo 6, ainda que dispensado da exigência, também traz as duas seções — o que não prejudica.

[LEVE] E3 — Duas considerações iniciais não enumeram a organização em seções

As Seções 3.1 e 4.1 remetem às subseções por número ou ordem. Já as Seções 2.1 e 5.1 descrevem os conteúdos em prosa corrida, sem indicar em quais seções cada assunto será tratado. A exigência é que a consideração inicial descreva a organização do capítulo em seções. Sugere-se acrescentar a remissão numérica: em 2.1, "...organizando-se em quatro pilares: (i) Mineração de Textos e PLN (Seção 2.2); (ii) Visão Computacional... (Seção 2.3); (iii)... (Seção 2.4); e (iv)... (Seção 2.5)".

3.2 Formato dos títulos (capitalização)

O modelo de TCC estabelece dois padrões distintos, visíveis tanto no sumário quanto no corpo do documento-modelo:

- Seções primárias (capítulos): indicativo numérico seguido do título em caixa alta e negrito — "1 INTRODUÇÃO", "2 REVISÃO BIBLIOGRÁFICA".
- Seções secundárias e subsequentes: primeira letra maiúscula e as demais minúsculas — "1.1 Instruções gerais de apresentação", "1.3 Numeração progressiva", "3.3 Até três autores".

A resposta direta à pergunta formulada é, portanto: sim, o formato indicado pelo modelo para os títulos de seção é primeira letra maiúscula e demais minúsculas (capitalização de sentença), reservando-se a caixa alta apenas aos títulos de capítulo. Substantivos próprios e siglas mantêm a maiúscula por regra ortográfica.

[POSITIVO] E4 — Títulos de capítulo em conformidade

Todos os seis títulos de capítulo seguem o padrão do modelo: indicativo numérico, caixa alta e negrito ("1 INTRODUÇÃO", "2 FUNDAMENTAÇÃO TEÓRICA", "3 TRABALHOS RELACIONADOS", "4 SOLUÇÃO PROPOSTA", "5 VALIDAÇÃO EXPERIMENTAL E RESULTADOS", "6 CONCLUSÕES E TRABALHOS FUTUROS"). Os títulos sem indicativo numérico (REFERÊNCIAS, APÊNDICES, ANEXOS) também estão centralizados e em folha distinta, conforme a Seção 1.3 do modelo.

[MODERADO] E5 — Praticamente todos os títulos de seção usam capitalização de título em vez de capitalização de sentença

Das 74 seções e subseções numeradas, 73 empregam maiúscula inicial em todas as palavras significativas, contrariando o padrão do modelo. Exemplos: "1.1 Contextualização e Formulação do Problema" deveria ser "1.1 Contextualização e formulação do problema"; "2.2.4 Classificadores Estatísticos Clássicos para Vetores Esparsos" deveria ser "2.2.4 Classificadores estatísticos clássicos para vetores esparsos"; "5.4 Protocolo Experimental e Métricas de Avaliação" deveria ser "5.4 Protocolo experimental e métricas de avaliação". A correção é mecânica e vale para todo o sumário, para todos os cabeçalhos do corpo e para as remissões no texto.

A única seção que já está no padrão correto é a 5.6.1, "Acurácia global versus F1-Macro" — o que evidencia que a divergência é de padronização, não de desconhecimento. Registre-se que a capitalização de título é comum em teses brasileiras e raramente reprovada; mas, como o modelo é explícito, a padronização é recomendada.

[MODERADO] E6 — Título da monografia e cabeçalho do resumo em caixa alta

O modelo apresenta o título da obra em capitalização de sentença ("Título do trabalho: subtítulo") tanto na capa quanto na folha de rosto, e o cabeçalho do resumo no formato "SOBRENOME, N. P. Título: subtítulo" — sobrenome em versalete/caixa alta, título em negrito e capitalização de sentença.

Na monografia ocorre o inverso: o título aparece integralmente em caixa alta ("SOLUÇÃO PARA EXTRAÇÃO E CLASSIFICAÇÃO EM FATURAS...") na capa, na folha de rosto e no cabeçalho do resumo, e o sobrenome do autor aparece em caixa baixa ("Lima, L."). Recomenda-se: (i) grafar o título como "Solução para extração e classificação em faturas de cartão de crédito utilizando ferramentas de inteligência artificial"; e (ii) corrigir o cabeçalho para "LIMA, L. H. M. S. Solução para extração...". O mesmo vale para o cabeçalho do abstract. Observe-se ainda que o modelo usa "f." (folhas) e não "p." (páginas) na referência do resumo.

[LEVE] E7 — Sugestão de reformulação do título

Independentemente da capitalização, o título atual tem duas fragilidades. Primeira, "extração e classificação em faturas" deixa implícito o objeto: não se extraem nem se classificam faturas, e sim as transações nelas contidas. Segunda, "ferramentas de inteligência artificial" é genérico a ponto de não informar. Uma formulação que preserva o escopo e ganha precisão: "Extração e classificação automática de transações em faturas de cartão de crédito com preservação de leiaute e agentes de linguagem em infraestrutura local". Caso se prefira manter a concisão atual, ao menos "...classificação de transações em faturas de cartão de crédito..." já resolve o primeiro problema.

[LEVE] E8 — Palavras-chave com capitalização de título e divergência entre locais

A ABNT NBR 6028 recomenda palavras-chave com apenas a inicial maiúscula. No resumo elas aparecem em capitalização de título ("Classificação de Transações Financeiras. Processamento de Linguagem Natural..."). Além disso, o conjunto diverge entre o resumo ("Geração Aumentada por Recuperação") e os metadados do PDF e da ficha ("Geração Aumentada por Recuperação (RAG)"), e a ordem dos termos não é a mesma nos três locais. Padronizar para: "Classificação de transações financeiras. Processamento de linguagem natural. Geração aumentada por recuperação. Reconhecimento óptico de caracteres. Agentes inteligentes."

[POSITIVO] E9 — Resumo e abstract dentro do limite de extensão do modelo

O modelo exige parágrafo único com 150 a 500 palavras. O resumo tem cerca de 357 palavras e o abstract cerca de 328, ambos em parágrafo único, seguidos das palavras-chave e precedidos da referência do documento — exatamente a ordem prescrita. Ambos contemplam objetivos, método, resultados e conclusões.

4. Capítulo 1 — Introdução

A Introdução foi avaliada contra a estrutura exigida: 1 a 3 parágrafos de contexto (com ao menos o assunto); 1 a 3 parágrafos de motivação e justificativa (com ao menos problema e relevância); 1 a 2 parágrafos de objetivos (com ao menos objetivo geral e escopo); e 1 parágrafo de organização da monografia.

4.1 Contexto

[POSITIVO] I1 — Assunto claramente estabelecido e amparado em dados

O contexto ocupa três parágrafos na Seção 1.1, dentro do limite. O assunto — gerenciamento financeiro pessoal e a categorização de despesas a partir de descrições de fatura — é explicitado já no primeiro período e sustentado por dados setoriais de fontes institucionais (ABECS, Serasa Experian, SPC Brasil, Poder360). O requisito mínimo está plenamente atendido.

[POSITIVO] I2 — Item opcional presente: área de aplicação

A área de aplicação está delimitada com precisão — finanças pessoais no mercado brasileiro de cartão de crédito, com referência explícita ao volume transacionado e ao perfil de inadimplência do país. É um dos itens opcionais da estrutura de contexto e merece registro.

[POSITIVO] I3 — Item opcional presente: conceitos

O contexto introduz os conceitos operantes na pesquisa — comércio eletrônico, fatura de cartão de crédito, descrição transacional despadronizada, reconhecimento óptico de caracteres e intermediação de pagamento — antes de formalizar o problema. Item opcional atendido.

[POSITIVO] I4 — O problema é formalizado em destaque e ilustrado empiricamente

O problema central aparece em negrito e em formulação fechada ("a categorização automática, precisa e escalável de transações financeiras de cartão de crédito a partir de descrições textuais curtas, heterogêneas, ruidosas e altamente despadronizadas"), seguido de cinco obstáculos numerados e do Quadro 1, que exhibe amostras reais anonimizadas de cada obstáculo. A combinação de formulação abstrata com evidência concreta é uma escolha de redação eficaz e deve ser preservada.

4.2 Motivação e justificativa

[POSITIVO] I5 — Relevância estabelecida em duas frentes

A Seção 1.2 cobre relevância em três parágrafos, no limite da estrutura exigida, articulando a frente técnico-científica (integração transdisciplinar de OCR, PLN, recuperação vetorial, engenharia de agentes e MLOps sob restrição de hardware local) e a frente socioeconômica (prevenção de endividamento e sustentabilidade orçamentária das famílias). Problema e relevância, os dois itens obrigatórios, estão atendidos.

[POSITIVO] I6 — Itens opcionais presentes: desafios, benefícios e limitações das soluções existentes

Três dos itens opcionais estão contemplados. Desafios: os cinco obstáculos numerados na Seção 1.1 (abreviações crípticas, prefixos de processadores, ruído de OCR, ambiguidade de marketplaces e restrição de privacidade). Benefícios: o terceiro parágrafo da Seção 1.2 descreve a eliminação do esforço cognitivo, as justificativas semânticas inteligíveis e o aprendizado contínuo com intervenção humana. Limitações nas soluções existentes: o segundo parágrafo identifica três lacunas concretas — dependência de APIs proprietárias em nuvem, heurísticas de leiaute visual fixo e ausência de tratamento do ciclo de vida do modelo em produção — e remete ao Capítulo 3 para o detalhamento.

[POSITIVO] I7 — Item opcional presente: limitações do próprio trabalho já na Introdução

A Seção 1.3 antecipa, no parágrafo de escopo, que a extração óptica de documentos genuinamente escaneados está implementada mas não foi validada empiricamente, remetendo à Seção 6.5. Antecipar uma limitação de escopo na Introdução, em vez de reservá-la para a conclusão, é prática de transparência pouco comum e deve ser mantida.

4.3 Objetivos

[POSITIVO] I8 — Objetivo geral e específicos bem formulados

O objetivo geral está em uma única sentença verbal ("conceber, implementar e avaliar experimentalmente uma solução computacional de ponta a ponta..."), com os verbos alinhados ao que o trabalho de fato entrega. Os sete objetivos específicos são rastreáveis um a um nas entregas do Capítulo 4 e nas medições do Capítulo 5, e a Seção 6.3 faz o confronto explícito entre objetivos e entregas. Ambos os itens obrigatórios estão atendidos.

[POSITIVO] I9 — Itens opcionais presentes: requisitos, restrições e domínio de aplicação

Requisitos: o parágrafo final da Seção 1.3 enumera quatro requisitos não funcionais (execução local, latência interativa, auditabilidade e explicabilidade) e informa onde cada um é ancorado arquiteturalmente e mensurado experimentalmente. Restrições: hardware local sem GPU em nuvem, tratadas como restrição de projeto e não como acaso. Domínio de aplicação: faturas de cartão de crédito de emissores brasileiros. Três itens opcionais atendidos, o que é incomum.

[LEVE] I10 — A seção de objetivos excede a extensão recomendada

A estrutura pede 1 a 2 parágrafos para os objetivos. A Seção 1.3 ocupa cerca de uma página e meia: dois parágrafos, uma lista de sete objetivos específicos com três a cinco linhas cada, mais dois parágrafos densos de escopo e requisitos. A lista numerada é legítima, mas os itens 1, 5 e 7 trazem detalhamento arquitetural que pertence ao Capítulo 4 (por exemplo, "backend PyPdfium", "estruturas Pydantic com cadeias de pensamento", "mensageria por eventos (Apache Kafka)"). Sugere-se enxugar cada objetivo específico a uma ou duas linhas, deixando a tecnologia para o Capítulo 4.

4.4 Organização da monografia

[POSITIVO] I11 — Organização completa e na sequência correta

A Seção 1.4 descreve, em um parágrafo introdutório seguido de lista, o conteúdo dos seis capítulos na ordem em que aparecem, e ainda cobre apêndices e anexo. As descrições são substantivas e não genéricas. Requisito plenamente atendido.

[LEVE] I12 — Antecipação do resultado alocada na seção errada

O último parágrafo da Seção 1.4 antecipa a refutação da hipótese central. A antecipação em si é defensável e até desejável; o problema é de alocação: ela está dentro da seção "Organização da Monografia", cujo escopo é descrever a estrutura do documento. Sugere-se movê-la para o encerramento da Seção 1.3, logo após os requisitos, ou abrir um parágrafo final sem título na Introdução.

[LEVE] I13 — Uso de seções na Introdução, contrariando a recomendação

A estrutura exigida admite a organização da Introdução em seções, mas recomenda a redação corrida. A monografia optou pelas Seções 1.1 a 1.4. Como a opção é explicitamente permitida, não há falha; registra-se apenas que a versão sem seções é a preferível e que, se houver revisão de forma, a fusão em texto contínuo aproximaria o capítulo da recomendação.

5. Capítulo 2 — Fundamentação Teórica

[POSITIVO] T1 — Ancoragem em referências fundadoras, inclusive as mais antigas

O capítulo apoia os conceitos centrais nas referências seminais do assunto, e não apenas em surveys recentes: Levenshtein (1966) para a distância de edição, Harel (1987) para os statecharts que fundamentam a orquestração por grafo de estados, Hochreiter e Schmidhuber (1997) para LSTM, McCallum e Nigam (1998) e Rennie et al. (2003) para as variantes de Naive Bayes, Breiman (2001) para florestas aleatórias, Vaswani et al. (2017) para a autoatenção, Reimers e Gurevych (2019) para o SBERT e Lewis et al. (2020) para a geração aumentada por recuperação. Esse é exatamente o padrão pedido — referência-base ou fundadora para cada conceito — e o capítulo o cumpre com consistência.

[POSITIVO] T2 — Formalização matemática presente e correta

Onze equações numeradas cobrem TF-IDF, similaridade de cosseno, Naive Bayes multinomial, agregação por voto majoritário, precisão, revocação, F1 por categoria, F1-Macro, F1-ponderado, CER, WER e atenção escalada. As fórmulas de CER e WER estão corretamente derivadas da distância de Levenshtein, e a distinção entre médias macro e ponderada é explicada com a consequência prática certa (a macro penaliza as classes de cauda). O requisito de incluir fórmulas e métricas está atendido.

[POSITIVO] T3 — Distinção conceitual entre OCR e extração de fluxo nativo

A Seção 2.3.2 estabelece a diferença entre reconhecimento óptico sobre imagem rasterizada e análise de leiaute com extração de fluxo textual nativo, e conclui que o segundo paradigma está, em princípio, livre do tipo de erro medido por CER e WER. Essa distinção é a chave interpretativa de todo o experimento da Seção 5.5 e foi construída antes, no lugar certo. É um exemplo de fundamentação teórica que efetivamente serve à pesquisa, em vez de decorá-la.

[MODERADO] T4 — Conceito descrito e nunca utilizado: Confident Learning

A Seção 2.5.2 intitula-se "Aprendizado Ativo (Active Learning) e Confident Learning" e cita Northcutt, Jiang e Chuang (2021). O Confident Learning é um método específico de estimação de ruído em rótulos, baseado em probabilidades de classe conjuntas e poda de exemplos suspeitos. Nada disso é implementado ou avaliado na monografia: o que existe é um limiar de confiança que encaminha transações à curadoria humana, o que é aprendizado ativo por incerteza, não Confident Learning. A citação está, portanto, aplicada a um conceito que ela não sustenta.

Recomenda-se retirar "Confident Learning" do título da seção e do corpo, mantendo apenas o aprendizado ativo por amostragem de incerteza — ou, alternativamente, aproveitar o conceito de fato: o risco de circularidade discutido na Seção 5.6.3 é precisamente um problema de ruído de rótulo, e uma menção ao Confident Learning ali teria pertinência que não tem no Capítulo 2.

[MODERADO] T5 — Equação 2.8 (F1-ponderado) definida e nunca reportada

A Equação 2.8 formaliza a média ponderada, e a Seção 2.2.5 explica quando ela difere da macro. Nenhuma tabela do Capítulo 5 reporta F1-ponderado: as Tabelas 6, 7, 8, 9, 10 e 11 trazem acurácia, precisão, revocação e F1-Macro. A definição fica órfã. Duas saídas possíveis, ambas aceitáveis: acrescentar a coluna de F1-ponderado à Tabela 6 — o que reforçaria empiricamente o argumento da Seção 5.6.1 sobre acurácia global versus F1-Macro, já que o F1-ponderado se situaria entre as duas — ou remover a Equação 2.8 e reduzir a discussão a uma frase.

[MODERADO] T6 — Data drift e concept drift fundamentados, mas nunca mensurados

A Seção 2.5.1 define os dois fenômenos com referências apropriadas (Quiñonero-Candela et al., 2008; Lu et al., 2019), e a Questão de Pesquisa Q5 pergunta sobre a sustentabilidade do sistema "diante de fenômenos de

Data Drift e Concept Drift". A resposta a Q5 na Seção 5.8, porém, trata apenas da viabilidade do ciclo de MLOps, da latência e da acurácia condicional do ramo LLM: nenhuma medição de desvio é conduzida, embora o acervo do C6 Bank cubra cinco anos e permita, em tese, exatamente esse teste.

Como o acervo é temporalmente ordenado, a correção de menor custo é reconhecer o descompasso: reformular Q5 para o que foi de fato investigado (viabilidade operacional e custo do ciclo de vida) e declarar na Seção 6.5 que a caracterização empírica de desvio não foi realizada. Manter Q5 na formulação atual sem medição correspondente é o tipo de lacuna que uma banca cobra na arguição.

[MODERADO] T7 — Atribuição imprecisa da arquitetura Medallion e do MLflow

Na Seção 2.5.3, a organização em camadas Bronze/Silver/Gold ("Medallion Architecture") é atribuída a Treveil et al. (2020), e o MLflow também. A arquitetura Medallion é terminologia originada na Databricks e difundida a partir de sua documentação técnica; o MLflow tem referência canônica própria na literatura (o artigo de apresentação da plataforma pela equipe da Databricks, 2018). Recomenda-se: (i) citar a fonte primária da Medallion Architecture ou apresentá-la como convenção de mercado sem atribuição a Treveil; e (ii) acrescentar a referência original do MLflow às Referências e citá-la na Seção 2.5.3 e no Capítulo 4.

[LEVE] T8 — Profundidade da Seção 2.4.1 desproporcional ao uso

A Equação 2.11 formaliza a atenção escalada por produto escalar. A pesquisa não modifica, analisa nem mede nada relativo ao mecanismo de atenção: os modelos baseados em Transformer (SBERT e ByT5) são usados como caixas-pretas pré-treinadas. A equação pode permanecer — é defensável como fundamento do ByT5 e do MiniLM —, mas a Seção 2.4.1 ganharia foco se a formalização fosse reduzida a uma menção e o espaço fosse realocado para o que é de fato instrumental: a tokenização em nível de byte (Seção 2.2.2), que sustenta uma das cinco arquiteturas avaliadas.

[LEVE] T9 — Variáveis não definidas em duas equações

Na Equação 2.11, o termo d_k não é definido no texto que a acompanha (é a dimensionalidade das chaves). Na Equação 2.3, o expoente x_i não é explicitado (é a contagem do termo i no documento). A ABNT e a boa prática de redação científica exigem que toda variável de uma equação destacada seja definida no período imediatamente subsequente. As demais equações do capítulo estão corretamente acompanhadas da definição de seus termos.

6. Capítulo 3 — Trabalhos Relacionados

[CRÍTICO] R1 — O capítulo é apresentado como revisão sistemática, mas o Apêndice A descreve outra coisa

A Seção 3.1 afirma que o capítulo segue "um protocolo de revisão sistemática", e a Seção 3.2 nomeia as questões da revisão como RSL-1 a RSL-4, sigla de revisão sistemática da literatura. O Apêndice A, contudo, informa o oposto em dois pontos: (i) o funil formal de triagem é interrompido na etapa de título e resumo, sem leitura integral registrada; e (ii) dos 197 candidatos aprovados, "nenhum foi submetido a um processo formal e exaustivo de leitura integral um a um", tendo a seleção final seguido "um critério de relevância e centralidade".

Uma revisão sistemática exige protocolo prospectivo, triagem em duas etapas com leitura integral e critérios de decisão registrados por estudo. O que foi realizado é um levantamento estruturado do estado da arte com elementos de revisão de escopo — o que é perfeitamente adequado a um TCC de MBA e atende ao requisito de apresentar o levantamento do estado da arte. O problema é exclusivamente de nomenclatura, e é sério porque a banca lerá o rótulo como uma afirmação metodológica verificável.

Correção recomendada: substituir "revisão sistemática" por "levantamento estruturado da literatura" ou "revisão de escopo (scoping review)" na Seção 3.1, no título do Apêndice A e em todas as ocorrências; renomear RSL-1 a RSL-4 para QR-1 a QR-4 (questões da revisão) ou LE-1 a LE-4; e manter o Apêndice A como está, já que sua transparência é o que torna o problema detectável e corrigível.

[CRÍTICO] R2 — O trabalho mais fortemente relacionado de toda a bibliografia está ausente do capítulo

Ta, Saad e Oh (2023), "Specialized text classification: An approach to classifying Open Banking transactions", consta das Referências e é citado duas vezes na Seção 2.2 do Capítulo 2 — mas não é analisado na Seção 3.6 nem figura no Quadro 3. Trata-se de classificação de texto especializada aplicada a transações bancárias: o mesmo problema desta pesquisa, no mesmo tipo de dado, publicado em evento indexado do IEEE dentro da janela de cinco anos.

A ausência tem três consequências. Primeira, enfraquece a afirmação da Seção 3.8 de que persiste uma lacuna quanto a soluções para faturas de cartão de crédito, porque o leitor que conhece o artigo perceberá que o trabalho mais próximo foi deixado fora da comparação. Segunda, compromete o Quadro 3, cuja função é mostrar o que a proposta faz e os demais não fazem. Terceira, é o tipo de omissão que uma banca identifica de imediato, já que o próprio texto do candidato cita o artigo em outro capítulo.

Correção: acrescentar Ta, Saad e Oh (2023) como Seção 3.6.6, com objetivo, abordagem, validação, resultados e relação com esta pesquisa no mesmo instrumento de extração de dados dos demais; incluir a linha correspondente no Quadro 2 (avaliação de qualidade) e no Quadro 3 (matriz de características); e ajustar as contagens do Apêndice A, que passam de seis para sete estudos incluídos.

[MODERADO] R3 — O funil de seleção da Tabela 13 é internamente implausível

A Tabela 13 registra 205 registros triados por título e resumo, 8 excluídos nessa triagem e 197 candidatos aptos — ou seja, uma taxa de exclusão de 3,9% na etapa cujo propósito é justamente descartar a maior parte do material recuperado. Em levantamentos dessa natureza, a triagem por título e resumo tipicamente elimina de 70% a 95% dos registros. Dos 197 "aptos", exatamente um estudo foi incluído. Um funil que aprova 96% na triagem e utiliza 0,5% do aprovado não descreve um processo de seleção; descreve a ausência de um.

Somando-se ao fato de a tabela ter sido "reconstruída retrospectivamente em setembro de 2026 a partir de reexecução ao vivo das três strings" — isto é, quatro a oito meses após as buscas originais, em bases cujo acervo mudou nesse intervalo —, os números não correspondem ao processo efetivamente conduzido entre janeiro e maio de 2026.

Recomenda-se substituir a Tabela 13 por um relato honesto e mais simples: número de registros recuperados por string e base, critério de corte aplicado, e a declaração de que a seleção final dos estudos analisados

seguir julgamento de centralidade em relação às questões da revisão, sem funil formal. Perde-se a aparência de sistematicidade e ganha-se veracidade — o que, nesse caso, é a troca certa.

[MODERADO] R4 — Categorias anunciadas na Seção 3.3 nunca são aplicadas aos estudos

A Seção 3.3 divide os trabalhos recuperados em "fortemente relacionados" e "fracamente relacionados" e define cada categoria. A Seção 3.6 analisa os seis estudos sem atribuir a nenhum deles uma das duas classificações, e o Quadro 3 tampouco traz essa coluna. A distinção fica declarada e não operada.

Essa lacuna interage com um requisito específico: quando não há número suficiente de trabalhos fortemente relacionados, o texto deve declarar explicitamente que a própria escassez é evidência da lacuna, reforçando a originalidade da pesquisa. A monografia tem exatamente esse caso — dos seis estudos, apenas Souza (2025) e, uma vez incluído, Ta, Saad e Oh (2023) tratam do mesmo problema; Zhang et al. (2015), Dhingra et al. (2016) e Araújo et al. (2025) resolvem problemas afins mas distantes —, mas não faz a declaração.

Correção: rotular cada estudo na Seção 3.6 e acrescentar uma coluna "Grau de relação" ao Quadro 3; e incluir na Seção 3.8 um período do tipo "A escassez de trabalhos fortemente relacionados constatada neste levantamento — apenas dois dos sete estudos incluídos abordam a classificação de transações financeiras reais em português do Brasil — constitui, ela própria, evidência da lacuna endereçada por esta pesquisa."

[MODERADO] R5 — Menos de cinco trabalhos dentro da janela de cinco anos

O requisito pede ao menos cinco trabalhos relacionados, preferencialmente dos últimos cinco anos. O total de seis atende ao mínimo quantitativo, mas apenas três são recentes: Santos (2022), Araújo et al. (2025) e Souza (2025). Os demais são de 2015, 2016 e 2019. A inclusão de Ta, Saad e Oh (2023), tratada no achado R2, elevaria para quatro.

Sugere-se acrescentar dois a três estudos de 2023 a 2026 sobre classificação de transações com modelos de linguagem ou sobre extração de documentos financeiros com modelos de visão e linguagem. A observação não desqualifica as referências antigas: Zhang, Zhao e LeCun (2015) é a referência fundadora da modelagem em nível de caractere e deve permanecer. O ponto é de equilíbrio entre base histórica e estado da arte corrente.

[MODERADO] R6 — Quadro 2: quatro perguntas binárias não produzem "Parcial" nem pontuação 3,5

A Seção 3.5 afirma que o critério de avaliação de qualidade é "composto por quatro perguntas binárias" e que a pontuação é a "soma das respostas afirmativas", de 0 a 4. O Quadro 2, no entanto, registra "Parcial" em cinco células e atribui 3,5 a cinco dos seis estudos. Uma soma de respostas binárias só pode produzir inteiros de 0 a 4.

Correção: declarar na Seção 3.5 que a escala é ternária (Sim = 1; Parcial = 0,5; Não = 0), o que torna o Quadro 2 coerente e é uma escolha metodológica comum; ou converter as respostas "Parcial" em "Sim" ou "Não" e recalculas as pontuações como inteiros. A primeira opção é menos trabalhosa e preserva a informação.

[MODERADO] R7 — QA1 atribuído indevidamente a Santos (2022)

O critério QA1 pergunta se o estudo foi publicado em periódico revisado por pares, evento indexado de relevância ou dissertação/tese de excelência. Santos (2022) recebe "Sim". A referência correspondente descreve a obra como "Monografia (Trabalho de Conclusão de Curso (Engenharia de Computação))" com 39 folhas — um TCC de graduação, que não é dissertação nem tese e não passa por revisão por pares.

Isso não significa que o trabalho deva ser excluído: ele é pertinente, trata de classificação de descrições curtas de notas fiscais em português e sustenta um argumento relevante da monografia. A correção é alterar QA1 para "Não" ou "Parcial" e recalculas a pontuação, registrando em nota de rodapé do Quadro 2 que o estudo foi mantido por pertinência temática direta apesar do critério. Manter "Sim" enfraquece a credibilidade de todo o instrumento de avaliação de qualidade.

[POSITIVO] R8 — Protocolo de levantamento documentado em apêndice, como exigido

O Apêndice A traz as bases consultadas, as três strings booleanas completas, os critérios de inclusão e exclusão, a técnica de snowballing com referência metodológica (Wohlin, 2014) e a indicação de qual canal originou cada estudo incluído. O requisito de detalhar o levantamento em apêndice — e não no corpo do capítulo — está integralmente atendido, e o nível de detalhe é superior ao usual em TCCs de MBA.

[POSITIVO] R9 — Transparência sobre a limitação de cobertura da string terciária

A Seção A.2 declara que a string terciária retornou volume inviável de triagem manual, explicita o critério de corte adotado (50 registros mais citados por base) e reconhece que isso privilegia estudos consolidados em detrimento de contribuições recentes pouco citadas — limitação também registrada na Seção 6.5. Declarar um viés de amostragem que se poderia simplesmente omitir é exatamente o comportamento esperado de um pesquisador, e deve ser preservado na revisão.

[POSITIVO] R10 — Quadro comparativo bem construído e com a proposta incluída

O Quadro 3 confronta dez capacidades centrais contra os seis estudos correlatos e inclui a linha "Esta Pesquisa (Proposta)", conforme exigido. A escala de três níveis (atende, atende parcialmente, não atende) é adequada, e o texto que precede o quadro é cuidadoso ao advertir que a comparação é necessariamente qualitativa, uma vez que os estudos reportam métricas sobre conjuntos de dados distintos e sem base comum. Essa ressalva evita o erro frequente de contrapor numericamente resultados incomparáveis.

[LEVE] R11 — Coluna do Quadro 3 com rótulo de difícil leitura

As colunas do Quadro 3 estão rotacionadas e algumas contêm rótulos longos ("Monitoramento de desvio / MLOps", "Execução local c/ aderência à LGPD"), o que dificulta a leitura em impressão. Sugere-se abreviar os rótulos para duas ou três palavras e mover a definição completa de cada capacidade para uma nota abaixo do quadro, como já se faz com a legenda dos símbolos.

7. Capítulo 4 — Solução Proposta

[POSITIVO] S1 — Questões de pesquisa, hipótese e tipo de pesquisa formalizados na abertura

A Seção 4.2 abre com cinco questões de pesquisa (Q1 a Q5) e a hipótese central; a Seção 4.3 classifica a pesquisa quanto à natureza (aplicada), à abordagem (experimental e quantitativa) e ao procedimento (CRISP-DM estendido com diretrizes de MLOps), com referências metodológicas apropriadas (Gerhardt e Silveira, 2009; Gil, 2019; Chapman et al., 2000; Wirth e Hipp, 2000). A sequência exigida — questões, hipóteses, tipo de pesquisa, metodologia, proposta detalhada — é respeitada.

[POSITIVO] S2 — Decomposição da hipótese em subhipóteses com veredito independente

A hipótese conjuntiva é decomposta em H1a (acurácia global superior a 85%) e H1b (F1-Macro superior a 85%), com a regra lógica de agregação declarada antecipadamente: a refutação de qualquer subhipótese refuta a conjunção. Isso é feito na Seção 4.2, antes de os resultados serem conhecidos pelo leitor, e o veredito é aplicado sem ajuste na Seção 5.8. Declarar o critério de refutação antes do resultado e sustentá-lo depois é a marca de um desenho experimental honesto e merece destaque na defesa.

[POSITIVO] S3 — Figuras ilustrativas presentes e funcionais

A Figura 1 apresenta a topologia do ecossistema de dados com os fluxos entre serviços, e a Figura 2 o grafo de estados do agente. A Figura 2 vem acompanhada de nota que mapeia cada identificador de nó do código à sua função em linguagem natural, o que permite ao leitor acompanhar a Seção 4.6 sem consultar o repositório. O requisito de explicação com figuras ilustrativas está atendido.

[MODERADO] S4 — A hipótese central contém cláusulas não falsificáveis que desaparecem na decomposição

A hipótese enunciada na Seção 4.2 afirma que a esteira é capaz de classificar transações "com acurácia global e F1-Macro superiores a 85% em uma taxonomia de 14 categorias, garantindo conformidade rigorosa com a LGPD e viabilidade de execução em infraestrutura local". A decomposição subsequente conserva apenas os dois limiares numéricos: conformidade legal e viabilidade de execução local somem sem menção.

Conformidade com a LGPD e execução em hardware local não são proposições testáveis por experimento — são requisitos de projeto, e a própria monografia já os trata como tal na Seção 1.3. Mantê-los dentro da hipótese torna o enunciado parcialmente não falsificável; descartá-los silenciosamente na decomposição cria a impressão de que o critério foi ajustado após o fato.

Correção: reescrever a hipótese contendo apenas as duas afirmações mensuráveis e acrescentar, imediatamente após, uma frase do tipo "A conformidade com a LGPD e a execução em infraestrutura local constituem requisitos não funcionais da solução (Seção 1.3), verificados por inspeção arquitetural na Seção 4.7 e não submetidos a teste de hipótese." Isso preserva o conteúdo e elimina a inconsistência lógica.

[MODERADO] S5 — Fonte de dados e amostragem ausentes da metodologia

O requisito determina que a metodologia descreva a fonte de dados e a amostragem, o tipo de dados (reais ou sintéticos) e a descrição dos dados. No Capítulo 4, a Seção 4.3 menciona os conjuntos apenas de passagem, na etapa 2 do CRISP-DM. Toda a caracterização substantiva — origem, volume, pareamento, taxonomia, particionamento, proveniência dos rótulos — está na Seção 5.3, dentro do capítulo de validação.

A alocação atual não é errada em absoluto, mas deixa o Capítulo 4 sem um elemento exigido. A correção de menor custo é criar a Seção 4.4 "Fonte de dados, amostragem e natureza dos dados", com meia página sintetizando: origem dos dois acervos, a decisão de operar sobre ruído real em vez de sintético (que é uma escolha metodológica defensável e merece estar na metodologia, não nos resultados), o critério de amostragem das 14 faturas e a natureza semiautomática da rotulagem, remetendo à Seção 5.3 para o detalhamento.

[MODERADO] S6 — A descrição do fluxo do agente tem duas passagens ambíguas

Primeira: o item 4 da Seção 4.6 afirma que uma similaridade maior ou igual a 0,85 encaminha a transação "diretamente para o nó salvar_resultado", ao passo que o item 9 afirma que transações classificadas com alta confiança "têm sua descrição normalizada e metadados persistidos no pgvector" pelo nó salvar_vectorstore. Não fica claro se os dois nós são executados em sequência, se salvar_vectorstore é condicional a outro critério, ou se há divergência entre a descrição e o grafo da Figura 2.

Segunda: o item 2 descreve o roteamento pós-normalização e afirma que o fluxo "converge para buscar_por_similaridade em seguida", o que também é repetido no item 3. A repetição sugere que a convergência foi acrescentada em revisão para sanar uma ambiguidade anterior; o texto ficaria mais limpo se a regra fosse enunciada uma única vez.

Recomenda-se descrever o fluxo em uma lista de arestas condicionais explícitas (origem, condição, destino), que é como o grafo de fato está codificado, em vez de em prosa sequencial.

[MODERADO] S7 — Defeitos no prompt reproduzido no Apêndice D não são analisados

O Apêndice D reproduz o prompt de sistema tal como está no código, e o próprio texto adverte que a numeração das regras salta de 4 para 6. Além da regra ausente, o prompt contém erros de português em campos que o modelo lê ("Raciocínio usado para categorizar a transação", "Lista de categoria sugeridas de possíveis categorias no mínimo 3") e uma tensão entre a regra 2, que instrui a inferir a categoria por pistas genéricas, e a regra 3, que combate alucinações — tensão que o próprio prompt tenta resolver com a ressalva "inferir a categoria a partir de pistas genéricas NÃO é alucinação".

Isso é relevante porque o ramo LLM obteve acurácia condicional de apenas 21% e a monografia atribui esse desempenho à capacidade do modelo local. A atribuição pode estar certa, mas a evidência apresentada não isola de uma explicação concorrente e mais simples: um prompt com regra faltante, instruções em tensão e campos de saída descritos com erro. Ver também o achado V9.

Recomenda-se acrescentar ao final do Apêndice D um parágrafo de análise crítica do artefato, reconhecendo os três defeitos e registrando que a separação entre limitação do modelo e limitação do prompt não foi isolada experimentalmente. Corrigir a numeração e a ortografia no código-fonte também é recomendável, ainda que sem reexecução dos experimentos.

[POSITIVO] S8 — Justificativa dos três limiares de roteamento e da relação entre eles

A Seção 4.6 encerra com uma explicação de por que os limiares 0,85, 0,80 e 0,70 não competem entre si, demonstrando que toda transação autoavaliada pelo modelo no piso de 0,70 já está contida no conjunto encaminhado à curadoria humana, uma vez que 0,70 é menor que 0,80. Ao mesmo tempo, declara que os valores foram adotados heurísticamente e não calibrados. Antecipar a objeção óbvia ("esses três limiares não conflitam?") e respondê-la com um argumento de contenção de conjuntos é um cuidado de redação que vale preservar.

[LEVE] S9 — Conformidade com a LGPD descrita por asserção, sem verificação

A Seção 4.7 enumera quatro princípios e associa cada um a um mecanismo implementado. A descrição é competente e a ressalva do item 3 — que o processamento local reduz mas não elimina todas as superfícies de risco — é bem-vinda. Falta, contudo, qualquer forma de verificação: não há inspeção de amostra confirmando que números de cartão e CVV foram de fato expurgados, nem verificação de que os identificadores pessoais estão pseudonimizados na base. Uma verificação simples (consulta à base de produção contando ocorrências de padrões de cartão e CPF, com resultado zero) converteria a asserção em evidência e ocuparia um parágrafo.

[LEVE] S10 — Detalhamento de implementação disperso entre três locais

Linguagens e arcabouços aparecem na Seção 4.8 (pytest, JUnit 5, Spring Boot), as versões de bibliotecas na Seção 5.2 e a organização do código no Apêndice C. O requisito de descrever detalhes de implementação e linguagem está atendido no conjunto, mas o leitor precisa reunir três fontes. Uma tabela única no Capítulo 4, listando componente, linguagem, arcabouço principal e versão, com remissão à Seção 5.2 para o ambiente de execução, resolveria.

8. Capítulo 5 — Validação experimental e resultados

8.1 Verificação aritmética independente

Todas as tabelas numéricas do capítulo foram recomputadas nesta revisão a partir dos próprios dados que elas exibem. O resultado é favorável e merece registro antes dos achados:

[POSITIVO] V1 — As tabelas são aritmeticamente consistentes entre si

Verificações realizadas e aprovadas: (i) na Tabela 11, o F1 de cada categoria corresponde à média harmônica da precisão e da revocação informadas, e as médias macro de precisão (74,1%), revocação (66,5%) e F1 (69,3%) reproduzem exatamente a média aritmética simples das onze categorias; (ii) a acurácia de 84,7% da Tabela 6 para o Random Forest é recuperável a partir dos volumes e revocações da Tabela 11 (283 acertos em 334); (iii) na Tabela 5, os 699 lançamentos de verdade de referência e as 357 páginas somam corretamente, e as médias de CER, WER e casamento exato por competência reproduzem os valores consolidados da Tabela 4; (iv) todas as razões da coluna "Vantagem / Impacto" da Tabela 4 conferem ($52,82/5,72 = 9,2$; $85,36/10,14 = 8,4$; $8,76/5,56 = 1,6$); (v) o particionamento $1.150 + 176 + 334$ totaliza as 1.660 transações e corresponde aos percentuais 69/11/20 da Seção 5.4.2; (vi) a acurácia global do agente (61,4%) é recuperável da composição dos ramos ($0,52 \times 0,98 + 0,48 \times 0,21 = 61,0\%$); (vii) as 1.398 comparações equivalem a 699×2 ; e (viii) a distribuição de faturas por ano soma 49, com 357 páginas. Essa consistência interna é evidência concreta de que a esteira experimental de fato gerou as tabelas, e não o contrário.

8.2 Achados críticos

[CRÍTICO] V2 — A comparação entre representações esparsas e densas usa a melhor configuração de uma e a pior da outra

A Tabela 6 reporta TF-IDF + Random Forest com F1-Macro de 69,3% e busca vetorial densa com 56,2%, diferença de 13,1 pontos percentuais que sustenta a Resposta a Q1 (Seção 5.8), o fechamento da Seção 5.9 e a terceira conclusão da Seção 6.4, esta última qualificada como "a contribuição empírica mais relevante do trabalho".

A Tabela 12, porém, mostra que a normalização léxica tem efeito oposto sobre as duas famílias: para o Random Forest, a melhor configuração é sem normalização (69,3% contra 67,4%); para a busca vetorial densa, a melhor é com normalização (66,8% contra 56,2%). Comparando cada arquitetura em sua própria melhor configuração, os números são 69,3% e 66,8% — diferença de 2,5 pontos percentuais. O intervalo de confiança de 95% do Random Forest, informado na Tabela 7, é [61,1%; 73,9%], e contém folgadoamente o valor 66,8%.

Consequência: a afirmação de que representações esparsas superaram embeddings densos não está estabelecida pelos próprios dados da monografia. O que os dados sustentam é mais matizado e, honestamente, mais interessante: as duas famílias têm desempenho estatisticamente indistinguível neste acervo, mas exigem pré-processamentos opostos — o que reforça, e não enfraquece, a quarta conclusão da Seção 6.4 sobre a dependência entre pré-processamento e representação.

Correção recomendada em quatro pontos. Primeiro, acrescentar à Tabela 6 uma coluna ou nota indicando a configuração de normalização de cada linha, de modo que o leitor veja que 69,3% e 56,2% são ambos "sem normalização". Segundo, incluir na Tabela 7 o intervalo de confiança do RAG com normalização (66,8%) e aplicar o teste de McNemar entre essa configuração e o Random Forest, exatamente como já se fez entre Random Forest e Naive Bayes. Terceiro, reescrever a Resposta a Q1 para refletir a comparação em melhor configuração. Quarto, e mais importante, reformular a conclusão 3 da Seção 6.4: o ByT5 (48,3%) permanece claramente inferior e essa parte da conclusão se sustenta, mas a superioridade sobre a busca densa não.

[CRÍTICO] V3 — Contradição sobre o tamanho do conjunto de treinamento

A Seção 5.4.2 afirma que, "na implementação efetiva da esteira experimental, o conjunto de validação foi incorporado ao conjunto de treinamento — formando o conjunto treino+validação sobre o qual se computaram a validação cruzada 5-fold e o ajuste final de cada arquitetura". Isso implica $1.150 + 176 = 1.326$ exemplos de treino para todas as arquiteturas. O item 3 da Seção 5.6 afirma, porém, que "com 1.150 exemplos de treino, o byt5-small convergiu a uma função de perda no treinamento inferior a 0,02". A Seção 6.5, item 9, repete a primeira versão.

Uma das duas afirmações está errada, e a diferença importa: o argumento de que o ByT5 sofreu sobreajuste por escassez de dados depende do volume efetivamente usado, e 1.326 contra 1.150 é uma diferença de 15%. Além disso, se a incorporação da validação valeu para umas arquiteturas e não para outras, as cinco não foram treinadas sobre o mesmo conjunto e a comparação da Tabela 6 deixa de ser pareada.

Correção: verificar nos artefatos do MLflow e nos scripts 02_baselines.py e 03_byt5.py qual foi o volume efetivo por arquitetura; uniformizar a redação em todas as três passagens; e, caso o conjunto de treino não tenha sido o mesmo para todas, declarar essa assimetria explicitamente como limitação de comparabilidade.

[CRÍTICO] V4 — Tabela 9: quatro arquiteturas distintas com métricas idênticas até a casa decimal

No subconjunto Nubank ($n = 100$), a Tabela 9 atribui acurácia de 98,0% e F1-Macro de 36,2% simultaneamente a TF-IDF + Random Forest, TF-IDF + Naive Bayes, ByT5 Fine-Tuning e busca vetorial RAG. Quatro arquiteturas com fundamentos matemáticos inteiramente distintos — ensemble de árvores sobre vetores esparsos, classificador bayesiano, modelo neural ajustado em nível de byte e recuperação por similaridade de cosseno — produzindo exatamente os mesmos dois valores é um evento que exige verificação, sobretudo porque o ByT5 obtém apenas 52,1% de acurácia no subconjunto C6 Bank e salta para 98,0% no Nubank.

Duas explicações são possíveis. Pode ser genuíno: se as 100 transações do Nubank se concentram em duas categorias (93% em Alimentação e Saúde, conforme a Seção 5.3.2) com padrões léxicos muito fortes, os quatro modelos podem convergir para as mesmas 98 predições corretas e os mesmos 2 erros. Ou pode ser um defeito de cruzamento entre os arquivos de predição e a coluna de origem, hipótese reforçada pelo fato de o agente híbrido — único a não compartilhar o pipeline de avaliação dos demais — ser também o único com valores diferentes.

A monografia não faz essa verificação nem comenta a coincidência, o que é uma omissão relevante: o leitor atento a notará e concluirá que há erro, mesmo que não haja. Correção: conferir os arquivos `predicoes_*.csv`; se a coincidência for real, reportar a matriz de confusão do subconjunto e explicar no texto por que as arquiteturas convergem; se for artefato, corrigir a tabela e reavaliar a Seção 5.6.2 inteira, cujas conclusões dependem dela.

8.3 Demais achados do capítulo

[MODERADO] V5 — O resumo não registra a ressalva que qualifica o resultado de destaque

A Seção 5.6 declara, com todas as letras, que o F1-Macro de 69,3% "corresponde à configuração sem a etapa de normalização léxica" e que, portanto, "o melhor resultado reportado é obtido omitindo um componente que os Capítulos 4 e 6 apresentam como parte da solução proposta". A Seção 6.3 repete a ressalva. O resumo, contudo, apresenta o número sem qualquer qualificação, e é o resumo que a maioria dos leitores — inclusive membros de banca — lerá primeiro e, às vezes, apenas.

Recomenda-se acrescentar a ressalva entre parênteses no resumo e no abstract, conforme a redação proposta na Seção 12 deste relatório. O custo é de seis palavras; o ganho é a coerência entre o resumo e o corpo do trabalho.

[MODERADO] V6 — A Tabela 12 mistura duas grandezas incomensuráveis sob um único cabeçalho

A Tabela 12 intitula-se "Ablação de componentes sobre o teste-cego (variação de F1-Macro)" e sua terceira coluna é rotulada " Δ F1 (p.p.)". As duas primeiras linhas trazem, de fato, variações de F1-Macro decorrentes da remoção de um componente. A terceira linha — "Ramo vetorial (RAG) — acurácia condicional, 97,7% contra 21,4%, $\Delta +76,3$ " — não é uma ablação nem uma variação de F1: é a comparação da acurácia condicional entre dois ramos do agente, ambos presentes.

A consequência prática é que um leitor que consulte apenas a tabela concluirá que remover o ramo vetorial custa 76,3 pontos de F1-Macro, o que não é o que foi medido. Correção: mover a terceira linha para a Seção 5.7, onde a análise por ramo já é conduzida, ou mantê-la na tabela sob um subcabeçalho próprio ("Desempenho por ramo do agente — acurácia condicional") claramente separado do bloco de ablação.

[MODERADO] V7 — Contabilidade do roteamento do agente incoerente entre a visão global e a por emissor

A Seção 5.6, item 5, informa que o agente roteou 52% das transações para a busca vetorial e 48% para o modelo de linguagem — uma partição em dois blocos que soma 100%. A Seção 5.6.2 apresenta, para os mesmos dados, uma partição em três blocos: C6 Bank com 52,6% vetorial, 41,5% LLM e 6,0% humano; Nubank com 52,0%, 47,0% e 1,0%.

Os números são reconciliáveis — a fatia "humano" é subconjunto do ramo LLM, já que a interrupção de confirmação ocorre após a inferência do modelo, e $41,5 + 6,0 \approx 47,5$ aproxima os 48% globais —, mas a monografia não declara essa relação. O leitor que tentar somar 52% + 48% e localizar os 4,5% de acionamento do Human-in-the-Loop não conseguirá.

Correção: declarar explicitamente, na primeira ocorrência, que as transações encaminhadas à confirmação humana constituem subconjunto do ramo LLM, e padronizar a apresentação em três blocos aninhados em todas as passagens.

[MODERADO] V8 — Rótulo "SOTA Neural" atribuído ao byt5-small

A Tabela 6 nomeia a terceira arquitetura como "SOTA Neural: ByT5 Fine-Tuning (byt5-small)". O byt5-small é o menor checkpoint de uma família publicada em 2022 e não constitui, sob nenhum critério, o estado da arte em classificação de texto — posição que o próprio resultado de 48,3% de F1-Macro desmente. O rótulo cria uma expectativa que a tabela imediatamente frustra, e dá a impressão de que a comparação foi montada contra um espantalho.

Correção simples: substituir por "Modelo neural em nível de byte: ajuste fino do ByT5 (byt5-small)". O argumento da monografia não perde nada — pelo contrário, fica mais defensável, porque deixa de reivindicar ter superado o estado da arte e passa a afirmar o que realmente mostrou: que um modelo neural compacto ajustado sobre pouco dado não compete com uma linha de base esparsa.

[MODERADO] V9 — A causa da baixa acurácia do ramo LLM não é isolada experimentalmente

A conclusão 5 da Seção 6.4 afirma que "a arquitetura em grafo de estados é sólida; o componente limitante é a capacidade do modelo local disponível, não a orquestração". A evidência disponível não separa essa hipótese de pelo menos três concorrentes: (i) defeitos no prompt, discutidos no achado S7; (ii) a indisponibilidade da ferramenta de busca na web, que retirou do agente justamente o recurso desenhado para os nomes opacos onde ele falhou; e (iii) a ausência de calibração dos limiares, reconhecida na Seção 6.5.

Um experimento de baixo custo isolaria a primeira: reexecutar o ramo LLM sobre as mesmas 160 transações com o prompt corrigido (regra 5 restaurada, ortografia dos campos ajustada) e comparar a acurácia condicional. Caso não haja tempo hábil, a alternativa é reformular a conclusão 5 para o que a evidência sustenta: "o ramo de raciocínio, na configuração avaliada — modelo local compacto, prompt não calibrado e ferramenta de busca indisponível —, não agregou valor sobre a busca vetorial; a atribuição dessa diferença à capacidade do modelo, ao prompt ou à ausência da ferramenta não foi isolada."

[POSITIVO] V10 — Tratamento estatístico acima do esperado para o nível

A Seção 5.4.3 aplica intervalos de confiança por reamostragem bootstrap com 2.000 repetições (Efron, 1979) e teste de McNemar pareado com correção de continuidade (McNemar, 1947), e a Seção 5.6 usa o resultado contra o próprio interesse: constata $p = 0,059$ e conclui que não há evidência para afirmar que o Random Forest supera o Naive Bayes, apesar de o F1-Macro pontual ser superior. Declarar que a diferença que favorece o seu melhor modelo não é significativa é o comportamento correto e raro. Deve ser explicitamente apontado na defesa.

[POSITIVO] V11 — Protocolo de teste cego por estabelecimento e quantificação do efeito de memorização

O particionamento por estabelecimento, com todas as ocorrências de um mesmo comércio confinadas a um único conjunto, é deliberadamente mais severo que a partição aleatória, e a Tabela 8 quantifica o custo dessa severidade: 23,4 pontos percentuais no Random Forest e 24,9 no Naive Bayes. Esse é, no julgamento desta revisão, o resultado de maior alcance da monografia — vale para qualquer trabalho de categorização de transações, não apenas para este —, e a ressalva de escopo que o acompanha (a medição foi feita apenas nas duas linhas de base esparsas) é registrada com a honestidade devida.

[POSITIVO] V12 — Ambiente computacional descrito com detalhe reproduzível

A Seção 5.2 especifica as duas máquinas físicas com processador, memória, GPU e sistema operacional, as versões de treze bibliotecas, o modelo de embeddings e o modelo de raciocínio. Mais notável: declara que as latências reportadas incluem o tempo de rede entre as duas máquinas, e não apenas o processamento local — um detalhe que a maioria dos trabalhos omite e que muda a interpretação dos números. O requisito de descrever hardware e software está atendido com folga.

[POSITIVO] V13 — Linha de base explicitamente identificada

As duas primeiras arquiteturas da Tabela 6 estão rotuladas como "Linha de Base 1" e "Linha de Base 2", e o objetivo específico 3 da Introdução já as designava como referências quantitativas de comparação. A exigência de indicar claramente o baseline está cumprida sem ambiguidade.

[LEVE] V14 — Divergência de arredondamento entre as Tabelas 6 e 11

A Tabela 6 informa precisão de 74,2% para o TF-IDF + Random Forest; a Tabela 11 informa 74,1% para a mesma grandeza, e a recomputação independente confirma 74,145%, que arredonda para 74,1%. Convém corrigir a Tabela 6. Na mesma linha, a latência do agente é reportada com duas casas decimais (6.529,97 ms) enquanto as demais têm duas casas significativas (0,03 ms; 0,28 ms); sugere-se padronizar para duas casas significativas em toda a coluna, já que a terceira casa de uma medida de 6,5 segundos não carrega informação.

[LEVE] V15 — Duas autorreferências de seção

Dentro da Seção 5.6, o item 4 remete a uma medida "da Seção 5.6" e o item 5 refere-se à "instrução SQL isolada de 1,4 ms medida na Seção 5.6" — ambas dentro da própria Seção 5.6. Trata-se provavelmente de remissões que deveriam apontar para a Seção 5.7, onde a distinção entre latência isolada e latência de ponta a ponta é de fato desenvolvida. Convém revisar as duas.

[LEVE] V16 — Descrição do acervo como "período contínuo"

A Seção 5.3 descreve o acervo do C6 Bank como abrangendo "o período contínuo de janeiro de 2022 a agosto de 2026". A Tabela 2 mostra 11 faturas em 2024 (uma competência ausente) e 2 em 2026, sobre 8 meses decorridos — logo, o período não é contínuo. Sugere-se "abrangendo competências de janeiro de 2022 a agosto de 2026, com 49 faturas efetivamente disponíveis", e uma nota na Tabela 2 registrando as competências ausentes.

9. Capítulo 6 — Conclusões e trabalhos futuros

[POSITIVO] N1 — Sequência exigida integralmente respeitada

O capítulo abre com a síntese da solução e das contribuições (Seção 6.2), segue com a avaliação do cumprimento dos objetivos (6.3), apresenta as principais conclusões (6.4), explicita as limitações (6.5) e só então aponta os desdobramentos futuros (6.6). É exatamente a ordem pedida: resumo da solução e dos resultados, limitações, e por último os assuntos decorrentes. A Seção 6.4, dedicada exclusivamente às conclusões da pesquisa, é uma escolha acertada — muitos trabalhos dissolvem as conclusões dentro da síntese e perdem o efeito.

[POSITIVO] N2 — Seção de limitações excepcionalmente completa

As onze limitações da Seção 6.5 cobrem dependência de conectividade, bootstrap da base vetorial, risco de circularidade na rotulagem, restrição do experimento de OCR a PDFs nativos, porte e proveniência do acervo, restrição da validação cruzada às linhas de base esparsas, simulação do Human-in-the-Loop, capacidade do modelo local, ausência de calibração de hiperparâmetros e limiares, reprodutibilidade incompleta do ramo LLM e cobertura parcial da string terciária. Várias delas são o tipo de informação que um autor menos escrupuloso simplesmente não registraria. A seção deve ser preservada integralmente e mencionada na defesa como escolha deliberada.

[POSITIVO] N3 — Conclusões formuladas como proposições, não como lista de entregas

As sete conclusões da Seção 6.4 são afirmações substantivas sobre o mundo ("preservar a topologia tabular na ingestão é condição necessária para a qualidade da classificação subsequente", "o protocolo de avaliação é determinante para a leitura dos resultados"), e não uma reenumeração do que foi construído. Cada uma remete à seção que a sustenta. Essa é a forma correta, e contrasta favoravelmente com o padrão comum de conclusões que apenas repetem os objetivos no pretérito.

[POSITIVO] N4 — Nota metodológica: as conclusões não invadem os trabalhos futuros

A Seção 6.4 abre declarando que nenhuma das conclusões antecipa as direções de trabalho futuro da Seção 6.6, e a separação é de fato respeitada. Isso mantém as duas seções com funções distintas — o que se aprendeu contra o que resta investigar — e evita a diluição frequente entre ambas.

[MODERADO] N5 — Itens rotulados como trabalho futuro na Seção 6.5 não constam da Seção 6.6

Três limitações da Seção 6.5 são explicitamente qualificadas pelo autor como trabalho futuro: o teste com transações validadas manualmente e independentes de ambos os métodos de rotulagem (item 3, descrito inclusive como "de maior prioridade que os demais itens desta lista"); a bateria comparativa de OCR sobre documentos genuinamente escaneados (item 4); e a varredura sistemática de hiperparâmetros e limiares (item 9). Nenhum dos três aparece na lista da Seção 6.6, que contém seis itens de natureza expansiva (Open Finance, multi-agente, Edge AI, aprendizado federado, camada analítica e automação de testes).

O efeito é que os desdobramentos mais urgentes e mais baratos ficam enterrados na seção de limitações, enquanto a lista de trabalhos futuros exhibe apenas ambições de longo prazo. Correção: criar na Seção 6.6 um bloco inicial de "consolidação dos resultados atuais" com esses três itens, antecedendo o bloco de expansão. Isso não acrescenta conteúdo novo — apenas realoca o que já está escrito — e melhora sensivelmente a impressão de que o autor sabe o que fazer a seguir.

[MODERADO] N6 — A conclusão 3 precisa ser reformulada em função do achado V2

Conforme detalhado no achado V2, a terceira conclusão — "em regime de baixo volume rotulado, representações esparsas com n-gramas de caractere superaram embeddings densos multilíngues, ajuste fino

de modelo no nível de byte e um agente com grande modelo de linguagem local" — não se sustenta na parte relativa aos embeddings densos quando cada arquitetura é avaliada em sua melhor configuração.

Redação alternativa que preserva o que a evidência de fato mostra: "Em regime de baixo volume rotulado, uma representação esparsa por n-gramas de caractere com classificador clássico iguala o desempenho de embeddings densos multilíngues a uma fração do custo computacional, e supera com clareza tanto o ajuste fino de um modelo no nível de byte quanto um agente apoiado em grande modelo de linguagem local. Sofisticação arquitetural não compensa escassez de dados rotulados — mas tampouco a penaliza: o que distingue as duas primeiras abordagens é o custo, não a eficácia."

[LEVE] N7 — Contribuição metodológica subdimensionada na síntese

A Seção 6.2 enumera cinco contribuições, todas de natureza técnica ou de engenharia (esteira de extração, agente em grafo, arquitetura de dados, validação sob protocolo rigoroso, publicação do código). A contribuição de maior alcance — a quantificação de 23 a 25 pontos percentuais entre validação cruzada e teste cego por estabelecimento — aparece apenas como um detalhe dentro do quarto item, embora a Seção 6.4 a classifique corretamente como "a contribuição metodológica mais relevante desta pesquisa".

Sugere-se promovê-la a item próprio na Seção 6.2, formulado como achado transferível: qualquer trabalho de categorização de transações que reporte desempenho sob validação cruzada convencional está, provavelmente, superestimando-o na mesma ordem de grandeza. É o resultado desta monografia com maior chance de ser citado por terceiros.

[LEVE] N8 — A Seção 6.7 repete a Seção 6.4 sem acrescentar

As "Considerações Finais" (6.7) reapresentam, em prosa contínua, o mesmo conteúdo das conclusões (6.4) e do encerramento do Capítulo 5 (5.9): viabilidade funcional da esteira, competitividade dos classificadores esparsos, limiar de 85% não alcançado, conformidade com a LGPD. Como o Capítulo 6 está dispensado da exigência de considerações finais, e como as conclusões já cumprem essa função, sugere-se suprimir a Seção 6.7 ou reduzi-la a um único parágrafo de fecho que não reitere números já apresentados.

10. Citações e referências bibliográficas (ABNT)

10.1 Correspondência entre citações e lista de referências

[POSITIVO] A1 — Nenhuma citação órfã e nenhuma referência não citada

Foi feito o cruzamento integral entre as entradas da lista de referências e as citações no corpo do texto, apêndices incluídos. Não foi encontrada nenhuma referência citada no texto e ausente da lista, nem nenhuma referência listada e nunca citada. Em trabalhos com quase cinquenta entradas produzidas ao longo de meses, esse resultado é raro e indica gestão disciplinada da bibliografia — provavelmente por gerenciador de referências acoplado ao abnTeX2. É um ponto a preservar em qualquer revisão subsequente, já que a inclusão de novos trabalhos no Capítulo 3 (achados R2 e R5) exigirá manter essa correspondência.

[POSITIVO] A2 — Sistema autor-data aplicado conforme o modelo

O modelo prescreve o sistema autor-data com sobrenome em maiúsculas e minúsculas quando integrado ao texto, e entre parênteses ao final do período. A monografia aplica o padrão de forma consistente — "(Caseli; Nunes, 2024)", "Zhang, Zhao e LeCun (2015) propuseram...", "(Rajaraman; Ullman, 2011)" —, com ponto e vírgula separando autores dentro dos parênteses e vírgula antes do ano. A regra de autor-entidade da Seção 3.8 do modelo também é observada: a ABECS aparece por extenso na primeira ocorrência, seguida da sigla, e apenas pela sigla nas seguintes.

[POSITIVO] A3 — Uso correto de referências fundadoras ao lado de recentes

A lista combina obras seminais anteriores a 2010 (Levenshtein, 1966; Harel, 1987; Hochreiter e Schmidhuber, 1997; McCallum e Nigam, 1998; Breiman, 2001; Rennie et al., 2003; Chowdhury, 2003; Smith, 2007; Efron, 1979; McNemar, 1947) com produção recente (Araújo et al., 2025; Souza, 2025; Gemma Team, 2026; Auer et al., 2024; Chase, 2024). Essa combinação é exatamente o que se espera: as referências que deram origem ao assunto e as que representam seu estado corrente.

[MODERADO] A4 — Uso indevido de "et al." para obras com exatamente três autores

O modelo distingue, nas Seções 3.3 e 3.4, o tratamento de obras com até três autores (todos listados) do de obras com mais de três ("et al."). Duas obras da monografia têm exatamente três autores e são citadas com "et al." em vários pontos:

- Zhang, Zhao e LeCun (2015) — citada como "Zhang et al. (2015)" no título da Seção 3.6.1, no Quadro 2, no Quadro 3 e no corpo da Seção 3.6.1.
- Araújo, Bezerra e Neto (2025) — citada como "Araújo et al. (2025)" no título da Seção 3.6.4, no Quadro 2, no Quadro 3 e na Seção 3.7.

É curioso que, nas mesmas seções, as citações parentéticas usem a forma correta ("(Zhang; Zhao; LeCun, 2015)", "(Araújo; Bezerra; Neto, 2025)"): a divergência está concentrada nos títulos de subseção e nas células dos quadros. Corrigir para "Zhang, Zhao e LeCun (2015)" e "Araújo, Bezerra e Neto (2025)" em todos os pontos. Dhingra et al. (2016) e Huang et al. (2019), com mais de três autores, estão corretos.

[MODERADO] A5 — Partículas de sobrenome truncadas nas entradas da lista

Quatro entradas apresentam a partícula do sobrenome abreviada como inicial, o que é um artefato típico de conversão automática de campos BibTeX e não corresponde ao padrão ABNT, que exige a partícula por extenso após as iniciais dos prenomes:

Como está	Como deveria estar
CASELI, H. d. M.; NUNES, M. d. G. V.	CASELI, H. de M.; NUNES, M. das G. V.
SANTOS, M. T. M. d.	SANTOS, M. T. M. dos

Como está	Como deveria estar
SOUZA, M. F. d.	SOUZA, M. F. de
ARAÚJO, S.; BEZERRA, B.; NETO, A.	Verificar: "Neto" costuma ser sufixo geracional e integra o sobrenome (ex.: SOUSA NETO, A. F. de)

A última linha merece atenção especial: em nomes brasileiros, "Neto", "Filho", "Júnior" e "Sobrinho" são sufixos geracionais que acompanham o sobrenome e não podem ser tratados como sobrenome isolado. Convém conferir a forma completa dos autores no artigo do DocEng 2025 e ajustar tanto a entrada quanto todas as citações no texto.

[MODERADO] A6 — Entrada "Gemma Team et al." combina autor coletivo com "et al."

A entrada "Gemma Team et al. Gemma 4 Technical Report. 2026." apresenta três problemas simultâneos: o nome do autor coletivo não está em caixa alta, como exige a ABNT para autor-entidade e como a própria lista faz com ABECS, SPC BRASIL e SERASA EXPERIAN; a expressão "et al." não se aplica a autor coletivo, que já designa o conjunto; e a entrada aparece fora da ordenação alfabética estrita, entre EFRON e GERHARDT, por efeito da caixa baixa.

Correção: "GEMMA TEAM. Gemma 4 technical report. [S.l.], 2026. arXiv:2607.02770. DOI: ...", e citação no texto como "(Gemma Team, 2026)". A entrada "CHASE, H.; LANGCHAIN TEAM" apresenta a mesma mistura de autor pessoal e coletivo; convém decidir por um dos dois e manter.

[MODERADO] A7 — Referência canônica do MLflow ausente

Conforme o achado T7, a plataforma MLflow é apresentada na Seção 2.5.3 e usada em todo o Capítulo 5 como instrumento central de rastreamento, mas apoiada apenas em Treveil et al. (2020), que é um livro de introdução a MLOps e não a publicação de apresentação da plataforma. Sendo o MLflow um dos pilares da quarta contribuição declarada na Seção 6.2, convém acrescentar sua referência primária à lista e citá-la nas Seções 2.5.3, 4.4 e 5.7.

[LEVE] A8 — Ausência de data de acesso em treze referências eletrônicas — agrupado

A ABNT exige a indicação de data de acesso para todo documento consultado em meio eletrônico. Cinco referências da lista trazem corretamente o elemento (ABECS, 2024; BRASIL/CGU, 2024; PODER360, 2025; SERASA EXPERIAN, 2024; SPC BRASIL, 2024). As treze seguintes apresentam "Disponível em:" sem o "Acesso em:" correspondente e devem ser complementadas: AUER, DOLFI e STAAR (2024); BRASIL, Lei nº 13.709 (2018); CASELI e NUNES (2024); CHASE e LANGCHAIN TEAM (2024); DHINGRA et al. (2016); GEMMA TEAM (2026); GERHARDT e SILVEIRA (2009); GIL (2019); MATOS, CIFERRI e PARDO (2009); SANTOS (2022); TREVEIL et al. (2020); VASWANI et al. (2017); e ZHANG, ZHAO e LECUN (2015).

Conforme orientado, esta correção é de menor prioridade e está agrupada em um único item. Observação prática: para as entradas que já trazem DOI (Dhingra, Gemma Team, Vaswani, Zhang, Auer), a alternativa mais limpa é suprimir o "Disponível em:" e conservar apenas o DOI, que é identificador persistente e dispensa data de acesso — o que reduz de treze para oito o número de datas a acrescentar.

[LEVE] A9 — Referência fundadora do TF-IDF ausente

A Seção 2.2.3.1 apoia o TF-IDF exclusivamente em Rajaraman e Ullman (2011), que é um livro-texto e referência-base legítima, mas não a origem do conceito. Como o critério adotado no restante do Capítulo 2 é ancorar cada conceito também em sua referência fundadora — critério que o capítulo cumpre exemplarmente para Levenshtein, Breiman, Harel e Vaswani —, convém acrescentar a obra seminal de Spärck Jones (1972) sobre a especificidade de termos e, opcionalmente, Salton e Buckley (1988) sobre esquemas de ponderação em recuperação de informação.

[LEVE] A10 — Local de publicação ausente em entradas de anais

Algumas entradas de trabalhos de evento trazem "[S.l.: s.n.]" onde o local e o editor são conhecidos e recuperáveis — casos de ARMBRUST et al. (2021, CIDR), DEVLIN et al. (2019, NAACL-HLT), LEWIS et al. (2020, NeurIPS), WEI et al. (2022, NeurIPS), YAO et al. (2023, ICLR) e ZHANG, ZHAO e LECUN (2015, NeurIPS). O modelo, na Seção de modelos de referência, apresenta trabalhos de evento com local e editora ("New York: IEEE, 2000"). Convém completar as entradas em que a informação é obtível.

11. Escrita, estilo e padronização terminológica

11.1 Impessoalidade e registro

[POSITIVO] W1 — Impessoalidade rigorosamente mantida em todo o corpo do texto

A varredura em busca de primeira pessoa (formas de "nós", "nosso", "realizamos", "apresentamos", "propomos", "concluímos", "eu", "meu") não encontrou nenhuma ocorrência no corpo da monografia. As únicas incidências estão na dedicatória, nos agradecimentos e na declaração anexa — onde a primeira pessoa é apropriada e esperada. O texto usa sistematicamente construções impessoais e a voz passiva sintética ("adotou-se", "optou-se", "estabeleceu-se", "Ressalta-se", "Adianta-se ao leitor"). Nenhuma correção necessária.

[LEVE] W2 — Ocorrências pontuais de registro informal

Três construções destoam do registro científico e convém substituir:

Ocorrência	Onde	Substituição sugerida
"maquininhas de pagamento"	Seções 4.6 e 5.3.1	"terminais de captura" ou "adquirentes"
"Loga Métricas" (rótulo de aresta)	Figura 1	"Registra métricas"
"Upload da Fatura" (rótulo de nó)	Figura 1	"Envio da fatura"

Observe-se que a primeira ocorrência de "maquininhas", na Seção 1.1, está corretamente introduzida como glosa de um termo técnico ("terminais eletrônicos (maquininhas)"), o que é legítimo. O problema está nos usos posteriores, em que o termo coloquial aparece sozinho. O verbo "logar", na Figura 1, é anglicismo que não se justifica havendo "registrar".

[MODERADO] W3 — Redundância sistemática: os mesmos achados repetidos de quatro a oito vezes

A monografia é escrita em registro defensivo: cada ressalva é reapresentada integralmente sempre que o assunto correlato retorna, em vez de ser enunciada uma vez e referenciada depois. O levantamento abaixo indica o número de passagens em que cada achado é reapresentado por extenso:

Achado reapresentado	Ocorrências	Onde concentrar
Ramo vetorial 98% contra ramo LLM 21%	8	Seção 5.6.5, com remissão nas demais
Diferença de 23 a 25 p.p. entre validação cruzada e teste cego	7	Seção 5.6 e Tabela 8
Efeito da normalização léxica (+11 / -2 p.p.)	6	Seção 5.6.5
Indisponibilidade da ferramenta de busca na web	6	Seção 5.2 e uma remissão em 6.5
Hipótese central refutada por H1b	6	Seção 5.8
Tesseract aplicado fora de seu regime	5	Seção 5.5, abertura
Human-in-the-Loop simulado no teste cego	4	Seção 5.7
Taxonomia de 11 categorias em vez de 14	4	Seção 5.3.2

A intenção é evidentemente a de não induzir o leitor a erro, e nesse sentido a repetição é bem-intencionada. O efeito, porém, é o oposto do pretendido: quando toda afirmação vem acompanhada de três linhas de ressalva, o leitor deixa de distinguir as ressalvas importantes das acessórias, e o texto ganha volume sem ganhar informação. A recomendação é enunciar cada ressalva uma única vez, na seção a que pertence, e substituir as demais ocorrências por remissão curta do tipo "(com a ressalva da Seção 5.6.5)". A estimativa é de redução de quatro a seis páginas sem perda de conteúdo.

[MODERADO] W4 — Prolixidade concentrada em parênteses explicativos dentro de listas

Os itens 4 e 5 da Seção 5.6 contêm parênteses de seis a dez linhas que interrompem a leitura do item principal. O item 5, em particular, abre um parêntese para explicar a diferença entre a latência de 1,4 ms e a de 40 ms, o fecha, e abre outro para explicar por que 52% difere de 57,5% — totalizando mais de vinte linhas de aparte dentro de um único item de lista. O mesmo padrão ocorre na Seção 4.6, item 5, e na Seção 5.2, no item do modelo de raciocínio.

Sugestão: converter esses apartes em notas de rodapé ou deslocá-los para um parágrafo próprio após a lista. O conteúdo é pertinente e não deve ser eliminado; o problema é exclusivamente de posicionamento.

11.2 Estrangeirismos

Termos estrangeiros devem aparecer em itálico. A verificação foi feita palavra a palavra sobre as 121 páginas do PDF, comparando a fonte aplicada a cada ocorrência. O resultado mostra que a regra é conhecida e aplicada, mas de forma inconsistente.

[MODERADO] W5 — Itálico aplicado de forma inconsistente ao mesmo termo

Os termos abaixo aparecem ora em itálico, ora em redondo, no mesmo trabalho:

Termo	Em itálico	Em redondo	Padrão recomendado
recall	2	15	Adotar "revocação" (já glosado na Seção 2.2.5) e reservar o itálico para as poucas ocorrências em que o termo inglês for indispensável
embedding / embeddings	15	9	Itálico em todas
marketplace / marketplaces	12	9	Itálico em todas
gateway / gateways	10	2	Itálico em todas
prompt / prompts	7	5	Itálico em todas
drift	4	5	Itálico em todas
tokens	4	3	Itálico em todas
e-commerce	2	3	Itálico em todas (ou "comércio eletrônico")
web	2	12	Redondo (termo incorporado ao português)
hardware	6	3	Redondo em todas (dicionarizado em português)
bootstrap	7	1	Itálico em todas
layout	2	2	Substituir por "leiaute", já usado 29 vezes
statecharts	1	1	Itálico em todas

Além desses, aparecem sempre em redondo e deveriam estar em itálico: dataset e datasets (5 ocorrências), clusters, endpoints, pipeline, threads, online, upload, softmax e token. Já software (5 ocorrências em redondo) e hardware estão dicionarizados em português e podem permanecer em redondo — desde que a escolha seja uniforme, o que hoje não ocorre para hardware.

[MODERADO] W6 — Substituição de estrangeirismos por equivalentes em português

Vários termos têm equivalente natural em português e ganham em clareza com a substituição. A monografia já faz isso bem em muitos casos, o que torna a inconsistência mais visível:

Termo em inglês	Equivalente sugerido	Observação
recall	revocação	Já glosado uma vez na Seção 2.2.5; adotar em todo o texto
Fine-Tuning	ajuste fino	7 ocorrências em inglês contra 5 em português; padronizar
on-premise (Seção 4.7)	em infraestrutura local	Expressão já usada em outras seções
endpoints (Seção 4.7)	pontos de acesso	—
parsers (Seção 4.8)	analísadores	—
wrapper (Seção 5.6)	invólucro / adaptador	—
round-trip (Seções 5.2, 5.6)	ida e volta	—
benchmark (Seção 5.3.2)	conjunto de referência	—
warmup ratio / weight decay	proporção de aquecimento / decaimento de pesos	Tabela 3
SOTA (Tabela 6)	estado da arte	Ver também o achado V8

Alguns termos devem permanecer em inglês por ausência de uso natural em português e por serem nomes consagrados de técnicas ou produtos: Data Lakehouse, Human-in-the-Loop (ainda que "humano no ciclo", já usado no Quadro 3, seja boa alternativa), Chain-of-Thought (a monografia acertadamente já usa "cadeia de pensamento"), TF-IDF, MLOps, bootstrap, LangGraph, pgvector e os nomes de bibliotecas. O critério é o uso corrente na literatura brasileira da área.

[POSITIVO] W7 — Boas opções de tradução já adotadas

A monografia faz escolhas acertadas que devem ser preservadas: "leiaute" em vez de layout (29 ocorrências), "linha de base (baseline)", "comércio eletrônico (e-commerce)", "código aberto (Open Source)", "compartimentos de armazenamento" para buckets, "execuções aninhadas" para nested runs, "cadeia de pensamento" para Chain-of-Thought, "agrupamento por k-médias", "chamada de ferramenta" para tool calling, "esteira" para pipeline e "Conjuntos de Dados (Datasets)". O padrão de glosar o termo em português com o original entre parênteses na primeira ocorrência está correto e é o que se recomenda generalizar.

11.3 Padronização terminológica e numérica

[LEVE] W8 — Variantes terminológicas do mesmo conceito

Convém fixar uma forma para cada conceito:

- "pós-OCR" (7 ocorrências) e "Pós-OCR" (7) — padronizar a caixa conforme a posição na frase.
- "Human-in-the-Loop" (15) e "HITL" (3) — definir a sigla na primeira ocorrência, inseri-la na lista de abreviaturas e então usá-la.
- "p.p." (30) e "pontos percentuais" (9) — usar a forma por extenso na primeira ocorrência de cada capítulo e a sigla nas demais.
- "teste-cego" (48 ocorrências) — em português, "teste cego" não leva hífen; a locução adjetiva não é composta. Corrigir para "teste cego" em todas as ocorrências, inclusive em legendas de tabelas e figuras.

[LEVE] W9 — Padronização de números e expoentes

A monografia está, no geral, correta: vírgula decimal, ponto de milhar e notação científica adequada ("5 × 10⁻⁴" na Tabela 3). Restam quatro ajustes:

- Tabela 4: as razões estão grafadas como "9,2x", "8,4x", "1,6x" com a letra "x". Usar o sinal de multiplicação ("9,2×") ou a forma por extenso ("9,2 vezes").

- Seção 6.6, item 3: "escala de 0.9B a 2B parâmetros" mistura ponto decimal inglês e abreviação inglesa. Corrigir para "escala de 0,9 a 2 bilhões de parâmetros".
- Conferir se a estatística qui-quadrado aparece com expoente sobrescrito (χ^2) e não como " χ^2 " na Seção 5.6.
- Tabela 6: uniformizar o número de casas decimais na coluna de latência (ver achado V14).

[MODERADO] W10 — Dezesesseis siglas usadas no texto e ausentes da lista de abreviaturas

A lista de abreviaturas e siglas contempla 38 entradas, mas deixa de fora siglas efetivamente empregadas — algumas com frequência elevada:

Sigla	Ocorrências	Significado a registrar
CSV	13	Comma-Separated Values (valores separados por vírgula)
RSL	8	Revisão Sistemática da Literatura — ver o achado R1, que recomenda renomear
SROIE	7	Scanned Receipts OCR and Information Extraction
HITL	3	Human-in-the-Loop (humano no ciclo)
DPI, CUDA, CVV, CNPJ, CPF	2 ou menos cada	Dots Per Inch; Compute Unified Device Architecture; Card Verification Value; Cadastro Nacional da Pessoa Jurídica; Cadastro de Pessoas Físicas
ANN, IVFFlat, CoT, QA, EMR, ORM, LAN	1 cada	Approximate Nearest Neighbor; Inverted File with Flat compression; Chain-of-Thought; Quality Assessment; Exact Match Rate; Object-Relational Mapping; Local Area Network

Chama atenção que CSV apareça 13 vezes sem constar da lista, enquanto OFX, JSON e PDF — de uso muito menos frequente — estão listados. Registre-se ainda que a lista contempla "TP — Verdadeiro Positivo" mas não FP e FN, que aparecem nas Equações 2.5 e 2.6 e na Seção 5.4.2.

[LEVE] W11 — Quebras de linha no interior de identificadores e caminhos

Seis identificadores em fonte monoespçada são partidos ao fim da linha sem hífen nem recurso tipográfico, o que os torna ambíguos para o leitor e inutilizáveis para cópia: "datala | ke-bronze-ingestao-topic" (Seção 4.4), "noteb | ooks/experimentos/" (Seção 4.8), "faturas_go | v.csv" (fonte da Tabela 1), "r | esultados/predicoes__*.csv" (Seção 5.4.3), "conso | lidado_modelos.csv" (fonte da Tabela 8) e "predicoes__*.c | sv" (fonte da Tabela 9). Em LaTeX, envolver esses trechos com `\path` ou `\url`, ou permitir quebras apenas em pontos de separação, resolve o problema.

[LEVE] W12 — Remissão cruzada imprecisa na Seção 2.3.2

O texto afirma que ferramentas de processamento documental empregam visão computacional "apenas para a Análise de Leiaute de Documentos (Seção 2.3)". A análise de leiaute é tratada na Seção 2.3.1; a Seção 2.3 é a seção-mãe, mais ampla. Corrigir a remissão para 2.3.1. Ver também o achado V15 para duas autorreferências na Seção 5.6.

[POSITIVO] W13 — Clareza técnica e precisão terminológica

Apesar dos ajustes apontados, a qualidade técnica da escrita é alta. Conceitos difíceis são explicados com precisão e sem simplificação indevida — a distinção entre CER e WER e a explicação de por que o WER pode ultrapassar 100% (nota da Tabela 5), a diferença entre acurácia global e F1-Macro sob desbalanceamento (Seção 5.6.1), o funcionamento do índice IVFFlat e o compromisso entre número de listas, velocidade e revocação (Seção 2.2.3.2), e a advertência de que o par acurácia/F1-Macro do subconjunto Nubank "mede propriedades diferentes do mesmo recorte" (Seção 5.6.2). Essa última passagem, em particular, previne uma leitura equivocada que a maioria dos trabalhos não anteciparia.

12. Legendas, equações e elementos gráficos (ABNT)

[POSITIVO] G1 — Posicionamento de legendas e fontes conforme a norma

O modelo determina que a identificação de ilustrações apareça na parte superior, precedida da palavra designativa e do número de ordem, e que a fonte apareça na parte inferior, ambas em corpo menor que o do texto. Todas as 8 figuras, 13 tabelas e 4 quadros da monografia seguem esse padrão sem exceção, com fonte declarada e corpo reduzido. Os elementos estão também inseridos próximos ao trecho a que se referem, e as listas de figuras, tabelas e quadros reproduzem a ordem de aparição com as páginas corretas.

[POSITIVO] G2 — Distinção correta entre tabela e quadro, com justificativa explícita

A monografia distingue tabela (dados estatísticos) de quadro (conteúdo qualitativo) e, na Seção 3.7, justifica a escolha no texto: "Por conter exclusivamente conteúdo qualitativo (sem dados estatísticos), o elemento é apresentado como Quadro, e não como Tabela, em conformidade com a distinção normativa da ABNT". Explicitar o critério em vez de apenas aplicá-lo é um cuidado que a maioria dos trabalhos omite, e que demonstra domínio da norma.

[MODERADO] G3 — Concordância de gênero invertida nas fontes de tabelas e quadros

A expressão "Elaborado/Elaborada pelo autor" deve concordar com o elemento que a antecede: tabela é substantivo feminino, quadro é masculino. A monografia inverte quase sistematicamente:

Elemento	Como está	Correção
Tabelas 1 a 12	"Elaborado pelo autor"	"Elaborada pelo autor"
Tabela 13	"Elaborada pelo autor"	Correto — manter
Quadro 2	"Elaborada pelo autor"	"Elaborado pelo autor"
Quadros 1, 3 e 4	"Elaborado pelo autor"	Correto — manter

Ou seja: os dois únicos elementos com a concordância correta quanto ao gênero são precisamente os dois que destoam do padrão adotado nos demais. Note-se ainda que o Quadro 2 e a Tabela 13 omitem o ano "(2026)" presente em todas as outras fontes. Convém padronizar para "Fonte: Elaborada pelo autor (2026)" nas tabelas e "Fonte: Elaborado pelo autor (2026)" nos quadros.

[POSITIVO] G4 — Equações destacadas e numeradas corretamente

O modelo determina que equações e fórmulas apareçam destacadas no texto. As onze equações da monografia estão centralizadas, destacadas do corpo do texto e numeradas sequencialmente por capítulo, com o indicativo entre parênteses alinhado à direita — (2.1) a (2.11) e (5.1) a (5.5). A ABNT não prevê legenda para equações no formato de figuras e tabelas; o que se exige é o destaque e a numeração, e ambos estão atendidos.

[MODERADO] G5 — Figura 6 combina dois painéis com eixos incomensuráveis

A Figura 6 dispõe lado a lado um painel de desempenho preditivo (escala linear, em porcentagem) e um painel de latência (escala logarítmica, em milissegundos), sob um único número de figura. A nota explicativa é cuidadosa e adverte que a legenda do painel esquerdo não se aplica ao direito e que não há relação numérica entre os eixos — o que atenua, mas não elimina, o problema: o leitor que consulte a figura sem ler a nota comparará visualmente barras que não são comparáveis.

Recomenda-se desmembrar em Figura 6 (desempenho preditivo) e Figura 7 (latência por arquitetura), renumerando as subsequentes. A justificativa atual — "dispostos lado a lado por brevidade" — não compensa o risco de leitura equivocada em um elemento que sintetiza o resultado central do capítulo.

[LEVE] G6 — Quadro 4 contém dados numéricos

O Quadro 4 traz as colunas "Lev. Doc." e "Lev. Tess." com distâncias de Levenshtein — dados numéricos, portanto — em um elemento classificado como quadro. Como o conteúdo predominante é textual (amostras de transcrição lado a lado) e o número cumpre função ilustrativa, a classificação é defensável; registra-se apenas que, dado o rigor com que a distinção é justificada na Seção 3.7, convém acrescentar nota análoga no Quadro 4 explicando por que o elemento permanece quadro apesar das colunas numéricas.

[LEVE] G7 — Pontuação final inconsistente nas legendas

Todas as legendas de tabelas, quadros e figuras encerram com ponto final, exceto a da Tabela 13 ("Fluxo de seleção dos estudos localizados por busca direta (Scopus e IEEE Xplore)"). Uniformizar.

[LEVE] G8 — Figuras 3, 4, 5, 7 e 8 sem descrição textual dos achados no corpo

As Seções 5.5.2 e 5.7 descrevem em prosa o que as figuras mostram, o que é correto. A Figura 7 (matriz de confusão do agente híbrido) e a Figura 8 (F1 por categoria do melhor modelo), porém, são apenas inseridas, sem que o texto aponte o que o leitor deve observar nelas. A matriz de confusão, em particular, é o instrumento natural para sustentar a Resposta a Q3 sobre as naturezas de erro; hoje essa resposta é dada sem remissão à figura que a evidencia. Sugere-se acrescentar dois ou três períodos comentando os agrupamentos de confusão mais frequentes visíveis na Figura 7 e remeter a ela na Seção 5.8.

13. Revisão geral: avaliação sintética

13.1 A monografia descreve claramente o problema investigado?

Sim, e com qualidade acima da média. O problema é enunciado em formulação fechada e destacada no corpo da Seção 1.1 — a categorização automática, precisa e escalável de transações de cartão de crédito a partir de descrições curtas, heterogêneas, ruidosas e despadronizadas —, decomposto em cinco obstáculos nomeados e ilustrado com amostras reais anonimizadas no Quadro 1. A articulação entre a formulação abstrata e a evidência concreta permite que o leitor compreenda a dificuldade sem conhecimento prévio do domínio. O único reparo é de ordem terminológica e está registrado no achado E7: o título da monografia não reflete essa clareza, por sugerir que o objeto da extração e da classificação são as faturas, e não as transações nelas contidas.

13.2 O problema de pesquisa é relevante para a área de Computação?

Sim. A relevância opera em três níveis distintos, o que é incomum. No nível aplicado, trata-se de um problema de impacto socioeconômico direto, dimensionado com dados setoriais na Seção 1.1. No nível técnico, o problema integra visão computacional, processamento de linguagem natural, recuperação de informação vetorial, engenharia de agentes e operações de aprendizado de máquina sob restrição severa de recursos — uma combinação que expõe os limites reais de cada componente.

No nível metodológico, porém, está a contribuição de maior alcance, e ela transcende o domínio de aplicação: a quantificação de 23 a 25 pontos percentuais de diferença entre a validação cruzada convencional e o teste cego por estabelecimento disjunto. Esse achado vale para toda a literatura de categorização de transações e sugere que resultados reportados sob partição aleatória nessa área podem estar superestimados na mesma ordem de grandeza. Um trabalho de MBA que produz um achado transferível dessa natureza excede o esperado para o nível, e recomenda-se que o autor o destaque na defesa — e, conforme o achado N7, que o promova a contribuição própria na Seção 6.2.

13.3 A monografia apresenta o levantamento do estado da arte?

Sim. Há um capítulo dedicado, com questões de revisão próprias, instrumento de extração de dados aplicado uniformemente, avaliação de qualidade dos estudos, análise crítica individual, quadro comparativo com matriz de características e posicionamento da proposta frente aos trabalhos analisados. O protocolo — bases consultadas, strings booleanas em três níveis de especificidade, critérios de inclusão e exclusão, snowballing com referência metodológica e fluxo quantitativo — está corretamente detalhado em apêndice, como exigido.

Duas ressalvas, ambas já registradas como achados críticos, qualificam essa resposta. A primeira: o trabalho mais fortemente relacionado de toda a bibliografia da monografia — Ta, Saad e Oh (2023), sobre classificação de transações de Open Banking — é citado no Capítulo 2 e não figura no Capítulo 3 nem no Quadro 3 (achado R2). A segunda: apenas três dos seis estudos analisados situam-se na janela dos últimos cinco anos (achado R5). Corrigidos esses dois pontos, o levantamento fica adequado ao nível.

13.4 A monografia apresenta revisão sistemática da literatura?

Não, apesar de assim se declarar. Este é o ponto de maior exposição do trabalho e está detalhado no achado R1. A Seção 3.1 afirma seguir "um protocolo de revisão sistemática" e as questões da revisão são nomeadas RSL-1 a RSL-4, mas o próprio Apêndice A informa que a leitura integral não foi conduzida como etapa isolada e sistematicamente registrada, e que dos 197 candidatos aprovados na triagem nenhum passou por avaliação formal um a um, tendo a seleção final seguido critério de centralidade. O funil da Tabela 13 reforça a incompatibilidade: 205 registros triados, 8 excluídos, 197 aptos e 1 utilizado (achado R3).

Convém sublinhar que a revisão sistemática da literatura é recomendação opcional nesta modalidade de trabalho, e sua ausência não constitui falha. O que constitui falha é o descompasso entre o rótulo e o procedimento. Duas saídas são possíveis. A primeira, de menor custo e recomendada: renomear para "levantamento estruturado da literatura" ou "revisão de escopo", ajustar as siglas das questões e substituir a Tabela 13 por um relato honesto do processo efetivamente conduzido. A segunda, de maior custo e maior retorno acadêmico: converter o levantamento em revisão sistemática de fato, aplicando triagem em duas etapas com decisões registradas por estudo, o que também resolveria os achados R2, R4 e R5 de uma só vez. Cabe ao autor, com o orientador, avaliar se há prazo para a segunda.

13.5 A monografia apresenta os principais conceitos básicos do problema investigado?

Sim. O Capítulo 2 cobre os quatro pilares instrumentais à pesquisa — mineração de textos e processamento de linguagem natural, visão computacional e inteligência de documentos, arquiteturas neurais e agentes, e engenharia de dados com MLOps —, cada conceito ancorado em citação pertinente, com a maioria remetendo à referência fundadora do assunto (achado T1). A formalização matemática é adequada e correta (achado T2), e a distinção conceitual entre reconhecimento óptico e extração de fluxo nativo, construída na Seção 2.3.2, é o que torna interpretável todo o experimento da Seção 5.5 (achado T3).

O capítulo evita corretamente a descrição de conceitos amplamente conhecidos: não há seções gerais sobre bancos de dados, aprendizado de máquina ou inteligência artificial, e os conceitos apresentados estão todos vinculados ao objeto pesquisado. As exceções são pontuais e estão registradas nos achados T4, T5 e T6: Confident Learning é nomeado e nunca utilizado; a Equação 2.8 é definida e nunca reportada; e os fenômenos de desvio estatístico são fundamentados e integram uma questão de pesquisa, mas nunca são mensurados. Retirados ou reaproveitados esses três elementos, o capítulo fica integralmente alinhado ao critério de descrever apenas o que a pesquisa efetivamente usa.

14. Proposta de resumo e abstract

O resumo atual é bom: cobre objetivos, método, resultados e conclusões, está em parágrafo único com 357 palavras e traz os números certos. As alterações propostas abaixo são cirúrgicas e atendem a quatro finalidades: (i) incorporar a ressalva de que o resultado de destaque é obtido sem a etapa de normalização léxica, hoje presente no corpo e ausente do resumo (achado V5); (ii) incorporar o resultado do teste de McNemar, que qualifica a comparação entre as duas melhores arquiteturas e hoje não aparece; (iii) padronizar a diferença entre validação cruzada e teste cego como 23 a 25 pontos percentuais, uniformizando-a com o Capítulo 5; e (iv) substituir estrangeirismos e ajustar a terminologia conforme os achados W6 e W8. As alterações estão assinaladas em *itálico*.

14.1 Resumo revisado

LIMA, L. H. M. S. Solução para extração e classificação em faturas de cartão de crédito utilizando ferramentas de inteligência artificial. 2026. 121 f. Monografia (MBA em Inteligência Artificial e Big Data) — Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos, 2026.

Descrições de transações em faturas de cartão de crédito são curtas, despadronizadas e ruidosas: trazem abreviações truncadas, prefixos de intermediadores de pagamento e erros introduzidos na leitura de documentos. Esse ruído inviabiliza a categorização automática de despesas e, com ela, o planejamento orçamentário pessoal. Esta monografia concebeu, implementou e avaliou experimentalmente uma solução computacional de ponta a ponta para a extração, o saneamento e a classificação automática de despesas no contexto brasileiro, executável em infraestrutura local e aderente à Lei Geral de Proteção de Dados Pessoais. A solução combina extração documental com preservação de *leiaute* tabular, rotinas determinísticas de normalização léxica e um agente orquestrado em grafo de estados que articula busca vetorial densa, raciocínio com um grande modelo de linguagem local, ferramentas autônomas de enriquecimento e confirmação humana em casos de baixa confiança, sobre uma infraestrutura de Data Lakehouse com rastreamento de experimentos. A avaliação empregou 699 transações de faturas reais, auditadas contra os arquivos oficiais da instituição emissora, para medir a qualidade da extração, e um conjunto de 1.660 transações rotuladas em 11 categorias, para medir o desempenho preditivo de cinco arquiteturas sob *teste cego* com estabelecimentos disjuntos entre treino e teste. A extração com preservação de *leiaute* reduziu a taxa de erro de caracteres de 52,82% para 5,72% e elevou o casamento exato de 3,3% para 86,2%. Na classificação, a representação esparsa por *n*-gramas de caractere associada a florestas aleatórias obteve o melhor F1-Macro (69,3%, *em configuração sem a etapa de normalização léxica*), *sem diferença estatisticamente significativa frente ao Naive Bayes* (63,6%; *teste de McNemar, $p = 0,059$*); a melhor acurácia global foi de 88,3%. Nenhuma arquitetura alcançou o limiar de 85% de F1-Macro estabelecido na hipótese central, que é, portanto, refutada na métrica primária. O *achado de maior alcance metodológico* é a diferença de 23 a 25 pontos percentuais entre a validação cruzada convencional e o *teste cego* por estabelecimento, que quantifica quanto do desempenho aparente desse tipo de classificador decorre da memorização de comércios já observados. Conclui-se que a esteira proposta é funcionalmente viável e auditável sob restrições de hardware local, e que sua eficácia preditiva permanece condicionada ao volume e à cobertura do acervo rotulado.

Palavras-chave: Classificação de transações financeiras. Processamento de linguagem natural. Geração aumentada por recuperação. Reconhecimento óptico de caracteres. Agentes inteligentes.

Extensão: 362 palavras — dentro do intervalo de 150 a 500 exigido pelo modelo, em parágrafo único.

14.2 Abstract revisado

LIMA, L. H. M. S. Solution for credit card statement extraction and classification using artificial intelligence tools. 2026. 121 f. Monograph (MBA in Artificial Intelligence and Big Data) — Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos, 2026.

Transaction descriptions in credit card statements are short, non-standardized and noisy: they contain truncated abbreviations, payment intermediary prefixes, and errors introduced during document reading. This noise prevents the automatic categorization of expenses and, with it, personal budget planning. This monograph designed, implemented, and experimentally evaluated an end-to-end computational solution for the extraction, sanitization, and automatic classification of expenses in the Brazilian context, executable on local infrastructure and compliant with the Brazilian General Data Protection Law. The solution combines document extraction with tabular layout preservation, deterministic lexical normalization routines, and an agent orchestrated as a state graph that articulates dense vector retrieval, reasoning with a local large language model, autonomous enrichment tools, and human confirmation for low-confidence cases, on a Data Lakehouse infrastructure with experiment tracking. The evaluation used 699 transactions from real statements, audited against the issuing institution's official files, to measure extraction quality, and a set of 1,660 transactions labeled into 11 categories, to measure the predictive performance of five architectures under a merchant-disjoint blind test. Layout-preserving extraction reduced the character error rate from 52.82% to 5.72% and raised the exact match rate from 3.3% to 86.2%. In classification, the sparse representation based on character n-grams combined with random forests achieved the best Macro-F1 (69.3%, *in a configuration without the lexical normalization stage*), with no statistically significant difference from Naive Bayes (63.6%; McNemar's test, $p = 0.059$); the best overall accuracy was 88.3%. No architecture reached the 85% Macro-F1 threshold established in the central hypothesis, which is therefore refuted on the primary metric. The finding of widest methodological reach is the gap of 23 to 25 percentage points between conventional cross-validation and the merchant-disjoint blind test, which quantifies how much of the apparent performance of this class of classifier stems from memorizing previously observed merchants. It is concluded that the proposed pipeline is functionally viable and auditable under local hardware constraints, and that its predictive effectiveness remains conditioned on the volume and coverage of the labeled corpus.

Keywords: Financial transaction classification. Natural language processing. Retrieval-augmented generation. Optical character recognition. Intelligent agents.

Extensão: 333 palavras. Observação de tradução: a expressão "teste-cego com estabelecimentos disjuntos entre treino e teste" foi condensada em "merchant-disjoint blind test", que é a formulação corrente na literatura em inglês e evita a construção literal. "Random Forest" foi vertido como "random forests" em minúsculas, por se tratar de nome de método e não de produto.

15. Conclusões sugeridas para destaque no Capítulo 6

A Seção 6.4 já apresenta sete conclusões bem formuladas. As observações abaixo propõem: a reformulação de uma delas em função do achado V2; e quatro conclusões adicionais que o conteúdo da monografia sustenta e que hoje não estão explicitadas. Nenhuma delas duplica os itens da lista de trabalhos futuros.

15.1 Conclusão a reformular

Conclusão 3 — atual:

Em regime de baixo volume rotulado, representações esparsas com n-gramas de caractere superaram embeddings densos multilíngues, ajuste fino de modelo no nível de byte e um agente com grande modelo de linguagem local.

Conclusão 3 — proposta:

Em regime de baixo volume rotulado, uma representação esparsa por n-gramas de caractere com classificador clássico iguala o desempenho de embeddings densos multilíngues (69,3% contra 66,8% de F1-Macro, com intervalos de confiança sobrepostos) a uma fração do custo computacional, e supera com folga tanto o ajuste fino de um modelo no nível de byte (48,3%) quanto um agente apoiado em grande modelo de linguagem local (60,0%). Sofisticação arquitetural não compensa escassez de dados rotulados — mas, entre representação esparsa e densa, o que as separa neste regime é o custo, não a eficácia.

15.2 Conclusões adicionais que o trabalho sustenta

Conclusão A — sobre a proveniência dos rótulos como fator de desempenho

O desempenho de um classificador de transações não é uniforme entre subconjuntos rotulados por métodos distintos: no acervo avaliado, o F1-Macro cai de 82,4% para 39,4% no melhor modelo quando se passa do subconjunto rotulado por dicionário léxico para o rotulado pela categoria nativa do emissor, e a queda ocorre em todas as cinco arquiteturas, inclusive nas que não compartilham característica alguma com a regra de rotulagem. Reportar uma métrica agregada sobre acervos de rotulagem heterogênea oculta variação dessa magnitude, e a proveniência do rótulo deveria ser tratada como variável de estratificação obrigatória nesse tipo de avaliação.

Sustentação: Seção 5.6.3 e Tabela 10. Esta é, no julgamento desta revisão, a segunda contribuição metodológica mais forte do trabalho, e hoje aparece apenas como limitação (Seção 6.5, item 3), não como conclusão. A diferença é relevante: como limitação, é uma fragilidade do estudo; como conclusão, é um achado sobre a prática de avaliação na área.

Conclusão B — sobre a incomparabilidade entre acurácia e F1-Macro em recortes desbalanceados

Em taxonomias de despesa com cauda longa, acurácia global e F1-Macro medem propriedades distintas e podem apontar em direções opostas sobre o mesmo recorte: no subconjunto do Nubank, quatro arquiteturas atingem 98,0% de acurácia e 36,2% de F1-Macro simultaneamente, porque as categorias ausentes do recorte contam como falha total na média macro. Daí decorre que o relato isolado de qualquer uma das duas métricas é insuficiente para caracterizar um classificador de despesas, e que a escolha da métrica primária deve ser declarada e justificada antes da avaliação, não depois.

Sustentação: Seções 5.6.1 e 5.6.2 e Tabela 9 — condicionada à verificação do achado V4. A monografia já declara e justifica a métrica primária antecipadamente (Seção 5.4.2), o que torna a conclusão uma observação sobre a própria prática adotada, e não apenas sobre os dados.

Conclusão C — sobre o custo de descartar a camada de texto nativa

Para documentos financeiros com camada de texto digitalmente codificada, submeter o arquivo a rasterização seguida de reconhecimento óptico multiplica por 9,2 a taxa de erro de caracteres e reduz o casamento exato de 86,2% para 3,3%. Como parcela expressiva das faturas emitidas no Brasil é nativa

digital, a decisão de arquitetura mais consequente em uma esteira de categorização de despesas não está no classificador, e sim na etapa de ingestão: nenhum saneamento léxico posterior recupera informação destruída na transcrição.

Sustentação: Seções 5.5 e 5.5.3, Tabelas 4 e 5, Quadro 4. A conclusão 1 da Seção 6.4 já enuncia parte disso; a formulação acima acrescenta a implicação prática — a decisão de projeto está na ingestão, não na modelagem — e a quantifica.

Conclusão D — sobre o efeito colateral do conservadorismo em classificação financeira

Diretrizes anti-alucinação aplicadas a modelos de linguagem em tarefas de classificação podem converter-se em abstenção sistemática: no agente avaliado, o ramo de raciocínio rotulou como despesa diversa nomes cuja categoria era lexicalmente evidente, resultando em acurácia condicional de 21% contra 98% do ramo de recuperação vetorial. Em sistemas de classificação financeira, portanto, o conservadorismo não é gratuito — ele tem um custo mensurável em recall efetivo, e o ponto de equilíbrio entre abstenção e erro deve ser calibrado explicitamente, e não herdado de convenções de segurança de outros domínios.

Sustentação: Seções 5.6, 5.6.5 e 5.8. A conclusão 6 da Seção 6.4 já registra o fenômeno; a formulação acima o generaliza em recomendação de projeto e conecta o efeito à métrica. Deve ser lida em conjunto com os achados S7 e V9, que advertem que a causa (modelo, prompt ou ausência da ferramenta de busca) não foi isolada experimentalmente — ressalva que convém incorporar à própria conclusão.

16. Plano de ação priorizado

A ordenação abaixo considera o impacto de cada correção sobre a qualidade do trabalho e o esforço estimado. Nenhum item exige novos experimentos, com exceção facultativa de A3.

16.1 Bloco A — antes do depósito (crítico)

Id	Ação	Achado	Esforço
A1	Reanalisar a comparação esparsa versus denso em melhor configuração; acrescentar IC e teste de McNemar para o RAG com normalização; reescrever a Resposta a Q1, o fecho da Seção 5.9 e a conclusão 3.	V2, N6	Alto
A2	Verificar os arquivos de predição do subconjunto Nubank e explicar ou corrigir a coincidência de métricas da Tabela 9.	V4	Médio
A3	Renomear o Capítulo 3 e o Apêndice A para "levantamento estruturado" / "revisão de escopo"; renomear RSL-1 a RSL-4; substituir a Tabela 13 por relato fiel do processo.	R1, R3	Médio
A4	Incluir Ta, Saad e Oh (2023) como Seção 3.6.6, no Quadro 2 e no Quadro 3; ajustar as contagens do Apêndice A.	R2	Médio
A5	Conferir o volume efetivo de treino por arquitetura no MLflow e uniformizar a redação nas Seções 5.4.2, 5.6 e 6.5.	V3	Baixo

16.2 Bloco B — fortemente recomendado

Id	Ação	Achado	Esforço
B1	Padronizar todos os títulos de seção em capitalização de sentença, conforme o modelo; ajustar título da obra, cabeçalhos de resumo e abstract e palavras-chave.	E5, E6, E8	Baixo
B2	Adotar o resumo e o abstract revisados da Seção 14 deste relatório.	V5	Baixo
B3	Reescrever a hipótese central conservando apenas as cláusulas falsificáveis e remetendo LGPD e execução local aos requisitos não funcionais.	S4	Baixo
B4	Reformular a conclusão 5 (Seção 6.4) e acrescentar análise crítica do prompt ao Apêndice D.	S7, V9	Baixo
B5	Eliminar a redundância sistemática: enunciar cada ressalva uma vez e substituir as repetições por remissão. Redução estimada de 4 a 6 páginas.	W3, W4	Médio
B6	Corrigir "et al." para obras de três autores; corrigir partículas de sobrenome; normalizar a entrada Gemma Team; acrescentar a referência canônica do MLflow.	A4, A5, A6, A7	Baixo
B7	Corrigir a concordância "Elaborado/Elaborada" em todas as tabelas e no Quadro 2.	G3	Baixo
B8	Declarar a escala ternária no Quadro 2 e reavaliar QA1 de Santos (2022).	R6, R7	Baixo
B9	Rotular cada estudo do Capítulo 3 como fortemente ou fracamente relacionado e declarar a escassez como evidência da lacuna na Seção 3.8.	R4	Baixo

Id	Ação	Achado	Esforço
B10	Criar bloco de consolidação na Seção 6.6 com os três itens hoje enterrados na Seção 6.5.	N5	Baixo
B11	Retirar Confident Learning da Seção 2.5.2; decidir sobre a Equação 2.8; reformular Q5 ou declarar a ausência de medição de desvio.	T4, T5, T6	Médio
B12	Criar seção de fonte de dados e amostragem no Capítulo 4; substituir o rótulo "SOTA Neural" na Tabela 6; reorganizar a Tabela 12.	S5, V6, V8	Baixo
B13	Uniformizar o itálico dos estrangeirismos e adotar os equivalentes em português indicados.	W5, W6	Médio
B14	Desmembrar a Figura 6 em duas figuras e comentar no texto as Figuras 7 e 8.	G5, G8	Baixo

16.3 Bloco C — ajustes finos

Id	Ação	Achado	Esforço
C1	Acrescentar data de acesso às treze referências eletrônicas, ou suprimir o "Disponível em" nas que já trazem DOI.	A8	Baixo
C2	Acrescentar as dezesseis siglas faltantes à lista de abreviaturas.	W10	Baixo
C3	Corrigir "teste-cego" para "teste cego"; padronizar pós-OCR, HITL, p.p. e ajuste fino.	W8	Baixo
C4	Corrigir quebras de linha em identificadores e caminhos; corrigir as remissões das Seções 2.3.2 e 5.6.	W11, W12, V15	Baixo
C5	Padronizar notação de razões ("9,2×"), decimais em bilhões e casas decimais na coluna de latência.	W9, V14	Baixo
C6	Substituir ocorrências de registro informal ("maquininhas", "Loga", "Upload") e revisar a descrição do acervo como período contínuo.	W2, V16	Baixo
C7	Enumerar as seções nas considerações iniciais dos Capítulos 2 e 5; enxugar a Seção 1.3; realocar a antecipação do resultado da Seção 1.4.	E3, I10, I12	Baixo
C8	Acrescentar as conclusões A a D da Seção 15 deste relatório à Seção 6.4 e promover a contribuição metodológica na Seção 6.2.	N7	Baixo
C9	Completar local e editora nas entradas de anais; acrescentar a referência fundadora do TF-IDF; definir d_k e x_i nas Equações 2.11 e 2.3.	A9, A10, T9	Baixo
C10	Uniformizar pontuação final das legendas; acrescentar nota justificando o Quadro 4; revisar rótulos do Quadro 3.	G6, G7, R11	Baixo

17. Parecer de encerramento

A monografia está apta a seguir para defesa após as correções do Bloco A. A estrutura de capítulos é conforme, o problema é bem colocado e relevante, a fundamentação teórica é instrumental e bem referenciada, a solução é coerente e efetivamente implementada, e o protocolo experimental supera o padrão da modalidade

— teste cego por estabelecimento, intervalos de confiança por reamostragem, teste de significância pareado, estudo de ablação, análise por emissor e por proveniência de rótulo, e rastreamento integral dos experimentos.

Merece registro específico a postura do autor diante dos próprios resultados. A hipótese central é refutada e a refutação é conduzida sem atenuação; a diferença que favorece o melhor modelo é declarada estatisticamente não significativa; o resultado de destaque é qualificado no corpo do texto como dependente da omissão de um componente da própria solução; o Human-in-the-Loop é declarado simulado; e onze limitações são catalogadas, várias das quais poderiam simplesmente não ter sido mencionadas. Essa postura é a principal qualidade do trabalho e deve ser preservada integralmente na revisão — inclusive porque é ela que torna detectáveis, e portanto corrigíveis, os problemas apontados neste relatório.

Os cinco achados críticos são, sem exceção, problemas de leitura dos resultados obtidos e de consistência interna do texto, não de condução da pesquisa. Nenhum deles exige novo experimento; todos se resolvem com reanálise das planilhas já existentes, verificação de dois arquivos de predição e reescrita de passagens localizadas. Corrigidos, o trabalho passa de bom a notável dentro de sua modalidade, e o achado metodológico sobre a diferença entre validação cruzada e teste cego por estabelecimento tem mérito suficiente para justificar, à parte, a submissão de um artigo curto a evento nacional da área.