

RELATÓRIO DE REVISÃO DE MONOGRAFIA

Título da monografia:

“Solução para Extração e Classificação em Faturas de Cartão de Crédito Utilizando Ferramentas de Inteligência Artificial”

Autor: Luiz Henrique Monteiro Silva Lima

Programa: MBA em Inteligência Artificial e Big Data – USP

Documento revisado: TCC.pdf (versão atual anexada)

Revisor: Prof. Dr. Ricardo Rodrigues Ciferri

Data: julho de 2026

Sumário

1. Como ler este relatório

Este relatório avalia a versão atual da monografia sob dois eixos: (i) a **conformidade estrutural** com o roteiro exigido (capítulos, seções de considerações iniciais/finais, organização interna); e (ii) a **qualidade de conteúdo** (clareza do problema, fundamentação teórica, estado da arte, normalização ABNT, redação). As recomendações usam três níveis de severidade:

- **[CRÍTICO]** bloqueia a aprovação; precisa ser resolvido antes da entrega/defesa.
- **[ATENÇÃO]** compromete a qualidade; deve ser corrigido, mas não impede a leitura.
- **[AJUSTE]** melhoria pontual de redação, forma ou detalhe.

Observação inicial importante: o documento ainda contém uma **lista de pendências (“Todo list”)** na página 9 e diversas anotações de rascunho embutidas no corpo do texto (ex.: “REFAZER ESSE PONTO...”, “Revisar esse ponto...”, “Modificar essa parte do TCC...”, “escrever sobre técnicas de LGPD”, “concluir referências”). Trata-se de uma versão em elaboração, e não de um texto final.

2. Avaliação da estrutura exigida

A norma solicitada define seis capítulos: (1) Introdução, (2) Fundamentação Teórica, (3) Trabalhos Relacionados, (4) Solução Proposta, (5) Validação e (6) Conclusões e Trabalhos Futuros — admitindo-se, alternativamente, Trabalhos Relacionados como seção da Fundamentação Teórica. O quadro abaixo confronta o exigido com o encontrado.

Capítulo exigido	Situação	Observação
1. Introdução	Presente / incompleto	Existe, mas não segue a subdivisão exigida (Considerações Iniciais, Contexto, Motivação, Objetivos, Organização da Monografia). Falta a seção de Organização da Monografia.
2. Fundamentação Teórica	Presente	Boa cobertura conceitual, porém sem Considerações Iniciais/Finais e com conceitos excessivamente básicos (ver §4).
3. Trabalhos Relacionados	Presente	Contém 5+ trabalhos e tabela comparativa. Falta mover o protocolo de busca para apêndice e há problemas de citação (ver §5).
4. Solução Proposta	Parcial / mal rotulado	O capítulo 4 chama-se “Procedimentos Metodológicos” e mistura metodologia + solução. Questões de pesquisa e hipóteses estão hoje na Introdução, não aqui.
5. Validação	Ausente	Não há capítulo de validação. Não há experimentos executados, resultados, tabelas/gráficos nem validação/refutação das hipóteses. Apenas a estratégia de testes de software (seção 4.4).
6. Conclusões e Trabalhos Futuros	Ausente	Não existe capítulo de conclusão. O documento termina na seção 4.4.4 e nas referências.

Conclusão do eixo estrutural: a monografia está, na prática, na fase de **projeto/proposta** (a própria página de rosto diz “Projeto de monografia”). Faltam os dois capítulos finais (Validação e Conclusões), que são justamente os que demonstram o resultado da pesquisa. Sem eles, o trabalho não fecha o ciclo exigido.

3. Análise capítulo a capítulo

3.1 Capítulo 1 – Introdução

A introdução apresenta contexto (popularização do cartão de crédito, dados da Abecs/Serasa/Elo/SPC), o problema (falta de padronização das descrições) e uma lista consistente de objetivos específicos. É o capítulo mais maduro do trabalho. Ainda assim, precisa ser reorganizado para atender ao roteiro.

Recomendações

- **[CRÍTICO]** Inserir a seção **Organização da Monografia** ao final da Introdução, com um parágrafo descrevendo o que cada capítulo aborda.
- **[CRÍTICO]** Remover o “Todo list” e todas as anotações de rascunho do corpo (ex.: “Fechar o escopo para diminuir saneamento léxico” aparece incrustado no meio do texto de requisitos).
- **[ATENÇÃO]** Reestruturar em subseções nomeadas: *1.1 Considerações Iniciais, 1.2 Contexto, 1.3 Motivação e Justificativa, 1.4 Objetivos, 1.5 Organização da Monografia*.
- **[ATENÇÃO]** As **questões de pesquisa (Q1–Q5)** e a **hipótese central** estão hoje na Introdução. O roteiro pede que questões de pesquisa e hipóteses abram o capítulo 4 (Solução Proposta). Recomenda-se movê-las (ou, no mínimo, repeti-las e desenvolvê-las lá).
- **[ATENÇÃO]** A hipótese afirma acurácia “superior a 85%” para 10–20 categorias. Como não há validação, essa meta fica sem comprovação — é preciso testá-la no cap. 5 e retomá-la na conclusão.
- **[AJUSTE]** Primeiro período do texto tem concordância quebrada: “Com a popularização do cartão de crédito... trouxe consigo...” — falta sujeito. Reescrever, p.ex.: “A popularização do cartão de crédito... trouxe consigo...”
- **[AJUSTE]** Padronizar a grafia “crédito” (aparece “credito” sem acento várias vezes), “inteligência”, “máquina”, “análise”; revisar acentuação em geral.
- **[AJUSTE]** Fontes jornalísticas (“poder 360, 2025”, “Panorama Abecs, 2024”) devem ser formalizadas como referências ABNT e citadas com AUTOR/ANO padronizados.

3.2 Capítulo 2 – Fundamentação Teórica

É o capítulo mais extenso e cobre bem os temas centrais: OCR e pré-processamento de imagem, métricas de OCR (CER/WER), pós-processamento com modelos sub-palavra (ByT5, BERT, BART, mT5), PLN aplicado a texto financeiro, TF-IDF, e ciclo de vida/MLOps. O material é rico e pertinente ao problema.

Recomendações

- **[CRÍTICO]** Há anotações de rascunho dentro do texto que precisam sumir: “REFAZER ESSE PONTO - PRECISO REESCREVER...” (seção 2.4.1), “Revisar esse ponto...” (2.5.3) e “Modificar essa parte do

TCC na questão do uso de regex” (2.6). Elas aparecem inclusive quebradas verticalmente no meio de parágrafos.

- **[ATENÇÃO]** Adicionar **Considerações Iniciais** (organização das seções do capítulo) e **Considerações Finais** (síntese + ligação com o capítulo seguinte), conforme exigido.
- **[ATENÇÃO]** Remover/enxugar conceitos **básicos e amplamente conhecidos**. A seção 2.1 (Aprendizado Supervisionado, features vs. labels, classificação vs. regressão, hold-out, k-fold) e a lista genérica de algoritmos (KNN, SVM, árvores, etc.) são conhecimento de base de IA/ML e não deveriam ocupar tanto espaço. Manter apenas o que é diretamente instrumental à solução (TF-IDF, tokenização em nível de caractere/byte, ByT5, métricas de OCR, drift/MLOps).
- **[ATENÇÃO]** Há forte **sobreposição/redundância**: as seções 2.6.9, 2.6.10 e 2.6.11 repetem quase o mesmo conteúdo sobre Data/Concept Drift, Active Learning e MLOps três vezes. Consolidar em uma única seção.
- **[ATENÇÃO]** As seções 2.6.6 a 2.6.8 já descrevem **a solução proposta** (“Aplicou-se a binarização adaptativa...”, “Foi adotado o modelo ByT5...”). Isso é conteúdo do capítulo 4, não da fundamentação. Mover para a Solução Proposta e manter na fundamentação apenas a teoria.
- **[AJUSTE]** Fórmulas foram coladas do PDF com símbolos corrompidos (ex.: “ $\phi_{y,j}$ ”, “ $ED[\Gamma D(d)]$ ”, “Learning_Error = Bias + Variance” com formatação quebrada). Reescrever em editor de equações e revisar a decomposição do erro (o correto é $MSE = Viés^2 + Variância + erro\ irreduzível$).
- **[AJUSTE]** Erros de digitação frequentes: “documetos”, “vialbiliza”, “aritgos”, “constraste”, “eficácia” usado como adjetivo (“fragmentação eficácia”), “fatoes”, “maisinformativas”, “cilco”. Passar corretor ortográfico.
- **[AJUSTE]** Falta espaço após pontuação em vários trechos (“gastos.Essa”, “impulsivo,o endividamento”, “(SANTOS, 2023)” sem ponto final). Uniformizar.

3.3 Capítulo 3 – Trabalhos Relacionados

O capítulo cumpre o essencial: descreve a string de busca, apresenta cinco conjuntos de trabalhos (Dhingra/Zhang, participantes do ICDAR 2019/CCC, Santos 2023, Araújo et al. 2024, Souza 2025) e fecha com a Tabela 1 comparativa incluindo a proposta. Boa aderência ao roteiro nesse ponto.

Recomendações

- **[CRÍTICO]** Mover o **protocolo do levantamento** (strings de busca, bases Scopus/IEEE/Web of Science, justificativa dos termos, critérios de inclusão/exclusão) para um **Apêndice**, como pede a norma. No corpo do capítulo, deixar apenas um resumo do método e a discussão dos trabalhos.
- **[CRÍTICO]** Verificar a **existência real das referências**. Vários itens da lista têm forte aparência de fontes não verificáveis ou fabricadas: “ARAÚJO et al. (2024) – Saneamento pós-OCR...” e “ZHANG et al. (2021) – Mineração de textos curtos...” não trazem veículo/DOI; “AMARAL (2026)” é um curso da Udemy usado como fonte de arquitetura; “SCHUMACHER et al. (2023)” e “KREUZBERGER et al. (2022)” aparecem com o mesmo título de artigo (possível duplicação/erro). Cada trabalho central precisa de referência bibliográfica completa e localizável.

- **[ATENÇÃO]** Uso de **primeira pessoa** impróprio para monografia: “dividi esta categoria...”, “Incluí o termo...”, “do seu projeto”, “no meu TCC”. Converter para forma impessoal (“dividiu-se”, “incluiu-se”, “nesta pesquisa”).
- **[ATENÇÃO]** Padronizar as descrições: várias começam com “Fulano (ano) descrevem um trabalho o qual...” — concordância errada (“descrevem” para autor único) e construção repetitiva. Reescrever cada entrada com: objetivo, abordagem, validação e principais resultados, nessa ordem.
- **[ATENÇÃO]** A Tabela 1 é citada no texto como “tabela 4” (“a tabela 4 exhibe...”). Corrigir a numeração cruzada.
- **[AJUSTE]** A distinção entre trabalhos “fortemente” e “fracamente” relacionados é anunciada, mas não fica clara na descrição final. Explicitar a classificação de cada trabalho.

3.4 Capítulo 4 – Solução Proposta (atual “Procedimentos Metodológicos”)

O capítulo 4 atual descreve classificação da pesquisa, framework CRISP-DM adaptado, o pipeline (OCR Tesseract → saneamento → baseline TF-IDF/Random Forest → ByT5), stack tecnológico (Python/Java Spring Boot, Docker), estratégia de testes e a arquitetura de Data Lakehouse (Figura 5). O conteúdo técnico é bom, mas o capítulo mistura metodologia de pesquisa, projeto de solução e engenharia de software.

Recomendações

- **[CRÍTICO]** Renomear/reorganizar para “**Solução Proposta**” e iniciar com: (a) **questões de pesquisa**, (b) **hipóteses**, (c) **metodologia de pesquisa** e (d) **proposta de solução detalhada com figuras**. Hoje as questões e hipóteses estão na Introdução.
- **[CRÍTICO]** Resolver as pendências marcadas no próprio texto: “escrever sobre técnicas de LGPD” (seção 4.3.1) e “concluir referências” (seção 4.4.4). Como o trabalho enfatiza privacidade de dados financeiros, a seção de LGPD é esperada e está apenas anotada, não escrita.
- **[ATENÇÃO]** Há duplicação: as seções 4.2 (CRISP-DM) e 4.3 (Desenvolvimento da Solução) descrevem o mesmo pipeline duas vezes (OCR, saneamento, baseline, ByT5, MLOps). Unificar para evitar repetição.
- **[ATENÇÃO]** Inconsistência de escopo: o núcleo do texto define o ByT5 como corretor pós-OCR e também como classificador semântico; em outros pontos o classificador é Bi-GRU a nível de caractere; e em outros, Random Forest/Naive Bayes. Definir claramente qual componente faz correção e qual faz classificação, e como se conectam.
- **[ATENÇÃO]** A Figura 5 introduz uma arquitetura sofisticada (Kafka, MinIO, Iceberg, Trino/DuckDB, DVC, Metabase, WebFlux reativo) que *excede* o escopo declarado e não é justificada no texto. Ou reduzir a arquitetura ao que será de fato implementado, ou justificar cada componente. Como não há validação, ela soa aspiracional.
- **[ATENÇÃO]** A seção 4.4 (Testes) refere StepVerifier, Flux/Mono, Kafka, Testcontainers, k6, camada Silver/Iceberg — elementos que não foram apresentados antes. Ou o texto introduz o paradigma reativo e o lakehouse na proposta, ou remove esse detalhamento de testes que pressupõe uma implementação inexistente.

- **[AJUSTE]** Numeração interna de referências cruzadas incorreta: o texto cita “correção/categorização via Hugging Face/ByT5 (4.5)”, mas não existe seção 4.5. Revisar todas as chamadas de seção/figura.
- **[AJUSTE]** Erros pontuais: “transação”, “Para combatendo a degradação” (regência), “diretrizes... exigem” vs. singular. Revisar.

3.5 Capítulo 5 – Validação (ausente)

[CRÍTICO] Este capítulo não existe e é indispensável. A norma exige: descrição dos experimentos, dados utilizados, detalhes de implementação, métricas, ambiente computacional (hardware e software), resultados em tabelas/gráficos, discussão à luz das métricas e, sobretudo, **validação ou refutação das hipóteses**. Atualmente há apenas a definição de métricas (Acurácia, Precisão, Recall, F1-Score Macro) e uma estratégia de testes de software — não há um único resultado empírico.

O que precisa ser produzido

1. Descrição do **dataset** (origem, nº de faturas/transações, nº de categorias, distribuição de classes, como o Ground-Truth foi rotulado, e se houve dados sintéticos/anonimizados).
2. Protocolo experimental: divisão treino/validação/teste, validação cruzada, hiperparâmetros do Random Forest e do fine-tuning do ByT5.
3. Ambiente computacional: CPU/GPU, VRAM, versões de bibliotecas (Tesseract, scikit-learn, transformers, PyTorch).
4. Resultados quantitativos: baseline vs. ByT5, com F1-Score Macro, matriz de confusão e, idealmente, CER/WER antes/depois do saneamento.
5. Respostas objetivas às questões Q1–Q5 e veredito sobre a hipótese de acurácia > 85%.

3.6 Capítulo 6 – Conclusões e Trabalhos Futuros (ausente)

[CRÍTICO] Também ausente. Deve resumir a solução proposta e suas características principais, sintetizar os resultados obtidos (após o cap. 5) e, então, apresentar trabalhos futuros. Alguns já são mencionados dispersos no texto (integração com Open Finance/APIs bancárias, contexto em nível de parágrafo para o corretor pós-OCR, generalização espacial de layout) e podem ser reaproveitados aqui.

4. Respostas às questões-chave da revisão

A monografia descreve claramente o problema que será investigado?

Veredito: SIM, com ressalvas.

O problema — categorizar automaticamente transações de cartão de crédito a partir de descrições textuais ruidosas e despadronizadas — está bem delimitado na Introdução e reforçado pela Figura 1. A ressalva é que o problema fica pulverizado entre “extração via OCR” e “classificação”; recomenda-se um enunciado único e explícito do problema central em um parágrafo dedicado.

O problema de pesquisa é relevante para a área de Computação?

Veredito: SIM.

O tema integra Visão Computacional/OCR, Processamento de Linguagem Natural, Aprendizado de Máquina e MLOps, com aplicação prática em finanças pessoais. É pertinente, atual e de interesse acadêmico e aplicado.

A monografia apresenta o levantamento do estado da arte?

Veredito: PARCIALMENTE.

O capítulo 3 apresenta trabalhos recentes (2016–2025) e uma tabela comparativa, o que caracteriza um levantamento do estado da arte. Porém, a confiabilidade depende da verificação das referências (ver §3.3), e o protocolo deveria estar em apêndice. Além disso, faltam trabalhos claramente “fortemente relacionados” que resolvam exatamente a classificação de faturas de cartão de crédito pessoais.

A monografia apresenta a revisão sistemática da literatura?

Veredito: PARCIALMENTE / INFORMAL.

Há elementos de revisão sistemática (strings booleanas, bases indexadas, critérios de inclusão/exclusão), mas não há um protocolo completo e reproduzível: faltam número de artigos retornados por base, fluxograma de seleção (estilo PRISMA), período de busca e contagem em cada etapa de triagem. Se a intenção é declarar “revisão sistemática”, esses itens são obrigatórios; caso contrário, chamar de “levantamento bibliográfico”.

A monografia apresenta os principais conceitos básicos que envolvem o problema (fundamentação teórica)?

Veredito: SIM — porém com excesso de conteúdo básico.

A fundamentação cobre bem OCR, pré-processamento, métricas CER/WER, modelos sub-palavra e MLOps. O problema é o oposto do esperado: há conceitos genéricos demais de IA/ML (definição de aprendizado supervisionado, features vs. labels, hold-out, algoritmos clássicos em geral) que, por serem amplamente conhecidos, deveriam ser suprimidos ou muito resumidos, dando espaço ao que é específico do problema.

5. Conformidade com a ABNT (citações e referências)

A lista de referências segue, em linhas gerais, o padrão ABNT NBR 6023 (autor em versalete, título, veículo, ano). Contudo, foram identificados problemas que precisam de correção:

- **[CRÍTICO] Referências sem dados de veículo/localização:** ARAÚJO et al. (2024) e ZHANG et al. (2021) aparecem apenas com título e ano, sem periódico, evento, editora, volume/página ou DOI. Sem isso não são verificáveis nem válidas em ABNT.
- **[CRÍTICO] Fonte inadequada:** AMARAL (2026) é um curso da Udeemy usado como base da Figura 4. Curso online não é fonte científica adequada para embasar arquitetura; substituir por artigo/livro revisado por pares.
- **[ATENÇÃO] Possível duplicação:** KREUZBERGER; KÜHL; HIRSCHL (2022) e SCHUMACHER et al. (2023) constam com títulos praticamente idênticos (“Machine learning operations (MLOps): Overview, definition, and architecture”). Verificar se não é a mesma obra citada em duplicidade.
- **[ATENÇÃO] Entradas duplicadas:** CASELI; NUNES (2024) aparece duas vezes (2024a e 2024b) com dados quase iguais — conferir se a diferenciação a/b está correta e consistente com as citações no texto.
- **[ATENÇÃO] Datas futuras:** há referências e acessos datados de 2026 (AMARAL 2026; Dataversity 2026; “Elaborado pelo autor (2026)”). Confirmar coerência com a data de submissão.
- **[ATENÇÃO] Citações não referenciadas / referências não citadas:** conferir 1:1. Ex.: DRUMOND (2023) e VALIENTE ROMERO (2018) são citados no texto (seções 2.5.7/2.6) mas não constam na lista de referências; FEI; ZHANG (2020), OSORIO; BITTENCOURT (2000), HOCHREITER; SCHMIDHUBER (1997), CHO et al. (2014), CHUNG et al. (2014), MITCHELL (1997) são citados e também ausentes da lista. Isso é uma falha grave de ABNT.
- **[ATENÇÃO] Fontes de dados estatísticos:** Abecs, Serasa, Elo/“poder 360” e SPC Brasil aparecem no texto como dados, mas não há entradas formais correspondentes na lista de referências. Formalizar.
- **[AJUSTE] Padronizar chamadas no texto** (SPC BRASIL, 2024) x (Serasa, 2024) x (Panorama Abecs, 2024) para o formato AUTOR, ANO consistente e sempre com a referência completa correspondente.

6. Redação, ortografia e consistência

Foram encontrados erros recorrentes que, somados, comprometem a qualidade formal. Amostra representativa (não exaustiva):

Tipo	Exemplos e correção sugerida
Ortografia	“credito”→crédito; “maquina”→máquina; “documetos”→documentos; “aritgos”→artigos; “constraste”→contraste; “vialbiliza”→viabiliza; “fatoes”→fatores; “cilco”→ciclo; “sofitisticadas”→sofisticadas.
Concordância / sintaxe	“Com a popularização... trouxe consigo” (sem sujeito); “Fulano (ano) descrevem” (autor único + verbo plural); “Para combatendo a

Tipo	Exemplos e correção sugerida
	degradação" (usar "Para combater"); "fragmentação eficaz" (falta "é eficaz").
Espaçamento / pontuação	Palavras coladas: "gastos.Essa", "impulsivo,o", "maisinformativas", "destaca se". Faltam espaços após vírgulas/pontos e há aspas coladas ao texto ("supervisionada" faz).
Pessoa do discurso	Trechos em 1ª pessoa ("dividi", "Incluí", "meu TCC", "seu projeto") — converter para impessoal.
Anotações de rascunho no corpo	"Todo list" (p.9); "REFAZER ESSE PONTO..."; "Revisar esse ponto..."; "Modificar essa parte do TCC..."; "escrever sobre técnicas de LGPD"; "concluir referências". Remover todas.
Siglas	A Lista de Abreviaturas está duplicada e inconsistente (USP/USPSC/ABCS aparecem em uma versão; PLN/Regex/TF-IDF/ML em outra). Unificar e definir cada sigla na primeira ocorrência no texto.
Referências cruzadas	"tabela 4" onde é Tabela 1; "(4.5)" para seção inexistente; conferir numeração de todas as figuras/tabelas/seções.

7. Plano de ação priorizado

Ordem sugerida de correção, do mais ao menos urgente:

6. Escrever os capítulos ausentes: **Validação (cap. 5)** com experimentos, dados, métricas, ambiente e resultados; e **Conclusões e Trabalhos Futuros (cap. 6)**.
7. Renomear o cap. 4 para **Solução Proposta** e abri-lo com questões de pesquisa, hipóteses e metodologia; mover Q1–Q5 e a hipótese da Introdução.
8. Remover o “Todo list” e todas as anotações de rascunho incrustadas no texto.
9. Escrever a seção de **LGPD/privacidade** (hoje só anotada) e concluir a lista de referências.
10. Auditar as **referências ABNT**: completar dados faltantes, remover fonte de curso online, resolver duplicações e garantir correspondência 1:1 entre citações e lista.
11. Adicionar **Considerações Iniciais e Finais** nos capítulos 2 a 5 e a seção de Organização da Monografia na Introdução.
12. Mover o protocolo de busca para **Apêndice** e formatar as descrições dos trabalhos relacionados de modo uniforme.
13. Enxugar conceitos básicos da Fundamentação Teórica e consolidar as seções redundantes de Drift/MLOps.
14. Revisão ortográfica e gramatical completa (corretor + leitura), com atenção a concordância, pessoa do discurso e espaçamento.
15. Alinhar o escopo declarado à arquitetura da Figura 5 (implementar/justificar ou simplificar).

8. Síntese final

A monografia tem um **tema relevante, bem contextualizado e uma fundamentação técnica sólida** nas partes específicas do domínio (OCR, pós-OCR com modelos sub-palavra, MLOps). Os capítulos 1 a 3 estão razoavelmente desenvolvidos e o capítulo 4 traz uma proposta técnica coerente. **Contudo, no estado atual o trabalho corresponde a um projeto/proposta, não a uma monografia concluída**: faltam os capítulos de Validação e de Conclusões, não há resultados empíricos e as hipóteses não são testadas. Somam-se a isso anotações de rascunho ainda visíveis, pendências declaradas pelo próprio autor (LGPD, referências), problemas de conformidade ABNT e uma revisão ortográfica/gramatical necessária.

Recomendação do revisor: o trabalho **não está pronto para defesa**. Após executar o plano de ação da §7 — sobretudo produzir a validação experimental e as conclusões, remover as marcas de rascunho e sanear as referências — o material tem base suficiente para se tornar uma monografia de boa qualidade.