

UNIVERSIDADE DE SÃO PAULO

Instituto de Ciências Matemáticas e de Computação

**SOLUÇÃO PARA EXTRAÇÃO E CLASSIFICAÇÃO
EM FATURAS DE CARTÃO DE CRÉDITO
UTILIZANDO FERRAMENTAS DE INTELIGÊNCIA
ARTIFICIAL**

Luiz Henrique Monteiro Silva de Lima

Monografia - MBA em Inteligência Artificial e Big Data

SERVIÇO DE PÓS-GRADUAÇÃO DO ICMC-USP

Data de Depósito:

Assinatura: _____

Luiz Henrique Monteiro Silva de Lima

SOLUÇÃO PARA EXTRAÇÃO E CLASSIFICAÇÃO EM FATURAS DE CARTÃO DE CRÉDITO UTILIZANDO FERRAMENTAS DE INTELIGÊNCIA ARTIFICIAL

Monografia apresentada ao Departamento de Ciências de Computação do Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo - ICMC/USP, como parte dos requisitos para obtenção do título de Especialista em Inteligência Artificial e Big Data.

Área de concentração: Inteligência Artificial

Orientador: Prof. Dr. Ricardo Ciferre

Versão original

São Carlos

2025

AUTORIZO A REPRODUÇÃO E DIVULGAÇÃO TOTAL OU PARCIAL DESTA TRABALHO,
POR QUALQUER MEIO CONVENCIONAL OU ELETRÔNICO PARA FINS DE ESTUDO E
PESQUISA, DESDE QUE CITADA A FONTE.

Ficha catalográfica elaborada pela Biblioteca Prof. Achille Bassi, ICMC/USP, com os dados
fornecidos pelo(a) autor(a)

S856m	Lima, Luiz
	SOLUÇÃO PARA EXTRAÇÃO E CLASSIFICAÇÃO EM FATURAS DE CARTÃO DE CRÉDITO UTILIZANDO FERRAMENTAS DE INTELIGÊNCIA ARTIFICIAL / Luiz Henrique Monteiro Silva de Lima ; orientador Ricardo Ciferre. – São Carlos, 2025.
	75 p. : il. (algumas color.) ; 30 cm.
	Monografia (MBA em Inteligência Artificial e Big Data) – Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, 2025.
Classificação de Transações Financeiras. Processamento de Linguagem Natural. Agentes Inteligentes. Geração Aumentada por Recuperação (RAG). Reconhecimento Óptico de Caracteres. MLOps. I. Ricardo Ciferre. II. Título.	

Luiz Henrique Monteiro Silva de Lima

**Solution for Credit Card Statement Extraction and
Classification Using Artificial Intelligence Tools**

Monograph presented to the Departamento de Ciências de Computação do Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo - ICMC/USP, as part of the requirements for obtaining the title of Specialist in Artificial Intelligence and Big Data.

Concentration area: Artificial Intelligence

Advisor: Prof. Dr. Ricardo Ciferre

Original version

São Carlos

2025

Dedico este trabalho aos meus pais e à minha família, pelo apoio incondicional, amor e paciência durante todas as etapas desta jornada acadêmica.

AGRADECIMENTOS

Agradeço primeiramente a Deus, por me conceder força, sabedoria e guiar os meus passos ao longo de toda essa jornada.

À minha família, por todo amor, dedicação e pelos valores que me transmitiram ao longo da vida, me apoiando em tudo, incondicionalmente.

Aos professores e tutores do curso, que compartilharam seus conhecimentos e experiências, contribuindo imensamente para a minha evolução e para a construção de meu futuro profissional.

Ao meu orientador, Ricardo Ciferre, por todo o apoio, disponibilidade e, sobretudo, pela orientação precisa e enriquecedora, fundamentais para o desenvolvimento desse trabalho com qualidade e profundidade.

À coordenadora Solange, pelos valiosos conselhos e presença atenta, bem como a todo o quadro de coordenadores, sempre prontos a esclarecer dúvidas, acolher sugestões e incentivar os alunos em cada etapa dessa trajetória.

Por fim, expresso minha profunda gratidão a todas as pessoas que, direta ou indiretamente, fizeram parte deste ciclo. Esta conquista é também de vocês, e o sucesso desta jornada não seria possível sem o apoio e o incentivo de cada um.

“A inteligência artificial é a ferramenta mais poderosa que já criamos para ampliar a capacidade humana, não para substituí-la.”
Satya Nadella (CEO da Microsoft)

RESUMO

Lima, L. **SOLUÇÃO PARA EXTRAÇÃO E CLASSIFICAÇÃO EM FATURAS DE CARTÃO DE CRÉDITO UTILIZANDO FERRAMENTAS DE INTELIGÊNCIA ARTIFICIAL**. 2025. 75 p. Monografia (MBA em Inteligência Artificial e Big Data) - Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos, 2025.

O gerenciamento financeiro pessoal enfrenta barreiras críticas decorrentes da despadronização e dos ruídos textuais presentes em descrições de faturas de cartão de crédito, tais como abreviações truncadas, prefixos de intermediadores de pagamento e erros de leitura óptica (OCR). Este trabalho apresenta uma solução computacional de ponta a ponta para a extração, higienização e classificação automática de despesas financeiras no contexto brasileiro, fundamentada em ferramentas de Inteligência Artificial, Processamento de Linguagem Natural (PLN) e engenharia de dados. A metodologia proposta combina um *pipeline* de extração híbrida com análise de *layout* estruturado (IBM Docling V2) e OCR local (Tesseract), rotinas algorítmicas de saneamento léxico e uma arquitetura de agente inteligente orquestrada em grafos de estado (LangGraph). O sistema integra busca vetorial densa em milissegundos via PostgreSQL com extensão pgvector (RAG), raciocínio semântico contextual com modelos de linguagem (LLMs), ferramentas autônomas de enriquecimento via busca na *web* e mecanismo de intervenção humana (*Human-in-the-Loop*) para casos de alta incerteza, suportado por uma infraestrutura containerizada de *Data Lakehouse* e esteira de MLOps com MLflow, MinIO e Apache Kafka em estrita conformidade com a LGPD. A validação experimental foi conduzida sobre um *corpus* de mais de 470 mil transações reais (Cartão de Pagamento do Governo Federal e bancos digitais) e sintéticas ruidosas, categorizadas em 14 classes canônicas. Os resultados demonstraram que o extrator estruturado alcançou redução expressiva na taxa de erro de caracteres (CER de 1,12%), enquanto o agente híbrido atingiu acurácia global de 94,2% e F1-Score Macro de 92,8%, superando significativamente os *baselines* clássicos (TF-IDF com Naive Bayes e Random Forest) com latência média ponderada de 18,4 ms por transação. Conclui-se que a solução proposta comprova a viabilidade de *pipelines* modulares, reativos e de alta performance operacional sob restrições severas de *hardware* local, viabilizando ferramentas inteligentes e acessíveis para a organização orçamentária dos cidadãos.

Palavras-chave: Classificação de Transações Financeiras. Processamento de Linguagem Natural. Agentes Inteligentes. Geração Aumentada por Recuperação. Reconhecimento Óptico de Caracteres. MLOps.

ABSTRACT

Lima, L. **Solution for Credit Card Statement Extraction and Classification Using Artificial Intelligence Tools**. 2025. 75 p. Monograph (MBA in Artificial Intelligence and Big Data) - Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos, 2025.

Personal financial management faces critical barriers due to the lack of standardization and textual noise present in credit card statement descriptions, such as truncated abbreviations, payment gateway prefixes, and optical character recognition (OCR) errors. This work presents an end-to-end computational solution for the extraction, sanitation, and automatic classification of financial expenses in the Brazilian context, based on Artificial Intelligence, Natural Language Processing (NLP), and data engineering. The proposed methodology combines a hybrid extraction pipeline with structured layout analysis (IBM Docling V2) and local OCR (Tesseract), lexical sanitation routines, and an intelligent agent architecture orchestrated in state graphs (LangGraph). The system integrates dense vector search in milliseconds via PostgreSQL with the pgvector extension (RAG), contextual semantic reasoning with Large Language Models (LLMs), autonomous web search enrichment tools, and a Human-in-the-Loop mechanism for ambiguous transactions, supported by a containerized Data Lakehouse infrastructure and an MLOps pipeline with MLflow, MinIO, and Apache Kafka in strict compliance with the LGPD. Experimental validation was conducted on a corpus of over 470,000 real transactions (Federal Government Payment Card and digital banks) and noisy synthetic data, categorized across 14 canonical classes. Results demonstrated that the structured extractor achieved a character error rate (CER) of 1.12%, while the hybrid agent reached 94.2% global accuracy and a 92.8% Macro F1-Score, significantly outperforming classical baselines (TF-IDF with Naive Bayes and Random Forest) with a weighted average latency of 18.4 ms per transaction. The proposed solution proves the feasibility of modular, reactive, and high-performance AI pipelines under local hardware constraints, enabling accessible intelligent tools for personal budget planning.

Keywords: Financial Transaction Classification. Natural Language Processing. Intelligent Agents. Retrieval-Augmented Generation. Optical Character Recognition. MLOps.

LISTA DE FIGURAS

Figura 1 – Exemplo ilustrativo de despadronização e ruídos em extrato de cartão de crédito.	32
Figura 2 – Arquitetura de Data Lakehouse orientada a eventos com MLOps e agentes de IA.	45
Figura 3 – Grafo do agente	50
Figura 4 – Distribuição comparativa de CER e WER entre Docling V2 e Tesseract OCR.	56
Figura 5 – Taxa de Erro de Caracteres (CER %) por competência de fatura (C6 Bank 2022–2026).	56
Figura 6 – Taxa de Casamento Exato (%) e Distância Média de Levenshtein por fatura.	57

LISTA DE TABELAS

Tabela 1 – Distribuição do acervo de faturas do C6 Bank com pareamento PDF e CSV.	52
Tabela 2 – Desempenho comparativo global entre Docling V2 e Tesseract OCR. . .	55
Tabela 3 – Detalhamento de CER, WER, Casamento Exato e Latência por fatura do C6 Bank.	55
Tabela 4 – Comparativo global de desempenho preditivo e tempo médio de inferência.	58
Tabela 5 – Desempenho do Agente Híbrido discriminado por categoria de despesa.	62
Tabela 7 – Estudo de ablação dos componentes do Agente Inteligente.	63

LISTA DE QUADROS

Quadro 1 – Amostra comparativa de transações reais: <i>Ground Truth</i> vs. Docling vs. Tesseract.	57
---	----

LISTA DE ABREVIATURAS E SIGLAS

ABECS	Associação Brasileira das Empresas de Cartões de Crédito e Serviços
ABNT	Associação Brasileira de Normas Técnicas
API	Application Programming Interface
AUC	Area Under Curve
BERT	Bidirectional Encoder Representations from Transformers
BI	Business Intelligence
ByT5	Byte-level T5
CER	Character Error Rate (Taxa de Erro de Caracteres)
CNN	Convolutional Neural Network (Rede Neural Convolucional)
CPGF	Cartão de Pagamento do Governo Federal
CRISP-DM	Cross-Industry Standard Process for Data Mining
CT	Continuous Training (Treinamento Contínuo)
DLA	Document Layout Analysis (Análise de Layout de Documentos)
DVC	Data Version Control
FN	Falso Negativo
FP	Falso Positivo
GPU	Graphics Processing Unit
GRU	Gated Recurrent Unit
IAM	Identity and Access Management
IEEE	Institute of Electrical and Electronics Engineers
JSON	JavaScript Object Notation
KNN	K-Nearest Neighbors
LGPD	Lei Geral de Proteção de Dados Pessoais (Lei nº 13.709/2018)
LLM	Large Language Model (Grande Modelo de Linguagem)

LOR	Logarithmic Overfitting Ratio
LSTM	Long Short-Term Memory
MAE	Mean Absolute Error (Erro Absoluto Médio)
MCC	Matthews Correlation Coefficient
ML	Machine Learning (Aprendizado de Máquina)
MLflow	Machine Learning Flow (Plataforma de MLOps)
MLOps	Machine Learning Operations
MSE	Mean Squared Error (Erro Quadrático Médio)
NFE	Nota Fiscal Eletrônica
NLTK	Natural Language Toolkit
OCR	Optical Character Recognition (Reconhecimento Óptico de Caracteres)
OIDC	OpenID Connect
OOV	Out-Of-Vocabulary (Fora do Vocabulário)
PDF	Portable Document Format
PGVector	PostgreSQL Vector Extension
PLN	Processamento de Linguagem Natural
RAG	Retrieval-Augmented Generation
RAM	Random Access Memory
RBAC	Role-Based Access Control
Regex	Regular Expressions (Expressões Regulares)
REST	Representational State Transfer
RMSE	Root Mean Squared Error (Raiz do Erro Quadrático Médio)
RNN	Recurrent Neural Network (Rede Neural Recorrente)
ROC	Receiver Operating Characteristic
ROUGE	Recall-Oriented Understudy for Gisting Evaluation
S3	Simple Storage Service

SMOTE	Synthetic Minority Over-sampling Technique
SOTA	State-of-the-Art (Estado da Arte)
SPC	Serviço de Proteção ao Crédito
SQL	Structured Query Language
SVM	Support Vector Machines
TF-IDF	Term Frequency-Inverse Document Frequency
TN	Verdadeiro Negativo
TP	Verdadeiro Positivo
USP	Universidade de São Paulo
VRAM	Video Random Access Memory
WER	Word Error Rate (Taxa de Erro de Palavras)
XGBoost	Extreme Gradient Boosting

SUMÁRIO

1	INTRODUÇÃO	31
1.1	Considerações Iniciais	31
1.2	Contextualização e Formulação do Problema	31
1.3	Motivação e Justificativa	33
1.4	Objetivos	33
1.5	Organização da Monografia	34
2	FUNDAMENTAÇÃO TEÓRICA	37
2.1	Considerações Iniciais	37
2.2	Mineração de Textos e Processamento de Linguagem Natural	37
2.2.1	Pré-processamento Léxico e Morfológico	37
2.2.2	Estratégias de Tokenização: Da Palavra ao Nível de Byte	37
2.2.3	Vetorização Estatística versus Representações Densas (Embeddings)	38
2.2.3.1	TF-IDF (Term Frequency-Inverse Document Frequency)	38
2.2.3.2	Embeddings Densos e Bancos de Dados Vetoriais	38
2.3	Visão Computacional e Inteligência de Documentos	39
2.3.1	Análise de Layout de Documentos (DLA) e Caixas Delimitadoras	39
2.3.2	Motores de OCR e Ferramentas de Conversão Estruturada	39
2.3.3	Métricas Formais de Avaliação de OCR: CER e WER	40
2.4	Arquiteturas Neurais e Agentes Inteligentes	40
2.4.1	Mecanismos de Autoatenção e Arquiteturas Transformer	40
2.4.2	Grandes Modelos de Linguagem (LLMs) e Raciocínio Estruturado	40
2.4.3	Orquestração Baseada em Grafos de Estado: LangGraph	41
2.5	Engenharia de Dados, MLOps e Sustentabilidade de Modelos	41
2.5.1	Desvios Estatísticos: Data Drift e Concept Drift	41
2.5.2	Aprendizado Ativo (Active Learning) e Confident Learning	42
2.5.3	Arquitetura de Data Lakehouse e Rastreamento com MLflow	42
2.6	Considerações Finais do Capítulo	42
3	METODOLOGIA	43
3.1	Considerações Iniciais	43
3.2	Questões de Pesquisa e Hipótese Central	43
3.3	Metodologia da Pesquisa e Framework CRISP-DM Adaptado	44
3.4	Arquitetura Geral da Solução e Ecossistema Data Lakehouse	45
3.5	Pipeline de Ingestão e Extração Híbrida de Documentos	46
3.6	Engenharia do Agente de Classificação Inteligente	47

3.7	Conformidade com a LGPD e Segurança da Informação Financeira	48
3.8	Estratégia de Garantia de Qualidade e Pirâmide de Testes	49
3.9	Considerações Finais do Capítulo	49
4	AVALIAÇÃO EXPERIMENTAL	51
4.1	Considerações Iniciais	51
4.2	Ambiente Computacional e Configuração Experimental	51
4.3	Caracterização dos Conjuntos de Dados (Datasets)	51
4.4	Protocolo Experimental e Métricas de Avaliação	53
4.4.1	Métricas para Extração Óptica e Reconhecimento de Texto	53
4.4.2	Métricas para Classificação Semântica de Transações	53
4.5	Resultados da Extração e Pré-Processamento Óptico	54
4.5.1	Desempenho Quantitativo Global: Docling versus Tesseract	54
4.5.2	Análise Visual das Métricas e Dispersão de Erros	54
4.5.3	Análise Qualitativa de Erros e Preservação Estrutural de Tabelas	55
4.6	Resultados Comparativos da Classificação de Transações	58
4.6.1	Desempenho Detalhado por Categoria de Despesa	58
4.6.2	Estudo de Ablação	59
4.7	Avaliação de MLOps, Latência e Observabilidade	59
4.8	Respostas às Questões de Pesquisa e Verificação da Hipótese	60
4.9	Considerações Finais do Capítulo	60
5	CONCLUSÕES	65
5.1	Considerações Iniciais	65
5.2	Síntese do Trabalho e Principais Contribuições	65
5.3	Avaliação dos Objetivos Atingidos	66
5.4	Limitações do Trabalho	66
5.5	Trabalhos Futuros	67
5.6	Considerações Finais	67
	APÊNDICE A – PROTOCOLO DO LEVANTAMENTO BIBLIO-GRÁFICO	69
A.1	Bases de Dados Consultadas	69
A.2	Strings de Busca Aplicadas	69
A.3	Critérios de Inclusão e Exclusão	70
	APÊNDICE B – ESQUEMA DO BANCO DE DADOS RELACIONAL E VETORIAL	71
B.1	Tabela de Estabelecimentos (Base de Conhecimento e Embeddings)	71
B.2	Tabela de Transações Financeiras	71

REFERÊNCIAS 73

1 INTRODUÇÃO

1.1 Considerações Iniciais

O gerenciamento financeiro pessoal constitui uma das competências mais críticas e desafiadoras para os cidadãos no cenário econômico contemporâneo. Com a digitalização em massa dos meios de pagamento e a consequente substituição do dinheiro em espécie por instrumentos eletrônicos, o volume de dados transacionais gerados cotidianamente atingiu patamares sem precedentes. No entanto, o aumento na facilidade de transacionar não foi acompanhado por ferramentas automáticas eficazes de organização e inteligência orçamentária, gerando um descompasso estrutural entre o consumo e a visibilidade financeira dos indivíduos. Este capítulo contextualiza a problemática da despadroneização de descrições em faturas de cartão de crédito, formaliza o problema de pesquisa, apresenta as motivações e justificativas deste trabalho, define os objetivos gerais e específicos, e detalha a organização estrutural desta monografia.

1.2 Contextualização e Formulação do Problema

A popularização do cartão de crédito como o principal meio de pagamento no Brasil trouxe consigo um desafio crescente: a dificuldade de compreender e organizar os próprios gastos de forma autônoma e tempestiva. Segundo dados consolidados pela Associação Brasileira das Empresas de Cartões de Crédito e Serviços (ABECS, 2024), as compras realizadas com cartões de crédito, débito e pré-pagos movimentaram aproximadamente 4,1 trilhões de reais em 2024, evidenciando o papel central desses instrumentos na economia nacional. Paralelamente, dados divulgados pela Serasa Experian (SERASA EXPERIAN, 2024) indicam a existência de mais de 200 milhões de cartões de crédito ativos no país, sendo que cerca de 29,37% dos consumidores brasileiros inadimplentes possuíam dívidas diretamente vinculadas ao crédito rotativo ou ao parcelamento de faturas.

O crescimento no volume transacional é impulsionado tanto pelas compras em estabelecimentos físicos quanto pelo comércio eletrônico (*e-commerce*). Relatórios de hábitos de consumo demonstram que os gastos digitais apresentaram expansão superior a 15% ao final de 2024 (PODER360, 2025). Não obstante a conveniência proporcionada por essa digitalização, a falta de padronização nas informações repassadas aos usuários nas faturas mensais impede o planejamento consciente. Conforme apontado pelo Serviço de Proteção ao Crédito (SPC BRASIL, 2024), a grande maioria dos consumidores não possui um controle sistemático de seu orçamento mensal, recorrendo frequentemente a anotações manuais em planilhas ou cadernos — práticas propensas a erros e com altas taxas de abandono ao longo do tempo.

Figura 1 – Exemplo ilustrativo de despadronização e ruídos em extrato de cartão de crédito.

MARIA OLIVEIRA COSTA 				R\$ 2.450,15
05 FEB		 1234	Livraria Cultura - São Paulo	R\$ 145,50
08 FEB		 5678	Academia SmartFit - Parcela 3/12	R\$ 99,90
11 FEB		 9012	Netshoes - Parcela 2/3	R\$ 110,33
14 FEB		 3456	Café Do Ponto - Ipanema	R\$ 22,80
16 FEB		 7890	Papelaria Grafite - Curitiba	R\$ 48,20
18 FEB		 1122	Padaria Pão de Queijo - Belo Horizonte	R\$ 15,90
21 FEB		 4455	Supermercado Pão de Açúcar - Recife	R\$ 299,75
24 FEB		 6677	Farmácia Drogasil - Salvador	R\$ 81,10
26 FEB		 8899	Restaurante Mocotó - São Paulo	R\$ 195,40
28 FEB		 1010	Cinema Kinoplex - Shopping Morumbi	R\$ 68,00
02 MAR		 2020	Gasolina Posto Shell	R\$ 210,00
05 MAR		 3030	Petshop Cão Fiel	R\$ 74,50
08 MAR		 4040	Loja Zara - Parcela 1/2	R\$ 125,00
11 MAR		 5050	Uber - Viagem Local	R\$ 18,90
14 MAR		 6060	Mercado Livre	R\$ 89,90
19 MAR		 8080	Padaria Dona Deôla	R\$ 12,50
21 MAR		 9090	Barbearia Corleone	R\$ 55,00
23 MAR		 1133	Restaurante Bráz Pizzaria	R\$ 138,00
25 MAR		 2244	Assinatura Netflix	R\$ 44,90
31 MAR		 0000	Transferência Bancária	R\$ 100,00

Fonte: Elaborado pelo autor (2026).

O problema central investigado nesta pesquisa reside na categorização automática, precisa e escalável de transações financeiras de cartão de crédito a partir de descrições textuais curtas, heterogêneas, ruidosas e altamente despadronizadas. Conforme ilustrado na Figura 1, as linhas de extrato apresentam obstáculos multidimensionais:

1. **Abreviações e Siglas Crípticas:** Nomes de fornecedores frequentemente aparecem severamente truncados, concatenados ou representados por razões sociais obsoletas (ex.: “AMZN MKTPLACE”, “PAG*RestSaoPaulo”, “DL*GOOGLE”);
2. **Prefixos de Processadores e Gateways de Pagamento:** Transações intermediadas por terminais eletrônicos (maquininhas) e facilitadores digitais inserem códigos e prefixos alfanuméricos espúrios (ex.: “PG*”, “MP*”, “ZOO*”, “SUMUP*”) que ocultam a identidade real do estabelecimento;
3. **Ruídos Decorrentes de Leitura Óptica (OCR):** Em documentos digitalizados, escaneados ou fotografados por câmeras móveis, motores de Reconhecimento Óptico de Caracteres introduzem erros de substituição, deleção e inserção de caracteres (ex.: letras trocadas por números semelhantes), gerando palavras fora do vocabulário padrão (*Out-Of-Vocabulary* – OOV);

4. **Ambiguidade de Marketplaces e Multicategorias:** Grandes plataformas de comércio eletrônico (como Mercado Livre, Amazon e Shopee) transacionam mercadorias de naturezas diametralmente opostas (eletrônicos, vestuário, alimentação, medicamentos) sob uma mesma fatura corporativa genérica, tornando a inferência categórica impossível apenas pelo texto bruto do canal;
5. **Privacidade e Soberania dos Dados Financeiros:** O tratamento de dados transacionais bancários envolve informações de alta sensibilidade pessoal, exigindo estrita conformidade com a Lei Geral de Proteção de Dados Pessoais (LGPD – Lei nº 13.709/2018) (BRASIL, 2018), o que restringe o envio indiscriminado de extratos a serviços terceirizados e APIs proprietárias em nuvem pública.

1.3 Motivação e Justificativa

A motivação deste trabalho apoia-se em duas perspectivas complementares: o avanço técnico-científico na área de Ciência da Computação e o impacto socioeconômico direto na gestão orçamentária dos cidadãos.

No âmbito da **Ciência da Computação**, o problema integra de maneira transdisciplinar a Visão Computacional/OCR, o Processamento de Linguagem Natural (PLN), os Sistemas de Recuperação de Informação Vetorial (RAG), a Engenharia de Agentes Inteligentes baseados em Grafos de Estado e as práticas de Operações de Aprendizado de Máquina (MLOps). Desenvolver uma arquitetura que funcione com alta precisão sob restrições severas de hardware local (sem demandar clusters de GPU de alto custo) preenche uma lacuna relevante na literatura de Inteligência Artificial aplicada, demonstrando a viabilidade de pipelines modulares, reativos e energeticamente eficientes.

Sob o ponto de vista **aplicado e socioeconômico**, automatizar o processo de saneamento e classificação de despesas elimina o esforço cognitivo e a sobrecarga de tempo associados à gestão financeira pessoal. Ao fornecer categorias precisas, justificativas semânticas inteligíveis e mecanismos de aprendizado contínuo com intervenção humana (*Human-in-the-Loop*), o sistema capacita os usuários a compreender seus reais padrões de consumo, auxiliando na prevenção do endividamento precoce e promovendo a sustentabilidade orçamentária das famílias.

1.4 Objetivos

O **objetivo geral** desta monografia é conceber, implementar e validar experimentalmente uma solução computacional de ponta a ponta baseada em ferramentas de Inteligência Artificial para a extração, normalização e classificação automática de transações financeiras em faturas de cartão de crédito, assegurando alta acurácia preditiva, resiliência a ruídos textuais e ópticos, privacidade dos dados e sustentabilidade operacional.

Para concretizar o objetivo geral, definiram-se os seguintes **objetivos específicos**:

1. **Ingestão e Extração Híbrida de Documentos:** Desenvolver um módulo capaz de ingerir faturas em formatos digitais nativos (CSV, OFX, JSON) e documentos ópticos (PDFs digitalizados e imagens), combinando conversores avançados com análise de layout (*Docling*) e motores de OCR locais (*Tesseract*) com filtragem de confiança;
2. **Pipeline de Normalização e Saneamento Léxico:** Projetar rotinas algorítmicas de pré-processamento para eliminação de prefixos de gateways de pagamento, supressão de ruídos alfanuméricos e resolução de sinônimos/alias comerciais;
3. **Estabelecimento de Linhas de Base Científicas (*Baselines*):** Implementar e mensurar o desempenho de algoritmos de aprendizado de máquina clássico (Naive Bayes e Random Forest) acoplados à vetorização estatística TF-IDF, estabelecendo referências quantitativas de comparação;
4. **Modelagem com Transformers e Recuperação Vetorial (RAG):** Construir uma base de conhecimento densa em banco de dados relacional e vetorial (*PostgreSQL* com extensão *pgvector*), permitindo buscas semânticas em milissegundos via embeddings multilíngues e investigando modelos no nível de byte/caractere (*Byte5*);
5. **Arquitetura de Agente Inteligente com Grafos de Estado:** Orquestrar a tomada de decisão preditiva através de um grafo de estados (*LangGraph*), integrando prompts dinâmicos conscientes da origem do dado, ferramentas autônomas de busca na web (*DuckDuckGo*), estruturas Pydantic com cadeias de pensamento (*Chain-of-Thought*) e pausas programadas para confirmação humana (*Human-in-the-Loop*) em casos ambíguos;
6. **Estruturação de Data Lakehouse e Esteira MLOps:** Desenvolver a infraestrutura containerizada da solução apoiada em armazenamento em camadas (MinIO Bronze/Silver), mensageria por eventos (Apache Kafka), rastreamento experimental e versionamento de modelos (MLflow);
7. **Validação Experimental e Diagnóstico Comparativo:** Avaliar quantitativamente a acurácia, precisão, recall, F1-Score Macro, matriz de confusão e latência em conjuntos de dados reais e sintéticos contendo mais de 470 mil registros, verificando formalmente as hipóteses de pesquisa.

1.5 Organização da Monografia

O presente documento está estruturado em seis capítulos e dois apêndices, organizados de forma sequencial e lógica conforme descrito a seguir:

- **Capítulo 1 – Introdução:** Apresenta as considerações iniciais, a contextualização da pesquisa, a formalização do problema de faturas despadronizadas, as motivações técnica e socioeconômica, os objetivos geral e específicos, e a visão geral da estrutura do trabalho;
- **Capítulo 2 – Fundamentação Teórica:** Discute os conceitos teóricos essenciais que sustentam a solução, abrangendo Processamento de Linguagem Natural, tokenização em subpalavras/bytes, modelos densos de embeddings, bancos de dados vetoriais, visão computacional e OCR, arquiteturas neurais Transformer, agentes inteligentes em grafos e práticas contemporâneas de MLOps e Data Lakehouse;
- **Capítulo 3 – Trabalhos Relacionados:** Analisa o estado da arte por meio de uma revisão estruturada da literatura, confrontando estudos sobre saneamento pós-OCR, mineração de textos informais e extração em notas fiscais, sintetizados em um quadro comparativo que explicita as lacunas abordadas por esta pesquisa;
- **Capítulo 4 – Solução Proposta:** Detalha a engenharia do sistema, formalizando as questões de pesquisa e a hipótese central, o framework metodológico CRISP-DM adaptado, a arquitetura de Data Lakehouse containerizada, o fluxo de extração híbrida, o grafo de estados do agente inteligente (LangGraph), as salvaguardas de privacidade e LGPD, e a estratégia de garantia de qualidade;
- **Capítulo 5 – Validação Experimental e Resultados:** Expõe o ambiente computacional, a caracterização dos datasets utilizados (CPGF, faturas reais de bancos digitais e dados com ruídos sintéticos), o protocolo de avaliação, as métricas obtidas nos baselines clássicos versus agente híbrido, as análises de ablação e a verificação formal das hipóteses;
- **Capítulo 6 – Conclusões e Trabalhos Futuros:** Sintetiza as principais contribuições técnicas alcançadas, avalia o cumprimento dos objetivos, discute as limitações identificadas e aponta direções para continuidade e evolução da pesquisa em cenários como Open Finance e aprendizado federado;
- **Apêndices:** O Apêndice A apresenta o protocolo detalhado do levantamento bibliográfico (strings booleanas, bases de dados e critérios de triagem), e o Apêndice B expõe o esquema do banco de dados relacional e vetorial implementado.

2 FUNDAMENTAÇÃO TEÓRICA

2.1 Considerações Iniciais

A concepção de uma ferramenta robusta para a interpretação e categorização de faturas financeiras requer o domínio integrado de fundamentos oriundos de múltiplas subáreas da Inteligência Artificial e da Engenharia de Software. Este capítulo estabelece as bases conceituais estritamente instrumentais ao projeto, organizando-se em quatro pilares fundamentais: (i) Mineração de Textos e Processamento de Linguagem Natural; (ii) Visão Computacional, Análise de Layout e Reconhecimento Óptico de Caracteres (OCR); (iii) Arquiteturas Neurais Profundas e Agentes Inteligentes baseados em Grafos; e (iv) Engenharia de Dados, MLOps e Sustentabilidade de Modelos em Produção.

2.2 Mineração de Textos e Processamento de Linguagem Natural

O Processamento de Linguagem Natural (PLN) constitui o ramo da Inteligência Artificial dedicado a capacitar sistemas computacionais a compreender, interpretar, manipular e gerar linguagens humanas (Caseli; Nunes, 2024; Chowdhury, 2003). No domínio financeiro, o desafio central da mineração textual reside na natureza não estruturada e altamente degenerada das descrições de compras em cartões de crédito (Santos, 2023).

2.2.1 Pré-processamento Léxico e Morfológico

A primeira barreira técnica na modelagem de textos curtos é a dispersão léxica. A padronização morfológica atua reduzindo a alta dimensionalidade do vocabulário através de operações determinísticas (Caseli; Nunes, 2024): conversão para caixa baixa (*lowercasing*), normalização de caracteres acentuados via codificação Unicode e aplicação de Expressões Regulares (Regex) para supressão de pontuações, caracteres de controle e símbolos especiais.

Adicionalmente, a literatura enfatiza a remoção de *stopwords* — palavras de alta frequência sem valor semântico discriminativo (artigos, preposições, conjunções) (Matos, 2010). Contudo, listas genéricas universais mostram-se insuficientes no domínio financeiro. É mandatório injetar heurísticas específicas do negócio para remover sufixos de naturezas jurídicas e corporativas (como “LTDA”, “S/A”, “ME”, “EPP”, “EIRELI”) e prefixos de liquidação financeira (“COMPRA”, “PARCELA”, “DEBITO”), os quais atuam como ruídos que distorcem as distribuições estatísticas (Santos, 2023).

2.2.2 Estratégias de Tokenização: Da Palavra ao Nível de Byte

A tokenização segmenta a cadeia textual contínua em unidades atômicas de processamento denominadas *tokens* (Caseli; Nunes, 2024). Modelos tradicionais baseados em

palavras inteiras (*word-level*) dependem de vocabulários fechados predefinidos. Diante de faturas financeiras, onde erros de digitação, truncamentos e aglutinações são onipresentes, essa abordagem falha sistematicamente devido à explosão de termos fora do vocabulário (*Out-Of-Vocabulary* – OOV).

Para superar essa fragilidade, o estado da arte avançou para a tokenização em subpalavras (*subwords*, como Byte-Pair Encoding e WordPiece) e, no limite da granularidade, para a tokenização no nível de caractere ou byte (Xue *et al.*, 2022; Zhang; Jin; Zhou, 2021). Modelos que operam diretamente sobre sequências de bytes UTF-8, a exemplo do ByT5 (Xue *et al.*, 2022), eliminam completamente o vocabulário fixo. Essa característica confere ao sistema imunidade contra erros ortográficos e capacidade inata de generalizar sobre siglas desconhecidas e nomes comerciais aglutinados (ex.: “MERCADOPAG*LOJA123”).

2.2.3 Vetorização Estatística versus Representações Densas (Embeddings)

Para que algoritmos computacionais processem dados textuais, é imperativo convertê-los em representações numéricas vetoriais.

2.2.3.1 TF-IDF (Term Frequency-Inverse Document Frequency)

A técnica clássica de TF-IDF quantifica a importância de um termo t em um documento d pertencente a um corpus D , calculada pelo produto da frequência do termo (TF) pelo inverso da frequência no documento (IDF) (Rajaraman; Ullman, 2011):

$$\text{TF-IDF}(t, d, D) = \text{TF}(t, d) \times \log \left(\frac{|D|}{1 + |\{d \in D : t \in d\}|} \right) \quad (2.1)$$

Embora gere matrizes esparsas de alta dimensionalidade que desconsideram o contexto e a ordem sintagmática das palavras, o TF-IDF permanece relevante como uma linha de base científica (*baseline*) de referência rápida, interpretável e de baixo custo computacional (Santos, 2023).

2.2.3.2 Embeddings Densos e Bancos de Dados Vetoriais

A superação das limitações esparsas consolidou-se com a semântica distribucional profunda. Modelos como o Sentence-BERT (SBERT) (Reimers; Gurevych, 2019), implementados através de arquiteturas siamesas de Sentence Transformers (ex.: **paraphrase-multilingual-MiniLM-L12-v2**), mapeiam sentenças inteiras em vetores densos e contínuos de dimensionalidade fixa (ex.: 384 dimensões).

Nesse espaço vetorial contínuo, a proximidade semântica entre duas transações u e v é mensurada diretamente pela similaridade de cosseno:

$$\text{Simil}(u, v) = \frac{u \cdot v}{\|u\|_2 \|v\|_2} = \frac{\sum_{i=1}^n u_i v_i}{\sqrt{\sum_{i=1}^n u_i^2} \sqrt{\sum_{i=1}^n v_i^2}} \quad (2.2)$$

Para viabilizar consultas em milissegundos sobre milhões de registros históricos, utilizam-se extensões vetoriais integradas ao banco de dados relacional, destacando-se a extensão *pgvector* para PostgreSQL. Essa infraestrutura permite implementar mecanismos de Geração Aumentada por Recuperação (*Retrieval-Augmented Generation* – RAG), onde exemplos canônicos rotulados são recuperados dinamicamente para subsidiar a tomada de decisão do classificador.

2.3 Visão Computacional e Inteligência de Documentos

A Inteligência de Documentos (*Document AI*) integra Visão Computacional e PLN para extrair informações estruturadas de imagens e documentos não nativos (Auer; Dolfi; Staar, 2024).

2.3.1 Análise de Layout de Documentos (DLA) e Caixas Delimitadoras

A Análise de Layout de Documentos (DLA) é a etapa encarregada de segmentar a imagem da página, identificando blocos lógicos como tabelas, colunas, parágrafos e cabeçalhos. Cada entidade visual é mapeada por coordenadas espaciais denominadas caixas delimitadoras (*bounding boxes*): $[x_{\min}, y_{\min}, x_{\max}, y_{\max}]$.

Em faturas de cartão de crédito, a preservação da topologia e da ordem de leitura é mandatória: a relação espacial de alinhamento horizontal entre o nome do estabelecimento comercial e o seu respectivo valor monetário em reais (R\$) carrega a semântica relacional necessária para isolar a transação e evitar a fusão indevida de dados entre colunas paralelas (Drumond, 2023).

2.3.2 Motores de OCR e Ferramentas de Conversão Estruturada

- **Tesseract OCR:** Mecanismo de reconhecimento óptico de código aberto amplamente utilizado (Smith, 2007). Baseia-se em redes neurais LSTM para converter matrizes de pixels em caracteres. O Tesseract opera localmente garantindo total privacidade, mas exige imagens rigorosamente limpas para evitar quedas acentuadas de precisão diante de ruídos visuais;
- **IBM Docling:** Ferramenta moderna de processamento documental (*Document Parsing*) especializada na extração estruturada de PDFs complexos (Auer; Dolfi; Staar, 2024). Ao combinar modelos de visão para segmentação de tabelas com exportação nativa em Markdown estruturado, o Docling preserva as linhas de transações tabulares sem depender de heurísticas frágeis de coordenadas manuais.

2.3.3 Métricas Formais de Avaliação de OCR: CER e WER

A qualidade da extração óptica é avaliada formalmente pela distância de edição de Levenshtein entre o texto predito pelo OCR e o texto de referência (*ground truth*). Definem-se três tipos fundamentais de erro: Substituição (S), Deleção (D) e Inserção (I).

A **Taxa de Erro de Caracteres** (CER – *Character Error Rate*) é calculada sobre o total de caracteres de referência N_c :

$$\text{CER} = \frac{S_c + D_c + I_c}{N_c} \quad (2.3)$$

A **Taxa de Erro de Palavras** (WER – *Word Error Rate*) opera de forma idêntica, porém adotando palavras inteiras como unidade amostral sobre o total de palavras N_w :

$$\text{WER} = \frac{S_w + D_w + I_w}{N_w} \quad (2.4)$$

Um único caractere lido incorretamente invalida a palavra inteira no cálculo do WER, tornando esta métrica estritamente mais rigorosa que o CER (Araújo; Bezerra; Neto, 2025).

2.4 Arquiteturas Neurais e Agentes Inteligentes

2.4.1 Mecanismos de Autoatenção e Arquiteturas Transformer

A introdução do mecanismo de autoatenção (*self-attention*) na arquitetura Transformer por Vaswani et al. (Vaswani *et al.*, 2017) superou as limitações de paralelização das redes recorrentes tradicionais (LSTM e GRU) (Hochreiter; Schmidhuber, 1997; Cho *et al.*, 2014). A atenção escalada por produto escalar calcula o alinhamento contextual entre matrizes de Consulta (Q), Chave (K) e Valor (V):

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (2.5)$$

Essa formulação permite que cada token pondere dinamicamente todos os demais elementos da sequência de entrada, capturando dependências semânticas não locais em textos curtos e informais.

2.4.2 Grandes Modelos de Linguagem (LLMs) e Raciocínio Estruturado

Os Grandes Modelos de Linguagem (*Large Language Models* – LLMs) pré-treinados em escala massiva demonstraram notável capacidade de inferência semântica e raciocínio contextual. Para mitigar o risco de alucinações e garantir o determinismo necessário a sistemas financeiros, duas técnicas são essenciais:

- **Cadeia de Pensamento (*Chain-of-Thought* – CoT):** Induz o modelo a explicitar seus passos intermediários de raciocínio antes de emitir o veredito final, elevando comprovadamente a precisão lógica;

- **Chamada de Ferramentas (*Tool Calling*):** Capacidade do modelo de suspender temporariamente a geração de texto para invocar funções externas (como motores de busca na web) a fim de obter evidências factuais em tempo real;
- **Saída Estruturada com Validação de Tipos:** Utilização de bibliotecas de validação de esquemas (como Pydantic) para forçar o modelo a responder exclusivamente em formatos JSON estritos e tipados.

2.4.3 Orquestração Baseada em Grafos de Estado: LangGraph

Enquanto cadeias lineares simples (*chains*) são rígidas, aplicações complexas demandam arquiteturas cíclicas e com controle fino de fluxo. O *LangGraph* (Chase; LangChain Team, 2024) estrutura a aplicação como um Grafo Direcionado de Estados (*StateGraph*), onde cada nó executa uma função atômica (normalização, consulta vetorial, inferência LLM, persistência) e as arestas condicionais determinam o próximo passo baseando-se no estado tipado (*AgentState*). O framework suporta nativamente persistência de memória (*checkpoints*) e o padrão *Human-in-the-Loop*, permitindo interromper o grafo de forma transparente para aguardar a confirmação humana e retomá-lo posteriormente.

2.5 Engenharia de Dados, MLOps e Sustentabilidade de Modelos

A sustentabilidade de uma solução de IA em ambientes de produção exige a incorporação de práticas de Engenharia de Dados e Operações de Aprendizado de Máquina (*Machine Learning Operations* – MLOps) (Kreuzberger; Kühn; Hirschl, 2022; Treveil *et al.*, 2020).

2.5.1 Desvios Estatísticos: Data Drift e Concept Drift

Modelos de machine learning operando sobre dados financeiros sofrem inevitável degradação temporal decorrente de dois fenômenos (Quiñonero-Candela *et al.*, 2008; Lu *et al.*, 2019):

- **Data Drift (Desvio de Covariáveis):** Ocorre quando a distribuição das variáveis de entrada $P(X)$ se altera ao longo do tempo (ex.: novos nomes de estabelecimentos no mercado, atualização de gateways ou mudanças de formatação no OCR), embora a relação mapeada $P(Y|X)$ permaneça estável;
- **Concept Drift (Desvio de Conceito):** Manifesta-se quando a probabilidade condicional real $P(Y|X)$ muda (ex.: uma grande rede de postos de combustível que passa a atuar predominantemente como loja de conveniência/alimentação, alterando a categoria esperada para uma mesma descrição textual).

2.5.2 Aprendizado Ativo (Active Learning) e Confident Learning

Para contornar o custo proibitivo da rotulação manual exaustiva diante do surgimento contínuo de novas empresas, a literatura preconiza o Aprendizado Ativo (*Active Learning*) (Ren *et al.*, 2021). Ao invés de amostrar dados aleatoriamente, o sistema calcula a incerteza estatística de suas inferências. Transações com escore de confiança inferior a um limiar seguro (ex.: confiança ≤ 0.70) são isoladas e encaminhadas para curadoria humana (*Human-in-the-Loop*) (Northcutt; Jiang; Chuang, 2021). Os dados confirmados expandem a base de conhecimento de forma cirúrgica e de alto valor agregado.

2.5.3 Arquitetura de Data Lakehouse e Rastreamento com MLflow

A infraestrutura de suporte a dados moderna adota o paradigma de Data Lakehouse, combinando a flexibilidade e o baixo custo de armazenamento de objetos compatíveis com S3 (como o MinIO) com as garantias transacionais e a organização em camadas (*Medallion Architecture*) (Treveil *et al.*, 2020):

- **Camada Bronze:** Armazena os dados brutos e imutáveis exatamente como foram ingeridos (PDFs originais, extratos bancários em CSV, textos ruidosos extraídos);
- **Camada Silver:** Contém os dados limpos, saneados, normalizados e enriquecidos em esquemas analíticos (Parquet/Iceberg);
- **Camada Gold:** Tabelas agregadas e visões analíticas prontas para consumo por motores SQL distribuídos (Trino) e dashboards de inteligência de negócios (Metabase).

O ciclo de vida experimental e operacional é unificado pelo *MLflow* (Treveil *et al.*, 2020). A plataforma atua como repositório centralizado de parâmetros, métricas e artefatos, suportando execuções aninhadas (*nested runs*) que viabilizam o rastreamento em dois níveis de granularidade: a corrida global correspondente à fatura completa e corridas filhas isoladas para cada transação individualmente classificada.

2.6 Considerações Finais do Capítulo

Os conceitos apresentados neste capítulo constituem a fundamentação técnica indispensável para a construção da solução proposta. A integração entre normalização morfológica, embeddings densos no PostgreSQL com pgvector, análise de layout com Docling, orquestração em grafos com LangGraph e práticas contínuas de MLOps no Data Lakehouse estabelece um arcabouço metodológico sólido para solucionar o desafio de classificar faturas de cartão de crédito com alto desempenho e sobriedade computacional.

3 METODOLOGIA

3.1 Considerações Iniciais

Este capítulo detalha a concepção arquitetural, os modelos matemáticos e a implementação prática da solução desenvolvida para a extração e classificação de faturas de cartão de crédito. Afastando-se de abstrações puramente teóricas, a seção formaliza as questões de pesquisa e as hipóteses norteadoras, descreve a metodologia baseada no CRISP-DM adaptado, especifica os microsserviços do ecossistema Data Lakehouse, pormenoriza a engenharia do agente inteligente em grafo (LangGraph), estabelece as salvaguardas de conformidade com a LGPD e delinea a pirâmide de testes de software.

3.2 Questões de Pesquisa e Hipótese Central

A formulação e a avaliação experimental deste trabalho são guiadas por cinco Questões de Pesquisa (Q1 a Q5) fundamentadas na literatura:

- **Q1:** Quais técnicas de representação textual (esparsas vs. densas) e algoritmos de aprendizado (estatísticos clássicos vs. modelos neurais baseados em subpalavras e agentes LLM) apresentam maior eficácia para categorizar transações a partir de descrições ruidosas e despadronizadas?
- **Q2:** Qual é o nível de acurácia global e F1-Score Macro alcançável por um classificador automático de gastos operando sobre faturas reais e ruidosas, considerando uma taxonomia de 10 a 20 categorias de despesas?
- **Q3:** Quais são as principais naturezas de erro cometidas pelos classificadores automatizados (ambiguidades de marketplace, erros de leitura de OCR, nomes informais de lojistas) e de que forma mecanismos como *Chain-of-Thought* e busca na web podem mitigá-los?
- **Q4:** Em que medida a injeção de metadados contextuais (origem do arquivo digital versus óptico, histórico de compras do usuário e descarte de prefixos de gateways) contribui para o incremento do desempenho preditivo?
- **Q5:** Qual é a viabilidade prática e a sustentabilidade computacional de manter e atualizar o sistema continuamente ao longo do tempo diante de fenômenos de *Data Drift* e *Concept Drift*, utilizando MLOps e Aprendizado Ativo com intervenção humana (*Human-in-the-Loop*)?

A **hipótese central** submetida a teste nesta pesquisa estabelece que:

“Um pipeline híbrido que integra normalização léxica de gateways, busca por similaridade semântica em banco vetorial (PGVector), raciocínio dinâmico via agente LLM com acesso a ferramentas de busca e intervenção humana programada (Human-in-the-Loop) é capaz de classificar transações de cartão de crédito com acurácia global e F1-Score Macro superiores a 85% em uma taxonomia de 14 categorias, garantindo conformidade rigorosa com a LGPD e viabilidade de execução em infraestrutura local.”

3.3 Metodologia da Pesquisa e Framework CRISP-DM Adaptado

A pesquisa classifica-se, quanto à sua natureza, como **aplicada**, voltada à resolução do problema prático de gestão financeira pessoal (Gerhardt; Silveira, 2009). Quanto à abordagem e procedimentos, define-se como uma pesquisa **experimental e quantitativa** (Gil, 2019), estruturada no controle de variáveis em ambiente simulado e na mensuração estatística rigorosa de métricas preditivas.


O ciclo metodológico adotou o framework padrão da indústria *Cross-Industry Standard Process for Data Mining* (CRISP-DM), estendido com diretrizes contemporâneas de MLOps (Kreuzberger; Kühn; Hirschl, 2022) conforme as seis etapas sequenciais:

1. **Compreensão do Negócio:** Mapeamento das regras de faturas de cartão de crédito no Brasil, identificação de intermediadores de pagamento e taxonomia de categorias orçamentárias;
2. **Compreensão dos Dados:** Coleta e exploração de datasets públicos oficiais (CPGF), faturas reais anonimizadas e geração de datasets sintéticos com ruídos de maquininhas de cartão;
3. **Preparação dos Dados:** Engenharia de extração híbrida (Docling e Tesseract OCR), normalização léxica com Regex, descarte de jargões corporativos e cálculo de embeddings vetoriais;
4. **Modelagem:** Desenvolvimento comparativo englobando baselines clássicos (TF-IDF + Random Forest / Naive Bayes), ajuste fino do ByT5 e construção do agente inteligente em grafo de estados (LangGraph com PGVector e LLM);
5. **Avaliação:** Mensuração de métricas estatísticas (Acurácia, Precisão, Recall, F1-Score Macro e Matriz de Confusão), estudos de ablação e auditoria de latência;
6. **Implantação e Ciclo de Vida:** Containerização em microsserviços via Docker, orquestração de Data Lakehouse com MinIO e Kafka, rastreamento de experimentos com MLflow e governança de acessos via Logto.

3.4 Arquitetura Geral da Solução e Ecossistema Data Lakehouse

A arquitetura geral do sistema foi concebida sob o paradigma orientado a eventos e microsserviços desacoplados, implementada integralmente com tecnologias de código aberto (*Open Source*) orquestradas via *Docker Compose*. A Figura 2 ilustra a topologia completa da infraestrutura.

Figura 2 – Arquitetura de Data Lakehouse orientada a eventos com MLOps e agentes de IA.



Fonte: Elaborado pelo autor (2026).

O ecossistema divide-se nos seguintes serviços especializados:

- **MinIO (Object Storage S3):** Provedor de armazenamento em nuvem local compatível com a API AWS S3. Organiza o Data Lakehouse em três buckets particionados por fonte e data: (i) **bronze-raw** para preservação imutável dos arquivos brutos (PDFs, CSVs); (ii) **bronze-txt** para dados textuais extraídos; e (iii) **mlflow-artifacts** para armazenamento de pesos e rastreios de modelos;
- **Apache Kafka:** Barramento de mensageria distribuído que garante o desacoplamento temporal e a resiliência volumétrica entre a camada de ingestão e os workers assíncronos através dos tópicos **test-topic**, **events-topic** e **datalake-bronze-ingestao-topic**;
- **PostgreSQL 16 com extensão PGVector:** Banco de dados relacional e vetorial encarregado de armazenar a base de conhecimento de estabelecimentos, usuários,

faturas, alocações de transações e vetores de características densas de 384 dimensões gerados pelo modelo `paraphrase-multilingual-MiniLM-L12-v2`;

- **Servidor MLflow:** Servidor centralizado de MLOps apoiado por backend relacional PostgreSQL (`mlops_db`) e bucket S3. Realiza o autologging de experimentos LangChain/LangGraph, registrando parâmetros de prompt, latência de inferência, tokens consumidos, tags de rastreamento e arquivos de cadeia de pensamento em formato texto (`results/raciocinio.txt`);
- **Motor Analítico Trino e Metabase BI:** Camada de consumo analítico que executa consultas SQL distribuídas e disponibiliza dashboards gerenciais para visualização interativa do orçamento do usuário;
- **n8n e Apache Airflow:** Plataformas de orquestração de fluxos para agendamento de pipelines de ingestão em lote e integração de webhooks reativos;
- **Logto IAM:** Servidor de autenticação e controle de acesso baseado em OpenID Connect (OIDC) e OAuth 2.0, garantindo o isolamento multi-inquilino (*multi-tenant*) e a segurança de acesso aos dados financeiros.

3.5 Pipeline de Ingestão e Extração Híbrida de Documentos

A camada de extração foi arquitetada para processar indistintamente documentos digitais nativos e arquivos ópticos escaneados, operando através de um fluxo em três etapas:

1. **Identificação de Metadados no Data Lakehouse:** A função determinística `extrair_metadados_datalake` inspeciona o caminho do arquivo (ex.: `bronze/source=nubank/year=`) e extrai o banco de origem, partições temporais e a flag `is_digital_nativo`. Caso a extensão seja `.csv`, `.ofx` ou `.json`, o sistema desativa hipóteses de erro de OCR; caso seja imagem ou PDF escaneado, ativa heurísticas de correção óptica;
2. **Conversão com Docling V2 (Layout Tabular):** Em faturas em formato PDF (como Nubank e C6 Bank), utiliza-se o *DocumentConverter* da biblioteca IBM Docling com backend PyPdfium acelerado por GPU CUDA. O conversor mapeia itens de tabela com caixas delimitadoras e exporta o conteúdo estruturado em Markdown delimitado por pipes (`|`), preservando a correspondência exata entre data, final do cartão de crédito, descrição do estabelecimento e valor em reais (R\$);
3. **Extração com Tesseract OCR e Filtro de Confiança:** Para recibos em imagem estrita ou páginas onde o conversor não identifica tabelas, aciona-se o Tesseract OCR configurado em modo OEM 3 (redes LSTM) e PSM 6 (bloco uniforme de texto).

Aplica-se a função `image_to_data` com um **filtro de confiança** $> 40\%$, descartando fragmentos visuais irrecuperáveis antes do envio à camada semântica.

3.6 Engenharia do Agente de Classificação Inteligente

O núcleo de tomada de decisão do sistema foi codificado como um grafo de estados direcionado (3)

(*StateGraph*) no framework *LangGraph*, suportado pelo estado tipado `AgentState`. O fluxo operacional do agente é estruturado nas seguintes etapas coordenadas:

1. **Nó `normalizar`:** Executa a limpeza léxica da descrição da transação com Regex, eliminando duplicações em torno de asteriscos (ex.: “TIM*TIM” $\rightarrow$ “TIM”), descartando termos de pagamento (“PAG*”, “PIX”, “COMPRA”) e sufixos societários (“LTDA”, “ME”). Realiza a resolução de aliases de marcas e verifica se a compra pertence à lista de marketplaces ambíguos (`eh_marketplace`);
2. **Roteamento Pós-Normalização (`rota_apos_normalizar`):** Se a transação for detectada como marketplace (Mercado Livre, Amazon, Shopee), encaminha o fluxo para o nó `buscar_historico_marketplace`; caso contrário, direciona para o nó de busca vetorial `buscar_por_similaridade`;
3. **Nó `buscar_historico_marketplace`:** Consulta o histórico consolidado do usuário no banco PostgreSQL (`sugestoes_categoria_marketplace`), recuperando as preferências de compras confirmadas anteriormente no mesmo marketplace;
4. **Nó `buscar_por_similaridade`:** Executa a busca por similaridade de cosseno na extensão PGVector utilizando os embeddings gerados pelo modelo `paraphrase-multilingual-Min`. Se a melhor correspondência apresentar escore de similaridade ≥ 0.85 , a transação é considerada classificada com alta certeza, sendo roteada diretamente para o nó `salvar_resultado`;
5. **Nó `classificar_com_llm`:** Caso a busca vetorial resulte em confiança inferior a 0.85, aciona-se o modelo de linguagem (LLM). O nó injeta um System Prompt dinâmico contendo: (i) metadados da origem do arquivo; (ii) regras de decodificação de maquininhas de pagamento; (iii) diretrizes anti-alucinação; (iv) cadeia de pensamento obrigatória gerando o campo `raciocinio` antes da categoria; e (v) acesso à ferramenta `duckduckgo_search` para pesquisar nomes comerciais obscuros;
6. **Roteador Unificado e Nó `tools`:** Se o LLM emitir uma chamada de ferramenta (*tool call*), o fluxo executa a pesquisa autônoma na web pelo `ToolNode` e retorna as evidências para o classificador;

7. **Nó estruturar_saida_llm:** Utiliza o método `with_structured_output` com validação Pydantic (`ClassificacaoLLM`) para garantir que a resposta do LLM respeite o contrato de tipos com categoria, subcategoria, escore de confiança de 0 a 1, justificativa, lista de categorias alternativas e cadeia de raciocínio;
8. **Nó aguardar_confirmacao (Human-in-the-Loop):** Se o escore de confiança for ≤ 0.80 ou se houver ambiguidade severa de marketplace, o grafo executa o comando `interrupt`, pausando o processamento da thread e aguardando a validação ou correção do usuário. A execução é retomada assincronamente via `Command(resume=resposta)`;
9. **Nó salvar_vectorstore:** Transações classificadas com alta confiança (≥ 0.85) ou validadas por humanos têm sua descrição normalizada e metadados persistidos no PGVector, retroalimentando a base de conhecimento de forma contínua;
10. **Nó salvar_resultado:** Persiste a transação definitiva no PostgreSQL com integridade referencial completa, registrando o método de classificação utilizado (`vetorial`, `llm`, `humano`), escores de confiança, logs de auditoria e status de revisão.

3.7 Conformidade com a LGPD e Segurança da Informação Financeira

O processamento de dados transacionais bancários envolve informações estritamente sensíveis que revelam hábitos de vida, localização geográfica, saúde e patrimônio dos cidadãos. A arquitetura proposta foi desenhada em estrita observância à Lei Geral de Proteção de Dados Pessoais (LGPD – Lei nº 13.709/2018) (BRASIL, 2018), estruturando-se sobre quatro princípios fundamentais:

1. **Princípio da Minimização de Dados (Art. 6º, III):** O pipeline descarta sistematicamente quaisquer dados que não sejam estritamente necessários para a finalidade de categorização orçamentária. Números completos de cartões de crédito, códigos de segurança (CVV), endereços residenciais e senhas são expurgados no estágio de ingestão, preservando-se apenas a descrição textual, data e valor da compra;
2. **Anonimização e Pseudonimização (Art. 13):** Os identificadores pessoais dos titulares (como CPF e nome completo) são pseudonimizados através de identificadores únicos universais (UIDs) e funções hash criptográficas unidirecionais antes do armazenamento na camada de dados;
3. **Soberania de Processamento On-Premise (Privacidade por Design):** Ao adotar o motor Tesseract, modelos locais de embeddings e containers executados

na infraestrutura do próprio usuário, a solução impede o vazamento de extratos bancários para servidores de terceiros ou provedores comerciais proprietários de IA;

4. **Autenticação e Rastreabilidade de Acesso (Art. 46):** O acesso às interfaces gerenciais e endpoints de API é protegido pelo servidor Logto via protocolo OpenID Connect (OIDC), com controle de acesso baseado em papéis (RBAC). Ademais, a tabela `log_classificacoes` mantém registro temporal auditável de todas as inferências, métodos e revisões humanas realizadas.

3.8 Estratégia de Garantia de Qualidade e Pirâmide de Testes


Para garantir a confiabilidade operacional de um sistema distribuído e poliglota, instituiu-se uma estratégia alinhada à Pirâmide de Testes de Software:

- **Testes Unitários:** Desenvolvidos com *pytest* no ambiente Python e *JUnit 5* com *StepVerifier* na camada reativa, validando funções determinísticas de saneamento Regex, parsers de datas, cálculos de métricas e contratos Pydantic de forma isolada em memória;
- **Testes de Integração com Testcontainers:** Utilização da biblioteca *Testcontainers* para instanciar containers Docker efêmeros do Apache Kafka, MinIO e PostgreSQL com pgvector durante a execução dos testes automatizados de integração, validando a persistência real de mensagens e consultas vetoriais;
- **Testes de Regressão de Agente:** Baterias de teste automatizadas que submetem um conjunto canônico de 100 transações de referência (*Golden Dataset*) ao grafo de estados, verificando se alterações de código ou hiperparâmetros causam regressão nas previsões semânticas;
- **Testes de Carga com k6:** Execução de testes de estresse assíncrono via ferramenta *k6*, simulando o envio concorrente de centenas de requisições de faturas para comprovar a estabilidade do barramento Kafka e a ausência de travamentos de memória.

3.9 Considerações Finais do Capítulo

A arquitetura da solução proposta materializa uma abordagem pragmática, moderna e escalável para o desafio da classificação de faturas financeiras. Ao articular a extração híbrida, busca vetorial densa em banco PostgreSQL, agente em grafo LangGraph com Human-in-the-Loop, salvaguardas rigorosas de privacidade e governança MLOps no Data Lakehouse, o sistema estabelece as bases técnicas necessárias para a validação empírica detalhada no capítulo seguinte.

Figura 3 – Grafo do agente



4 AVALIAÇÃO EXPERIMENTAL

4.1 Considerações Iniciais

A validação empírica constitui a etapa decisiva para comprovar a eficácia prática da solução proposta e responder formalmente às questões de pesquisa estabelecidas. Este capítulo apresenta o ambiente computacional dos experimentos, a caracterização detalhada dos conjuntos de dados utilizados (com ênfase no acervo de faturas do C6 Bank e seus respectivos arquivos de *Ground Truth*), o protocolo formal de mensuração adotado (incluindo as definições matemáticas da Distância de Edição de Levenshtein, CER e WER), os resultados comparativos detalhados de extração óptica entre o IBM Docling e o Tesseract OCR, o desempenho dos classificadores (baselines clássicos versus agente inteligente híbrido), a análise de ablações, a avaliação de MLOps e observabilidade, e a verificação conclusiva da hipótese central da monografia.

4.2 Ambiente Computacional e Configuração Experimental

Todos os experimentos foram conduzidos em um ambiente computacional controlado, representativo de estações de trabalho de desenvolvimento comuns, com as seguintes especificações de hardware e software:

- **Hardware:** Processador Intel Core i7 / AMD Ryzen de 8 núcleos e 16 threads, 32 GB de memória RAM DDR4, GPU dedicada NVIDIA GeForce RTX com 16 GB de VRAM (suporte a aceleração CUDA 12.x) e armazenamento SSD NVMe de alta velocidade;
- **Software e Bibliotecas:** Sistema Operacional Windows 11 / Linux Ubuntu 22.04 LTS, Docker Engine v26.1, Python v3.11.15, PyTorch v2.3.1, Transformers v4.41, LangChain v0.2, LangGraph v0.1, Sentence-Transformers v3.0, Scikit-Learn v1.5, PostgreSQL v16.3 com extensão pgvector v0.7, MLflow v2.14, IBM Docling v2.0, PyTesseract v0.3.13 (motor Tesseract 5.3 com modelos em português), PyPDFium2 v4.30, RapidFuzz v3.14 e JiWER v4.0.

4.3 Caracterização dos Conjuntos de Dados (Datasets)

A experimentação foi estruturada sobre conjuntos de dados complementares que somam mais de 470 mil transações, abrangendo dados governamentais e faturas reais de instituições financeiras:

1. **Dataset Governamental CPGF (Cartão de Pagamento do Governo Federal):** Acervo público oficial obtido no Portal da Transparência do Governo Federal (SPC BRASIL, 2024). O conjunto reúne 44 arquivos CSV mensais consolidados, totalizando **477.740 transações financeiras reais** contendo campos como nome do favorecido comercial, CNPJ, órgão responsável, data e valor monetário transacionado;
2. **Acervo Real de Faturas Bancárias C6 Bank e Nubank:** Extratos de cartões de crédito pessoais obtidos junto a instituições financeiras brasileiras em formatos digitais nativos (CSV) e documentos ópticos protegidos (PDFs com layout tabular multicolumnar). No caso do C6 Bank, reuniu-se um acervo abrangendo o período contínuo de janeiro de 2022 a agosto de 2026, composto por **49 faturas em PDF** (totalizando 357 páginas protegidas por senha) e **105 arquivos CSV oficiais**, os quais foram utilizados como *Ground Truth* de alta fidelidade para a mensuração de erros de OCR;
3. **Dataset Sintético com Ruído de Maquininhas de Cartão:** Para estressar a robustez algorítmica diante de falhas extremas, desenvolveu-se um gerador estocástico de ruído que transformou nomes canônicos de fornecedores inserindo truncamentos (máximo de 20 caracteres), códigos aleatórios de autorização (ex.: “*4821 LOJA”), sufixos numéricos (ex.: “DROGARIA 9482”) e corrupções tipográficas com probabilidade controlada.

Para a avaliação de extração óptica, estabeleceu-se um procedimento determinístico de pareamento temporal entre os documentos em PDF e os arquivos CSV do C6 Bank. Por meio da leitura dos metadados das primeiras páginas dos PDFs, identificou-se a data de corte (fechamento por volta do dia 8 de cada mês) e o vencimento (fixado no dia 15), mapeando-se com exatidão 1 : 1 cada uma das 49 faturas ao seu respectivo arquivo `Fatura_AAAA-MM-15.csv`. A Tabela 1 resume a distribuição do acervo de faturas do C6 Bank por ano de competência.

Tabela 1 – Distribuição do acervo de faturas do C6 Bank com pareamento PDF e CSV.

Ano de Competência	Qtd. de Faturas em PDF	CSVs de <i>Ground Truth</i>	Total de Páginas
2022	12 faturas (ano completo)	12 arquivos CSV	74 páginas
2023	12 faturas (ano completo)	12 arquivos CSV	80 páginas
2024	11 faturas	11 arquivos CSV	73 páginas
2025	12 faturas (ano completo)	12 arquivos CSV	112 páginas
2026	2 faturas	2 arquivos CSV	18 páginas
Total Geral	49 faturas	49 arquivos CSV	357 páginas

Fonte: Elaborado pelo autor (2026).

As transações foram rotuladas em uma taxonomia de **14 categorias canônicas de despesas**: Alimentação, Transporte, Moradia, Saúde, Educação, Vestuário, Lazer e Entretenimento, Tecnologia, Beleza e Cuidados Pessoais, Pets, Serviços Financeiros, Marketplace / E-commerce, Doações / Presentes e Despesas Diversas.

4.4 Protocolo Experimental e Métricas de Avaliação

Para garantir rigor estatístico e reprodutibilidade, a avaliação foi dividida em duas frentes complementares: avaliação da extração de texto (OCR) e avaliação da classificação semântica.

4.4.1 Métricas para Extração Óptica e Reconhecimento de Texto

Para avaliar a qualidade da transcrição em relação ao *Ground Truth* fornecido pelos CSVs bancários oficiais, adotaram-se as métricas fundamentadas na Distância de Edição de Levenshtein $L(s_1, s_2)$, definida como o número mínimo de operações de inserção, remoção ou substituição de caracteres necessárias para transformar a cadeia s_1 na cadeia s_2 :

1. **Character Error Rate (CER)**: Proporção de caracteres incorretos em relação ao comprimento da cadeia de referência:

$$\text{CER} = \frac{\sum_{i=1}^N L(\text{ref}_i, \text{hyp}_i)}{\sum_{i=1}^N \text{len}(\text{ref}_i)} \quad (4.1)$$

onde ref_i representa o texto oficial no CSV (verdade-terrestre) e hyp_i representa a transcrição obtida pelo motor de OCR;

2. **Word Error Rate (WER)**: Taxa de erro calculada no nível de palavras tokenizadas, mensurando inserções, deleções e substituições de palavras completas:

$$\text{WER} = \frac{\sum_{i=1}^N L_{\text{palavras}}(\text{ref}_i, \text{hyp}_i)}{\sum_{i=1}^N \text{len}_{\text{palavras}}(\text{ref}_i)} \quad (4.2)$$

3. **Taxa de Casamento Exato (*Exact Match Rate*)**: Fração percentual de transações transcritas com exatidão perfeita ($L(\text{ref}_i, \text{hyp}_i) = 0$):

$$\text{EMR} = \frac{1}{N} \sum_{i=1}^N \mathbb{I}[L(\text{ref}_i, \text{hyp}_i) = 0] \quad (4.3)$$

4.4.2 Métricas para Classificação Semântica de Transações

Para a classificação de categorias, adotou-se o particionamento estratificado do corpus em: 70% para treinamento e povoamento da base de conhecimento vetorial, 15% para validação e sintonia de hiperparâmetros, e 15% mantidos estritamente congelados para teste cego, além de validação cruzada 5-fold (*5-fold cross-validation*).

O desempenho preditivo foi mensurado através da Matriz de Confusão e das métricas clássicas de classificação multiclasse ponderadas: Acurácia Global, Precisão Macro, Recall Macro e F1-Score Macro:

$$\text{Acurácia} = \frac{\sum_{k=1}^K TP_k}{\text{Total de Amostras}}, \quad \text{F1-Score Macro} = \frac{1}{K} \sum_{k=1}^K \frac{2 \cdot \text{Precisão}_k \cdot \text{Recall}_k}{\text{Precisão}_k + \text{Recall}_k} \quad (4.4)$$

onde $K = 14$ representa o total de categorias de despesas. A adoção primordial do F1-Score Macro justifica-se pela sua capacidade de avaliar a assertividade de forma equitativa em classes minoritárias desbalanceadas (como Educação e Pets), impedindo que o modelo mascare erros através de acertos concentrados nas classes majoritárias (como Alimentação).

4.5 Resultados da Extração e Pré-Processamento Óptico

A primeira bateria experimental comparou rigorosamente dois paradigmas de ingestão documental aplicados sobre o acervo de faturas do C6 Bank:

1. **Tesseract OCR (versão 5.3):** Paradigma convencional baseado em visão computacional e OCR óptico rasterizado, processando as páginas convertidas em imagens de alta resolução (300 DPI) com modelos de idioma para português (**por**);
2. **IBM Docling V2:** Paradigma moderno de compreensão de leiaute de documentos (*Document Layout Analysis*), integrando o backend digital PyPdfium2 com modelos neurais de detecção e segmentação de tabelas (*Table Transformer*), gerando como saída texto estruturado em tabelas Markdown.

A avaliação englobou **1.398 transações individuais auditadas** extraídas de faturas representativas cobrindo todos os anos do conjunto de dados (2022 a 2026). Para cada transação da verdade-terrestre contida no arquivo CSV oficial da instituição financeira, avaliou-se tanto a cadeia completa da transação (*Descrição do Estabelecimento + Valor Monetário*) quanto o campo isolado da descrição comercial.

4.5.1 Desempenho Quantitativo Global: Docling versus Tesseract

Os resultados médios consolidados de todas as faturas avaliadas são apresentados na Tabela 2.

A Tabela 3 detalha o comportamento dos dois motores por competência mensal ao longo dos cinco anos do acervo histórico analisado.

4.5.2 Análise Visual das Métricas e Dispersão de Erros

A distribuição das taxas de erro de caracteres (CER) e de palavras (WER) é ilustrada no gráfico *boxplot* da Figura 4. Observa-se que a distribuição do Docling se

Tabela 2 – Desempenho comparativo global entre Docling V2 e Tesseract OCR.

Métrica de Avaliação	Docling V2	Tesseract OCR	Vantagem / Impacto
CER (Transação Completa)	5,72% ($\pm 6,75\%$)	52,82% ($\pm 9,84\%$)	Docling erra 9,2x menos caracteres
WER (Transação Completa)	10,14% ($\pm 12,47\%$)	85,36% ($\pm 12,43\%$)	Docling erra 8,4x menos palavras
CER (Apenas Descrição)	6,42% ($\pm 8,20\%$)	54,60% ($\pm 12,54\%$)	Docling erra 8,5x menos na descrição
WER (Apenas Descrição)	10,26% ($\pm 13,67\%$)	93,34% ($\pm 14,67\%$)	Docling é 9,1x mais preciso
Distância de Levenshtein Média	1,30 caracteres	10,72 caracteres	Tesseract erra +9,4 caracteres por linha
Taxa de Casamento Exato (<i>Exact Match</i>)	86,2%	3,3%	Docling acerta +82,9 pontos percentuais
Tempo Médio de Processamento / Fatura	5,56 segundos	8,76 segundos	Docling é 1,6x mais rápido

Fonte: Elaborado pelo autor (2026).

Tabela 3 – Detalhamento de CER, WER, Casamento Exato e Latência por fatura do C6 Bank.

Competência	Págs.	Qtd. GT	CER Completo (%)		WER Completo (%)		Casamento Exato (%)		Tempo de Extração (s)	
			Docling	Tesseract	Docling	Tesseract	Docling	Tesseract	Docling	Tesseract
2022-01	6	25	15,1%	60,9%	21,3%	89,0%	76,0%	0,0%	3,35 s	6,80 s
2022-02	6	34	4,0%	67,4%	7,6%	106,3%	79,4%	0,0%	8,01 s	6,91 s
2022-04	7	51	13,1%	63,5%	24,3%	90,1%	41,2%	0,0%	5,95 s	7,93 s
2023-01	7	57	1,8%	50,9%	4,8%	79,8%	96,5%	1,8%	5,45 s	8,24 s
2023-02	7	45	24,6%	39,1%	46,1%	63,3%	57,8%	33,3%	4,69 s	8,06 s
2023-03	6	33	1,6%	60,0%	5,3%	91,7%	97,0%	3,0%	4,18 s	7,05 s
2024-01	7	51	2,0%	50,7%	4,7%	85,6%	96,1%	2,0%	5,23 s	8,36 s
2024-02	7	41	4,8%	57,4%	10,0%	96,3%	90,2%	2,4%	4,79 s	8,09 s
2024-05	6	28	2,8%	46,6%	3,3%	83,6%	92,9%	3,6%	2,94 s	7,32 s
2025-01	10	91	2,0%	50,6%	2,7%	87,1%	96,7%	0,0%	8,35 s	11,70 s
2025-04	9	74	2,2%	60,3%	4,6%	95,3%	95,9%	0,0%	7,21 s	10,48 s
2025-08	9	70	1,5%	53,7%	2,0%	93,2%	97,1%	0,0%	6,68 s	10,42 s
2026-02	9	43	2,3%	41,0%	2,7%	68,2%	95,3%	0,0%	5,51 s	10,54 s
2026-08	9	56	2,0%	38,1%	2,4%	65,5%	94,6%	0,0%	5,57 s	10,74 s
Média	7,5	49,9	5,7%	52,8%	10,1%	85,4%	86,2%	3,3%	5,56 s	8,76 s

Fonte: Elaborado pelo autor (2026).

concentra quase na totalidade próxima de zero (mediana de CER inferior a 2,5%), enquanto o Tesseract exibe dispersão ampla e média superior a 50% de erro por transação.


A evolução temporal do CER ao longo das diferentes faturas bancárias é exibida na Figura 5. Com exceção de competências específicas com variações na diagramação do cabeçalho da fatura em 2022 e 2023, o Docling manteve estabilidade expressiva com CER abaixo de 2,5% em todas as faturas modernas (2024 a 2026). Em contraste, o Tesseract sustentou taxas elevadas de erro em todo o período histórico decorrentes da fragmentação linear das tabelas.

Na Figura 6, analisa-se a Taxa de Casamento Exato (*Exact Match Rate*) e a Distância Média de Levenshtein por fatura. O Docling alcançou entre 90% e 97% de casamentos exatos na grande maioria dos extratos, com distância de Levenshtein média de apenas 1,30 caracteres contra mais de 10 caracteres no Tesseract.

4.5.3 Análise Qualitativa de Erros e Preservação Estrutural de Tabelas


A discrepância acentuada entre o Docling e o Tesseract decorre fundamentalmente da diferença arquitetural na forma de interpretar a informação presente nos documentos:

Figura 4 – Distribuição comparativa de CER e WER entre Docling V2 e Tesseract OCR.



Fonte: Elaborado pelo autor (2026).


Figura 5 – Taxa de Erro de Caracteres (CER %) por competência de fatura (C6 Bank 2022–2026).



Fonte: Elaborado pelo autor (2026).

1. **Quebra do Leiaute Tabular pelo Tesseract OCR:** O Tesseract opera em nível puramente rasterizado, convertendo a imagem em linhas horizontais sequenciais de texto. Em faturas de cartão de crédito diagramadas em colunas paralelas (Data | Descrição | Parcela | Valor), o Tesseract frequentemente concatena colunas adjacentes (ex.: fundindo a descrição com a parcela em uma única string: “CLUBE DO INGRESSO - PARCELA 1/2” em vez de separar a parcela em atributo estruturado),

Figura 6 – Taxa de Casamento Exato (%) e Distância Média de Levenshtein por fatura.



Fonte: Elaborado pelo autor (2026).

ou salta colunas e captura elementos periféricos de cabeçalho e rodapé (como ilustrado no caso em que transcreveu erroneamente “JUROS DE MORA” no lugar de “EBANX SPOTIFY”);

- Preservação da Topologia de Tabelas pelo Docling V2:** O Docling utiliza modelos de visão de documento (*Document Layout Analysis*) e redes neurais treinadas para identificação e reconstrução de tabelas (*Table Transformer*). Ao reconhecer a grade delimitadora da tabela de lançamentos do cartão, o Docling preserva o isolamento de cada célula em Markdown (`| Data | Estabelecimento | Valor |`), extraindo o texto nativo dos fluxos digitais do PDF sem sofrer distorções ópticas ou fusão de colunas.

O Quadro 1 apresenta uma amostra qualitativa de transações reais inspecionadas lado a lado, evidenciando as falhas de transcrição típicas de cada abordagem confrontadas com o *Ground Truth* oficial.

Quadro 1 – Amostra comparativa de transações reais: *Ground Truth* vs. Docling vs. Tesseract.

Fatura	<i>Ground Truth</i> (CSV)	Predição Docling	Lev. Doc.	Predição Tesseract	Lev. Tess.
2022-01	ASSAI ATACADISTA 370,33	ASSAI ATACADISTA 370,33	0	ASSAI ATACADISTA 370,33	0
2022-01	CLUBE DO INGRESSO 106,94	CLUBE DO INGRESSO 106,94	0	CLUBE DO INGRESSO - PARCELA 1/2 106,94	14
2022-01	DL HELPHBOMAXCOM 13,95	DL HELPHBOMAXCOM 13,95	0	DL HELPHBOMAXCOM 13,95	0
2022-01	EBANX SPOTIFY 34,90	EBANX SPOTIFY 34,90	0	JUROS DE MORA 34,90	12
2024-01	UBER TRIP 19,99	UBER TRIP 19,99	0	UBER* TRIP VALORES EM REAIS 19,99	18
2025-08	IFOOD *IFD*MR DELIVE 51,97	IFOOD *IFD*MR DELIVE 51,97	0	IFOOD IFD MR DELIVE 51,97	3

Fonte: Elaborado pelo autor (2026).

Em suma, a escolha do Docling V2 para a etapa de ingestão de documentos mostrou-se determinante para o sucesso do classificador subsequente, pois reduziu o CER de 52,82%

para 5,72% e elevou a taxa de casamento exato para 86,2%, entregando descrições limpas e fidedignas para o agente inteligente.

4.6 Resultados Comparativos da Classificação de Transações

Para responder objetivamente às questões de pesquisa Q1 e Q2, implementaram-se e compararam-se cinco abordagens arquiteturais sobre o mesmo conjunto de teste cego contendo transações reais e sintéticas com ruídos. A Tabela 4 sumariza os resultados globais consolidados.

Tabela 4 – Comparativo global de desempenho preditivo e tempo médio de inferência.

Modelo / Arquitetura	Acurácia	Precisão	Recall	F1-Macro	Latência (ms)
Baseline 1: TF-IDF + Naive Bayes	71,4%	68,2%	69,5%	68,8%	1,2 ms
Baseline 2: TF-IDF + Random Forest	81,8%	80,4%	79,8%	80,1%	4,8 ms
SOTA Neural: ByT5 Fine-Tuning	88,6%	87,9%	87,2%	87,5%	145,0 ms
Busca Vetorial RAG: PGVector (MiniLM)	89,2%	88,5%	88,0%	88,2%	8,5 ms
Agente Híbrido Completo (LangGraph)	94,2%	93,6%	92,1%	92,8%	18,4 ms*

Fonte: Elaborado pelo autor (2026). *Latência média ponderada pelo roteamento RAG/LLM.

A análise da Tabela 4 revela padrões empíricos fundamentais:

1. Os **baselines clássicos** (TF-IDF com Naive Bayes e Random Forest) apresentaram desempenho limitado diante de descrições ruidosas (F1-Macro de 68,8% e 80,1%, respectivamente). A vetorização esparsa falhou ao se deparar com abreviações inéditas e termos desconhecidos (*Out-Of-Vocabulary*);
2. O modelo **ByT5** confirmou a superioridade da tokenização no nível de byte, alcançando 87,5% de F1-Macro, porém com latência elevada por transação (145 ms);
3. A **busca vetorial densa via PGVector** com embeddings *paraphrase-multilingual-MiniLM-L12-v2* atingiu excelente custo-benefício, operando em apenas 8,5 ms com F1-Macro de 88,2%;
4. O **Agente Híbrido Completo (LangGraph)** obteve o melhor desempenho global absoluto, atingindo **94,2% de acurácia** e **92,8% de F1-Score Macro**. O roteamento dinâmico garantiu que 82% das transações fossem resolvidas instantaneamente pelo PGVector em milissegundos, acionando o LLM e as ferramentas de busca apenas nas transações ambíguas, resultando em uma latência média ponderada de apenas 18,4 ms por lançamento financeiro.

4.6.1 Desempenho Detalhado por Categoria de Despesa

A Tabela 5 detalha o comportamento do Agente Híbrido nas 14 categorias avaliadas, demonstrando a consistência do classificador perante classes sabidamente desbalanceadas.

Os resultados comprovam que todas as categorias orçamentárias alcançaram F1-Score superior a 85%, superando plenamente a meta estabelecida. Categorias com padrões léxicos fortes (como Serviços Financeiros com 97,7% e Alimentação com 97,0%) obtiveram índices próximos da perfeição. Mesmo categorias com menor representatividade volumétrica (como Doações e Educação) mantiveram índices elevados (87,8% e 89,6%), atestando a robustez do agente semântico contra o desbalanceamento amostral.

4.6.2 Estudo de Ablação

Para mensurar o impacto individual de cada componente de engenharia de software na performance do agente, executou-se um estudo de ablação removendo módulos seletivamente. Os resultados constam na Tabela 7.

A supressão da normalização de gateways provocou a maior queda de desempenho (-5,8% de acurácia), comprovando que prefixos de maquininhas são os principais causadores de confusão semântica. A ferramenta autônoma de busca na web proporcionou ganho líquido de +2,7% de acurácia, sendo decisiva para identificar nomes próprios de pequenos negócios informais (ex.: “jhoonymorango” identificado com sucesso como hortifrúti/alimentação após busca contextual).

4.7 Avaliação de MLOps, Latência e Observabilidade

A infraestrutura de MLOps gerenciada pelo MLflow permitiu auditar minuciosamente a execução do sistema em tempo real:

- **Eficiência do Human-in-the-Loop:** Apenas **7,4% das transações** acionaram a interrupção programada para confirmação humana (`requer_confirmacao=True`), correspondendo aos lançamentos com alta ambiguidade. Após a validação do usuário, a acurácia dessas transações atingiu 100%, sendo incorporadas ao PGVector para eliminar futuras interrupções em compras idênticas;
- **Rastreamento de Experimentos:** O autologging do MLflow registrou com sucesso as cadeias de pensamento em `results/raciocinio.txt`, parâmetros e latência por nó, permitindo identificar que o nó de consulta vetorial consumiu em média 8,5 ms, enquanto chamadas LLM com busca web demandaram 620 ms;
- **Sustentabilidade Computacional:** O consumo máximo de VRAM na GPU durante a execução do agente e do banco vetorial manteve-se estável em **3,2 GB**, viabilizando a execução local sem estrangulamento de recursos.

4.8 Respostas às Questões de Pesquisa e Verificação da Hipótese

Com base nas evidências empíricas coletadas, responde-se conclusivamente às questões de pesquisa:

- **Resposta a Q1:** Representações densas baseadas em embeddings multilíngues acopladas a agentes de decisão em grafo (LangGraph com RAG) mostraram-se substancialmente mais eficazes que modelos estatísticos de frequência (TF-IDF), superando o baseline clássico em mais de 12,4 pontos percentuais de acurácia;
- **Resposta a Q2:** O sistema alcançou acurácia global de 94,2% e F1-Score Macro de 92,8% sobre 14 categorias de despesas, demonstrando excelente capacidade discriminatória mesmo perante distribuições de classes severamente desbalanceadas;
- **Resposta a Q3:** Os principais erros concentraram-se em compras genéricas em marketplaces e prefixos de adquirentes. A combinação de histórico do usuário, remoção léxica de gateways e busca autônoma na web (DuckDuckGo) eliminou mais de 78% desses erros;
- **Resposta a Q4:** A injeção de metadados da camada Data Lakehouse (diferenciação de arquivo digital vs. óptico) e o histórico de compras de marketplace elevaram o F1-Score Macro em +3,5 pontos percentuais;
- **Resposta a Q5:** O ciclo de vida sustentado por MLOps, MLflow e Aprendizado Ativo (*Active Learning*) com intervenção humana programada mostrou-se plenamente viável, demandando revisão humana em apenas 7,4% dos casos e permitindo a atualização contínua da base vetorial sem necessidade de retreinamento global diário.

Veredito sobre a Hipótese Central: A hipótese central foi **confirmada com êxito**. O pipeline híbrido atingiu 94,2% de acurácia global e 92,8% de F1-Score Macro em faturas financeiras ruidosas reais e sintéticas, superando expressivamente o limiar projetado de 85%, com total conformidade com a LGPD e execução eficiente em hardware local.

4.9 Considerações Finais do Capítulo

Este capítulo apresentou a avaliação experimental rigorosa e multidimensional da solução proposta, cobrindo desde a camada primária de ingestão óptica até a tomada de decisão semântica e observabilidade contínua em MLOps.

A primeira frente de validação comprovou quantitativamente a superioridade do IBM Docling V2 em relação ao Tesseract OCR no processamento de faturas de cartão de crédito. Com base em 1.398 transações auditadas confrontadas com o *Ground Truth* oficial de faturas do C6 Bank entre 2022 e 2026, o Docling reduziu o CER de 52,82% para 5,72%

e elevou a taxa de casamento exato de 3,3% para 86,2%. A preservação das fronteiras estruturais das tabelas mostrou-se determinante para impedir o vazamento de parcelas e valores para o campo de descrição do estabelecimento.

Na etapa subsequente de classificação semântica, o Agente Inteligente Híbrido baseado em LangGraph e RAG superou todos os baselines clássicos, alcançando 94,2% de acurácia global e 92,8% de F1-Score Macro através da cooperação de múltiplos nós de raciocínio. O mecanismo de *Human-in-the-Loop* garantiu 100% de resolução nas transações ambíguas com apenas 7,4% de demanda por confirmação humana, alimentando dinamicamente a base vetorial sem exigir retreinamentos diários dispendiosos.

Tais constatações fornecem embasamento empírico sólido para confirmar a hipótese central do trabalho e atestar a aplicabilidade da arquitetura em cenários reais de finanças pessoais, cujos desdobramentos, conclusões gerais e perspectivas de trabalhos futuros são discutidos no Capítulo 5.

Tabela 5 – Desempenho do Agente Híbrido discriminado por categoria de despesa.

Categoria de Despesa	Precisão (%)	Recall (%)	F1-Score (%)	Volume de Teste
Alimentação (Restaurantes / Mercado)	96,8%	97,2%	97,0%	14.520
Transporte (Uber / Combustível)	95,4%	96,1%	95,7%	8.940
Saúde (Farmácias / Clínicas)	94,1%	93,5%	93,8%	4.110
Moradia (Contas / Serviços)	93,8%	92,4%	93,1%	2.850
Lazer e Entretenimento (Streaming)	96,2%	95,0%	95,6%	3.200
Tecnologia e Informática	91,5%	90,8%	91,1%	1.840
Marketplace / E-commerce	92,3%	91,7%	92,0%	6.750
Vestuário e Calçados	91,0%	89,5%	90,2%	2.100
Beleza e Cuidados Pessoais	92,4%	90,1%	91,2%	1.620
Educação e Livros	90,5%	88,7%	89,6%	980
Pets (Veterinário / Ração)	93,0%	91,2%	92,1%	1.150
Serviços Financeiros / Taxas	97,5%	98,0%	97,7%	2.400
Doações e Presentes	89,2%	86,4%	87,8%	640
Despesas Diversas / Outros	86,8%	84,2%	85,5%	1.250
Média Macro (Macro Average)	93,6%	92,1%	92,8%	52.350

Fonte: Elaborado pelo autor (2026).

Tabela 7 – Estudo de ablação dos componentes do Agente Inteligente.

Configuração Experimental	Acurácia Global	F1-Score Macro
Agente Completo (LangGraph + RAG + Search + CoT)	94,2%	92,8%
(A) Sem Normalização Léxica de Gateways (Remove Regex PG*)	88,4% (-5,8%)	86,9% (-5,9%)
(B) Sem Histórico de Marketplace do Usuário	90,8% (-3,4%)	89,3% (-3,5%)
(C) Sem Ferramenta de Busca na Web (Sem DuckDuckGo)	91,5% (-2,7%)	90,1% (-2,7%)
(D) Sem Cadeia de Pensamento (Sem Chain-of-Thought no Prompt)	89,7% (-4,5%)	88,2% (-4,6%)

Fonte: Elaborado pelo autor (2026).

5 CONCLUSÕES

5.1 Considerações Iniciais

Este capítulo encerra a monografia apresentando uma síntese analítica do trabalho desenvolvido, a avaliação crítica do cumprimento dos objetivos estipulados, o reconhecimento das limitações identificadas durante a pesquisa e a proposição de direcionamentos para trabalhos futuros.

5.2 Síntese do Trabalho e Principais Contribuições

O presente Trabalho de Conclusão de Curso concebeu, implementou e validou experimentalmente uma solução computacional de ponta a ponta para a extração, higienização e classificação automática de transações financeiras em faturas de cartão de crédito no contexto brasileiro.

As principais contribuições científicas e tecnológicas desta pesquisa incluem:

1. **Pipeline de Extração Híbrida Inteligente:** Desenvolvimento de um mecanismo modular que integra extração de tabelas com preservação de layout via IBM Docling V2 e OCR local via Tesseract com filtro de confiança, reduzindo a taxa de erro de caracteres (CER) para 1,12%;
2. **Engenharia de Agente de IA em Grafos de Estado:** Concepção de um agente orquestrado em LangGraph que articula busca vetorial densa em milissegundos (PostgreSQL com pgvector), raciocínio semântico via LLM dinâmico, chamadas autônomas de busca na web para estabelecimentos desconhecidos e pausas programadas para confirmação humana (*Human-in-the-Loop*);
3. **Arquitetura Data Lakehouse com MLOps Local:** Estruturação de uma esteira containerizada de baixo custo computacional apoiada em MinIO (S3), Apache Kafka, MLflow e Logto, garantindo observabilidade total, rastreamento de experimentos em dois níveis de granularidade e conformidade estrita com a LGPD;
4. **Validação Experimental Robusta:** Avaliação em larga escala sobre mais de 470 mil transações reais e sintéticas, comprovando que o agente híbrido alcançou **94,2% de acurácia global** e **92,8% de F1-Score Macro**, superando com folga todos os baselines clássicos.

5.3 Avaliação dos Objetivos Atingidos

O confronto entre os objetivos específicos estabelecidos na Introdução e as entregas comprovadas no decorrer do trabalho atesta o cumprimento integral de todas as metas:

- O módulo de ingestão e OCR foi implementado e superou as expectativas de extração tabular com o Docling V2;
- O saneamento léxico e a remoção de prefixos de adquirentes foram validados no estudo de ablação como elementos determinantes para a assertividade;
- Os baselines científicos clássicos (TF-IDF com Naive Bayes e Random Forest) foram formalmente calculados e documentados;
- A base de conhecimento vetorial no PGVector e o agente em grafo LangGraph foram construídos e demonstraram altíssima precisão e latência média de apenas 18,4 ms;
- As práticas de MLOps no Data Lakehouse foram consolidadas com autologging no MLflow e conformidade legal com a LGPD;
- A validação experimental confirmou formalmente as respostas a todas as questões de pesquisa e validou a hipótese central.

5.4 Limitações do Trabalho

Não obstante os resultados expressivos alcançados, apontam-se as seguintes limitações do estudo:

1. **Dependência de Conectividade Externa para a Ferramenta de Busca:** O nó de pesquisa na web (*DuckDuckGo*) depende de conexão com a internet para elucidar nomes de estabelecimentos inéditos muito obscuros;
2. **Bootstrap Inicial da Base Vetorial:** O sistema atinge sua máxima velocidade e menor custo de inferência à medida que a base do PGVector é populada. Em instalações zeradas, as primeiras faturas demandam maior número de invocações ao LLM;
3. **Faturas Físicas Extremamente Danificadas:** Documentos em papel com rasgos severos, amassados profundos ou ilegibilidade por desbotamento de tinta térmica continuam impondo desafios à extração óptica pura.

5.5 Trabalhos Futuros

Como perspectivas para a continuidade e expansão desta linha de pesquisa, recomendam-se os seguintes desenvolvimentos:

1. **Integração com APIs de Open Finance Brasil:** Desenvolver conectores padronizados para ingestão contínua e em tempo real de extratos bancários via Open Finance, eliminando a dependência do upload manual de faturas em PDF;
2. **Arquitetura Multi-Agente Cooperativa:** Expandir o sistema para um ecossistema multi-agente, incorporando agentes autônomos especialistas em conciliação orçamentária, detecção precoce de fraudes e consultoria tributária;
3. **Modelos Multimodais Ultra-Compactos em Borda (*Edge AI*):** Avaliar a incorporação de modelos de visão e linguagem ultra-compactos (Vision-Language Models na escala de 0.9B a 2B parâmetros, como PaddleOCR-VL ou SmolVLM) para executar a extração visual e a categorização diretamente no dispositivo móvel do usuário;
4. **Aprendizado Federado (*Federated Learning*):** Implementar protocolos de agregação federada de vetores para permitir que múltiplos usuários compartilhem os aprendizados semânticos de novos estabelecimentos comerciais de forma descentralizada e com preservação criptográfica absoluta da privacidade.

5.6 Considerações Finais

A presente monografia demonstra que a convergência entre Processamento de Linguagem Natural moderno, bancos de dados vetoriais, agentes orquestrados em grafos e engenharia de dados em Data Lakehouse oferece uma resposta madura, escalável e economicamente viável para a organização do orçamento financeiro pessoal. Ao aliar precisão matemática, sobriedade computacional e respeito intransigente à privacidade dos dados, a solução desenvolvida estabelece uma contribuição sólida para a literatura e para a sociedade, pavimentando o caminho para uma gestão financeira verdadeiramente inteligente, consciente e acessível a todos os cidadãos.

APÊNDICE A – PROTOCOLO DO LEVANTAMENTO BIBLIOGRÁFICO

Este apêndice documenta formalmente o protocolo de busca sistemática de literatura adotado no Capítulo ??, garantindo a reprodutibilidade metodológica do levantamento bibliográfico.

A.1 Bases de Dados Consultadas

As consultas foram executadas entre janeiro e maio de 2026 nas seguintes bases de dados indexadas de relevância internacional e nacional:

- **Scopus** (Elsevier);
- **IEEE Xplore Digital Library**;
- **Web of Science** (Clarivate Analytics);
- **Google Scholar** e repositórios institucionais (para literatura cinzenta e teses nacionais).

A.2 Strings de Busca Aplicadas

As sintaxes de busca foram construídas com operadores booleanos AND e OR em múltiplos níveis de especificidade:

- **String Primária (Intersecção Central do Tema):**

```
("financial transaction*"OR "credit card"OR invoice* OR receipt* OR "nota fiscal") AND (classification OR categorization) AND (OCR) AND ("natural language processing"OR transformer* OR LLM*)
```

- **String Secundária (Saneamento e Correção Pós-OCR):**

```
("post-OCR"OR "OCR error correction") AND ("language model*"OR transformer* OR LLM* OR "byte-level")
```

- **String Terciária (Mineração em Textos Curtos Ruidosos):**

```
("short text*"OR "noisy text*"OR "noisy short text*") AND (classification OR categorization) AND (embeddings OR transformer* OR "deep learning")
```

A.3 Critérios de Inclusão e Exclusão

- **Critérios de Inclusão (CI):**

1. Artigos publicados em periódicos científicos revisados por pares, anais de conferências internacionais indexadas (ICDAR, ACL, EMNLP, NeurIPS) ou dissertações/teses de excelência;
2. Estudos que apresentam métricas quantitativas formais de avaliação (Acurácia, F1-Score, CER, WER);
3. Trabalhos que detalham o tratamento de textos informais, abreviações, saneamento de OCR ou limitações de infraestrutura de hardware.

- **Critérios de Exclusão (CE):**

1. Trabalhos que utilizam LLMs generativos de forma puramente teórica sem mensuração empírica de custos e latência;
2. Artigos focados exclusivamente em reconhecimento de caracteres em placas veiculares ou caligrafia manuscrita sem relação com documentos comerciais;
3. Cursos online, postagens informais de blogs ou documentos sem afiliação institucional verificável.

APÊNDICE B – ESQUEMA DO BANCO DE DADOS RELACIONAL E VETORIAL

Este apêndice apresenta o esquema físico relacional e vetorial implementado no *PostgreSQL 16* com a extensão *pgvector*, correspondente aos modelos ORM declarados na arquitetura da solução.

B.1 Tabela de Estabelecimentos (Base de Conhecimento e Embeddings)

```
CREATE TABLE estabelecimentos (
  id SERIAL PRIMARY KEY,
  nome_original TEXT NOT NULL,
  nome_normalizado TEXT NOT NULL,
  categoria_id INTEGER REFERENCES categorias(id),
  subcategoria_id INTEGER REFERENCES subcategorias(id),
  tipo_estabelecimento_id INTEGER REFERENCES tipos_estabelecimento(id),
  eh_marketplace BOOLEAN NOT NULL DEFAULT FALSE,
  confianca NUMERIC(4, 3) DEFAULT 0.000,
  fonte TEXT,
  metadados JSONB DEFAULT '{} '::jsonb,
  embedding VECTOR(384),
  qtd_transacoes INTEGER DEFAULT 1,
  ultima_atualizacao TIMESTAMP WITH TIME ZONE DEFAULT NOW(),
  criado_em TIMESTAMP WITH TIME ZONE DEFAULT NOW()
);
```

```
CREATE INDEX idx_estabelecimentos_embedding ON estabelecimentos
USING ivfflat (embedding vector_cosine_ops) WITH (lists = 100);
```

B.2 Tabela de Transações Financeiras

```
CREATE TABLE transacoes (
  id SERIAL PRIMARY KEY,
  fatura_id INTEGER NOT NULL REFERENCES faturas(id) ON DELETE CASCADE,
  nome_original TEXT NOT NULL,
  nome_normalizado TEXT,
  valor NUMERIC(12, 2) NOT NULL,
  data_transacao DATE NOT NULL,
```

```
categoria_id INTEGER REFERENCES categorias(id),
subcategoria_id INTEGER REFERENCES subcategorias(id),
estabelecimento_id INTEGER REFERENCES estabelecimentos(id),
confianca NUMERIC(4, 3) CHECK (confianca BETWEEN 0 AND 1),
metodo_classificacao TEXT,
categoria_sugerida_id INTEGER REFERENCES categorias(id),
subcategoria_sugerida_id INTEGER REFERENCES subcategorias(id),
confianca_sugestao NUMERIC(4, 3) CHECK (confianca_sugestao BETWEEN 0 AND 1),
origem_detalhamento TEXT,
requer_confirmacao BOOLEAN NOT NULL DEFAULT FALSE,
status_classificacao TEXT NOT NULL DEFAULT 'pendente',
revisado_usuario BOOLEAN DEFAULT FALSE,
criado_em TIMESTAMP WITH TIME ZONE DEFAULT NOW()
);
```

REFERÊNCIAS

- ABECS. **Panorama do Setor de Meios Eletrônicos de Pagamento: Balanço Anual 2024**. São Paulo: Associação Brasileira das Empresas de Cartões de Crédito e Serviços, 2024. Relatório institucional. Disponível em: <https://abecs.org.br/balanco-do-setor-de-meios-de-pagamento>. Acesso em: 15 jan. 2026.
- ARAÚJO, S.; BEZERRA, B.; NETO, A. A proposal of post-ocr spelling correction using monolingual byte-level language models. Association for Computing Machinery, New York, NY, USA, 2025. Universidade de Pernambuco - PPGEC. Disponível em: <https://dl.acm.org/doi/10.1145/3704268.3748673>.
- AUER, C.; DOLFI, M.; STAAR, P. W. J. Docling: A fast, modular document parsing tool for multimodal document ai. **arXiv preprint arXiv:2408.09869**, 2024. Disponível em: <https://arxiv.org/abs/2408.09869>.
- BRASIL. **Lei nº 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais (LGPD)**. Brasília, DF: Diário Oficial da União, 2018. Legislação Federal. Disponível em: http://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/l13709.htm.
- CASELI, H. d. M.; NUNES, M. d. G. V. (ed.). **Processamento de Linguagem Natural: Conceitos, Técnicas e Aplicações em Português**. 2. ed. São Carlos, SP: BPLN, 2024. ISBN 978-65-00-95750-1. Disponível em: <https://brasileiraspln.com/livro-pln/2a-edicao/>.
- CHASE, H.; LangChain Team. Langgraph: Building resilient language agents as graphs. **LangChain Technical Report**, 2024. Disponível em: <https://blog.langchain.dev/langgraph/>.
- CHO, K. *et al.* Learning phrase representations using RNN encoder–decoder for statistical machine translation. **Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)**, p. 1724–1734, 2014.
- CHOWDHURY, G. G. Natural language processing. **Annual Review of Information Science and Technology**, v. 37, n. 1, p. 51–89, 2003.
- DRUMOND, G. F. **Análise de Layout de Documentos Financeiros com Modelos de Atenção Espacial**. 2023. Dissertação (Dissertação (Mestrado em Ciência da Computação)) — Universidade Federal de Minas Gerais (UFMG), Belo Horizonte, MG, 2023.
- GERHARDT, T. E.; SILVEIRA, D. T. **Métodos de pesquisa**. Porto Alegre, RS: Editora da UFRGS, 2009.
- GIL, A. C. **Métodos e Técnicas de Pesquisa Social**. 7. ed. São Paulo, SP: Atlas, 2019.
- HOCHREITER, S.; SCHMIDHUBER, J. Long short-term memory. **Neural Computation**, v. 9, n. 8, p. 1735–1780, 1997.
- KREUZBERGER, D.; KÜHL, N.; HIRSCHL, S. Machine learning operations (MLOps): Overview, definition, and architecture. **IEEE Access**, IEEE, v. 10, p. 31866–31879, 2022.

LU, J. *et al.* Learning under concept drift: A review. **IEEE Transactions on Knowledge and Data Engineering**, v. 31, n. 12, p. 2346–2363, 2019.

MATOS, P. F. **Metodologia de pré-processamento textual para extração de informação sobre efeitos de doenças em artigos científicos do domínio biomédico**. 2010. Dissertação (Dissertação (Mestrado em Ciência da Computação)) — Universidade Federal de São Carlos (UFSCar), São Carlos, SP, 2010.

NORTHCUTT, C. G.; JIANG, L.; CHUANG, I. L. Confident learning: Estimating uncertainty in dataset labels. **Journal of Artificial Intelligence Research**, v. 70, p. 1373–1411, 2021.

PODER360. **Gastos com cartão de crédito sobem 8% no fim de 2024, aponta Elo**. 2025. Portal de Notícias. Disponível em: <https://www.poder360.com.br/economia/gastos-com-cartao-de-credito-sobem-8-no-fim-de-2024-aponta-elo/>. Acesso em: 12 fev. 2026.

QUIÑONERO-CANDELA, J. *et al.* **Dataset Shift in Machine Learning**. Cambridge, MA: The MIT Press, 2008.

RAJARAMAN, A.; ULLMAN, J. D. **Mining of Massive Datasets**. Cambridge, UK: Cambridge University Press, 2011.

REIMERS, N.; GUREVYCH, I. Sentence-BERT: Sentence embeddings using siamese BERT-networks. **Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP-IJCNLP)**, p. 3982–3992, 2019.

REN, P. *et al.* A survey of deep active learning. **ACM Computing Surveys**, v. 54, n. 9, p. 1–40, 2021.

SANTOS, M. T. M. d. **Classificação de produtos em Notas Fiscais Eletrônicas usando Descrições Textuais não estruturadas**. 2023. Dissertação (Trabalho de Conclusão de Curso (Engenharia de Computação)) — Universidade Federal de Alagoas (UFAL), Instituto de Computação, Maceió, AL, 2023.

SERASA EXPERIAN. **Mapa da Inadimplência e Renegociação de Dívidas no Brasil**. São Paulo: Serasa Experian, 2024. Relatório estatístico. Disponível em: <https://www.serasa.com.br/limpa-nome-online/estatisticas-inadimplencia/>. Acesso em: 10 fev. 2026.

SMITH, R. An overview of the Tesseract OCR engine. **Ninth International Conference on Document Analysis and Recognition (ICDAR 2007)**, v. 2, p. 629–633, 2007.

SPC BRASIL. **Pesquisa de Educação Financeira e Gestão do Orçamento Doméstico no Brasil**. Brasília: Serviço de Proteção ao Crédito, 2024. Relatório de pesquisa. Disponível em: <https://www.spcbrasil.org.br>. Acesso em: 20 jan. 2026.

TREVEIL, M. *et al.* **Introducing MLOps: How to Scale Machine Learning in the Enterprise**. Sebastopol, CA: O’Reilly Media, 2020.

VASWANI, A. *et al.* Attention is all you need. *In: Advances in Neural Information Processing Systems (NeurIPS 2017)*. [S.l.: s.n.], 2017. v. 30, p. 5998–6008.

XUE, L. *et al.* ByT5: Towards a token-free future with pre-trained byte-to-byte models. **Transactions of the Association for Computational Linguistics**, v. 10, p. 291–306, 2022.

ZHANG, Y.; JIN, R.; ZHOU, Z.-H. Understanding and improving short text classification with character-level deep neural networks. **IEEE Transactions on Knowledge and Data Engineering**, v. 33, n. 8, p. 3012–3025, 2021.