

UNIVERSIDADE DE SÃO PAULO

Instituto de Ciências Matemáticas e de Computação

**Extração e classificação automática de transações
em faturas de cartão de crédito com preservação de
leiaute e agentes de linguagem em infraestrutura
local**

Luiz Henrique Monteiro Silva de Lima

Monografia - MBA em Inteligência Artificial e Big Data

SERVIÇO DE PÓS-GRADUAÇÃO DO ICMC-USP

Data de Depósito:

Assinatura: _____

Luiz Henrique Monteiro Silva de Lima

Extração e classificação automática de transações em faturas de cartão de crédito com preservação de leiaute e agentes de linguagem em infraestrutura local

Trabalho de conclusão de curso apresentado ao Departamento de Ciências de Computação do Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo - ICMC/USP, como parte dos requisitos para obtenção do título de Especialista em Inteligência Artificial e Big Data.

Área de concentração: Inteligência Artificial

Orientador: Prof. Dr. Ricardo Rodrigues Ciferri

Versão original

São Carlos

2026

AUTORIZO A REPRODUÇÃO E DIVULGAÇÃO TOTAL OU PARCIAL DESTA TRABALHO,
POR QUALQUER MEIO CONVENCIONAL OU ELETRÔNICO PARA FINS DE ESTUDO E
PESQUISA, DESDE QUE CITADA A FONTE.

Ficha catalográfica elaborada pela Biblioteca Prof. Achille Bassi, ICMC/USP, com os dados
fornecidos pelo(a) autor(a)

S856m	Lima, Luiz Henrique Monteiro Silva de Extração e classificação automática de transações em faturas de cartão de crédito com preservação de layout e agentes de linguagem em infraestrutura local / Luiz Henrique Monteiro Silva de Lima ; orientador Ricardo Rodrigues Ciferri. – São Carlos, 2026. 147 p. : il. (algumas color.) ; 30 cm. Monografia (MBA em Inteligência Artificial e Big Data) – Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, 2026. Classificação de transações financeiras. Processamento de linguagem natural. Geração aumentada por recuperação. Reconhecimento óptico de caracteres. Agentes inteligentes. I. Ciferri, Ricardo Rodrigues, orient. II. Título.
-------	--

Luiz Henrique Monteiro Silva de Lima

**Automatic extraction and classification of transactions in
credit card statements with layout preservation and
language agents on local infrastructure**

Monograph presented to the Departamento de Ciências de Computação do Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo - ICMC/USP, as part of the requirements for obtaining the title of Specialist in Artificial Intelligence and Big Data.

Concentration area: Artificial Intelligence

Advisor: Prof. Dr. Ricardo Rodrigues Ciferri

Original version

São Carlos

2026

Dedico este trabalho aos meus pais e à minha família, pelo apoio incondicional, amor e paciência durante todas as etapas desta jornada acadêmica.

AGRADECIMENTOS

Agradeço primeiramente a Deus, por me conceder força, sabedoria e guiar os meus passos ao longo de toda essa jornada.

À minha família, por todo amor, dedicação e pelos valores que me transmitiram ao longo da vida, me apoiando em tudo, incondicionalmente.

Aos professores e tutores do curso, que compartilharam seus conhecimentos e experiências, contribuindo imensamente para a minha evolução e para a construção de meu futuro profissional.

Ao meu orientador, Prof. Dr. Ricardo Rodrigues Ciferri, por todo o apoio, disponibilidade e, sobretudo, pela orientação precisa e enriquecedora, fundamentais para o desenvolvimento desse trabalho com qualidade e profundidade.

À coordenadora Solange, pelos valiosos conselhos e presença atenta, bem como a todo o quadro de coordenadores, sempre prontos a esclarecer dúvidas, acolher sugestões e incentivar os alunos em cada etapa dessa trajetória.

Por fim, expresso minha profunda gratidão a todas as pessoas que, direta ou indiretamente, fizeram parte deste ciclo. Esta conquista é também de vocês, e o sucesso desta jornada não seria possível sem o apoio e o incentivo de cada um.

RESUMO

LIMA, L. H. M. S. **Extração e classificação automática de transações em faturas de cartão de crédito com preservação de leiaute e agentes de linguagem em infraestrutura local**. 2026. 147 p. Monografia (MBA em Inteligência Artificial e Big Data) - Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos, 2026.

Descrições de transações em faturas de cartão de crédito são curtas, despadronizadas e ruidosas: trazem abreviações truncadas, prefixos de intermediadores de pagamento e erros introduzidos na leitura do documento. Esse ruído inviabiliza a categorização automática de despesas e, com ela, o planejamento orçamentário pessoal. Esta pesquisa teve por objetivo conceber, implementar e avaliar experimentalmente uma solução computacional de ponta a ponta para a extração, o saneamento e a classificação automática de despesas no contexto brasileiro, executável em infraestrutura local e aderente à Lei Geral de Proteção de Dados Pessoais. A solução combina extração documental com preservação de leiaute tabular, rotinas determinísticas de normalização léxica e um agente orquestrado em grafo de estados, que articula busca vetorial densa, raciocínio com um grande modelo de linguagem local e confirmação humana em casos de baixa confiança, sobre uma infraestrutura de dados em camadas com rastreamento de experimentos. A avaliação empregou dois conjuntos de dados reais: 699 transações auditadas contra os arquivos oficiais da instituição emissora, para medir a qualidade da extração, e 1.660 transações rotuladas em 11 categorias, para comparar cinco arquiteturas sob teste cego com estabelecimentos disjuntos entre treino e teste. A extração com preservação de leiaute reduziu a taxa de erro de caracteres de 52,82% para 5,72% e elevou o casamento exato de 3,3% para 86,2%. Na classificação, a representação esparsa por n -gramas de caractere associada a Random Forest obteve o melhor F1-Macro (69,3%), sem diferença estatisticamente significativa frente à busca vetorial densa em sua melhor configuração (66,8%; teste de McNemar, $p = 0,86$), e à frente do agente híbrido (60,0%) e do ajuste fino de um modelo no nível de byte (48,3%). A hipótese central, enunciada sobre a esteira híbrida, foi refutada em suas duas subhipóteses: nenhuma arquitetura alcançou o limiar de 85% de F1-Macro. O achado de maior alcance metodológico é a diferença de 23 a 25 pontos percentuais entre a validação cruzada convencional e o teste cego por estabelecimento, que quantifica quanto do desempenho aparente desse tipo de classificador decorre da memorização de comércios já observados. Conclui-se que a esteira proposta é funcionalmente viável e auditável sob restrições de hardware local, e que sua eficácia preditiva permanece condicionada ao volume e à cobertura do acervo rotulado.

Palavras-chave: Classificação de transações financeiras. Processamento de linguagem

natural. Busca vetorial por similaridade. Reconhecimento óptico de caracteres. Agentes inteligentes.

ABSTRACT

LIMA, L. H. M. S. **Automatic extraction and classification of transactions in credit card statements with layout preservation and language agents on local infrastructure.** 2026. 147 p. Monograph (MBA in Artificial Intelligence and Big Data) - Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos, 2026.

Transaction descriptions in credit card statements are short, non-standardized and noisy: they contain truncated abbreviations, payment intermediary prefixes and errors introduced during document reading. This noise prevents the automatic categorization of expenses and, with it, personal budget planning. The objective of this research was to design, implement and experimentally evaluate an end-to-end computational solution for the extraction, sanitization and automatic classification of expenses in the Brazilian context, executable on local infrastructure and compliant with the Brazilian General Data Protection Law. The solution combines document extraction with tabular layout preservation, deterministic lexical normalization routines and an agent orchestrated as a state graph, which articulates dense vector retrieval, reasoning with a local large language model and human confirmation in low-confidence cases, on a layered data infrastructure with experiment tracking. The evaluation used two sets of real data: 699 transactions audited against the issuing institution's official files, to measure extraction quality, and 1,660 transactions labeled into 11 categories, to compare five architectures under a merchant-disjoint blind test. Layout-preserving extraction reduced the character error rate from 52.82% to 5.72% and raised the exact match rate from 3.3% to 86.2%. In classification, the sparse representation based on character n -grams combined with Random Forest achieved the best Macro-F1 (69.3%), with no statistically significant difference from dense vector retrieval in its best configuration (66.8%; McNemar's test, $p = 0.86$), and ahead of the hybrid agent (60.0%) and the fine-tuning of a byte-level model (48.3%). The central hypothesis, stated for the hybrid pipeline, was refuted in both of its sub-hypotheses: no architecture reached the 85% Macro-F1 threshold. The finding of widest methodological reach is the gap of 23 to 25 percentage points between conventional cross-validation and the merchant-disjoint blind test, which quantifies how much of the apparent performance of this class of classifier stems from memorizing previously observed merchants. It is concluded that the proposed pipeline is functionally viable and auditable under local hardware constraints, and that its predictive effectiveness remains conditioned on the volume and coverage of the labeled corpus.

Keywords: Financial transaction classification. Natural language processing. Vector

similarity search. Optical character recognition. Intelligent agents.

LISTA DE FIGURAS

Figura 1 – Arquitetura em camadas inspirada no paradigma <i>lakehouse</i> , orientada a eventos, com MLOps e agentes de IA.	65
Figura 2 – Grafo de estados do agente de classificação (StateGraph no LangGraph), com os nós de normalização, roteamento, busca vetorial, inferência com modelo de linguagem e confirmação humana.	76
Figura 3 – Distribuição comparativa de CER e WER entre Docling V2 e Tesseract OCR.	89
Figura 4 – Taxa de Erro de Caracteres (CER %) por competência de fatura (C6 Bank 2022–2026).	89
Figura 5 – Taxa de Casamento Exato (%) e Distância Média de Levenshtein por competência de fatura (painéis superior e inferior, respectivamente). . .	90
Figura 6 – Acurácia e F1-Macro por arquitetura no teste cego (eixo vertical linear, em %).	92
Figura 7 – Latência média de inferência por transação e por arquitetura no teste cego (eixo vertical em escala logarítmica, em ms).	92
Figura 8 – F1-Score por categoria de despesa (melhor modelo).	100
Figura 9 – Matriz de confusão do Agente Híbrido no teste cego (334 transações). .	102

LISTA DE TABELAS

Tabela 1 – Componentes da solução: linguagem, arcabouço principal e versão efetivamente utilizada.	67
Tabela 2 – Caracterização textual do campo NOME FAVORECIDO no acervo CPGF ($N = 477.740$).	81
Tabela 3 – Distribuição do acervo de faturas do C6 Bank com pareamento PDF e CSV.	82
Tabela 4 – Hiperparâmetros efetivamente adotados por arquitetura (valores fixados <i>a priori</i>).	85
Tabela 5 – Desempenho comparativo global entre Docling V2 e Tesseract OCR.	87
Tabela 6 – Detalhamento de CER, WER, Casamento Exato e Latência por fatura do C6 Bank.	88
Tabela 7 – Comparativo global de desempenho preditivo e tempo médio de inferência (teste cego de 334 transações, estabelecimentos disjuntos).	91
Tabela 8 – Intervalos de confiança de 95% (<i>bootstrap</i> , $B = 2.000$) para o F1-Macro.	93
Tabela 9 – Validação cruzada 5-fold versus teste cego por estabelecimento disjunto (F1-Macro).	95
Tabela 10 – Acurácia e F1-Macro por arquitetura, discriminados por instituição emissora (teste cego).	97
Tabela 11 – Matriz de confusão do subconjunto do Nubank no teste cego ($n = 100$), comum às quatro arquiteturas com métricas idênticas na Tabela 10.	97
Tabela 12 – F1-Macro por arquitetura, segmentado pela proveniência do rótulo de referência.	99
Tabela 13 – Desempenho do TF-IDF + Random Forest discriminado por categoria de despesa efetivamente avaliada.	101
Tabela 14 – Ablação da normalização léxica sobre o teste cego (variação de F1-Macro) e desempenho por ramo do agente (acurácia condicional).	103
Tabela 15 – Acurácia global por arquitetura no teste cego, com intervalo de confiança de 95% (Wilson) e teste binomial exato unilateral contra o limiar de 85%.	107
Tabela 16 – Registros recuperados por busca direta, por string de busca e base (Scopus e IEEE Xplore).	127

LISTA DE QUADROS

Quadro 1 – Amostra real de descrições de transações extraídas de faturas do C6 Bank e do Nubank, ilustrando os obstáculos tratados nesta pesquisa. .	30
Quadro 2 – Avaliação de qualidade dos estudos incluídos na revisão.	50
Quadro 3 – Matriz de características: atendimento das capacidades centrais por trabalho correlato.	58
Quadro 4 – Arestas do grafo de estados do agente (origem, condição de roteamento, destino).	72
Quadro 5 – Amostra comparativa de transações reais: verdade de referência versus Docling V2 versus Tesseract.	91

LISTA DE ABREVIATURAS E SIGLAS

ABECS	Associação Brasileira das Empresas de Cartões de Crédito e Serviços
ABNT	Associação Brasileira de Normas Técnicas
ANN	Approximate Nearest Neighbor (Busca Aproximada de Vizinhos Mais Próximos)
API	Application Programming Interface
BERT	Bidirectional Encoder Representations from Transformers
BI	Business Intelligence
ByT5	Byte-level T5
CER	Character Error Rate (Taxa de Erro de Caracteres)
CNN	Convolutional Neural Network (Rede Neural Convolucional)
CNPJ	Cadastro Nacional da Pessoa Jurídica
CORD	Consolidated Receipt Dataset (base pública de recibos anotados)
CoT	Chain-of-Thought (Cadeia de Pensamento)
CPF	Cadastro de Pessoas Físicas
CPGF	Cartão de Pagamento do Governo Federal
CRISP-DM	Cross-Industry Standard Process for Data Mining
CSV	Comma-Separated Values (Valores Separados por Vírgula)
CUDA	Compute Unified Device Architecture
CVV	Card Verification Value (Código de Verificação do Cartão)
DLA	Document Layout Analysis (Análise de Leiaute de Documentos)
DPI	Dots Per Inch (Pontos por Polegada)
EMR	Exact Match Rate (Taxa de Casamento Exato)
FN	Falso Negativo
FP	Falso Positivo

FPR	False Positive Rate (Taxa de Falsos Positivos)
GPU	Graphics Processing Unit
GRU	Gated Recurrent Unit
HITL	Human-in-the-Loop (Humano no Ciclo)
IAM	Identity and Access Management (Seção 4.5); no Capítulo 3, refere-se também à base de manuscritos <i>IAM Handwriting Database</i> , sigla homônima e sem relação com o serviço de autenticação
IEEE	Institute of Electrical and Electronics Engineers
IVFFlat	Inverted File with Flat compression (índice do pgvector)
JSON	JavaScript Object Notation
LAN	Local Area Network (Rede Local)
LGPD	Lei Geral de Proteção de Dados Pessoais (Lei nº 13.709/2018)
LLM	Large Language Model (Grande Modelo de Linguagem)
LSTM	Long Short-Term Memory
MCC	Merchant Category Code (Código de Categoria do Estabelecimento)
MLflow	Machine Learning Flow (Plataforma de MLOps)
MLOps	Machine Learning Operations
NFE	Nota Fiscal Eletrônica
NFS-e	Nota Fiscal de Serviços Eletrônica
OCR	Optical Character Recognition (Reconhecimento Óptico de Caracteres)
OFX	Open Financial Exchange
OIDC	OpenID Connect
OOV	Out-Of-Vocabulary (Fora do Vocabulário)
ORM	Object-Relational Mapping (Mapeamento Objeto-Relacional)
PDF	Portable Document Format
pgvector	PostgreSQL Vector Extension

PLN	Processamento de Linguagem Natural
QA	Quality Assessment (Avaliação de Qualidade dos estudos)
QR	Questão da Revisão (questões de pesquisa do levantamento bibliográfico, QR-1 a QR-4)
RAG	Retrieval-Augmented Generation
RAM	Random Access Memory
RBAC	Role-Based Access Control
Regex	Regular Expressions (Expressões Regulares)
RNN	Recurrent Neural Network (Rede Neural Recorrente)
RVL-CDIP	Ryerson Vision Lab Complex Document Information Processing (base pública de imagens de documentos)
S3	Simple Storage Service
SBERT	Sentence-BERT
SPC	Serviço de Proteção ao Crédito
SQL	Structured Query Language
SROIE	Scanned Receipts OCR and Information Extraction (competição ICDAR 2019)
TF-IDF	Term Frequency-Inverse Document Frequency
TP	Verdadeiro Positivo
USP	Universidade de São Paulo
VLM	Vision-Language Model (Modelo de Visão e Linguagem)
VRAM	Video Random Access Memory
WER	Word Error Rate (Taxa de Erro de Palavras)

SUMÁRIO

1	INTRODUÇÃO	29
2	FUNDAMENTAÇÃO TEÓRICA	35
2.1	Considerações iniciais	35
2.2	Mineração de textos e processamento de linguagem natural	35
2.2.1	Pré-processamento léxico e morfológico	35
2.2.2	Estratégias de tokenização: da palavra ao nível de byte	35
2.2.3	Vetorização estatística versus representações densas (<i>embeddings</i>)	36
2.2.3.1	TF-IDF (Term Frequency-Inverse Document Frequency)	36
2.2.3.2	Embeddings densos e bancos de dados vetoriais	37
2.2.4	Classificadores estatísticos clássicos para vetores esparsos	38
2.2.4.1	Naive Bayes multinomial e complementar	38
2.2.4.2	Florestas aleatórias (Random Forest)	39
2.2.5	Métricas de avaliação para classificação multiclasse	39
2.3	Visão computacional e inteligência de documentos	40
2.3.1	Análise de leiaute de documentos (DLA) e caixas delimitadoras	40
2.3.2	Paradigmas de ingestão documental: reconhecimento óptico versus extração de fluxo nativo	40
2.3.3	Métricas formais de avaliação de OCR: CER e WER	41
2.4	Arquiteturas neurais e agentes inteligentes	41
2.4.1	Mecanismos de autoatenção e arquiteturas Transformer	41
2.4.2	Grandes modelos de linguagem (LLMs) e raciocínio estruturado	42
2.4.3	Orquestração baseada em grafos de estado: LangGraph	42
2.5	Engenharia de dados, MLOps e sustentabilidade de modelos	43
2.5.1	Desvios estatísticos: <i>data drift</i> e <i>concept drift</i>	43
2.5.2	Aprendizado ativo (<i>active learning</i>) por amostragem de incerteza	43
2.5.3	Arquitetura de <i>data lakehouse</i> e rastreamento com MLflow	44
2.6	Considerações finais do capítulo	44
3	TRABALHOS RELACIONADOS	47
3.1	Considerações iniciais	47
3.2	Questões de pesquisa da revisão	47
3.3	Levantamento bibliográfico e categorização dos estudos	48
3.4	Instrumento de extração de dados	48
3.5	Avaliação de qualidade dos estudos incluídos	49
3.6	Análise crítica dos estudos selecionados	49

3.6.1	Zhang, Zhao e LeCun (2015) e Dhingra et al. (2016)	49
3.6.2	Huang et al. (2019) – competição SROIE	51
3.6.3	Santos (2022)	51
3.6.4	Araújo, Bezerra e Souza Neto (2025)	52
3.6.5	Souza (2025)	53
3.6.6	Ta, Saad e Oh (2023)	53
3.6.7	Curcio, Galfré e Le Van (2026)	54
3.6.8	Gandikota et al. (2026)	55
3.6.9	Farias, Mendes e Conceição (2025)	56
3.7	Quadro comparativo e posicionamento desta pesquisa	57
3.8	Considerações finais do capítulo	58
4	SOLUÇÃO PROPOSTA	61
4.1	Considerações iniciais	61
4.2	Questões de pesquisa e hipótese central	61
4.3	Metodologia da pesquisa e arcabouço CRISP-DM adaptado	63
4.4	Fonte de dados, amostragem e natureza dos dados	63
4.5	Arquitetura geral da solução e ecossistema de dados em camadas	64
4.6	Esteira de ingestão e extração híbrida de documentos	67
4.7	Engenharia do agente de classificação inteligente	69
4.8	Conformidade com a LGPD e segurança da informação financeira	72
4.9	Estratégia de garantia de qualidade e testes	74
4.10	Considerações finais do capítulo	75
5	VALIDAÇÃO EXPERIMENTAL E RESULTADOS	77
5.1	Considerações iniciais	77
5.2	Ambiente computacional e configuração experimental	77
5.3	Caracterização dos conjuntos de dados (<i>datasets</i>)	79
5.3.1	Caracterização textual do acervo governamental CPGF	80
5.3.2	Conjunto rotulado de referência para a classificação	82
5.4	Protocolo experimental e métricas de avaliação	83
5.4.1	Métricas para extração óptica e reconhecimento de texto	83
5.4.2	Métricas para classificação semântica de transações	84
5.4.3	Intervalos de confiança e teste de significância	85
5.5	Resultados da extração e pré-processamento óptico	86
5.5.1	Desempenho quantitativo global: Docling V2 versus Tesseract	87
5.5.2	Análise visual das métricas e dispersão de erros	87
5.5.3	Análise qualitativa de erros e preservação estrutural de tabelas	88
5.6	Resultados comparativos da classificação de transações	91
5.6.1	Acurácia global versus F1-Macro	96

5.6.2	Desempenho discriminado por instituição emissora	96
5.6.3	Risco de circularidade entre rotulagem e desempenho	98
5.6.4	Desempenho detalhado por categoria de despesa	100
5.6.5	Estudo de ablação	102
5.7	Avaliação de MLOps, latência e observabilidade	103
5.8	Respostas às questões de pesquisa e verificação da hipótese	105
5.9	Considerações finais do capítulo	107
6	CONCLUSÕES E TRABALHOS FUTUROS	109
6.1	Considerações iniciais	109
6.2	Síntese do trabalho, contribuições e objetivos atingidos	109
6.3	Principais conclusões da pesquisa	110
6.4	Limitações do trabalho	112
6.5	Trabalhos futuros	114
	REFERÊNCIAS	117
	APÊNDICES	123
	APÊNDICE A – PROTOCOLO DO LEVANTAMENTO BIBLIO-GRÁFICO	125
A.1	Bases de dados consultadas	125
A.2	Strings de busca aplicadas	125
A.3	Critérios de inclusão e exclusão	126
A.4	Técnica de snowballing (citação em cascata)	126
A.5	Registros recuperados e seleção dos estudos	127
	APÊNDICE B – ESQUEMA DO BANCO DE DADOS RELACIONAL E VETORIAL	129
B.1	Tabela de estabelecimentos (base de conhecimento relacional) . . .	129
B.2	Coleção vetorial consultada pelo agente	129
B.3	Tabela de transações financeiras	130
	APÊNDICE C – REPOSITÓRIO DE CÓDIGO-FONTE E REPRODUTIBILIDADE	133
	APÊNDICE D – <i>SYSTEM PROMPT</i> E CONTRATO PYDANTIC DO RAMO LLM	135
D.1	<i>System prompt</i> dinâmico	135
D.2	Contrato Pydantic ClassificacaoLLM	136

D.3	Análise crítica do artefato	137
-----	---------------------------------------	-----

APÊNDICE E – REGRAS DE NORMALIZAÇÃO LÉXICA E LISTAS DE MARKETPLACES 139

E.1	Expressões regulares de saneamento	139
E.2	Lista de <i>marketplaces</i> ambíguos	139
E.3	Dicionário de aliases de estabelecimento	140
E.4	Análise crítica do artefato	140

ANEXOS 143

ANEXO A – DECLARAÇÃO DE USO DE INTELIGÊNCIA ARTIFICIAL 145

1 INTRODUÇÃO

O gerenciamento financeiro pessoal constitui uma das competências mais críticas e desafiadoras para os cidadãos no cenário econômico contemporâneo. Com a digitalização em massa dos meios de pagamento e a consequente substituição do dinheiro em espécie por instrumentos eletrônicos, o volume de dados transacionais gerados cotidianamente atingiu patamares sem precedentes. No entanto, o aumento na facilidade de transacionar não foi acompanhado por ferramentas automáticas eficazes de organização e inteligência orçamentária, gerando um descompasso estrutural entre o consumo e a visibilidade financeira dos indivíduos.

A popularização do cartão de crédito como o principal meio de pagamento no Brasil trouxe consigo um desafio crescente: a dificuldade de compreender e organizar os próprios gastos de forma autônoma e tempestiva. Segundo dados consolidados pela Associação Brasileira das Empresas de Cartões de Crédito e Serviços (ABECS, 2024), as compras realizadas com cartões de crédito, débito e pré-pagos movimentaram aproximadamente 4,1 trilhões de reais em 2024, evidenciando o papel central desses instrumentos na economia nacional. Paralelamente, dados divulgados por SERASA EXPERIAN (2024) indicam a existência de mais de 200 milhões de cartões de crédito ativos no país, e cerca de 29,37% dos consumidores brasileiros inadimplentes possuíam dívidas diretamente vinculadas ao crédito rotativo ou ao parcelamento de faturas.

O crescimento no volume transacional é impulsionado tanto pelas compras em estabelecimentos físicos quanto pelo comércio eletrônico (*e-commerce*). Relatórios de hábitos de consumo indicam que os gastos digitais apresentaram expansão superior a 15% ao final de 2024 (PODER360, 2025). Não obstante a conveniência proporcionada por essa digitalização, a falta de padronização nas informações repassadas aos usuários nas faturas mensais impede o planejamento consciente. Conforme apontado pelo Serviço de Proteção ao Crédito (SPC BRASIL, 2024), a grande maioria dos consumidores não possui um controle sistemático de seu orçamento mensal, recorrendo frequentemente a anotações manuais em planilhas ou cadernos — práticas propensas a erros e com altas taxas de abandono ao longo do tempo.

O problema central investigado nesta pesquisa reside na **categorização automática, precisa e escalável de transações financeiras de cartão de crédito a partir de descrições textuais curtas, heterogêneas, ruidosas e altamente despadronizadas**. Conforme ilustrado no Quadro 1, as linhas de extrato apresentam obstáculos multidimensionais:

1. **Abreviações e Siglas Crípticas:** Nomes de fornecedores frequentemente aparecem

Quadro 1 – Amostra real de descrições de transações extraídas de faturas do C6 Bank e do Nubank, ilustrando os obstáculos tratados nesta pesquisa.

Descrição bruta no extrato	Obstáculo ilustrado
jhoonymorango	Nome informal e aglutinado de pequeno estabelecimento
DL HELPHBOMAXCOM	Abreviação/sigla críptica de serviço digital
IFOOD *IFD*MR DELIVE	Prefixo de intermediador de pagamento (<i>marketplace</i>)
PAYPAL *BOSS LIFE	Prefixo de <i>gateway</i> internacional sobre o nome da loja
DIVIPAYPAYMENTS	Prefixo de parcelamento aglutinado ao nome do processador
UBER* TRIP VALORES EM REAIS	Ruído de leitura óptica (verdade de referência: UBER TRIP)
CLUBE DO INGRESSO – PARCELA 1/2	Ruído de leitura óptica (verdade de referência: CLUBE DO INGRESSO)

Fonte: Elaborado pelo autor (2026), a partir de transações reais (nomes de estabelecimento, sem dados do titular) detalhadas na Seção 5.5.

severamente truncados, concatenados ou representados por razões sociais obsoletas (ex.: “AMZN MKTPLACE”, “PAG*RestSaoPaulo”, “DL*GOOGLE”);

2. **Prefixos de Processadores e *Gateways* de Pagamento:** Transações intermediadas por terminais eletrônicos (maquininhas) e facilitadores digitais inserem códigos e prefixos alfanuméricos indevidos (ex.: “PG*”, “MP*”, “ZOO*”, “SUMUP*”) que ocultam a identidade real do estabelecimento;
3. **Ruídos Decorrentes de Leitura Óptica (OCR):** Em documentos digitalizados, escaneados ou fotografados por câmeras móveis, motores de Reconhecimento Óptico de Caracteres introduzem erros de substituição, deleção e inserção de caracteres (ex.: letras trocadas por números semelhantes), gerando palavras fora do vocabulário padrão (*Out-Of-Vocabulary* – OOV);
4. **Ambiguidade de *Marketplaces* e Multicategorias:** Grandes plataformas de comércio eletrônico (como Mercado Livre, Amazon e Shopee) transacionam mercadorias de tipos muito diferentes entre si (eletrônicos, vestuário, alimentação, medicamentos) sob uma mesma fatura corporativa genérica, tornando inviável a inferência da categoria apenas pelo texto bruto do canal;
5. **Privacidade e Soberania dos Dados Financeiros:** O tratamento de dados transacionais bancários envolve informações de alta sensibilidade pessoal, exigindo estrita conformidade com a Lei Geral de Proteção de Dados Pessoais (LGPD – Lei

nº 13.709/2018) (BRASIL, 2018), o que restringe o envio indiscriminado de extratos a serviços terceirizados e APIs proprietárias em nuvem pública.

A motivação deste trabalho apoia-se em duas perspectivas complementares: o avanço técnico-científico na área de Ciência da Computação e o impacto socioeconômico direto na gestão orçamentária dos cidadãos.

No âmbito da **Ciência da Computação**, o problema integra de maneira transdisciplinar a Visão Computacional/OCR, o Processamento de Linguagem Natural (PLN), os Sistemas de Recuperação de Informação Vetorial, a Engenharia de Agentes Inteligentes baseados em Grafos de Estado e as práticas de Operações de Aprendizado de Máquina (MLOps). Desenvolver e avaliar criticamente uma arquitetura que opere sob restrições severas de hardware local (sem demandar *clusters* de GPU de alto custo) contribui para a literatura de Inteligência Artificial aplicada, evidenciando as possibilidades e os limites de esteiras modulares, reativas e de baixo custo computacional.

As abordagens descritas na literatura (Capítulo 3), contudo, apresentam limitações que reforçam a necessidade desta investigação: parte expressiva delas depende de APIs proprietárias em nuvem para a extração e a classificação, implicando custos recorrentes e riscos à soberania dos dados financeiros; outra parte ampara-se em heurísticas de leiaute visual fixo, fragilizando-se diante de qualquer mudança estética promovida pelas instituições emissoras; e, de modo geral, poucas delas tratam do ciclo de vida do modelo em produção – isto é, do monitoramento contínuo de desvios de dados e de conceito ao longo do tempo. Essas lacunas são detalhadas na revisão da literatura do Capítulo 3.

Sob o ponto de vista **aplicado e socioeconômico**, automatizar o processo de saneamento e classificação de despesas reduz o esforço cognitivo e a sobrecarga de tempo associados à gestão financeira pessoal. Ao fornecer categorias precisas, justificativas semânticas inteligíveis e mecanismos de aprendizado contínuo com intervenção humana (*Human-in-the-Loop* – HITL), o sistema capacita os usuários a compreender seus reais padrões de consumo, com potencial de auxiliar na prevenção do endividamento precoce e de promover a sustentabilidade orçamentária das famílias.

O **objetivo geral** desta monografia é conceber, implementar e avaliar experimentalmente uma solução computacional de ponta a ponta para a extração, normalização e classificação automática de transações financeiras em faturas de cartão de crédito, apoiada em extração com preservação de leiaute e em agentes de linguagem executados em infraestrutura local. Essa avaliação caracteriza a acurácia preditiva alcançável e a resiliência a ruídos textuais e ópticos, sob restrições de privacidade dos dados e de sustentabilidade operacional em hardware local.

Para concretizar o objetivo geral, definiram-se os seguintes **objetivos específicos**:

1. **Ingestão e Extração Híbrida de Documentos:** Desenvolver um módulo que ingira faturas em formatos digitais nativos e, arquiteturalmente, documentos ópticos, combinando extração com preservação de leiaute e reconhecimento óptico local (Seção 4.6);
2. **Esteira de Normalização e Saneamento Léxico:** Projetar rotinas algorítmicas de pré-processamento para eliminação de prefixos de *gateways* de pagamento, supressão de ruídos alfanuméricos e resolução de sinônimos/alias comerciais;
3. **Estabelecimento de Linhas de Base Científicas (*Baselines*):** Implementar e mensurar o desempenho de classificadores estatísticos clássicos sobre representação textual esparsa, estabelecendo referências quantitativas de comparação;
4. **Modelagem com Representações Densas e Modelos Neurais:** Construir uma base de conhecimento vetorial para busca por similaridade semântica com *embeddings* multilíngues e investigar modelos no nível de byte/caractere;
5. **Arquitetura de Agente Inteligente com Grafos de Estado:** Orquestrar a decisão preditiva em um grafo de estados que integre raciocínio com modelo de linguagem, ferramentas autônomas de busca e confirmação humana (HITL) em casos ambíguos;
6. **Estruturação da Infraestrutura de Dados em Camadas e da Esteira MLOps:** Desenvolver a infraestrutura containerizada da solução, com armazenamento em camadas, mensageria por eventos e rastreamento de experimentos;
7. **Validação Experimental e Diagnóstico Comparativo:** Avaliar quantitativamente as arquiteturas sobre faturas reais, sob protocolo de teste cego por estabelecimento, confrontando formalmente as hipóteses de pesquisa com as evidências obtidas.

O **escopo** desta pesquisa compreende a extração de faturas em formatos digitais nativos (CSV e PDF com camada de texto codificada; a ingestão de OFX e JSON está prevista na arquitetura, mas não possui analisador implementado), o saneamento léxico das descrições extraídas e a classificação automática em uma taxonomia canônica de categorias orçamentárias. A extração óptica de documentos genuinamente escaneados ou fotografados está **implementada como componente autônomo** (via Tesseract OCR, Seção 4.6), não acoplado ao serviço de extração, e **não foi empiricamente validada** sobre material dessa natureza: a avaliação experimental do Capítulo 5 opera inteiramente sobre PDFs nativos digitais e arquivos CSV, e essa lacuna é registrada como limitação no Capítulo 6. Também não integram o escopo a conciliação orçamentária automatizada, a detecção de

fraudes, a consultoria tributária e a camada de consumo analítico (painéis gerenciais de *Business Intelligence*), apontadas como direções de trabalhos futuros no Capítulo 6.

Do ponto de vista dos **requisitos não funcionais**, a solução deve atender a: execução integral em hardware local, sem dependência de infraestrutura de GPU em nuvem; latência compatível com o uso interativo por parte do usuário final; auditabilidade das decisões de classificação, com registro rastreável do método e da confiança de cada inferência; e explicabilidade das predições geradas pelo agente, sustentada pela cadeia de raciocínio (*Chain-of-Thought*) exposta em linguagem natural. Esses requisitos ancoram as escolhas arquiteturais detalhadas no Capítulo 4, que também registra o grau em que cada um foi atendido na versão avaliada, e são mensurados experimentalmente no Capítulo 5. A hipótese central da pesquisa é formalizada na Seção 4.2 e verificada na Seção 5.8.

O presente documento está estruturado em seis capítulos, cinco apêndices e um anexo. O Capítulo 2 discute os conceitos teóricos instrumentais à solução: processamento de linguagem natural, tokenização em subpalavras e bytes, representações densas e bancos de dados vetoriais, visão computacional e OCR, arquiteturas Transformer, agentes em grafos de estado e práticas de MLOps e de dados em camadas. O Capítulo 3 analisa o estado da arte por meio de um levantamento estruturado da literatura sobre saneamento pós-OCR, mineração de textos informais e extração em documentos fiscais, sintetizado em um quadro comparativo que explicita as lacunas abordadas. O Capítulo 4 detalha a solução proposta: questões de pesquisa e hipótese central, arcabouço CRISP-DM adaptado, fonte de dados e amostragem, arquitetura de dados em camadas, extração de documentos, grafo de estados do agente, salvaguardas de privacidade e estratégia de garantia de qualidade. O Capítulo 5 expõe o ambiente computacional, os conjuntos de dados, o protocolo de avaliação, os resultados das linhas de base e do agente híbrido, as análises de ablação e a verificação formal das hipóteses. O Capítulo 6 sintetiza as contribuições, avalia o cumprimento dos objetivos, discute as limitações e aponta direções de continuidade. Os Apêndices A a E documentam, respectivamente, o protocolo do levantamento bibliográfico, o esquema do banco de dados relacional e vetorial, o repositório de código-fonte e as instruções de reprodutibilidade, o *system prompt* e o contrato Pydantic do ramo LLM, e as regras de normalização léxica com as listas de *marketplaces* e aliases; o Anexo A reproduz a declaração institucional de uso de inteligência artificial exigida pelo programa.

2 FUNDAMENTAÇÃO TEÓRICA

2.1 Considerações iniciais

A concepção de uma ferramenta robusta para a interpretação e categorização de faturas financeiras requer o domínio integrado de fundamentos oriundos de múltiplas subáreas da Inteligência Artificial e da Engenharia de Software. Este capítulo estabelece as bases conceituais estritamente instrumentais ao projeto, organizando-se em quatro pilares fundamentais: (i) mineração de textos e processamento de linguagem natural (Seção 2.2); (ii) visão computacional, análise de leiaute e reconhecimento óptico de caracteres (Seção 2.3); (iii) arquiteturas neurais profundas e agentes inteligentes baseados em grafos (Seção 2.4); e (iv) engenharia de dados, MLOps e sustentabilidade de modelos em produção (Seção 2.5). A Seção 2.6 encerra o capítulo.

2.2 Mineração de textos e processamento de linguagem natural

O Processamento de Linguagem Natural (PLN) constitui o ramo da Inteligência Artificial dedicado a capacitar sistemas computacionais a compreender, interpretar, manipular e gerar linguagens humanas (Caseli; Nunes, 2024; Chowdhury, 2003). No domínio financeiro, o desafio central da mineração textual reside na natureza não estruturada, ruidosa e despadronizada das descrições de transações bancárias e de cartão de crédito, que exige tratamento com conhecimento específico do domínio em vez de abordagens textuais genéricas (Ta; Saad; Oh, 2023).

2.2.1 Pré-processamento léxico e morfológico

A primeira barreira técnica na modelagem de textos curtos é a dispersão léxica, atacada pelas operações determinísticas usuais de padronização (caixa baixa, normalização de acentos e supressão de pontuação por expressões regulares) e pela remoção de *stopwords* (Caseli; Nunes, 2024; Matos; Ciferri; Pardo, 2009). Contudo, listas genéricas universais mostram-se insuficientes no domínio financeiro. É indispensável incorporar heurísticas específicas do negócio para remover sufixos de naturezas jurídicas e corporativas (como “LTDA”, “S/A”, “ME”, “EPP”, “EIRELI”) e prefixos de liquidação financeira (“COMPRA”, “PARCELA”, “DEBITO”), os quais atuam como ruídos que distorcem as distribuições estatísticas (Ta; Saad; Oh, 2023).

2.2.2 Estratégias de tokenização: da palavra ao nível de byte

A tokenização segmenta a cadeia textual contínua em unidades atômicas de processamento denominadas *tokens* (Caseli; Nunes, 2024). Modelos tradicionais baseados em

palavras inteiras (*word-level*) dependem de vocabulários fechados predefinidos. Diante de faturas financeiras, em que erros de digitação, truncamentos e aglutinações são onipresentes, essa abordagem falha sistematicamente devido à explosão de termos fora do vocabulário (*Out-Of-Vocabulary* – OOV).

Para superar essa fragilidade, o estado da arte avançou para a tokenização em subpalavras (*subwords*, como Byte-Pair Encoding e WordPiece) e, no limite da granularidade, para a tokenização no nível de caractere ou byte (Zhang; Zhao; LeCun, 2015; Xue *et al.*, 2022). Modelos que operam diretamente sobre sequências de bytes UTF-8, a exemplo do ByT5 (Xue *et al.*, 2022), eliminam completamente o vocabulário fixo. Essa característica confere ao modelo maior tolerância a erros ortográficos e capacidade de generalizar sobre siglas desconhecidas e nomes comerciais aglutinados (ex.: “MERCADOPAG*LOJA123”).

O custo dessa granularidade é o comprimento das sequências: uma descrição de 30 caracteres, que um tokenizador de subpalavras representa com 8 a 12 unidades, torna-se uma sequência de 30 a 40 bytes (caracteres acentuados ocupam dois bytes em UTF-8), o que multiplica o custo da atenção – quadrático no comprimento – e exige mais exemplos para que o modelo aprenda composições de bytes que em subpalavras já viriam pré-compostas. É por isso que modelos em nível de byte tendem a exigir *corpora* maiores para atingir o mesmo desempenho, uma consideração central na leitura dos resultados do ajuste fino do ByT5 no Capítulo 5. Os classificadores esparsos desta pesquisa exploram a mesma intuição de granularidade por outra via: *n*-gramas de caractere (2 a 4) como atributos do TF-IDF, que capturam a morfologia recorrente das descrições sem depender de vocabulário fechado nem de treinamento neural.

2.2.3 Vetorização estatística versus representações densas (*embeddings*)

Para que algoritmos computacionais processem dados textuais, é imperativo convertê-los em representações numéricas vetoriais.

2.2.3.1 TF-IDF (Term Frequency-Inverse Document Frequency)

A técnica clássica de TF-IDF quantifica a importância de um termo t em um documento d pertencente a um corpus D , calculada pelo produto da frequência do termo (TF) pelo inverso da frequência no documento (IDF) – noção de especificidade de termos introduzida por Spärck Jones (1972) e consolidada como esquema de ponderação por Salton e Buckley (1988) –, aqui na formulação de Rajaraman e Ullman (2011):

$$\text{TF-IDF}(t, d, D) = \text{TF}(t, d) \times \log \left(\frac{|D|}{1 + |\{d \in D : t \in d\}|} \right) \quad (2.1)$$

Embora gere matrizes esparsas de alta dimensionalidade que desconsideram o contexto e a ordem sintagmática das palavras, o TF-IDF permanece relevante como uma linha de

base científica (*baseline*) de referência rápida, interpretável e de baixo custo computacional (Rajaraman; Ullman, 2011).

2.2.3.2 Embeddings densos e bancos de dados vetoriais

A superação das limitações esparsas consolidou-se com a semântica distribucional profunda, cuja formulação moderna remonta aos vetores de palavras aprendidos por redes neurais rasas a partir do contexto de ocorrência (*word2vec*) (Mikolov *et al.*, 2013). Modelos como o Sentence-BERT (SBERT) (Reimers; Gurevych, 2019), implementados por meio de arquiteturas siamesas de Sentence Transformers (ex.: **paraphrase-multilingual-MiniLM-L12-v2**), mapeiam sentenças inteiras em vetores densos e contínuos de dimensionalidade fixa (ex.: 384 dimensões).

Nesse espaço vetorial contínuo, a proximidade semântica entre duas transações u e v é mensurada diretamente pela similaridade de cosseno:

$$\text{Simil}(u, v) = \frac{u \cdot v}{\|u\|_2 \|v\|_2} = \frac{\sum_{i=1}^n u_i v_i}{\sqrt{\sum_{i=1}^n u_i^2} \sqrt{\sum_{i=1}^n v_i^2}} \quad (2.2)$$

Para viabilizar consultas em milissegundos sobre milhões de registros históricos, utilizam-se extensões vetoriais integradas ao banco de dados relacional, destacando-se a extensão pgvector para PostgreSQL. Essa infraestrutura é o substrato de dois usos distintos, que convém não confundir. O primeiro é a **busca vetorial por similaridade** propriamente dita: os vizinhos mais próximos de uma consulta são recuperados e a categoria é decidida a partir deles (por exemplo, por votação ponderada pela similaridade). O segundo é a **Geração Aumentada por Recuperação** (*Retrieval-Augmented Generation* – RAG) (Lewis *et al.*, 2020), em que os exemplos recuperados são *injetados no prompt* de um modelo de linguagem, que gera a resposta condicionado a essa evidência – o mecanismo pelo qual um modelo passa a decidir “em cima” de uma base de conhecimento externa, em regime *few-shot* dinâmico. A solução desta pesquisa implementa o primeiro uso, como ramo autônomo de classificação e como critério de roteamento do agente; os vizinhos recuperados **não são repassados** ao modelo de linguagem, que opera em regime *zero-shot* (Seção 4.7). Por essa razão, a arquitetura correspondente é denominada ao longo do texto “busca vetorial densa”, reservando-se o termo RAG ao conceito aqui definido e à discussão, no Capítulo 6, da injeção de vizinhos como evolução natural do ramo de raciocínio.

A recuperação eficiente nesse espaço vetorial de alta dimensionalidade não precisa ser exaustiva: extensões como o pgvector empregam estruturas de indexação por Busca Aproximada de Vizinhos Mais Próximos (*Approximate Nearest Neighbor* – ANN), que trocam a garantia de exatidão por ganhos expressivos de velocidade (Jégou; Douze; Schmid, 2011). Na variante *IVFFlat* (*Inverted File with Flat compression*), o espaço vetorial é particionado em um número fixo de células (*listas*) por meio de agrupamento por k -médias, e a consulta é comparada apenas contra os vetores das células cujos centroides lhe são mais

próximos; na variante *HNSW* (*Hierarchical Navigable Small World*), constrói-se um grafo de vizinhança em múltiplas camadas, navegado de forma gulosa da camada mais esparsa à mais densa, com parâmetros que regem o grau do grafo (m) e o esforço de construção ($ef_construction$). Em ambas, há um compromisso entre velocidade e revocação: quanto mais agressiva a aproximação, maior a probabilidade de omitir o vizinho verdadeiramente mais próximo. Nesta pesquisa, o esquema físico cria um índice HNSW ($m = 16$, $ef_construction = 64$) sobre a tabela relacional de estabelecimentos (Apêndice B); a coleção vetorial consultada pelo agente, mantida pela integração LangChain, não recebe índice aproximado e é percorrida por busca exaustiva – decisão adequada à escala do acervo (centenas de estabelecimentos), em que a busca exata custa poucos milissegundos (Seção 5.7).

2.2.4 Classificadores estatísticos clássicos para vetores esparsos

Sobre as representações esparsas de alta dimensionalidade produzidas pelo TF-IDF, duas famílias de classificadores estatísticos clássicos mostram-se particularmente adequadas e computacionalmente econômicas, sendo adotadas como linhas de base na avaliação experimental (Capítulo 5).

2.2.4.1 Naive Bayes multinomial e complementar

O classificador *Naive Bayes* aplica o teorema de Bayes sob a hipótese simplificadora (*naive*) de independência condicional entre os atributos dada a classe. Na variante Multinomial (McCallum; Nigam, 1998), cada atributo (termo do vocabulário) é modelado pela sua contagem/frequência de ocorrência no documento, estimando-se a probabilidade *a posteriori* de uma classe c dado um vetor de termos x por:

$$P(c \mid x) \propto P(c) \prod_{i=1}^n P(t_i \mid c)^{x_i} \quad (2.3)$$

em que $P(c)$ é a probabilidade *a priori* da classe, t_i é o i -ésimo termo do vocabulário de tamanho n , $P(t_i \mid c)$ é a probabilidade de ocorrência desse termo na classe e o expoente x_i é a contagem (ou peso TF-IDF) do termo t_i no documento. Essa formulação é nativamente compatível com vetores TF-IDF esparsos e de alta dimensionalidade, pois a complexidade de treino e inferência escala linearmente com o número de termos não nulos, dispensando o cálculo de matrizes de covariância densas exigido por classificadores gaussianos. A variante Complementar (*Complement Naive Bayes*) (Rennie *et al.*, 2003) corrige o viés sistemático do Multinomial em favor das classes majoritárias sob desbalanceamento, calculando as estatísticas de cada classe a partir do complemento (isto é, de todas as demais classes). Esta pesquisa avaliou a variante Multinomial com suavização de Laplace (Capítulo 5); a variante Complementar, assim como as técnicas de reamostragem para desbalanceamento, não foi avaliada e é apontada como desdobramento imediato (Seção 6.4).

2.2.4.2 Florestas aleatórias (Random Forest)

As Florestas Aleatórias (Breiman, 2001) constituem um método de *ensemble* que agrega as predições de múltiplas árvores de decisão treinadas independentemente sobre subamostras *bootstrap* dos dados (*bagging*) e sobre subconjuntos aleatórios de atributos sorteados em cada nó de divisão. A predição final é obtida por voto majoritário:

$$\hat{y} = \text{moda}\{h_1(x), h_2(x), \dots, h_B(x)\} \quad (2.4)$$

em que $h_b(x)$ denota a predição da b -ésima árvore, treinada sobre uma amostra *bootstrap* distinta. A aleatoriedade na seleção de atributos por nó descorrelaciona as árvores individuais, reduzindo a variância do estimador agregado sem elevar substancialmente seu viés (Breiman, 2001). Florestas Aleatórias lidam nativamente com espaços de atributos esparsos e de alta dimensionalidade (como TF-IDF), são robustas a atributos irrelevantes e dispensam normalização prévia dos dados, o que as consolida como uma linha de base cientificamente relevante frente a arquiteturas neurais computacionalmente mais custosas.

2.2.5 Métricas de avaliação para classificação multiclasse

O desempenho de um classificador multiclasse com K categorias é formalmente descrito, seguindo a análise sistemática de medidas de Sokolova e Lapalme (2009), para cada categoria k , a partir de três contagens extraídas da matriz de confusão: Verdadeiros Positivos (TP_k), Falsos Positivos (FP_k) e Falsos Negativos (FN_k). A **Precisão** da categoria k mede a proporção de predições daquela categoria que estavam corretas, e a **Revocação** (*recall*) mede a proporção de instâncias verdadeiramente pertencentes à categoria k que foram corretamente identificadas:

$$\text{Precisão}_k = \frac{TP_k}{TP_k + FP_k}, \quad \text{Revocação}_k = \frac{TP_k}{TP_k + FN_k} \quad (2.5)$$

O **F1-Score** por categoria é a média harmônica entre Precisão e Revocação, penalizando desequilíbrios acentuados entre as duas grandezas:

$$F1_k = \frac{2 \cdot \text{Precisão}_k \cdot \text{Revocação}_k}{\text{Precisão}_k + \text{Revocação}_k} \quad (2.6)$$

Para consolidar essas métricas por categoria em um único indicador do classificador, duas estratégias de agregação são adotadas na literatura (Sokolova; Lapalme, 2009). A **média Macro** calcula a média aritmética simples das métricas de cada categoria, atribuindo peso igual a todas elas independentemente do seu volume de amostras:

$$F1\text{-Macro} = \frac{1}{K} \sum_{k=1}^K F1_k \quad (2.7)$$

Já a **média Ponderada** (*weighted average*) pondera a métrica de cada categoria k pelo seu suporte n_k (número de instâncias verdadeiras daquela categoria) em relação ao total

de amostras N :

$$\text{F1-Ponderado} = \sum_{k=1}^K \frac{n_k}{N} \cdot \text{F1}_k \quad (2.8)$$

A distinção entre as duas médias é decisiva sob desbalanceamento de classes: a média Ponderada tende a refletir principalmente o desempenho nas categorias majoritárias, ao passo que a média Macro penaliza igualmente o fraco desempenho em categorias minoritárias e de cauda longa, sendo por isso adotada como métrica primária nesta pesquisa (Capítulo 5).

2.3 Visão computacional e inteligência de documentos

A Inteligência de Documentos (*Document AI*) integra Visão Computacional e PLN para extrair informações estruturadas de imagens e documentos não nativos (Auer; Dolfi; Staar, 2024).

2.3.1 Análise de leiaute de documentos (DLA) e caixas delimitadoras

A Análise de Leiaute de Documentos (DLA) é a etapa encarregada de segmentar a imagem da página, identificando blocos lógicos como tabelas, colunas, parágrafos e cabeçalhos – problema clássico da área de análise de documentos, cujas abordagens evoluíram de heurísticas geométricas para detectores neurais de regiões (Binmakhashen; Mahmoud, 2019). Cada entidade visual é mapeada por coordenadas espaciais denominadas caixas delimitadoras (*bounding boxes*): $[x_{\min}, y_{\min}, x_{\max}, y_{\max}]$.

Em faturas de cartão de crédito, a preservação da topologia e da ordem de leitura é obrigatória: a relação espacial de alinhamento horizontal entre o nome do estabelecimento comercial e o seu respectivo valor monetário em reais (R\$) carrega a semântica relacional necessária para isolar a transação e evitar a fusão indevida de dados entre colunas paralelas (Auer; Dolfi; Staar, 2024).

2.3.2 Paradigmas de ingestão documental: reconhecimento óptico versus extração de fluxo nativo

A ingestão automatizada de documentos comerciais admite dois paradigmas conceitualmente distintos, cuja escolha depende da natureza do arquivo de origem.

O primeiro paradigma é o **Reconhecimento Óptico de Caracteres sobre imagem rasterizada** (*raster-based OCR*), aplicável quando o documento de origem não possui nenhuma camada de texto digitalmente codificada – como em faturas escaneadas ou fotografadas por câmeras móveis. Nesse cenário, o documento chega à esteira como uma matriz de pixels, e um modelo de reconhecimento (tipicamente redes neurais recorrentes do tipo LSTM, a exemplo do motor Tesseract (Smith, 2007)) infere, símbolo a símbolo, qual caractere melhor explica cada região da imagem. Trata-se de um problema inerentemente

probabilístico: a qualidade da inferência degrada-se diante de ruídos visuais (baixa resolução, amassados, iluminação irregular), e mesmo em condições favoráveis persiste uma taxa de erro residual não nula.

O segundo paradigma é a **Análise de Leiaute com Extração de Fluxo Textual Nativo** (*native text-stream extraction*), aplicável quando o documento de origem já contém uma camada de texto codificada digitalmente – como em um PDF gerado programaticamente por um banco ou emissora de cartão. Nesse cenário, ferramentas de processamento documental (*Document Parsing*), a exemplo do IBM Docling (Auer; Dolfi; Staar, 2024), empregam modelos de visão computacional apenas para a Análise de Leiaute de Documentos (Seção 2.3.1) – isto é, para segmentar tabelas, colunas e blocos textuais e inferir a ordem de leitura – ao passo que os *caracteres em si* são recuperados diretamente da codificação digital nativa do arquivo, sem qualquer etapa de reconhecimento óptico. Por não envolver inferência símbolo a símbolo sobre pixels, esse paradigma está, em princípio, livre do tipo de erro de transcrição mensurado pelo CER e pelo WER (Seção 2.3.3) – uma distinção retomada na discussão dos resultados do Capítulo 5.

2.3.3 Métricas formais de avaliação de OCR: CER e WER

A qualidade da extração óptica é avaliada formalmente pela distância de edição de Levenshtein (Levenshtein, 1966) entre o texto predito pelo OCR e a verdade de referência. Definem-se três tipos fundamentais de erro: Substituição (S), Deleção (D) e Inserção (I).

A **Taxa de Erro de Caracteres** (CER – *Character Error Rate*) é calculada sobre o total de caracteres de referência N_c :

$$\text{CER} = \frac{S_c + D_c + I_c}{N_c} \quad (2.9)$$

A **Taxa de Erro de Palavras** (WER – *Word Error Rate*) opera de forma idêntica, porém adotando palavras inteiras como unidade amostral sobre o total de palavras N_w :

$$\text{WER} = \frac{S_w + D_w + I_w}{N_w} \quad (2.10)$$

Um único caractere lido incorretamente invalida a palavra inteira no cálculo do WER, tornando esta métrica estritamente mais rigorosa que o CER (Araújo; Bezerra; Souza Neto, 2025).

2.4 Arquiteturas neurais e agentes inteligentes

2.4.1 Mecanismos de autoatenção e arquiteturas Transformer

A introdução do mecanismo de autoatenção (*self-attention*) na arquitetura Transformer por Vaswani et al. (2017) superou as limitações de paralelização das redes recorrentes tradicionais (LSTM e GRU) (Hochreiter; Schmidhuber, 1997; Cho *et al.*, 2014). Seu núcleo

é a atenção escalada por produto escalar entre matrizes de consulta, chave e valor, que permite a cada *token* ponderar dinamicamente todos os demais elementos da sequência de entrada e capturar dependências semânticas não locais mesmo em textos curtos e informais. Esta pesquisa não modifica, analisa nem mede o mecanismo de atenção: os modelos baseados em Transformer aqui empregados – o codificador de sentenças MiniLM (Seção 2.2) e o ByT5 – são usados como caixas-pretas pré-treinadas, razão pela qual sua formalização matemática (Vaswani et al., 2017) não é reproduzida. O que é instrumental a esta pesquisa é a forma como esses modelos tokenizam a entrada – em subpalavras, no caso do MiniLM, e em bytes, no caso do ByT5 (Seção 2.2.2) –, pois é a tokenização, e não a atenção, que determina a robustez a nomes truncados e aglutinados.

2.4.2 Grandes modelos de linguagem (LLMs) e raciocínio estruturado

Os Grandes Modelos de Linguagem (*Large Language Models* – LLMs) pré-treinados em escala massiva demonstraram notável capacidade de inferência semântica e raciocínio contextual, inclusive em regime de poucos ou nenhum exemplo (*few-shot* e *zero-shot*), em que a tarefa é especificada apenas em linguagem natural no *prompt* (Brown et al., 2020). Para mitigar o risco de alucinações e favorecer a previsibilidade das saídas exigida por sistemas financeiros, três técnicas são empregadas nesta pesquisa:

- **Cadeia de Pensamento (*Chain-of-Thought* – CoT):** Técnica de indução por exemplos (*prompting*) que leva o modelo a explicitar seus passos intermediários de raciocínio antes de emitir o veredito final, elevando a precisão lógica em tarefas que exigem inferência multietapa (Wei et al., 2022);
- **Chamada de Ferramentas (*Tool Calling*) e Raciocínio-e-Ação:** Capacidade do modelo de suspender temporariamente a geração de texto para invocar funções externas (como motores de busca na web) a fim de obter evidências factuais em tempo real, intercalando passos de raciocínio verbalizado com ações concretas no padrão *ReAct* (Yao et al., 2023);
- **Saída Estruturada com Validação de Tipos:** Utilização de bibliotecas de validação de esquemas – nesta pesquisa, a Pydantic, que valida dados a partir de anotações de tipo da linguagem Python (PYDANTIC, 2025) – para forçar o modelo a responder exclusivamente em formatos JSON estritos e tipados.

2.4.3 Orquestração baseada em grafos de estado: LangGraph

Enquanto cadeias lineares simples (*chains*) são rígidas, aplicações complexas demandam arquiteturas cíclicas e com controle fino de fluxo. O conceito de orquestração por grafo de estados remonta à formalização dos *statecharts* (Harel, 1987), que estende

diagramas de transição de estados convencionais com hierarquia, concorrência e comunicação para especificar sistemas reativos complexos. O LangGraph (LANGCHAIN, 2024) aplica esse princípio à orquestração de agentes de IA, estruturando a aplicação como um Grafo Direcionado de Estados (StateGraph), em que cada nó executa uma função atômica (normalização, consulta vetorial, inferência LLM, persistência) e as arestas condicionais determinam o próximo passo baseando-se no estado tipado (**AgentState**). O arcabouço suporta nativamente persistência de memória (*checkpoints*) e o padrão HITL, permitindo interromper o grafo de forma transparente para aguardar a confirmação humana e retomá-lo posteriormente.

2.5 Engenharia de dados, MLOps e sustentabilidade de modelos

A sustentabilidade de uma solução de IA em ambientes de produção exige a incorporação de práticas de Engenharia de Dados e Operações de Aprendizado de Máquina (*Machine Learning Operations* – MLOps) (Kreuzberger; Kühn; Hirschl, 2022; Treveil *et al.*, 2020).

2.5.1 Desvios estatísticos: *data drift* e *concept drift*

Modelos de aprendizado de máquina operando sobre dados financeiros sofrem inevitável degradação temporal decorrente de dois fenômenos (Quiñonero-Candela *et al.*, 2008; Lu *et al.*, 2019). Registra-se desde já que esses fenômenos cumprem, nesta pesquisa, papel **motivador** do ciclo de MLOps e do aprendizado ativo (Seções 4.5 e 5.7), e não de objeto de medição: sua caracterização empírica sobre o acervo é apontada como trabalho futuro (Seção 6.4).

- **Data Drift (Desvio de Covariáveis):** Ocorre quando a distribuição das variáveis de entrada $P(X)$ se altera ao longo do tempo (ex.: novos nomes de estabelecimentos no mercado, atualização de *gateways* ou mudanças de formatação no OCR), embora a relação mapeada $P(Y|X)$ permaneça estável;
- **Concept Drift (Desvio de Conceito):** Manifesta-se quando a probabilidade condicional real $P(Y|X)$ muda (ex.: uma grande rede de postos de combustível que passa a atuar predominantemente como loja de conveniência/alimentação, alterando a categoria esperada para uma mesma descrição textual).

2.5.2 Aprendizado ativo (*active learning*) por amostragem de incerteza

Para contornar o custo proibitivo da rotulação manual exaustiva diante do surgimento contínuo de novas empresas, a literatura preconiza o Aprendizado Ativo (*Active Learning*) (Ren *et al.*, 2021). Em vez de amostrar dados aleatoriamente, o sistema calcula a

incerteza estatística de suas inferências – a estratégia de amostragem por incerteza introduzida por Lewis e Gale (1994) para o treinamento de classificadores de texto. Transações com escore de confiança inferior a um limiar seguro (nesta pesquisa, confiança $\leq 0,80$, Seção 4.7) são isoladas e encaminhadas para curadoria humana (HITL) – a estratégia de amostragem por incerteza. Os dados confirmados ampliam seletivamente a base de conhecimento. Um problema correlato, mas distinto, é o do **ruído nos rótulos já existentes**: métodos como o *Confident Learning* (Northcutt; Jiang; Chuang, 2021) estimam a distribuição conjunta entre rótulos observados e rótulos verdadeiros para identificar exemplos provavelmente mal rotulados. Esse método não é empregado nesta pesquisa; sua pertinência é discutida na Seção 5.6.3, a propósito do risco de circularidade entre a rotulagem semiautomática e o desempenho medido.

2.5.3 Arquitetura de *data lakehouse* e rastreamento com MLflow

A infraestrutura de suporte a dados moderna adota o paradigma de *data lakehouse* (Armbrust *et al.*, 2021), combinando a flexibilidade e o baixo custo de armazenamento de objetos compatíveis com S3 (como o MinIO) com as garantias transacionais e a organização em camadas Bronze/Silver/Gold – a chamada *Medallion Architecture*, convenção de mercado difundida pela Databricks a partir de sua documentação técnica, e não uma contribuição da literatura acadêmica (Armbrust *et al.*, 2021; Treveil *et al.*, 2020):

- **Camada Bronze:** Armazena os dados brutos e imutáveis exatamente como foram ingeridos (PDFs originais, extratos bancários em CSV, textos ruidosos extraídos);
- **Camada Silver:** Contém os dados limpos, saneados, normalizados e enriquecidos, organizados em esquemas analíticos;
- **Camada Gold:** Tabelas agregadas e visões analíticas prontas para consumo por motores de consulta e ferramentas de inteligência de negócios.

O ciclo de vida experimental e operacional é unificado pelo MLflow (Zaharia *et al.*, 2018; Treveil *et al.*, 2020). A plataforma atua como repositório centralizado de parâmetros, métricas e artefatos, suportando execuções aninhadas (*nested runs*) que viabilizam o rastreamento em dois níveis de granularidade: a corrida global correspondente à fatura completa e corridas filhas isoladas para cada transação individualmente classificada.

2.6 Considerações finais do capítulo

Os conceitos apresentados neste capítulo constituem a fundamentação técnica indispensável para a construção da solução proposta. A integração entre normalização morfológica, *embeddings* densos no PostgreSQL com pgvector, análise de leiaute com Docling, orquestração em grafos com LangGraph e práticas contínuas de MLOps no

data lakehouse estabelece um arcabouço metodológico sólido para o desafio de classificar faturas de cartão de crédito sob restrições de baixo custo computacional – cuja eficácia preditiva é apurada empiricamente nos Capítulos 5 e 6, e não pressuposta aqui. O capítulo seguinte revisa os trabalhos correlatos que empregam esses fundamentos, posicionando cientificamente as escolhas arquiteturais desta pesquisa frente ao estado da arte.

3 TRABALHOS RELACIONADOS

3.1 Considerações iniciais

A identificação das lacunas de pesquisa e o delineamento das escolhas arquiteturais deste trabalho exigem uma análise rigorosa do estado da arte. Este capítulo sintetiza a literatura recente referente à extração, saneamento de erros ópticos e classificação de documentos comerciais e textos informais, na forma de um **levantamento estruturado da literatura** (com elementos de revisão de escopo, *scoping review*), e não de uma revisão sistemática em sentido estrito: adotam-se questões de pesquisa próprias da revisão (Seção 3.2), um instrumento de extração de dados aplicado uniformemente a cada estudo (Seção 3.4) e uma avaliação de qualidade dos estudos incluídos (Seção 3.5). O protocolo metodológico completo do levantamento (strings de busca booleanas, bases científicas consultadas, critérios de triagem e o fluxo quantitativo de seleção) encontra-se formalizado no Apêndice A. Nas seções seguintes, apresentam-se a discussão crítica dos estudos selecionados, o quadro comparativo e o posicionamento distintivo da presente monografia. Ressalta-se que a seleção final dos estudos analisados em profundidade seguiu julgamento de centralidade em relação às questões da revisão, e não um funil formal de triagem em duas etapas com leitura integral registrada por estudo, conforme documentado com transparência no Apêndice A.

3.2 Questões de pesquisa da revisão

Distintas das Questões de Pesquisa Q1–Q5 que orientam a avaliação experimental da solução proposta (Seção 4.2), a revisão da literatura é guiada por questões de pesquisa próprias, voltadas a mapear o estado da arte:

- **QR-1:** Quais representações textuais e arquiteturas de aprendizado têm sido empregadas na literatura para classificar textos curtos, ruidosos e informais?
- **QR-2:** Quais estratégias de correção pós-OCR e saneamento léxico são reportadas para textos ruidosos oriundos de reconhecimento óptico de caracteres?
- **QR-3:** Quais abordagens de extração estruturada de documentos comerciais (notas fiscais, recibos e faturas) existem na literatura, e quais são suas limitações de generalização e de custo computacional?
- **QR-4:** Em que medida os protocolos de validação empregados nesses estudos controlam o vazamento de informação entre treino e teste (por exemplo, sobreposição de estabelecimentos ou entidades entre as partições)?

A QR-4 tem papel central no posicionamento desta pesquisa: como discutido na Seção 3.8, nenhum dos estudos selecionados reporta um protocolo de particionamento por entidade comercial, o que motiva o teste cego por estabelecimento adotado no Capítulo 5 e a quantificação da diferença de 23 a 25 pontos percentuais frente à validação cruzada convencional.

3.3 Levantamento bibliográfico e categorização dos estudos

O levantamento bibliográfico foi conduzido nas principais bases indexadoras internacionais e nacionais (Scopus, IEEE Xplore e Google Scholar), cobrindo publicações entre 2015 e 2026. A busca inicial foi executada entre janeiro e maio de 2026; em setembro de 2026, as três strings foram reexecutadas nas bases para reconstruir as contagens de registros e incorporar trabalhos publicados no intervalo, o que explica a presença de estudos de 2026 no conjunto final (protocolo detalhado no Apêndice A). Os trabalhos recuperados dividem-se em duas categorias conceituais:

- **Trabalhos Fortemente Relacionados:** Pesquisas dedicadas especificamente ao processamento de notas fiscais, faturas comerciais e saneamento de textos financeiros curtos oriundos de OCR;
- **Trabalhos Fracamente Relacionados:** Estudos focados em problemas afins, como mineração de textos informais em redes sociais, arquiteturas teóricas de autoatenção e classificação de leiaute baseada exclusivamente em visão computacional.

3.4 Instrumento de extração de dados

Para garantir a comparabilidade entre os estudos incluídos, definiu-se um instrumento de extração de dados aplicado uniformemente a cada um deles, com quatro campos fixos — detalhados na análise crítica da Seção 3.6 e sintetizados no quadro comparativo da Seção 3.7:

1. **Objetivo:** o problema de pesquisa declarado pelo(s) autor(es) e o contexto de aplicação;
2. **Abordagem:** a técnica, arquitetura ou algoritmo empregado para resolver o problema;
3. **Validação e Resultados:** o protocolo experimental adotado, os conjuntos de dados utilizados e as métricas quantitativas reportadas;
4. **Relação com esta Pesquisa:** a lacuna ou limitação identificada no estudo e de que forma ela é endereçada pela solução proposta nesta monografia.

3.5 Avaliação de qualidade dos estudos incluídos

Complementarmente aos critérios de inclusão e exclusão (Apêndice A), aplicou-se aos dez estudos incluídos um critério de avaliação de qualidade (*Quality Assessment*, QA) composto por quatro perguntas, cada uma respondida em escala ternária – Sim (1 ponto), Parcial (0,5 ponto) ou Não (0 ponto):

- **QA1:** O estudo foi publicado em periódico revisado por pares, evento indexado de relevância ou dissertação/tese de excelência?
- **QA2:** O estudo apresenta validação empírica com métricas quantitativas formais (Acurácia, F1-Score, CER ou WER)?
- **QA3:** O protocolo experimental (dados, particionamento, hiperparâmetros) é descrito com detalhe suficiente para reprodutibilidade?
- **QA4:** O domínio de aplicação do estudo (textos curtos/ruidosos ou documentos comerciais) tem correspondência direta ou indireta com o problema desta pesquisa?

O Quadro 2 sintetiza a pontuação de cada um dos dez estudos incluídos (0 a 4, soma dos pontos das quatro respostas). Nove dos dez estudos obtiveram pontuação igual ou superior a 3,5; a exceção é Santos (2022), um trabalho de conclusão de curso de graduação que, por não se enquadrar em nenhum dos veículos previstos em QA1, recebe “Não” nesse critério e pontuação 2,5 – ainda assim mantido no conjunto por sua pertinência temática direta (classificação de descrições curtas de documentos fiscais em português do Brasil), como registrado em nota ao quadro.

3.6 Análise crítica dos estudos selecionados

A seguir, examinam-se individualmente os trabalhos que compõem o núcleo do estado da arte, padronizados conforme seus objetivos, abordagem metodológica, validação experimental e principais conclusões.

3.6.1 Zhang, Zhao e LeCun (2015) e Dhingra et al. (2016)

Grau de relação: Fracamente relacionado (Seção 3.3). Ambos tratam de textos curtos e informais fora do domínio financeiro.

Objetivo: Investigar métodos de representação vetorial e classificação profunda em textos curtos, informais e ruidosos, operando diretamente no nível de caractere para dispensar vocabulários fechados.

Abordagem: Zhang, Zhao e LeCun (2015) propuseram redes convolucionais profundas (*character-level ConvNets*) que classificam texto lendo a sequência bruta de

Quadro 2 – Avaliação de qualidade dos estudos incluídos na revisão.

Estudo	QA1	QA2	QA3	QA4	Pontuação
Zhang, Zhao e LeCun (2015)	Sim	Sim	Sim	Parcial	3,5
Dhingra et al. (2016)	Sim	Sim	Sim	Parcial	3,5
Huang et al. (2019) – SROIE	Sim	Sim	Sim	Sim	4
Santos (2022)*	Não	Sim	Parcial	Sim	2,5
Araújo, Bezerra e Souza Neto (2025)	Sim	Sim	Sim	Parcial	3,5
Souza (2025)	Sim	Sim	Parcial	Sim	3,5
Ta, Saad e Oh (2023)	Sim	Sim	Parcial	Sim	3,5
Curcio, Galfré e Le Van (2026)	Sim	Sim	Parcial	Sim	3,5
Gandikota et al. (2026)	Sim	Sim	Sim	Sim	4
Farias, Mendes e Conceição (2025)	Sim	Sim	Parcial	Sim	3,5

Fonte: Elaborado pelo autor (2026). Escala ternária: Sim = 1, Parcial = 0,5, Não = 0. “Parcial” indica atendimento apenas indireto ao critério (ex.: domínio tecnicamente afim, mas não financeiro; ou dependência de dados/API proprietários que restringe a reprodutibilidade integral). *Trabalho de conclusão de curso de graduação (não revisado por pares nem dissertação/tese), mantido no conjunto por pertinência temática direta ao problema desta pesquisa, apesar de não atender a QA1.

caracteres, comparando-as a *bag-of-words*, *n*-gramas, TF-IDF e modelos baseados em palavras. Dhingra et al. (2016), com o modelo *tweet2vec*, adotaram uma Rede Neural Recorrente bidirecional (Bi-GRU) no nível de caractere para gerar *embeddings* de mensagens curtas. Ambas as linhas constroem representações semânticas densas a partir de sequências de letras adjacentes.

Validação e Resultados – Zhang, Zhao e LeCun: oito coleções de classificação de textos construídas pelos autores, com 120 mil a 3,6 milhões de exemplos de treino. A rede convolucional por caracteres (variante grande) obteve erros de teste de 5,51% em Amazon Polaridade, 39,62% em Yelp Completo e 29,55% em Yahoo Answers, contra 8,46%, 45,20% e 31,49% do melhor método tradicional (*n*-gramas com TF-IDF) – vantagem restrita às coleções de milhões de exemplos. Na menor coleção (AG News, 120 mil exemplos), a relação se inverte: 12,82% de erro da rede contra 7,64% dos *n*-gramas com TF-IDF. Os próprios autores concluem que os métodos tradicionais permanecem fortes em coleções de porte reduzido.

Validação e Resultados – Dhingra et al.: predição de *hashtags* em 2 milhões de *tweets*. O modelo por caracteres obteve precisão@1 de 28,4% e revocação@10 de 48,5% no conjunto de teste completo (50 mil mensagens), contra 24,1% e 42,8% do modelo por palavras; no subconjunto de mensagens com muitas palavras fora do vocabulário, a vantagem amplia-se (32,9% contra 20,4% de precisão@1), ao custo de tempo de treinamento maior.

Relação com esta Pesquisa: Fundamenta a decomposição de termos financeiros

em subpalavras e caracteres para reconhecer descrições truncadas (ex.: “IFD*RESTAUR”) que não constam em dicionários formais; e, ao mesmo tempo, antecipa o achado do Capítulo 5: a superioridade da modelagem por caractere depende do volume de dados rotulados, e em coleções pequenas as representações esparsas com n -gramas permanecem competitivas ou superiores.

3.6.2 Huang et al. (2019) – competição SROIE

Grau de relação: Fortemente relacionado (Seção 3.3). Documentos comerciais (recibos) com extração de campos-chave.

Objetivo: Promover o avanço de técnicas automatizadas para localização de texto, reconhecimento óptico (OCR) e extração de informação-chave em recibos comerciais digitalizados, por meio de um conjunto de dados público com mil imagens anotadas (Huang *et al.*, 2019).

Abordagem: A competição estruturou-se em três tarefas (localização de texto, OCR e extração de campos-chave). As equipes de melhor desempenho combinaram detecção de texto baseada em redes convolucionais com módulos de reconhecimento sequencial e, na etapa de extração, codificadores contextuais do tipo *Transformer* (Devlin *et al.*, 2019).

Validação e Resultados: 1.000 recibos digitalizados (600 de treino e 400 de teste), com 29, 24 e 18 submissões válidas nas três tarefas. Na localização de texto, 16 equipes superaram 90% de medida-F; no OCR, 7 equipes superaram 90%, mas nenhuma atingiu os 99% que os organizadores consideraram necessários para aplicações de recibos; na extração de informação-chave, apenas um método ultrapassou 90% (90,49% de medida-F, equipe Ping An) e mais da metade das submissões ficou abaixo de 80%. Os organizadores concluem que detecção e OCR estão maduros para recibos, ao passo que a extração de campos permanece em aberto.

Relação com esta Pesquisa: Consolida o cupom/recibo como um problema de leitura estruturada em que a preservação do leiaute tabular e a correção contextual são decisivas, motivando a extração híbrida e o saneamento adotados nesta monografia; a demanda de hardware das arquiteturas vencedoras justifica a investigação de modelos compactos e locais.

3.6.3 Santos (2022)

Grau de relação: Fortemente relacionado (Seção 3.3). Classificação de descrições curtas de documentos fiscais em português do Brasil.

Objetivo: Avaliar a viabilidade de algoritmos de aprendizado de máquina para classificar produtos em Notas Fiscais Eletrônicas (NFE) a partir de descrições textuais desestruturadas e curtas (Santos, 2022).

Abordagem: A autora comparou um classificador clássico no nível de palavras – vetorização TF-IDF associada a uma máquina de vetores de suporte (SVM) linear – com o modelo *tweet2vec* de Dhingra et al. (2016), uma rede recorrente bidirecional (Bi-GRU) no nível de caracteres, ambos treinados para atribuir a cada item a sua unidade de medida a partir da descrição textual, sobre uma amostra rotulada manualmente de notas fiscais de fornecimento à administração pública (Ministério Público da Paraíba).

Validação e Resultados: O classificador por palavras (TF-IDF com SVM linear) obteve acurácia média de 78,25% em validação cruzada estratificada de 5 dobras e acurácia máxima de 85,35% no conjunto de validação, com precisão média de 78,96%; o modelo por caracteres alcançou, em sua melhor configuração, 69,04% de acurácia. A linha de base esparsa superou, portanto, a rede por caracteres na maioria das classes. A autora atribui parte da diferença ao desbalanceamento extremo da amostra e à classe residual “indefinida”, que degradou o modelo recorrente, e relata o custo computacional do treinamento sequencial em máquinas convencionais.

Relação com esta Pesquisa: É o precedente nacional mais próximo do resultado central do Capítulo 5: em um acervo real de descrições curtas em português, com poucos milhares de exemplos e forte desbalanceamento, a representação esparsa com classificador clássico superou o modelo neural no nível de caracteres. Reforça, ainda, a necessidade de métricas sensíveis ao desbalanceamento (como o F1-Macro) e de atenção à classe residual, cujo papel na abstenção do ramo LLM é discutido na Seção 5.6.

3.6.4 Araújo, Bezerra e Souza Neto (2025)

Grau de relação: Fracamente relacionado (Seção 3.3). Correção pós-OCR de texto manuscrito genérico, não de documentos comerciais.

Objetivo: Avaliar a eficácia de modelos de linguagem monolíngues no nível de *byte* para a correção ortográfica pós-OCR de textos ruidosos produzidos por sistemas de reconhecimento de escrita (Araújo; Bezerra; Souza Neto, 2025).

Abordagem: Os autores treinaram três modelos *Monobyte* — baseados no ByT5 do Google (Xue et al., 2022) — de forma independente para inglês, francês e português do Brasil, aplicando-os como etapa de pós-processamento sobre saídas de reconhecimento textual.

Validação e Resultados: A avaliação sobre três conjuntos de manuscritos contemporâneos (IAM, RIMES e BRESSAY) mostrou reduções consistentes das taxas de erro: no IAM, 2,24% de CER e 26,37% de WER; no RIMES, 13,48% e 33,34%; e no BRESSAY, 12,78% e 40,62%. Os resultados evidenciam a eficácia da tokenização no nível de *byte* em texto ruidoso e o potencial de modelos monolíngues computacionalmente eficientes.

Relação com esta Pesquisa: Sustenta a escolha de representações no nível de

byte/caractere para tratar descrições truncadas e aglutinadas de faturas, além de reforçar a viabilidade de modelos compactos e locais em vez de LLMs massivos na etapa de saneamento.

3.6.5 Souza (2025)

Grau de relação: Fortemente relacionado (Seção 3.3). Extração estruturada de faturas comerciais.

Objetivo: Desenvolver um sistema automatizado para extração e estruturação de informações em imagens de faturas de energia elétrica e notas de serviços (Souza, 2025).

Abordagem: O autor encadeou etapas de visão computacional (segmentação de instâncias, detecção do documento, correção de perspectiva e de orientação, remoção de ruído e realce de bordas) a classificadores de leiaute baseados em Redes Neurais Convolucionais profundas (família EfficientNet), seguidos pela invocação da API comercial em nuvem Amazon Textract, em seu modo de consultas, para extração dos campos das faturas de energia elétrica.

Validação e Resultados: Em faturas da concessionária CEMIG, a solução obteve acurácia de 97,3% no conjunto de teste, com tempo médio de processamento de 35,3 segundos por documento. O sistema, contudo, é dependente dos leiautes catalogados: novos modelos de fatura exigem novos adaptadores a cada mudança estética promovida pelas concessionárias, e a extração depende de custos recorrentes de uma API externa.

Relação com esta Pesquisa: Evidencia os riscos e limitações da dependência rígida de leiautes visuais e APIs proprietárias em nuvem, justificando a opção do presente trabalho por uma arquitetura independente de leiaute visual estático, processada localmente e focada na semântica textual das transações.

3.6.6 Ta, Saad e Oh (2023)

Grau de relação: Fortemente relacionado (Seção 3.3). Classificação de descrições reais de transações bancárias – o problema mais próximo ao desta pesquisa.

Objetivo: Construir um sistema completo de classificação de transações bancárias obtidas por *Open Banking* (diretiva PSD2) no mercado francês, cobrindo coleta, rotulagem, pré-processamento, modelagem e avaliação, com foco nas particularidades linguísticas e de domínio das descrições de transação em francês (Ta; Saad; Oh, 2023). É, de toda a bibliografia consultada, o trabalho que aborda o problema mais próximo ao desta pesquisa: classificação de texto curto de descrições reais de transações financeiras.

Abordagem: Os autores definem uma etapa de pré-processamento específica do domínio – remoção de datas, de números mascarados de cartão, de moedas e localidades, filtragem de *stopwords* e de sinônimos redundantes (“cb”, “carte bancaire”), e anonimização

de nomes de pessoas por dicionário, presentes em mais de 10% das transações – seguida de deduplicação por similaridade de cosseno sobre vetores TF-IDF. A rotulagem é feita por regras de palavras-chave inclusivas e exclusivas por categoria, com validação manual posterior. Como classificadores, comparam Regressão Logística, Random Forest, SVM linear e Naive Bayes sobre n -gramas de palavra (TF-IDF) e, em um segundo experimento, sobre *embeddings* Word2Vec reduzidos por PCA, optando por um único classificador multiclasse em vez de classificadores pareados.

Validação e Resultados: O acervo compreende 94.356 transações de treino e 109.509 de teste, de clientes de grandes bancos franceses (dezembro de 2021 a janeiro de 2023), distribuídas em 84 categorias fortemente desbalanceadas. As métricas reportadas são precisão, revocação e F1 **ponderados** pelo suporte de cada classe: o SVM linear sobre TF-IDF atinge 94% de F1 ponderado com 80% do conjunto de treino, e o Random Forest sobre Word2Vec, 94–95%. Os autores observam que o pior desempenho concentra-se nas categorias de menor suporte e que, em *Groceries*, “a classificação dependeu fortemente do nome do estabelecimento”. O particionamento treino/teste é aleatório por transação, sem controle de sobreposição de estabelecimentos entre as partições.

Relação com esta Pesquisa: O estudo confirma, em outro idioma e em escala duas ordens de grandeza maior, três escolhas desta monografia: o pré-processamento léxico específico do domínio, a rotulagem semiautomática por regras com validação manual, e a competitividade de classificadores clássicos sobre representações esparsas (o TF-IDF + Random Forest desta pesquisa é diretamente comparável à sua configuração). Em contrapartida, expõe três lacunas que esta pesquisa endereça: (i) o uso exclusivo de métricas ponderadas, que mascaram o desempenho nas classes de cauda – daí a adoção do F1-Macro como métrica primária aqui; (ii) a ausência de controle de vazamento de estabelecimentos entre treino e teste (QR-4), justamente quando os próprios autores reconhecem que a classificação “dependeu fortemente do nome do estabelecimento” – o fenômeno que o teste cego por estabelecimento do Capítulo 5 quantifica; e (iii) a inexistência de mecanismos de recuperação vetorial, raciocínio com modelo de linguagem, intervenção humana no ciclo e monitoramento de desvio, tratados como componentes integrados nesta solução. O trabalho não aborda faturas de cartão de crédito brasileiras nem a extração a partir de documentos.

3.6.7 Curcio, Galfré e Le Van (2026)

Grau de relação: Fortemente relacionado (Seção 3.3). Extração de campos de faturas comerciais com modelo de visão e linguagem e decisão explícita sobre quando encaminhar à revisão humana.

Objetivo: Tornar segura a automação da extração de dados de faturas em ambiente corporativo, formalizando a decisão de dispensar a revisão humana como um problema

de classificação seletiva sob restrição de taxa de falsos positivos (FPR) por campo – uma vez que, em fluxos financeiros, um campo extraído incorretamente e não detectado pode disparar um pagamento errado e irreversível, ao passo que um falso negativo custa apenas uma revisão humana (Curcio; Galfré; Le Van, 2026).

Abordagem: Arquitetura em múltiplos estágios: extração de campos por OCR e PLN, rejeição por regras de negócio, correção por um modelo de visão e linguagem (VLM) e um módulo de pontuação por aprendizado de máquina tabular que decide, campo a campo, se a extração é confiável o bastante para dispensar revisão. Uma camada geométrica de segurança fornece um parâmetro ajustável que garante o limite de FPR entre partições dos dados, ao custo de cobertura. Os autores destacam que a contribuição mais relevante do VLM foi como *denoiser* da extração – corrigindo erros sistemáticos da cadeia OCR–PLN em campos não protegidos por regras.

Validação e Resultados: Sobre 11.253 faturas corporativas reais, o sistema atinge 73% de cobertura de validação automática (documentos que não exigem revisão humana) com FPR de 0,96% por campo, superando linhas de base apoiadas apenas em pontuações de confiança. O trabalho recebeu o prêmio de melhor artigo do DocEng 2026. Os dados são proprietários da empresa dos autores, o que restringe a reprodutibilidade integral.

Relação com esta Pesquisa: É o estudo recente mais próximo do mecanismo de confirmação humana desta monografia: ambos tratam a intervenção humana como decisão explícita e quantificada, e não como recurso residual. A diferença de enfoque é instrutiva – ali o critério é uma garantia formal de FPR por campo com cobertura medida; aqui, limiares heurísticos de confiança não calibrados (Seção 4.7), lacuna registrada na Seção 6.4. O estudo também corrobora, em escala industrial, o uso de modelos de visão e linguagem como corretores de erros de extração, e sua observação de que o ruído de rótulo em dados de produção precisa ser mitigado dialoga diretamente com o risco de circularidade discutido na Seção 5.6.3. Não aborda classificação semântica de despesas nem execução em infraestrutura local.

3.6.8 Gandikota et al. (2026)

Grau de relação: Fortemente relacionado (Seção 3.3). Extração de pares chave–valor de documentos financeiros com OCR segmentado por região e modelo de linguagem compacto ajustado.

Objetivo: Evitar a perda da informação espacial que ocorre quando esteiras OCR–LLM processam a página inteira como um fluxo de texto plano, propondo um arcabouço de compreensão de documentos financeiros (faturas, recibos e ordens de compra) consciente do leiaute (Gandikota *et al.*, 2026).

Abordagem: Renderização do PDF com PyMuPDF, segmentação da página em

cinco zonas semânticas (cabeçalho, metadados, itens, totais e rodapé) por análise de contornos com OpenCV, Tesseract OCR aplicado independentemente a cada região e um modelo Gemma-2B ajustado que recebe a saída do OCR com marcações espaciais (*layout-encoded prompting*) para extrair pares chave–valor estruturados.

Validação e Resultados: Avaliação sobre três *benchmarks* públicos (ICDAR 2019 SROIE, CORD e um subconjunto do RVL-CDIP): F1 de 94,2% na extração de informação-chave do SROIE, 4,8 pontos acima de linhas de base OCR–LLM sobre texto plano; ablações indicam contribuições independentes e sinérgicas da segmentação por região e do *prompt* com codificação de leiaute; latência média de 1,87 s por página em GPU de consumo.

Relação com esta Pesquisa: Converge com duas decisões centrais desta monografia – a preservação do leiaute como pré-condição da qualidade de extração (Seção 5.5) e o uso de um modelo de linguagem compacto da família Gemma executado em hardware de consumo – e diverge na forma de obter o leiaute: segmentação visual seguida de OCR por região, em vez de extração nativa do fluxo de texto do PDF (Seção 2.3.2). É, portanto, o contraponto natural para documentos genuinamente ópticos, regime que esta pesquisa não avaliou (Seção 6.4). Não trata da classificação semântica das transações extraídas.

3.6.9 Farias, Mendes e Conceição (2025)

Grau de relação: Fortemente relacionado (Seção 3.3). Classificação de descrições textuais curtas de documentos fiscais brasileiros, em português, com integração a sistemas de auditoria.

Objetivo: Apoiar a fiscalização tributária da Prefeitura do Recife classificando automaticamente, a partir do campo de discriminação textual, os serviços descritos em Notas Fiscais de Serviços Eletrônicas (NFS-e) do setor de saúde, para identificar divergências entre o serviço declarado e a alíquota aplicada (Farias; Mendes; Conceição, 2025).

Abordagem: Classificação multirrótulo de códigos de serviço com vetorização TF-IDF e sete algoritmos comparados (Random Forest, árvore de decisão, SVM linear, LightGBM, regressão logística, *gradient boosting* e Naive Bayes multinomial), com seleção do Random Forest; exposição do modelo por uma API em Python/FastAPI com autenticação JWT e banco PostgreSQL, integrada ao *data warehouse* municipal e a um módulo de notificação aos contribuintes.

Validação e Resultados: Base de aproximadamente 5,69 milhões de NFS-e (2022–2024), rotuladas manualmente em 21 serviços mais uma classe residual para descrições genéricas, balanceada para 2,1 milhões de amostras; validação cruzada 5-fold com partição aleatória. O Random Forest obteve F1 de 0,9969 sob validação cruzada; em avaliação

subsequente com dois auditores sobre 500 NFS-e sorteadas, o F1 foi de 0,945 – uma queda de cerca de 5 pontos percentuais entre a validação cruzada e a verificação humana independente.

Relação com esta Pesquisa: É o estudo brasileiro recente mais próximo do problema aqui tratado: descrições curtas e informais de documentos fiscais em português, TF-IDF com Random Forest como modelo vencedor entre clássicos (a mesma linha de base que lidera nesta pesquisa) e uma classe residual para descrições sem pista de categoria (análoga a *Despesas Diversas / Outros*). Duas de suas características reforçam escolhas desta monografia: a classificação multirrótulo por códigos de serviço em vez de regras fiscais temporais, e a verificação por auditores como etapa distinta da validação cruzada – cuja diferença de F1 (0,9969 contra 0,945) é um eco, em escala menor, do efeito de memorização quantificado no Capítulo 5. Diferentemente desta pesquisa, o particionamento é aleatório por nota (QR-4), o F1 reportado não é discriminado por classe e não há mecanismos de recuperação vetorial, modelo de linguagem, intervenção humana no ciclo ou extração a partir de documentos; os autores apontam *embeddings* como trabalho futuro. O domínio é o de notas de serviço para fiscalização, não o de faturas de cartão de crédito do consumidor.

3.7 Quadro comparativo e posicionamento desta pesquisa

O Quadro 3 registra o grau de relação de cada estudo com esta pesquisa (Seção 3.3) e confronta, em forma de matriz de características, quais das dez capacidades centrais da solução proposta são atendidas – integral, parcial ou inexistentemente – por cada um dos estudos correlatos, permitindo identificar de relance o que a proposta faz e os demais não fazem. A descrição narrativa de cada estudo, incluindo suas limitações específicas e a lacuna que motiva esta pesquisa, permanece detalhada na Seção 3.6. Por conter exclusivamente conteúdo qualitativo (sem dados estatísticos), o elemento é apresentado como Quadro, e não como Tabela, em conformidade com a distinção normativa da ABNT. Ressalta-se que essa comparação é necessariamente qualitativa: os estudos correlatos reportam suas métricas sobre conjuntos de dados distintos entre si e distintos do acervo desta pesquisa (IAM, RIMES e BRESSAY em Araújo, Bezerra e Souza Neto, o *benchmark* SROIE na competição ICDAR, notas fiscais eletrônicas em Santos, faturas de energia em Souza, transações de *Open Banking* francesas em 84 categorias com F1 ponderado em Ta, Saad e Oh, faturas corporativas proprietárias em Curcio, Galfré e Le Van, os *benchmarks* SROIE/CORD/RVL-CDIP em Gandikota et al., notas fiscais de serviço municipais em Farias, Mendes e Conceição), de modo que não há base comum para contrapor numericamente o F1-Macro de 69,3% obtido nesta pesquisa (Capítulo 5) aos resultados desses trabalhos.

Quadro 3 – Matriz de características: atendimento das capacidades centrais por trabalho correlato.

Trabalho	C0 Grau de relação	C1 Extração	C2 Saneamento	C3 Busca vetorial	C4 LLM	C5 HITL	C6 MLOps	C7 Local/LGPD	C8 Dados pt-BR	C9 <i>Marketplaces</i>	C10 F1-Macro
Zhang, Zhao e LeCun (2015)	Fraco	–	–	–	–	–	–	–	–	–	–
Dhingra et al. (2016)	Fraco	–	–	±	–	–	–	–	–	–	–
Huang et al. (2019) – SROIE	Forte	✓	–	–	–	–	–	–	–	–	–
Santos (2022)	Forte	–	–	±	–	–	–	–	✓	–	–
Araújo, Bezerra e Souza Neto (2025)	Fraco	–	✓	–	–	–	–	–	✓	–	–
Souza (2025)	Forte	✓	–	–	–	–	–	–	✓	–	–
Ta, Saad e Oh (2023)	Forte	–	–	±	–	–	–	±	–	–	–
Curcio, Galfré e Le Van (2026)	Forte	✓	✓	–	✓	✓	–	–	–	–	–
Gandikota et al. (2026)	Forte	✓	–	–	✓	–	–	±	–	–	–
Farias, Mendes e Conceição (2025)	Forte	–	–	–	–	±	–	–	✓	–	±
Esta Pesquisa (Proposta)	–	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓

✓ Atende ± Atende parcialmente – Não atende. Capacidades: C0 – grau de relação com esta pesquisa (Seção 3.3); C1 – extração de documentos com preservação de layout tabular; C2 – saneamento léxico pós-OCR; C3 – representação densa com recuperação vetorial; C4 – raciocínio com modelo de linguagem e uso de ferramentas; C5 – intervenção humana no ciclo (HITL); C6 – monitoramento de desvio e práticas de MLOps; C7 – execução em infraestrutura local com aderência à LGPD; C8 – avaliação sobre dados reais em português do Brasil; C9 – desambiguação de *marketplaces*; C10 – reporte de F1-Macro.

Fonte: Elaborado pelo autor (2026), com base nas descrições da Seção 3.6.

3.8 Considerações finais do capítulo

A revisão da literatura evidencia que, embora existam contribuições expressivas em tarefas isoladas (correção pós-OCR com Transformers, extração visual de notas fiscais ou classificação de transações de *Open Banking* com classificadores clássicos, esta última a mais próxima do problema aqui tratado), persiste uma lacuna quanto a soluções completas, locais e integradas para o tratamento de faturas de cartão de crédito – e, mesmo no trabalho mais próximo (Ta; Saad; Oh, 2023), o desempenho é reportado apenas em métricas ponderadas e sem controle de sobreposição de estabelecimentos entre treino e teste. A escassez de trabalhos fortemente relacionados constatada neste levantamento – dos dez estudos incluídos, apenas um aborda a classificação de descrições reais de transações financeiras, e nenhum o faz sobre faturas de cartão de crédito brasileiras nem combina essa classificação com a extração a partir do documento – constitui, ela própria, evidência da lacuna endereçada por esta pesquisa. Os estudos mais recentes (2025–2026) confirmam a direção do campo – modelos de visão e linguagem e modelos de linguagem compactos na extração de documentos financeiros, com decisão explícita sobre a revisão humana – mas permanecem em uma das duas metades do problema: extraem sem classificar despesas, ou classificam descrições fiscais sem partir do documento. Ao combinar a extração tabular

estruturada, normalização léxica, banco vetorial pgvector, agente inteligente em grafo (LangGraph) com suporte a HITL e governança MLOps no *data lakehouse*, este trabalho posiciona-se de forma distintiva frente ao estado da arte, ao integrar em um único sistema aspectos que a literatura consultada trata isoladamente – sem, contudo, antecipar aqui o desempenho preditivo alcançável, cuja verificação empírica é o objeto do Capítulo 5. As lacunas aqui identificadas são traduzidas em decisões arquiteturais concretas no capítulo seguinte, que detalha a solução proposta.

4 SOLUÇÃO PROPOSTA

4.1 Considerações iniciais

Este capítulo detalha a concepção arquitetural, os modelos matemáticos e a implementação prática da solução desenvolvida para a extração e classificação de faturas de cartão de crédito: formaliza as questões de pesquisa e as hipóteses norteadoras, descreve a metodologia baseada no CRISP-DM adaptado, caracteriza a fonte de dados e a amostragem, especifica os microsserviços do ecossistema *data lakehouse*, pormenoriza a engenharia do agente inteligente em grafo (LangGraph), estabelece as salvaguardas de conformidade com a LGPD e delinea a estratégia de garantia de qualidade e testes de software.

4.2 Questões de pesquisa e hipótese central

A formulação e a avaliação experimental deste trabalho são guiadas por cinco Questões de Pesquisa (Q1 a Q5) fundamentadas na literatura:

- **Q1:** Quais técnicas de representação textual (esparsas versus densas) e algoritmos de aprendizado (estatísticos clássicos versus modelos neurais baseados em subpalavras e agentes LLM) apresentam maior eficácia para categorizar transações a partir de descrições ruidosas e despadronizadas?
- **Q2:** Qual é o nível de acurácia global e F1-Macro alcançável por um classificador automático de gastos operando sobre faturas reais e ruidosas, considerando uma taxonomia de 10 a 20 categorias de despesas?
- **Q3:** Quais são as principais naturezas de erro cometidas pelos classificadores automatizados (ambiguidades de *marketplace*, erros de leitura de OCR, nomes informais de lojistas) e de que forma mecanismos como *Chain-of-Thought* e busca na web podem mitigá-los?
- **Q4:** Em que medida a injeção de metadados contextuais (origem do arquivo digital versus óptico, histórico de compras do usuário e descarte de prefixos de *gateways*) contribui para o incremento do desempenho preditivo?
- **Q5:** Qual é a viabilidade operacional e o custo (latência, rastreabilidade e acurácia condicional do ramo de raciocínio) de um ciclo de vida de MLOps com Aprendizado Ativo e intervenção humana (HITL) para manter e atualizar o sistema, executado integralmente em infraestrutura local? A caracterização empírica de *Data Drift* e *Concept Drift* ao longo do tempo (Seção 2.5.1), embora motivadora do ciclo de MLOps, não é objeto de medição nesta pesquisa (Seção 6.4).

A **hipótese central** submetida a teste nesta pesquisa estabelece que:

“Uma esteira híbrida que integra normalização léxica de gateways, busca por similaridade semântica em banco vetorial (pgvector), raciocínio dinâmico via agente LLM com acesso a ferramentas de busca e intervenção humana programada (Human-in-the-Loop) é capaz de classificar transações de cartão de crédito com acurácia global e F1-Macro superiores a 85% em uma taxonomia de 14 categorias.”

A conformidade com a LGPD e a execução em infraestrutura local, embora indissociáveis da solução, não integram a hipótese: são requisitos não funcionais do projeto (Capítulo 1), verificados por inspeção arquitetural (Seção 4.8) e não submetidos a teste de hipótese, por não constituírem proposições falsificáveis por experimento. Por conjugar dois critérios quantitativos distintos sob uma mesma afirmação, a hipótese central é decomposta em duas subhipóteses independentes, cada uma submetida a verificação e veredito próprios (Seção 5.8):

- **H1a (Acurácia):** a acurácia global do classificador é superior a 85%;
- **H1b (F1-Macro):** o F1-Macro do classificador é superior a 85%.

Em termos de teste estatístico, cada subhipótese é a hipótese alternativa de um par formalizado a priori: para H1a, H_0 : acurácia populacional $\leq 85\%$ contra H_1 : acurácia populacional $> 85\%$, verificado por teste binomial exato unilateral e pelo intervalo de confiança de Wilson sobre a proporção de acertos; para H1b, H_0 : F1-Macro populacional $\leq 85\%$ contra H_1 : F1-Macro populacional $> 85\%$, verificado pelo intervalo de confiança de 95% obtido por reamostragem *bootstrap*. Adota-se o nível de significância $\alpha = 0,05$; uma subhipótese é considerada sustentada somente se a estimativa pontual supera o limiar e o teste rejeita H_0 , reportando-se o intervalo de confiança como medida complementar da incerteza. Os procedimentos são detalhados na Seção 5.4.3. Como a formulação original é conjuntiva (E lógico entre H1a e H1b), a hipótese central como um todo é considerada refutada caso qualquer uma das subhipóteses seja refutada, independentemente do resultado da outra. O **objeto** da hipótese é a esteira híbrida enunciada – isto é, o agente em grafo de estados descrito na Seção 4.7 –, e é sobre ela que as duas subhipóteses são verificadas (Seção 5.8). As demais arquiteturas avaliadas (linhas de base esparsas, modelo no nível de byte e busca vetorial isolada) cumprem o papel de referência comparativa exigido pela Q1; seus resultados são reportados frente ao mesmo limiar de 85%, mas não substituem a esteira híbrida como objeto da verificação.

4.3 Metodologia da pesquisa e arcabouço CRISP-DM adaptado

A pesquisa classifica-se, quanto à sua natureza, como **aplicada**, voltada à resolução do problema prático de gestão financeira pessoal (Gerhardt; Silveira, 2009). Quanto à abordagem e procedimentos, define-se como uma pesquisa **experimental e quantitativa** (Gil, 2019), estruturada no controle de variáveis em ambiente controlado e na mensuração estatística de métricas preditivas.

O ciclo metodológico adotou o arcabouço padrão da indústria *Cross-Industry Standard Process for Data Mining* (CRISP-DM) (Chapman *et al.*, 2000; Wirth; Hipp, 2000), estendido com diretrizes contemporâneas de MLOps (Kreuzberger; Kühl; Hirschl, 2022) conforme as seis etapas sequenciais:

1. **Compreensão do Negócio:** Mapeamento das regras de faturas de cartão de crédito no Brasil, identificação de intermediadores de pagamento e taxonomia de categorias orçamentárias;
2. **Compreensão dos Dados:** Coleta e exploração de conjuntos de dados públicos oficiais (CPGF) e de faturas reais pseudonimizadas (Seção 4.8), com inspeção qualitativa do ruído nativo introduzido por intermediadores de pagamento e terminais de captura;
3. **Preparação dos Dados:** Engenharia de extração com preservação de leiaute (Docling V2) e comparação experimental com reconhecimento óptico (Tesseract OCR), normalização léxica com Regex, descarte de jargões corporativos e cálculo de *embeddings* vetoriais;
4. **Modelagem:** Desenvolvimento comparativo englobando linhas de base clássicas (TF-IDF + Random Forest / Naive Bayes), ajuste fino do ByT5 e construção do agente inteligente em grafo de estados (LangGraph com pgvector e LLM);
5. **Avaliação:** Mensuração de métricas estatísticas (Acurácia, Precisão, Revocação, F1-Macro e Matriz de Confusão), estudos de ablação e auditoria de latência;
6. **Implantação e Ciclo de Vida:** Containerização em microsserviços via Docker, armazenamento em camadas com MinIO e mensageria com Kafka, rastreamento de experimentos com MLflow (Zaharia *et al.*, 2018) e autenticação da aplicação *web* via Logto.

4.4 Fonte de dados, amostragem e natureza dos dados

A pesquisa opera exclusivamente sobre **dados reais**, e não sintéticos, provenientes de dois acervos de naturezas distintas e papéis complementares, caracterizados em detalhe na Seção 5.3:

- **Acervo governamental CPGF** (Cartão de Pagamento do Governo Federal): 477.740 transações públicas obtidas no Portal da Transparência (BRASIL, 2024), empregadas apenas para a caracterização exploratória do ruído textual em escala, e não para a mensuração preditiva;
- **Acervo pessoal de faturas de cartão de crédito** de dois emissores brasileiros (C6 Bank e Nubank), pertencentes a dois portadores de cartão: 49 faturas do C6 Bank em PDF (357 páginas) pareadas com os 49 arquivos CSV oficiais correspondentes, que constituem a verdade de referência para a medição da qualidade da extração; e os lançamentos em CSV de ambos os emissores, que alimentam a base rotulada de classificação.

A decisão de avaliar a classificação diretamente sobre o **ruído real** das faturas – truncamentos, prefixos de intermediadores de pagamento, sufixos de autorização e nomes informais aglutinados – em vez de gerá-lo sinteticamente é uma escolha metodológica deliberada: ruído sintético reproduz apenas os fenômenos que o pesquisador já conhece, ao passo que o acervo real contém a distribuição efetiva desses fenômenos e aqueles ainda não catalogados. O custo dessa escolha é o porte reduzido do acervo e sua origem em apenas dois portadores, limitação de validade externa registrada na Seção 6.4.

Quanto à **amostragem**, a base rotulada de classificação foi construída a partir dos lançamentos dos dois emissores após deduplicação e limitação a no máximo 12 lançamentos por estabelecimento – de modo que a avaliação meça a amplitude de comércios distintos, e não a frequência de poucos estabelecimentos dominantes –, totalizando 1.660 transações em 11 categorias efetivamente povoadas. A **rotulagem** é semiautomática, em duas camadas: um dicionário léxico de alta precisão validado manualmente sobre amostra (74% dos rótulos) e, nos casos não cobertos, o mapeamento da categoria nativa do emissor para a taxonomia canônica. O particionamento em treino, validação e teste cego é feito por estabelecimento, sem sobreposição de comércios entre as partições. O detalhamento completo – composição por emissor, distribuição por categoria, cobertura da taxonomia e risco de circularidade entre rotulagem e desempenho – é apresentado na Seção 5.3.2.

4.5 Arquitetura geral da solução e ecossistema de dados em camadas

A arquitetura geral do sistema foi concebida sob o paradigma orientado a eventos e microsserviços desacoplados, implementada com tecnologias de código aberto (*Open Source*) orquestradas via Docker Compose. Trata-se de uma arquitetura em camadas **inspirada no paradigma lakehouse** (Armbrust *et al.*, 2021). Desse paradigma, esta pesquisa implementa a camada Bronze em armazenamento de objetos (arquivos brutos imutáveis) e a camada de dados tratados em banco relacional e vetorial. As propriedades que caracterizam um *lakehouse* completo – formato de tabela aberto com transações ACID

- **MinIO (armazenamento de objetos S3):** Provedor de armazenamento em nuvem local compatível com a API AWS S3. A esteira utiliza o *bucket bronze-raw*, particionado por fonte e data (`bronze/source={c6|nubank}/year=/month=/day={uuid}/original`), para a preservação imutável dos arquivos brutos, e o *bucket mlflow-artifacts* como raiz de artefatos do servidor MLflow. O *script* de provisionamento cria ainda os *buckets bronze-txt* e *silver*, reservados para uma camada de textos extraídos e para tabelas abertas que não foram materializadas nesta pesquisa: os dados extraídos são gravados diretamente no PostgreSQL pelo trabalhador de extração;
- **Apache Kafka:** Barramento de mensageria que desacopla temporalmente a camada de ingestão do trabalhador de extração por meio do tópico `datalake-bronze-ingestao-topic` (os tópicos `test-topic` e `events-topic`, também criados pelo *script* de inicialização, não são usados pela esteira). O consumidor opera com uma partição, confirmação

automática de deslocamento (*auto-commit*) e leitura a partir das mensagens mais recentes, o que configura semântica de entrega *no máximo uma vez*: um evento consumido durante uma falha do trabalhador não é reprocessado – comportamento aceitável para o protótipo e registrado como evolução no Capítulo 6;

- **PostgreSQL 16 com extensão pgvector:** Banco de dados relacional e vetorial encarregado de armazenar usuários, faturas, transações, a base de conhecimento de estabelecimentos e os vetores de características densas de 384 dimensões gerados pelo modelo *paraphrase-multilingual-MiniLM-L12-v2*. A base vetorial efetivamente consultada pelo agente é a coleção *baseconhecimento*, mantida pela integração *langchain-postgres* nas tabelas *langchain_pg_collection* e *langchain_pg_embedding*; a tabela relacional *estabelecimentos* (Apêndice B) guarda cópia do mesmo *embedding* para consulta relacional e é povoada na mesma etapa (Seção 5.4);
- **Servidor MLflow:** Servidor centralizado de MLOps apoiado por *backend* relacional PostgreSQL (*mlops_db*) e *bucket* S3. A esteira experimental registra, por chamadas explícitas ao cliente MLflow, os parâmetros, as métricas globais, os relatórios por categoria, as predições e as figuras de cada arquitetura sob o experimento *experimento_faturas*. O registro automático (*autologging*) das chamadas LangChain/LangGraph – com *prompt*, *tokens* e cadeia de pensamento por transação – foi empregado apenas no *notebook* exploratório do agente e não integra a esteira reprodutível que gera os resultados do Capítulo 5;
- **Logto IAM:** Servidor de identidade baseado em OpenID Connect (OIDC) e OAuth 2.0 que autentica o usuário da aplicação *web*. Nesta versão, os pontos de acesso da API de ingestão e da API de classificação não validam o *token* emitido pelo Logto, e todos os registros são associados a um único usuário interno; o controle de acesso por papéis e o isolamento multi-inquilino são, portanto, previstos pela arquitetura mas não implementados (Seções 4.8 e 6.4).

A Tabela 1 consolida, para cada componente da solução, a linguagem, o arcabouço principal e a versão efetivamente utilizada; o ambiente de execução dos experimentos é descrito na Seção 5.2.

A camada de consumo analítico dedicada (motor SQL distribuído e painéis gerenciais de *Business Intelligence*) e a orquestração de esteiras em lote não integram o escopo implementado e avaliado nesta monografia, sendo apontadas como evolução natural da solução no Capítulo 6. A aplicação *web* (submódulo *web*) encontra-se em estágio de protótipo: implementa a autenticação via Logto e a interface de envio de faturas, mas ainda não está conectada à API de ingestão nem ao PostgreSQL; a visualização orçamentária e a tela de confirmação humana são, por isso, entregas previstas e não realizadas nesta versão (Seção 6.5).

Tabela 1 – Componentes da solução: linguagem, arcabouço principal e versão efetivamente utilizada.

Componente	Linguagem Arcabouço principal e versão	
API de ingestão reativa (<i>service-ingestao</i>)	Java 25	Spring Boot 4.0.6 (WebFlux, Spring Kafka, Reactor Kafka 1.3.22); AWS SDK for Java v2 2.27.21 (cliente S3 assíncrono contra o MinIO); ICU4J 78.3 (detecção de codificação)
Trabalhador de extração (<i>worker-prata</i>)	Python 3.11	IBM Docling 2.112.0 sobre PyPDFium2 5.9.0, com OCR desativado (entradas nativas digitais); kafka-python; SQLAlchemy
Agente de classificação (<i>notebooks/modules</i>)	Python 3.11	LangGraph 1.2.8; LangChain 1.3.12; Pydantic 2.13.4; langchain-postgres 0.0.17; RapidFuzz 3.14.5
API de classificação (<i>service-classification</i>)	Python 3.11	FastAPI 0.138.0; protótipo de classificação <i>zero-shot</i> por similaridade com <i>intfloat/multilingual-e5-large</i> , não integrado ao agente nem avaliado no Capítulo 5
Esteira experimental (<i>notebooks/experimentos</i> e <i>notebook</i> de avaliação de OCR)	Python 3.11	scikit-learn 1.7.2; PyTorch 2.12.1 (CUDA 13.0); Transformers 5.12.1; Sentence-Transformers 5.6.0; PyTesseract 0.3.13 sobre Tesseract 5.5.0; JiWER 4.0.0; cliente MLflow 3.14.0
Modelo de <i>embeddings</i>	–	<i>paraphrase-multilingual-MiniLM-L12-v2</i> (384 dimensões)
Modelo de raciocínio local	–	<i>google/gemma-4-e4b</i> servido pelo LM Studio (API compatível com OpenAI)
Banco relacional e vetorial	SQL	PostgreSQL 16 com pgvector (imagem <i>pgvector/pgvector:pg16</i>)
Barramento de eventos	–	Apache Kafka 4.3.0
Armazenamento de objetos	–	MinIO (imagem <i>minio/minio</i> , API S3)
Servidor de rastreamento	–	MLflow (imagem <i>ghcr.io/mlflow/mlflow</i>)
Identidade e acesso	–	Logto (imagem <i>svhd/logto</i>), OIDC/OAuth 2.0
Aplicação web (<i>web</i> , submódulo)	TypeScript	Next.js 16.2.10; React 19.2.4; <i>@logto/next</i> 4.2.10
Orquestração de contêineres	–	Docker Engine 29.4.0 com Docker Compose

Fonte: Elaborada pelo autor (2026), a partir de *service-ingestao/build.gradle*, *web/package.json*, *infra/docker-compose-externalinfra.yml* e do ambiente Python que executou os experimentos (versões instaladas conferidas em setembro de 2026). Versões das imagens marcadas como *latest* no *compose* não são fixadas pelo repositório. O ambiente de execução (máquinas e sistema operacional) é descrito na Seção 5.2.

4.6 Esteira de ingestão e extração híbrida de documentos

A camada de extração foi concebida para processar documentos digitais nativos (CSV e PDF com camada de texto) e, arquiteturalmente, arquivos ópticos escaneados, por meio de um fluxo em três etapas:

1. **Identificação de Metadados no *data lakehouse*:** A API de ingestão persiste cada

arquivo em `bronze-raw` sob um caminho particionado (ex.: `bronze/source=nubank/year=2026/month=08/day=09/{uuid}/original.csv`) e o anota com metadados S3 (emissor de origem, formato detectado, *hash* SHA-256, codificação de caracteres e *flag requer-ocr*). Somente os formatos CSV e PDF são aceitos pela ingestão; OFX e JSON, citados no escopo do Capítulo 1, constam apenas da heurística de metadados e não têm analisador implementado. No agente, a função determinística `extrair_metadados_datalake` inspeciona esse caminho e deriva o banco de origem, as partições temporais e a *flag is_digital_nativo*, que alterna a instrução de origem do dado no *prompt* do modelo de linguagem (Apêndice D). A heurística classifica como nativos digitais os arquivos `.csv`, `.ofx`, `.json`, `.txt` e `.xml`; qualquer outra extensão – inclusive `.pdf`, que no acervo desta pesquisa é sempre nativo digital – recebe a instrução de considerar possíveis erros de OCR. Essa imprecisão, e o fato de o metadado ter permanecido fixo durante o teste cego, são discutidos na Seção 5.2;

2. **Conversão com Docling V2 (Leiaute Tabular):** Em faturas em formato PDF (Nubank e C6 Bank), o trabalhador de extração (`worker-prata`) utiliza o `DocumentConverter` da biblioteca IBM Docling V2 com *backend* PyPdfium para a leitura da camada de texto nativa e com os modelos neurais de análise de leiaute e reconstrução de tabelas executados em GPU (CUDA). O reconhecimento óptico interno do Docling é mantido **desativado** (`do_ocr = False`), pois as entradas são nativas digitais e protegidas por senha. O conversor mapeia itens de tabela com caixas delimitadoras e exporta o conteúdo estruturado em Markdown delimitado por pipes (`|`), preservando a correspondência exata entre data, final do cartão de crédito, descrição do estabelecimento e valor em reais (R\$). Analisadores específicos por emissor (`extrator_c6bank`, `extrator_nubank`) convertem as linhas em transações e as persistem no PostgreSQL com *status* pendente de classificação;
3. **Extração com Tesseract OCR e Filtro de Confiança:** Para recibos em imagem estrita ou páginas sem camada de texto, foi implementada a rotina `extrair_texto_avancado` (`notebooks/modules/utils.py`), que rasteriza as páginas a 300 DPI e aciona o Tesseract OCR em modo OEM 3 (redes LSTM) e PSM 6 (bloco uniforme de texto), aplicando à saída de `image_to_data` um **filtro de confiança** $> 40\%$ que descarta fragmentos visuais irrecuperáveis.

Cabe explicitar o estado de integração da terceira etapa: a rotina Tesseract está implementada como componente autônomo e foi exercitada na bateria comparativa de extração (Seção 5.5), mas **não está acoplada ao trabalhador de extração** – não há, nesta versão, roteamento automático que a acione quando o Docling não identifica tabelas ou quando o arquivo é uma imagem. Tampouco foi submetida a validação sobre documentos genuinamente escaneados ou fotografados: a avaliação quantitativa do Capítulo 5 opera

inteiramente sobre PDFs nativos digitais do C6 Bank, artificialmente rasterizados para viabilizar a comparação com o Docling V2. Ambas as lacunas são registradas como limitação do trabalho (Seção 6.4).

4.7 Engenharia do agente de classificação inteligente

O núcleo de tomada de decisão do sistema foi codificado como um grafo de estados direcionado (StateGraph) no arcabouço LangGraph, suportado pelo estado tipado `AgentState` e ilustrado na Figura 2. O fluxo operacional do agente é estruturado nas seguintes etapas coordenadas:

1. **Nó `normalizar`:** Executa a limpeza léxica da descrição da transação com Regex, eliminando duplicações em torno de asteriscos (ex.: “TIM*TIM” → “TIM”), descartando termos de pagamento (“PAG*”, “PIX”, “COMPRA”) e sufixos societários (“LTDA”, “ME”). Realiza a resolução de aliases de marcas e verifica se a compra pertence à lista de *marketplaces* ambíguos (`eh_marketplace`) – as expressões regulares completas, a lista de *marketplaces* e o dicionário de aliases encontram-se reproduzidos no Apêndice E, acompanhados de uma análise crítica do artefato;
2. **Roteamento Pós-Normalização (`rota_apos_normalizar`):** Se a transação for detectada como *marketplace*, o fluxo passa primeiro pelo nó `buscar_historico_marketplace` antes de prosseguir; caso contrário, é direcionado diretamente ao nó de busca vetorial `buscar_por_similaridade`. Na versão avaliada, a detecção compara o nome canônico devolvido pela resolução de aliases com as chaves do dicionário de *marketplaces*; como o alias canônico do Mercado Livre (“mercado livre”) difere da chave correspondente (“mercado_livre”), esse *marketplace* – o mais frequente do acervo – nunca foi roteado pelo ramo de histórico (Apêndice E, Seção E.4);
3. **Nó `buscar_historico_marketplace`:** Consulta o histórico consolidado do usuário no banco PostgreSQL (`sugestoes_categoria_marketplace`), recuperando as categorias confirmadas anteriormente em compras de *marketplace*, e armazena o resultado no estado do agente; o fluxo segue para o nó `buscar_por_similaridade`, executado para toda transação. Na versão avaliada, a consulta é filtrada apenas pelo usuário (não pelo estabelecimento) e o histórico recuperado **não é injetado** no *prompt* do nó `classificar_com_llm`: o enriquecimento do contexto por histórico está previsto no estado tipado e no esquema do banco, mas não chega a influenciar a decisão – lacuna registrada na Seção 6.4 e relevante para a resposta à Q4;
4. **Nó `buscar_por_similaridade`:** Executa a busca por similaridade de cosseno na coleção vetorial do pgvector ($k = 3$ vizinhos), utilizando os *embeddings* gerados pelo modelo `paraphrase-multilingual-MiniLM-L12-v2` sobre a descrição normalizada.

Se a melhor correspondência apresentar escore de similaridade $\geq 0,85$, a transação é considerada classificada com alta certeza pelo ramo vetorial e roteada diretamente para o nó `salvar_resultado`, sem passar pelo ramo LLM nem pelo nó `salvar_vectorstore` (o estabelecimento já consta da base vetorial). Os vizinhos recuperados são usados exclusivamente para essa decisão de roteamento: eles **não são repassados ao modelo de linguagem** como exemplos, de modo que o ramo LLM opera em regime *zero-shot* (Seção 2.2.3.2);

5. **Nó `classificar_com_llm`:** Caso a busca vetorial resulte em confiança inferior a 0,85, aciona-se o modelo de linguagem (LLM). O nó injeta um *System Prompt* dinâmico contendo: (i) metadados da origem do arquivo; (ii) regras de decodificação de terminais de captura e adquirentes; (iii) diretrizes antialucinação; (iv) cadeia de pensamento obrigatória gerando o campo `raciocinio` antes da categoria; e (v) acesso à ferramenta `duckduckgo_search` para pesquisar nomes comerciais obscuros – o texto integral do *prompt* encontra-se reproduzido no Apêndice D. A mensagem de usuário enviada ao modelo contém a **descrição bruta** da transação (“Classifique esta transação: ...”), não a descrição normalizada – a normalização léxica alimenta o ramo vetorial, e o ramo LLM recebe o texto original acompanhado das regras de decodificação de *gateways* do *prompt*. Se o servidor de inferência rejeitar a vinculação de ferramentas (*tool binding*), o nó repete a chamada sem ferramentas, de forma transparente;
6. **Roteador Unificado e Nó `tools`:** Se o LLM emitir uma chamada de ferramenta (*tool call*), o fluxo executa a pesquisa autônoma na web pelo `ToolNode` e retorna as evidências para o classificador;
7. **Nó `estruturar_saida_llm`:** Converte a resposta em texto livre do LLM no contrato `Pydantic ClassificacaoLLM` (categoria, subcategoria, escore de confiança de 0 a 1, justificativa, lista de categorias alternativas e cadeia de raciocínio; esquema completo no Apêndice D) por uma cascata de três estratégias: (a) extração por expressão regular do bloco JSON que o próprio *prompt* exige ao final da resposta; (b) na ausência desse bloco, nova chamada ao modelo com `with_structured_output` e validação Pydantic; (c) em caso de falha, uma segunda chamada de extração em texto livre com análise manual do JSON. Em todas as vias, o rótulo devolvido é **ancorado** à lista de categorias do banco por casamento exato, aproximado (`difflib`, corte 0,6) ou por substring; rótulos sem correspondência recebem a categoria residual *Despesas Diversas / Outros*. A implicação desse ancoramento para a leitura da matriz de confusão é discutida na Seção 5.6;
8. **Nó `aguardar_confirmacao (HITL)`:** Se o escore de confiança for $\leq 0,80$ ou se o LLM sinalizar `requer_confirmacao`, o grafo executa o comando `interrupt`, pau-

sando o processamento da *thread* e aguardando a validação ou correção do usuário; a execução é retomada via `Command(resume=resposta)`. O ponto de verificação (*checkpoint*) empregado é o `MemorySaver`, mantido em memória do processo: a retomada só é possível pelo mesmo processo que interrompeu o grafo. Em consequência, nas duas modalidades de execução desta pesquisa a interrupção é retomada programaticamente – no teste cego aceitando a sugestão do LLM, no modo de gravação mantendo a sugestão com *status sugerida* para revisão posterior no banco – e nenhuma delas aguarda um revisor humano em tempo real (Seção 5.7). A espera efetiva por confirmação exige um *checkpoint* persistente e uma interface de revisão, ambos previstos como trabalho futuro;

9. **Nó salvar_vectorstore:** Alcançado somente pelo ramo LLM: transações classificadas pelo modelo de linguagem com confiança autoavaliada $> 0,85$, ou confirmadas por humano (confiança 1,0), têm sua descrição normalizada e metadados persistidos na coleção vetorial, retroalimentando a base de conhecimento; as demais atravessam o nó sem persistência. No teste cego, esse nó é substituído por uma operação nula para impedir que o próprio teste contamine a base vetorial;
10. **Nó salvar_resultado:** Persiste a transação definitiva no PostgreSQL com integridade referencial, registrando a categoria, o método de classificação utilizado (`vetorial`, `llm`, `humano`), o escore de confiança, a *flag* de confirmação pendente e o *status* de revisão. A tabela de *log* por inferência (`log_classificacoes`, com *prompt*, resposta bruta e tempo de processamento) está modelada no esquema, mas **não é alimentada** por este nó na versão avaliada; a rastreabilidade por transação limita-se, portanto, às colunas de método e confiança de `transacoes`, e a rastreabilidade por experimento ao MLflow (Seção 5.7).

Para eliminar qualquer ambiguidade da descrição em prosa, o Quadro 4 enumera as arestas do grafo exatamente como codificadas (`notebooks/experimentos/05_agente.py`, função `build_graph`): cada linha é uma aresta (origem, condição, destino); arestas sem condição são incondicionais.

A ferramenta de busca autônoma na web (`duckduckgo_search`), descrita nos itens acima como parte da engenharia do agente, é habilitada por variável de ambiente (`AGENTE_WEB`) e foi exercitada em uma execução complementar do teste cego, na qual os *backends* de busca do pacote cliente falharam por erros de conexão na maior parte das chamadas (registro na Seção 5.2). Os resultados principais do Capítulo 5 correspondem à execução com a ferramenta desabilitada; a execução com a ferramenta é reportada como evidência complementar.

Os três limiares numéricos que governam o roteamento do agente desempenham papéis distintos e não concorrentes: similaridade de cosseno $\geq 0,85$ decide a classificação direta

Quadro 4 – Arestas do grafo de estados do agente (origem, condição de roteamento, destino).

Origem	Condição	Destino
normalizar	eh_marketplace verdadeiro	buscar_historico_marketplace
normalizar	caso contrário	buscar_por_similaridade
buscar_historico_marketplace	–	buscar_por_similaridade
buscar_por_similaridade	similaridade $\geq 0,85$	salvar_resultado
buscar_por_similaridade	caso contrário	classificar_com_llm
classificar_com_llm	o LLM emite chamada de ferramenta	tools
classificar_com_llm	caso contrário	estruturar_saida_llm
tools	–	classificar_com_llm
estruturar_saida_llm	requer_confirmacao ou confiança $\leq 0,80$	aguardar_confirmacao
estruturar_saida_llm	caso contrário	salvar_vectorstore
aguardar_confirmacao	–	salvar_vectorstore
salvar_vectorstore	– (persiste somente se confiança $> 0,85$)	salvar_resultado
salvar_resultado	–	fim

Fonte: Elaborado pelo autor (2026), a partir de `notebooks/experimentos/05_agente.py`.

pelo ramo vetorial (nó `buscar_por_similaridade`); confiança $\leq 0,80$ é o único critério operacional que efetivamente aciona a intervenção humana (nó `aguardar_confirmacao`); e confiança $\leq 0,70$ é um piso interno que o LLM aplica à sua própria autoavaliação ao sinalizar estabelecimentos totalmente opacos no *prompt* do nó `classificar_com_llm`, não um critério de roteamento independente. Como $0,70 < 0,80$, toda transação autoavaliada pelo LLM nesse piso já está necessariamente contida no conjunto encaminhado à curadoria humana, de modo que os dois valores não competem pela mesma decisão. Os três valores foram adotados de forma **heurística**, com base em convenções usuais de literatura de aprendizado ativo e recuperação de informação (valores redondos que demarcam, respectivamente, alta confiança, incerteza relevante e baixa confiança). Não foram submetidos a calibração formal nem a análise de sensibilidade sobre o conjunto de validação de 176 transações (Seção 5.3.2), ainda que esse conjunto tenha sido reservado com essa finalidade. A ausência dessa calibração é registrada como limitação do trabalho (Seção 6.4).

4.8 Conformidade com a LGPD e segurança da informação financeira

O processamento de dados transacionais bancários envolve informações altamente sensíveis que revelam hábitos de vida, localização geográfica, saúde e patrimônio dos cidadãos. A arquitetura proposta foi desenhada em observância à Lei Geral de Proteção de Dados Pessoais (LGPD – Lei nº 13.709/2018) (BRASIL, 2018), estruturando-se sobre quatro salvaguardas:

1. **Princípio da Necessidade (Art. 6º, III):** A esteira limita o tratamento ao mínimo necessário à finalidade de categorização orçamentária. Números completos de cartões de crédito, códigos de segurança (CVV), endereços residenciais e senhas não são extraídos dos documentos, preservando-se apenas a descrição textual, a data, o valor

da compra e os quatro dígitos finais do cartão, necessários para distinguir cartões adicionais e virtuais de uma mesma fatura;

2. **Pseudonimização do Titular (Art. 13, § 4º):** Nenhum CPF, documento de identidade ou dado de cartão do titular é armazenado. O cadastro de usuários restringe-se ao mínimo necessário à autenticação (identificador numérico, nome, e-mail e situação), e todas as tabelas transacionais referenciam o titular exclusivamente por esse identificador numérico interno – de modo que faturas, transações e histórico de classificação são **pseudonimizados**, no sentido legal do termo: só podem ser associados a um indivíduo com o uso de informação mantida separadamente (o cadastro e o servidor de identidade Logto, item 4). Não se trata, portanto, de anonimização, e a lei continua aplicável a esses dados;
3. **Soberania de Processamento em Infraestrutura Local (Privacidade por Design):** Ao adotar extração documental local, modelos locais de *embeddings* e de linguagem e contêineres executados na infraestrutura do próprio usuário, a solução reduz substancialmente o risco de vazamento de extratos bancários para servidores de terceiros ou provedores comerciais proprietários de IA, eliminando essa via específica de exposição – ainda que não elimine outras superfícies de risco (por exemplo, o próprio ambiente local do usuário). A única exceção é a ferramenta opcional de busca na web, que envia à internet o nome do estabelecimento (nunca valores, datas ou dados do titular);
4. **Autenticação e Rastreabilidade (Art. 46):** A aplicação *web* autentica o usuário pelo servidor Logto via protocolo OpenID Connect (OIDC). Na versão avaliada, contudo, as APIs de ingestão e de classificação não validam o *token* de acesso, e o controle por papéis (RBAC) não está implementado – a segurança de acesso aos dados depende, por ora, do isolamento de rede da infraestrutura local. A rastreabilidade das decisões é atendida em dois níveis: por transação, pelas colunas de método, confiança e *status* de revisão da tabela `transacoes`; e por experimento, pelo MLflow. A tabela `log_classificacoes`, modelada para registrar cada inferência com *prompt* e resposta, não é alimentada nesta versão (Seção 4.7).

Base legal do tratamento. O tratamento dos dados dos dois portadores de cartão realizou-se para fins exclusivamente acadêmicos, hipótese em que a LGPD dispensa parte de suas exigências (Art. 4º, II, “b”), mas preserva a aplicação de seus princípios e a necessidade de uma base legal (Arts. 7º e 11). A base legal adotada é o **consentimento** (Art. 7º, I): o autor é um dos portadores, e o segundo portador consentiu expressamente com o uso de suas faturas nesta pesquisa. Descrições de estabelecimento, datas e valores não constituem dados pessoais sensíveis (Art. 5º, II); observa-se apenas que a categoria *Saúde*,

inferida a partir do nome do estabelecimento, pode ser lida como indício indireto sobre a saúde do titular, razão adicional para que o acervo não seja distribuído (Apêndice C).

Verificação empírica. Para que os princípios acima não fiquem apenas como asserção, a base de produção do agente foi inspecionada por consulta somente leitura (`notebooks/experimentos/10_verificacao_lgpd.py`), que conta, nas colunas textuais persistidas (3.025 transações e 488 estabelecimentos, nos campos de descrição original e normalizada, além das seis colunas textuais do log de classificações), as ocorrências de quatro padrões de dado sensível: número de cartão (13 a 19 dígitos, com ou sem separadores), CPF (com ou sem máscara), código de verificação rotulado (“cvv”/“cvc” seguido de dígitos) e endereço de e-mail. O resultado foi de **zero ocorrências** para CPF, CVV e e-mail em todas as colunas. O padrão de número de cartão, deliberadamente amplo, apontou quatro cadeias candidatas, todas a mesma descrição de estabelecimento (um lançamento parcelado do *marketplace* Shopee e seu registro na base de conhecimento) contendo um identificador numérico de 15 dígitos que não satisfaz o algoritmo de Luhn – isto é, um número de pedido do *marketplace*, e não um PAN de cartão (`notebooks/experimentos/10b_inspecao_lgpd.py`, que imprime os candidatos com os dígitos mascarados). A mesma consulta confirmou que a tabela de usuários não possui coluna de CPF e que nenhum de seus campos textuais contém padrão de CPF, e que as seis colunas textuais de `log_classificacoes` estão vazias – consistente com o fato de essa tabela não ser alimentada nesta versão. A verificação converte a asserção de necessidade em evidência sobre o estado efetivo da base; ela não substitui, contudo, uma auditoria da camada bruta (*bucket* Bronze), em que os PDFs originais das faturas – que naturalmente contêm nome do titular e final do cartão – são preservados por desígnio. Registra-se, por fim, que as credenciais de serviço da infraestrutura local (banco, armazenamento de objetos e servidor de identidade) constam em claro no repositório e nos arquivos de configuração; sua externalização para variáveis de ambiente é uma correção de segurança pendente, sem impacto nos resultados.

4.9 Estratégia de garantia de qualidade e testes

Para um sistema distribuído e poliglota de natureza exploratória, a garantia de qualidade apoiou-se em três frentes, de maturidade desigual:

- **Testes de Regressão de Modelo:** A esteira experimental reproduzível (`notebooks/experimentos/`, etapas 01 a 11) fixa a semente aleatória e um conjunto de teste cego particionado por estabelecimento (sem vazamento de estabelecimento entre conjuntos), permitindo detectar regressões nas métricas preditivas a cada alteração de código, *prompt* ou hiperparâmetro, com os resultados versionados no MLflow. Esta é a frente efetivamente automatizada e exercitada;
- **Validação de Integração Assistida:** A comunicação de ponta a ponta entre a

API de ingestão, o barramento Kafka, o armazenamento de objetos MinIO e o serviço consumidor de extração foi exercitada de forma assistida em ambiente Docker Compose, confirmando a publicação e o consumo de eventos e a persistência dos arquivos brutos e das transações extraídas;


- **Testes Unitários:** O ambiente Python está preparado para *pytest* (com suporte a execução assíncrona), mas a suíte de testes unitários das funções determinísticas de pré-processamento — saneamento léxico com *Regex*, analisadores (*parsers*) de datas e valores monetários, resolução de *aliases* comerciais e contratos Pydantic — **não foi escrita** nesta versão; o serviço de ingestão em Java conta apenas com a verificação de carga do contexto *Spring Boot* via *JUnit 5*. A ausência dessa suíte explica, em parte, que defeitos determinísticos do agente (como a chave de *marketplace* não casada, Apêndice E) tenham sido identificados apenas na revisão final do código.

A suíte de testes unitários e a automação plena da esteira de testes (integração com *Testcontainers* e testes de carga do barramento) são registradas como trabalho futuro no Capítulo 6.

4.10 Considerações finais do capítulo

A arquitetura da solução proposta materializa uma abordagem pragmática e modular para o desafio da classificação de faturas financeiras. Ao articular a extração híbrida, busca vetorial densa em banco PostgreSQL, agente em grafo LangGraph com HITL, salvaguardas de privacidade e governança MLOps no *data lakehouse*, o sistema estabelece as bases técnicas necessárias para a validação empírica detalhada no capítulo seguinte.

Figura 2 – Grafo de estados do agente de classificação (StateGraph no LangGraph), com os nós de normalização, roteamento, busca vetorial, inferência com modelo de linguagem e confirmação humana.



Nota: correspondência entre identificadores e função – **normalizar**: limpeza léxica; **buscar_historico_marketplace**: consulta ao histórico do usuário; **buscar_por_similaridade**: busca vetorial por similaridade (pgvector); **classificar_com_llm**: inferência com modelo de linguagem; **tools**: pesquisa autônoma na web; **aguardar_confirmacao**: confirmação humana (HITL); **estruturar_saida_llm**: validação estruturada da resposta do LLM; **salvar_vectorstore**/**salvar_resultado**: persistência no banco de dados. Descrição detalhada de cada nó na lista da Seção 4.7; arestas no Quadro 4.

Fonte: Elaborada pelo autor (2026).

5 VALIDAÇÃO EXPERIMENTAL E RESULTADOS

5.1 Considerações iniciais

A validação empírica constitui a etapa decisiva para verificar a eficácia prática da solução proposta e responder formalmente às questões de pesquisa estabelecidas. Este capítulo apresenta o ambiente computacional dos experimentos (Seção 5.2); a caracterização dos conjuntos de dados, com ênfase no acervo de faturas do C6 Bank e seus arquivos de verdade de referência (Seção 5.3); o protocolo de mensuração e as métricas adotadas (Seção 5.4); os resultados da extração óptica, confrontando o IBM Docling V2 e o Tesseract OCR (Seção 5.5); os resultados comparativos da classificação, incluindo análise por emissor, por proveniência do rótulo, por categoria e o estudo de ablação (Seção 5.6); a avaliação de MLOps, latência e observabilidade (Seção 5.7); e as respostas às questões de pesquisa com a verificação da hipótese central (Seção 5.8), seguidas das considerações finais (Seção 5.9).

5.2 Ambiente computacional e configuração experimental

O ambiente computacional foi composto por duas máquinas físicas distintas na rede local, com papéis complementares: uma estação de trabalho principal, na qual foram executados os experimentos de treinamento e inferência, e um servidor doméstico dedicado, que hospedou a infraestrutura containerizada de dados durante toda a pesquisa.

- **Estação de Trabalho (treinamento e inferência):** Processador AMD Ryzen 7 5700G (8 núcleos / 16 *threads*, 3,8 GHz base), 32 GB de memória RAM DDR4 2667 MHz, GPU dedicada NVIDIA GeForce RTX 3060 Ti com 8 GB de VRAM GDDR6 (suporte a aceleração CUDA 13.0), armazenamento SSD NVMe e Sistema Operacional Windows 11 Pro N. Nela rodaram o treinamento das linhas de base TF-IDF, o ajuste fino do ByT5, a geração de *embeddings*, a extração via Docling V2/Tesseract e o modelo de raciocínio local (LM Studio);
- **Servidor de Infraestrutura de Dados (*data lakehouse* containerizado):** Mini computador Beelink Mini S (Intel Celeron N5095, 4 núcleos / 4 *threads*, 8 GB de RAM DDR4, SSD de 256 GB), executando AlmaLinux 9.8, conectado à estação de trabalho por rede local (Ethernet Gigabit). Hospeda, via Docker, os contêineres de PostgreSQL 16 com extensão pgvector, MinIO e MLflow (Tabela 1), todos acessados pela estação de trabalho por IP fixo na rede local – ou seja, as latências de consulta ao pgvector e de registro no MLflow reportadas neste capítulo incluem o tempo de rede LAN entre as duas máquinas, não apenas o tempo de processamento local. Um segundo mini computador idêntico (mesmo modelo, com Windows 11) compõe a

mesma infraestrutura doméstica mas não foi utilizado diretamente na execução dos experimentos reportados neste capítulo;

- **Software e Bibliotecas (estação de trabalho):** Python 3.11.15, PyTorch 2.12.1 (CUDA 13.0), Transformers 5.12.1, Sentence-Transformers 5.6.0, scikit-learn 1.7.2, LangChain 1.3.12, LangGraph 1.2.8, IBM Docling 2.112.0, PyTesseract 0.3.13 sobre o motor Tesseract 5.5.0 (modelos em português), PyPDFium2 5.9.0, RapidFuzz 3.14.5, JiWER 4.0.0 e cliente MLflow 3.14.0, sob Docker Engine 29.4.0 – a relação completa por componente está na Tabela 1;
- **Modelo de *Embeddings* (Sentence Transformers):** `sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2` (Reimers; Gurevych, 2019), executado localmente na estação de trabalho para gerar os vetores densos de 384 dimensões utilizados pelo ramo de busca vetorial densa e armazenados na extensão pgvector (Seção 4.5);
- **Modelo de Raciocínio Local (LLM):** `google/gemma-4-e4b` (GEMMA TEAM, 2026), servido localmente pelo aplicativo LM Studio por meio de uma API compatível com o padrão OpenAI (`langchain.chat_models.init_chat_model`), com **temperatura fixada em 0** (decodificação gulosa/determinística) e limite de **2.048 *tokens*** de saída por chamada. A configuração do servidor de inferência não foi registrada pela esteira experimental no momento da execução, mas pôde ser **documentada retroativamente** a partir do registro de execução do próprio LM Studio (versão 0.4.23) referente ao dia dos experimentos (08/09/2026): *checkpoint* instruído `gemma-4-E4B-it`, no formato GGUF com quantização **Q4_K_M** (distribuição `lmstudio-community`, com projetor multimodal em BF16 carregado mas não utilizado), servido pelo motor `llama.cpp` para CUDA 12 (extensão 2.33.0), com **janela de contexto de 8.192 *tokens*** (`n_ctx_slot = 8192`) em quatro *slots* paralelos. Todas as requisições de conclusão registradas nesse dia (509, abrangendo as duas execuções do teste cego) enviaram apenas `temperature = 0` e `max_completion_tokens = 2048`; os demais parâmetros de amostragem permaneceram nos valores configurados no servidor, conferidos na configuração de carregamento do modelo: `top-k = 40`, `top-p = 0,95` e semente aleatória (`-1`, isto é, sorteada a cada requisição). Com temperatura 0 a decodificação é gulosa, de modo que `top-k`, `top-p` e semente não afetam a escolha do *token*; a variabilidade residual entre execuções decorre apenas de efeitos numéricos do motor de inferência (quantização e paralelismo em lote), não de amostragem;
- **Ferramenta de busca na web (DuckDuckGo):** o teste cego do agente foi executado duas vezes, com a ferramenta desabilitada e habilitada (variável `AGENTE_WEB`). Na execução **com** a ferramenta, os *backends* de busca do pacote cliente (`ddgs`) falharam por erro de conexão em 48 das 334 transações (14,4%; predominantemente

no *backend* de consulta à Wikipédia, com falhas residuais no Yahoo e uma desconexão do servidor), abortando o grafo nessas transações, que receberam a categoria residual; nas demais, o LLM chamou ou não a ferramenta a seu critério. Essa execução obteve acurácia de 57,2% e F1-Macro de 53,8% (61,2% das transações concluídas resolvidas pelo ramo vetorial, 1,2% de intervenção humana, latência média de 8,9 s), contra 61,4% e 60,0% da execução sem a ferramenta. Como os erros de conexão contaminam a comparação – não é possível separar o efeito da evidência recuperada do efeito das falhas de execução –, adotou-se como **resultado principal a execução sem a ferramenta**, e a execução com a ferramenta é tratada como evidência complementar (arquivos `agente_teste_bruto_COMWEB.csv` e `agente_metricas_COMWEB.json` no repositório). As demais menções à indisponibilidade da ferramenta neste trabalho remetem a este registro;

- **Metadado de origem no teste cego:** o caminho do arquivo que alimenta o metadado de origem do *prompt* (Seção 4.6) foi **fixado** em um caminho CSV do C6 Bank para todas as 334 transações do teste cego, inclusive as 100 do Nubank, porque o conjunto rotulado não carrega o caminho de origem de cada lançamento. Em consequência, o LLM recebeu “Banco Origem: c6” e a instrução de arquivo nativo digital para todo o teste, o que (i) informa origem incorreta ao subconjunto do Nubank e (ii) impede que a componente “origem do arquivo” da Q4 tenha sido efetivamente variada na avaliação. No modo de gravação em produção, o caminho real é utilizado. O efeito é discutido nas Seções 5.6.2 e 5.8.

O código-fonte completo da solução e a esteira experimental reproduzível que gera os resultados apresentados neste capítulo estão disponíveis no repositório público descrito no Apêndice C.

Limitação de reprodutibilidade do ramo LLM: a temperatura zero direciona o modelo à decodificação gulosa, o que reduz – mas não elimina por si só – a variabilidade entre execuções, já que fatores do servidor de inferência (versão do *backend*, quantização, paralelismo em lote) podem introduzir pequenas diferenças numéricas não controladas por este trabalho. Como o ramo LLM responde por 48% das transações do teste cego (Seção 5.6), esses efeitos numéricos limitam a reprodutibilidade bit a bit dos resultados desse ramo, ainda que a configuração do modelo e do servidor esteja integralmente documentada acima; a lacuna residual é registrada como limitação do trabalho (Seção 6.4).

5.3 Caracterização dos conjuntos de dados (*datasets*)

A experimentação foi estruturada sobre conjuntos de dados complementares, abrangendo dados governamentais e faturas reais de instituições financeiras. O acervo governamental (mais de 470 mil transações) foi empregado para a **caracterização exploratória**

do ruído textual; a **mensuração preditiva** da classificação apoiou-se em um subconjunto rotulado das faturas pessoais reais (detalhado ao final desta seção):

1. **Conjunto de Dados Governamental CPGF (Cartão de Pagamento do Governo Federal):** Acervo público oficial obtido no Portal da Transparência do Governo Federal (BRASIL, 2024). O conjunto reúne 44 arquivos CSV mensais consolidados, totalizando **477.740 transações financeiras reais** contendo campos como nome do favorecido comercial, CNPJ, órgão responsável, data e valor monetário transacionado;
2. **Acervo Real de Faturas Bancárias C6 Bank e Nubank:** Extratos de cartões de crédito pessoais obtidos junto a instituições financeiras brasileiras em formatos digitais nativos (CSV) e em documentos PDF nativos digitais protegidos por senha (leiaute tabular multicolumnar). No caso do C6 Bank, reuniu-se um acervo abrangendo competências de janeiro de 2022 a agosto de 2026, com 49 das 56 competências efetivamente disponíveis (Tabela 3), composto por **49 faturas em PDF** (totalizando 357 páginas protegidas por senha) e os respectivos **49 arquivos CSV oficiais**, os quais foram utilizados como verdade de referência de alta fidelidade para a mensuração de erros de OCR;
3. **Ruído Real de Intermediadores de Pagamento:** As próprias faturas do C6 Bank e do Nubank já contêm, de forma nativa, os fenômenos de ruído que se deseja estressar — truncamentos de descrição, prefixos de adquirentes (“PAG*”, “MP*”, “IFD*”), sufixos numéricos de autorização e nomes informais aglutinados de pequenos negócios (ex.: “jhoonymorango”). Optou-se por avaliar os modelos diretamente sobre esse ruído real, em vez de gerá-lo sinteticamente.

5.3.1 Caracterização textual do acervo governamental CPGF

O campo **NOME FAVORECIDO** das 477.740 transações do CPGF foi processado para caracterizar quantitativamente a natureza do ruído textual desse acervo, complementando a formulação do problema do Capítulo 1. A Tabela 2 sintetiza os resultados.

A caracterização revela um perfil de ruído **qualitativamente distinto** do observado nas faturas de cartão de crédito pessoais (Quadro 1): o campo **NOME FAVORECIDO** do CPGF é preenchido a partir do cadastro de pessoa jurídica do favorecido, não da descrição livre impressa por um terminal de captura ou *gateway* de pagamento. Em consequência, a incidência de prefixos de *gateway* (asterisco) é **nula** neste acervo – confirmando que esse fenômeno específico é característico do domínio de faturas de cartão de crédito ao consumidor (C6 Bank e Nubank, item 3 acima), e não do universo de pagamentos institucionais. Por outro lado, o CPGF exhibe dois fenômenos de ruído próprios: (i) alta prevalência (50,1%) de sufixos de natureza jurídica, o mesmo fenômeno que a rotina de

Tabela 2 – Caracterização textual do campo NOME FAVORECIDO no acervo CPGF ($N = 477.740$).

Métrica	Valor
Comprimento (caracteres): média / mediana / desvio-padrão	23,7 / 22 / 14,4
Comprimento: percentis 10/25/75/90/99	8 / 12 / 34 / 44 / 64
Registros com valor administrativo redigido ou ausente*	37,6%
Registros contendo sufixo de natureza jurídica (LTDA, S.A., EIRELI, ME, EPP)	50,1%
Registros contendo prefixo de <i>gateway</i> /adquirente (asterisco “*”)	0,0%
Registros contendo sequência numérica de 4 ou mais dígitos	0,8%
Entropia lexical, nível de caractere (49 símbolos distintos)	4,13 bits/caractere
Entropia lexical, nível de <i>token</i> (37.766 <i>tokens</i> distintos)	8,47 bits/ <i>token</i>

* Valores como *Sigiloso* (23,6%), *Não se Aplica* (9,3%), *Sem Informação* (4,5%) e campo vazio (0,2%).

Fonte: Elaborada pelo autor (2026), a partir do processamento de `data/datasets/faturas_gov.csv`.

normalização léxica desta pesquisa trata (Apêndice E), corroborando empiricamente a necessidade dessa etapa em escala; e (ii) uma parcela substancial (37,6%) de registros com valores administrativos redigidos ou ausentes (*Sigiloso*, *Não se Aplica*, *Sem Informação*), um tipo de ruído – ausência sistemática de informação, não distorção textual – não tratado pela esteira de saneamento léxico desta pesquisa e não caracterizado anteriormente na formulação do problema do Capítulo 1. O acervo CPGF cumpre, portanto, um papel de **diversidade e escala** (quase meio milhão de transações reais de centenas de órgãos públicos) e de caracterização exploratória de ruído institucional, distinto e complementar ao papel do acervo pessoal C6 Bank/Nubank na mensuração preditiva (Seção 5.3.2).

Para a avaliação de extração óptica, estabeleceu-se um procedimento determinístico de pareamento temporal entre os documentos em PDF e os arquivos CSV do C6 Bank. Por meio da leitura dos metadados das primeiras páginas dos PDFs, identificou-se a data de corte (fechamento por volta do dia 8 de cada mês) e o vencimento (fixado no dia 15), mapeando-se com exatidão 1 : 1 cada uma das 49 faturas ao seu respectivo arquivo `Fatura_AAAA-MM-15.csv`. A Tabela 3 resume a distribuição do acervo de faturas do C6 Bank por ano de competência.

As transações foram rotuladas em uma taxonomia de **14 categorias canônicas de despesas**: Alimentação, Transporte, Moradia, Saúde, Educação, Vestuário, Lazer e Entretenimento, Tecnologia, Beleza e Cuidados Pessoais, Pets, Serviços Financeiros, Marketplace / E-commerce, Doações / Presentes e Despesas Diversas. Por convenção

Tabela 3 – Distribuição do acervo de faturas do C6 Bank com pareamento PDF e CSV.

Ano de Competência	Faturas (PDF)	CSVs (verdade de referência)	Páginas
2022	12	12	74
2023	12	12	80
2024	11	11	73
2025	12	12	112
2026	2	2	18
Total	49	49	357

Fonte: Elaborada pelo autor (2026). O acervo não é contínuo: uma competência de 2024 não estava disponível e, em 2026, apenas duas das oito competências decorridas até a coleta estavam disponíveis.

tipográfica, os nomes de categoria da taxonomia são grafados em redondo ao longo do texto, mesmo quando contêm estrangeirismos (“Marketplace / E-commerce”, “Pets”), por se tratarem de rótulos de classe e não de termos em uso corrente; o estrangeirismo como termo comum permanece em itálico (*marketplace*, *e-commerce*).

5.3.2 Conjunto rotulado de referência para a classificação

Como as faturas do Nubank não trazem rótulo de categoria e a categorização nativa do emissor C6 Bank é derivada de códigos MCC — frequentemente imprecisa (por exemplo, serviços de nuvem rotulados como “Elétrico” e plataformas de ingressos como “Serviços Profissionais”) — adotou-se um procedimento de rotulagem de referência em duas camadas: (i) um **dicionário léxico de alta precisão** com dezenas de padrões de estabelecimentos consolidados (“UBER”→Transporte, “IFD*”→Alimentação, “DROGA”→Saúde, “NETFLIX/STEAM”→Lazer etc.), validado manualmente sobre amostra; e (ii) o **mapeamento da categoria nativa do emissor** para a taxonomia canônica nos casos não cobertos pelo dicionário.

Após deduplicação e limitação a no máximo 12 lançamentos por estabelecimento — para que o conjunto de referência meça a amplitude de comércios e não a frequência de um único estabelecimento dominante (ex.: “UBER* TRIP”) — o conjunto totalizou **1.660 transações rotuladas**, das quais 74% pelo dicionário léxico. As categorias *Pets*, *Serviços Financeiros* e *Doações e Presentes* não apresentaram amostragem suficiente no acervo pessoal disponível e foram agregadas a *Despesas Diversas / Outros*, restando **11 categorias efetivamente avaliadas**.

O particionamento foi feito **por estabelecimento** (todas as ocorrências de uma mesma descrição pertencem a um único conjunto), impedindo o vazamento de comércios entre treino e teste: 1.150 transações para treino, 176 para validação e **334 para o teste cego congelado**. Como detalhado na Seção 5.4, os conjuntos de treino e validação

foram unificados na implementação efetiva, de modo que o volume de treinamento (e de povoamento da base vetorial) foi de **1.326 transações** para todas as arquiteturas. Esse protocolo é deliberadamente mais severo que a partição aleatória: mede a capacidade de generalizar para *estabelecimentos inéditos*, não a de reconhecer comércios já vistos. Ressalta-se que a rotulagem semiautomática e o porte reduzido do acervo constituem limitações discutidas no Capítulo 6. Como o dicionário léxico de alta precisão compartilha padrões de superfície (ex.: “UBER”, “IFD*”) com os próprios atributos que os classificadores esparsos aprendem, existe um **risco de circularidade** entre o método de rotulagem e o desempenho relativo dos modelos, quantificado na Seção 5.6.3.

Quanto à **composição por instituição emissora e à validade externa**, das 1.660 transações rotuladas, 1.388 (83,6%) têm origem no C6 Bank e 272 (16,4%) no Nubank, cobrindo 11 e 9 das 11 categorias canônicas, respectivamente. O acervo como um todo provém das faturas pessoais de apenas **dois portadores de cartão**, o que limita a diversidade de hábitos de consumo, estabelecimentos frequentados e faixas de renda representados na rotulagem – uma limitação de validade externa detalhada na Seção 6.4. No teste cego de 334 transações, resultante do particionamento aleatório por estabelecimento, a proporção por emissor desloca-se para 234 do C6 Bank (70,1%) e 100 do Nubank (29,9%); nesse recorte específico, o subconjunto do Nubank cobre apenas 5 categorias, concentradas em *Alimentação* (53%) e *Saúde* (40%) – consequência do porte menor do acervo Nubank combinado ao particionamento por estabelecimento, que pode não sortear comércio algum de uma categoria de cauda para o teste. O desempenho discriminado por emissor é reportado na Seção 5.6.

5.4 Protocolo experimental e métricas de avaliação

Para garantir rigor estatístico e reprodutibilidade, a avaliação foi dividida em duas frentes complementares: avaliação da extração de texto (OCR) e avaliação da classificação semântica.

5.4.1 Métricas para extração óptica e reconhecimento de texto

Para avaliar a qualidade da transcrição em relação à verdade de referência fornecida pelos CSVs bancários oficiais, adotaram-se o *Character Error Rate* (CER) e o *Word Error Rate* (WER), formalmente definidos na Seção 2.3.3 a partir da Distância de Edição de Levenshtein $L(\cdot, \cdot)$, aqui agregados sobre o corpus de N transações auditadas (ref_i denotando o texto oficial no CSV e hyp_i a transcrição obtida pelo motor de OCR para a i -ésima transação). Complementarmente, define-se a **Taxa de Casamento Exato** (*Exact Match Rate*) como a fração percentual de transações transcritas com exatidão perfeita

$(L(ref_i, hyp_i) = 0)$:

$$EMR = \frac{1}{N} \sum_{i=1}^N \mathbb{I}[L(ref_i, hyp_i) = 0] \quad (5.1)$$

5.4.2 Métricas para classificação semântica de transações

Para a classificação de categorias, adotou-se o particionamento **por estabelecimento** (Seção 5.3.2): 69% para treinamento, 11% nominalmente reservados para validação, e 20% (334 transações) mantidos estritamente congelados para teste cego, com todas as ocorrências de um mesmo comércio confinadas a um único conjunto. Na implementação efetiva da esteira experimental, o conjunto de validação foi incorporado ao conjunto de treinamento – formando o conjunto “treino+validação”, de 1.326 transações, sobre o qual se computaram a validação cruzada 5-fold (*5-fold cross-validation*) e o ajuste final de cada arquitetura – e não foi empregado para uma busca sistemática de hiperparâmetros: os valores adotados por cada modelo (Tabela 4) foram fixados *a priori*, não sintonizados empiricamente. Essa lacuna é registrada como limitação do trabalho (Seção 6.4). A comparação entre a validação cruzada e o teste cego quantifica o efeito de memorização de comércios.

O desempenho preditivo foi mensurado por meio da Matriz de Confusão e de quatro métricas clássicas de classificação multiclasse, a partir das contagens por categoria TP_k , FP_k e FN_k e das grandezas Precisão_k e Revocação_k já formalizadas na Seção 2.2.5: Acurácia Global (Equação 5.2), Precisão Macro (Equação 5.3), Revocação Macro (Equação 5.4) e F1-Macro (Equação 5.5).

$$\text{Acurácia} = \frac{\sum_{k=1}^K TP_k}{\text{Total de Amostras}} \quad (5.2)$$

$$\text{Precisão Macro} = \frac{1}{K} \sum_{k=1}^K \text{Precisão}_k \quad (5.3)$$

$$\text{Revocação Macro} = \frac{1}{K} \sum_{k=1}^K \text{Revocação}_k \quad (5.4)$$

$$\text{F1-Macro} = \frac{1}{K} \sum_{k=1}^K \frac{2 \cdot \text{Precisão}_k \cdot \text{Revocação}_k}{\text{Precisão}_k + \text{Revocação}_k} \quad (5.5)$$

em que K representa o total de categorias efetivamente avaliadas ($K = 11$ no acervo disponível). A Revocação Macro (Equação 5.4) coincide com a **acurácia balanceada**, métrica recomendada para dados desbalanceados por atribuir peso igual a cada classe independentemente do seu suporte; ela é reportada nas tabelas sob o nome de Revocação. A adoção primordial do F1-Macro justifica-se pela sua capacidade de avaliar o desempenho preditivo de forma equitativa em classes minoritárias desbalanceadas (como Educação e Moradia), impedindo que o modelo mascare erros por meio de acertos concentrados nas classes majoritárias (como Alimentação).

Tabela 4 – Hiperparâmetros efetivamente adotados por arquitetura (valores fixados *a priori*).

Arquitetura	Hiperparâmetros
Vetorização TF-IDF	ColumnTransformer com dois vetorizadores concatenados: palavras (<i>analyzer=word</i> , <i>n</i> -gramas (1,2), <i>min_df</i> =1, <i>sublinear_tf</i> =True) e caracteres (<i>analyzer=char_wb</i> , <i>n</i> -gramas (2,4), <i>min_df</i> =1); sem dimensão máxima de vocabulário
TF-IDF + Naive Bayes	MultinomialNB nos valores padrão do <i>scikit-learn</i> (suavização de Laplace $\alpha = 1,0$)
TF-IDF + Random Forest	RandomForestClassifier : 400 árvores, <i>class_weight</i> ="balanced_subsample" (tratamento de desbalanceamento), profundidade máxima não limitada (padrão <i>scikit-learn</i>)
ByT5 com ajuste fino	google/byt5-small ; taxa de aprendizado 5×10^{-4} ; 12 épocas (sem parada antecipada – critério de parada é o número fixo de épocas); lote de 16 amostras (sem acumulação de gradiente); proporção de aquecimento (<i>warmup ratio</i>) 0,1; decaimento de pesos (<i>weight decay</i>) 0,01; comprimento máximo de entrada/saída de 64/16 <i>tokens</i> . Os parâmetros <i>epochs</i> e <i>lr</i> registrados no MLflow para esse <i>run</i> (18 e 3×10^{-4}) refletem uma versão anterior do <i>script</i> e não os valores efetivamente usados no treino, aqui reportados a partir do código
Busca vetorial densa	paraphrase-multilingual-MiniLM-L12-v2 (384 dimensões, sem ajuste fino); base de conhecimento com um vetor por estabelecimento único do conjunto treino+validação (488 estabelecimentos); classificação por $k = 3$ vizinhos mais próximos com voto ponderado pela similaridade de cosseno, calculada em memória; limiar de alta confiança 0,85 (apenas para a métrica de cobertura); a consulta ao pgvector é usada para medir a latência

Fonte: Elaborada pelo autor (2026), a partir de `notebooks/experimentos/02_baselines.py`, `03_byt5.py` e `04_rag_pgvector.py`.

5.4.3 Intervalos de confiança e teste de significância

Com apenas 334 transações no conjunto de teste cego, distribuídas de forma desbalanceada entre 11 categorias (algumas com 4 a 5 exemplos), diferenças pontuais de poucos pontos percentuais entre arquiteturas não são, por si só, evidência de superioridade real – podem ser explicadas por ruído amostral. Para caracterizar essa incerteza, adotaram-se dois procedimentos:

- **Intervalos de confiança por reamostragem *bootstrap*** (Efron, 1979): para cada arquitetura, o conjunto de 334 predições pareadas ($y_{\text{verdadeiro}}, y_{\text{predito}}$) foi reamostrado com reposição 2.000 vezes: a cada reamostragem, recalculou-se o F1-Macro, obtendo-se uma distribuição empírica da métrica. O intervalo de confiança de 95% corresponde aos percentis 2,5% e 97,5% dessa distribuição;

- **Teste de McNemar pareado** (McNemar, 1947): entre as duas arquiteturas de maior F1-Macro, contabilizaram-se as transações em que apenas uma delas acertou a classificação, formando uma tabela de contingência 2×2 . A estatística χ^2 (com correção de continuidade) avalia se a discordância entre os dois classificadores é assimétrica o suficiente para rejeitar a hipótese nula de desempenho equivalente, ao nível de significância $\alpha = 0,05$;
- **Intervalo de confiança e teste exato para a acurácia global:** como a subhipótese H_{1a} é enunciada sobre a acurácia, e a acurácia é a proporção de acertos k/n em $n = 334$ ensaios, adotou-se para ela o intervalo de confiança de 95% de Wilson e o teste binomial exato unilateral da hipótese nula de que a acurácia populacional é menor ou igual a 85% – de modo que a verificação de H_{1a} não dependa apenas da estimativa pontual.

Os procedimentos foram aplicados sobre as predições brutas de cada arquitetura no mesmo conjunto de teste cego (Seção 5.3.2), disponíveis em `notebooks/experimentos/resultados/predicoes_*.csv` no repositório do projeto (Apêndice C); os dois primeiros na etapa `09_rag_norm_significancia.py` e o terceiro na etapa `11_ic_acuracia.py`.

5.5 Resultados da extração e pré-processamento óptico

A primeira bateria experimental comparou dois paradigmas de ingestão documental (Seção 2.3.2) aplicados sobre o acervo de faturas do C6 Bank:

1. **Tesseract OCR (versão 5.5):** Paradigma convencional baseado em visão computacional e OCR óptico rasterizado, processando as páginas convertidas em imagens de alta resolução (300 DPI) com modelos de idioma para português (`por`);
2. **IBM Docling V2:** Paradigma de compreensão de leiaute de documentos (*Document Layout Analysis*), integrando o *backend* digital PyPdfium2 com modelos neurais de detecção e segmentação de tabelas (*Table Transformer*), gerando como saída texto estruturado em tabelas Markdown.

Cabe explicitar o desenho experimental: as faturas do C6 Bank utilizadas nesta bateria são **PDFs nativos digitais**, com camada de texto codificada (Seção 2.3.2) – não documentos escaneados ou fotografados. O Docling V2 opera nesse regime em seu paradigma natural, extraindo o texto diretamente da codificação digital do arquivo. O Tesseract, por não realizar essa extração nativa, foi aplicado sobre a rasterização das mesmas páginas em imagens de 300 DPI, isto é, fora do cenário em que o reconhecimento óptico é estritamente necessário. A comparação a seguir mede, portanto, o **custo de descartar a camada de texto nativa** de um PDF já digital e submetê-lo a rasterização

seguida de OCR – não uma comparação entre dois motores de OCR sobre material genuinamente escaneado, cenário em que o Tesseract permanece a escolha pertinente e que não foi avaliado nesta pesquisa (Seção 6.4).

A avaliação englobou **14 das 49 faturas** pareadas do acervo C6 Bank (Seção 5.3), totalizando **699 transações auditadas**: duas a três competências por ano civil (2022–2026), escolhidas para cobrir a variação temporal do acervo: a primeira competência disponível de cada ano (janeiro, ou fevereiro em 2026) e uma ou duas competências adicionais espaçadas ao longo do ano (Tabela 6), de modo a expor a bateria às mudanças de diagramação da fatura entre anos e dentro de um mesmo ano. Como a extração automatizada custa poucos segundos por fatura, a extensão da bateria às 49 competências tem custo baixo e fica registrada como desdobramento (Seção 6.5). Não foi aplicado um procedimento de amostragem probabilística; trata-se de uma amostra de conveniência, e os resultados desta seção devem ser lidos como um diagnóstico sobre essas 14 faturas, não uma estimativa com garantias estatísticas sobre as 49. Para cada transação da verdade de referência contida no arquivo CSV oficial da instituição financeira, avaliou-se tanto a cadeia completa da transação (*Descrição do Estabelecimento + Valor Monetário*) quanto o campo isolado da descrição comercial, totalizando **1.398 comparações** entre predição e verdade de referência.

5.5.1 Desempenho quantitativo global: Docling V2 versus Tesseract

Os resultados médios consolidados das 14 faturas avaliadas (de um total de 49 pareadas no acervo) são apresentados na Tabela 5.

Tabela 5 – Desempenho comparativo global entre Docling V2 e Tesseract OCR.

Métrica de Avaliação	Docling V2	Tesseract OCR	Vantagem / Impacto
CER (Transação Completa)	5,72% ($\pm 6,75\%$)	52,82% ($\pm 9,84\%$)	Docling V2 erra 9,2× menos caracteres
WER (Transação Completa)	10,14% ($\pm 12,47\%$)	85,36% ($\pm 12,43\%$)	Docling V2 erra 8,4× menos palavras
CER (Apenas Descrição)	6,42% ($\pm 8,20\%$)	54,60% ($\pm 12,54\%$)	Docling V2 erra 8,5× menos na descrição
WER (Apenas Descrição)	10,26% ($\pm 13,67\%$)	93,34% ($\pm 14,67\%$)	Docling V2 é 9,1× mais preciso
Distância de Levenshtein Média	1,30 caracteres	10,72 caracteres	Tesseract erra +9,4 caracteres por linha
Taxa de Casamento Exato (<i>Exact Match</i>)	86,2%	3,3%	Docling V2 acerta +82,9 pontos percentuais
Tempo Médio de Processamento / Fatura	5,56 segundos	8,76 segundos	Docling V2 é 1,6× mais rápido

Fonte: Elaborada pelo autor (2026).

A Tabela 6 detalha o comportamento dos dois motores por competência mensal ao longo dos cinco anos do acervo histórico analisado.

5.5.2 Análise visual das métricas e dispersão de erros

A distribuição das taxas de erro de caracteres (CER) e de palavras (WER) é ilustrada no diagrama de caixa da Figura 3. Observa-se que a distribuição do Docling V2 concentra-se quase integralmente próxima de zero (mediana de CER inferior a 2,5%), enquanto o Tesseract exibe dispersão ampla e média superior a 50% de erro por transação.

Tabela 6 – Detalhamento de CER, WER, Casamento Exato e Latência por fatura do C6 Bank.

Competência	Págs.	Qtd. GT	CER Completo (%)		WER Completo (%)		Casamento Exato (%)		Tempo de Extração (s)	
			Docling V2	Tesseract	Docling V2	Tesseract	Docling V2	Tesseract	Docling V2	Tesseract
2022-01	6	25	15,1%	60,9%	21,3%	89,0%	76,0%	0,0%	3,35 s	6,80 s
2022-02	6	34	4,0%	67,4%	7,6%	106,3%*	79,4%	0,0%	8,01 s	6,91 s
2022-04	7	51	13,1%	63,5%	24,3%	90,1%	41,2%	0,0%	5,95 s	7,93 s
2023-01	7	57	1,8%	50,9%	4,8%	79,8%	96,5%	1,8%	5,45 s	8,24 s
2023-02	7	45	24,6%	39,1%	46,1%	63,3%	57,8%	33,3%	4,69 s	8,06 s
2023-03	6	33	1,6%	60,0%	5,3%	91,7%	97,0%	3,0%	4,18 s	7,05 s
2024-01	7	51	2,0%	50,7%	4,7%	85,6%	96,1%	2,0%	5,23 s	8,36 s
2024-02	7	41	4,8%	57,4%	10,0%	96,3%	90,2%	2,4%	4,79 s	8,09 s
2024-05	6	28	2,8%	46,6%	3,3%	83,6%	92,9%	3,6%	2,94 s	7,32 s
2025-01	10	91	2,0%	50,6%	2,7%	87,1%	96,7%	0,0%	8,35 s	11,70 s
2025-04	9	74	2,2%	60,3%	4,6%	95,3%	95,9%	0,0%	7,21 s	10,48 s
2025-08	9	70	1,5%	53,7%	2,0%	93,2%	97,1%	0,0%	6,68 s	10,42 s
2026-02	9	43	2,3%	41,0%	2,7%	68,2%	95,3%	0,0%	5,51 s	10,54 s
2026-08	9	56	2,0%	38,1%	2,4%	65,5%	94,6%	0,0%	5,57 s	10,74 s
Média	7,5	49,9	5,72%	52,82%	10,14%	85,36%	86,2%	3,3%	5,56 s	8,76 s

* Diferentemente do CER e da Taxa de Casamento Exato, o WER (Seção 2.3.3) não é limitado superiormente a 100%: como o termo de Inserção I_w no numerador não guarda relação de tamanho com o total de palavras de referência N_w no denominador, uma transcrição suficientemente fragmentada (por exemplo, quando o Tesseract quebra uma linha tabular em *tokens* espúrios adicionais) pode inserir mais palavras espúrias do que a referência possui, produzindo $WER > 100\%$ – é o que ocorre em 2022-02.

Fonte: Elaborada pelo autor (2026).

A evolução temporal do CER ao longo das diferentes faturas bancárias é exibida na Figura 4. Com exceção de competências específicas com variações na diagramação do cabeçalho da fatura em 2022 e 2023, o Docling V2 manteve estabilidade expressiva: CER abaixo de 5% em todas as competências a partir de 2024 (Tabela 6) e abaixo de 2,5% em todas as competências de 2025 e 2026. Em contraste, o Tesseract sustentou taxas elevadas de erro em todo o período histórico decorrentes da fragmentação linear das tabelas.


Na Figura 5, analisa-se a Taxa de Casamento Exato (*Exact Match Rate*) e a Distância Média de Levenshtein por fatura. O Docling V2 alcançou entre 90% e 97% de casamentos exatos na grande maioria dos extratos, com distância de Levenshtein média de apenas 1,30 caracteres contra mais de 10 caracteres no Tesseract.

5.5.3 Análise qualitativa de erros e preservação estrutural de tabelas

A discrepância acentuada entre o Docling V2 e o Tesseract decorre fundamentalmente da diferença arquitetural na forma de interpretar a informação presente nos documentos:


1. **Quebra do Leiaute Tabular pelo Tesseract OCR:** O Tesseract opera em nível puramente rasterizado, convertendo a imagem em linhas horizontais sequenciais de texto. Em faturas de cartão de crédito diagramadas em colunas paralelas (**Data | Descrição | Parcela | Valor**), o Tesseract frequentemente concatena colunas

Figura 3 – Distribuição comparativa de CER e WER entre Docling V2 e Tesseract OCR.



Fonte: Elaborada pelo autor (2026).


Figura 4 – Taxa de Erro de Caracteres (CER %) por competência de fatura (C6 Bank 2022–2026).



Fonte: Elaborada pelo autor (2026).

adjacentes (ex.: fundindo a descrição com a parcela em uma única string: “CLUBE DO INGRESSO - PARCELA 1/2” em vez de separar a parcela em atributo estruturado), ou salta colunas e captura elementos periféricos de cabeçalho e rodapé (como ilustrado no caso em que transcreveu erroneamente “JUROS DE MORA” no lugar de “EBANX SPOTIFY”);

Figura 5 – Taxa de Casamento Exato (%) e Distância Média de Levenshtein por competência de fatura (painéis superior e inferior, respectivamente).



Fonte: Elaborada pelo autor (2026).

2. **Preservação da Topologia de Tabelas pelo Docling V2:** O Docling V2 utiliza modelos de visão de documento (*Document Layout Analysis*) e redes neurais treinadas para identificação e reconstrução de tabelas (*Table Transformer*). Ao reconhecer a grade delimitadora da tabela de lançamentos do cartão, o Docling V2 preserva o isolamento de cada célula em Markdown (`| Data | Estabelecimento | Valor |`), extraíndo o texto nativo dos fluxos digitais do PDF sem sofrer distorções ópticas ou fusão de colunas.

O Quadro 5 apresenta uma amostra qualitativa de transações reais inspecionadas lado a lado, evidenciando as falhas de transcrição típicas de cada abordagem confrontadas com a verdade de referência oficial.

Em suma, a escolha do Docling V2 para a etapa de ingestão de documentos mostrou-se determinante para a qualidade da entrada do classificador subsequente, pois reduziu o CER de 52,82% para 5,72% e elevou a taxa de casamento exato para 86,2%, entregando

Quadro 5 – Amostra comparativa de transações reais: verdade de referência versus Docling V2 versus Tesseract.

Fatura	Verdade de Referência (CSV)	Predição Docling V2	Lev. Doc.	Predição Tesseract	Lev. Tess.
2022-01	ASSAI ATACADISTA 370,33	ASSAI ATACADISTA 370,33	0	ASSAI ATACADISTA 370,33	0
2022-01	CLUBE DO INGRESSO 106,94	CLUBE DO INGRESSO 106,94	0	CLUBE DO INGRESSO - PARCELA 1/2 106,94	14
2022-01	DL HELPHBOMAXCOM 13,95	DL HELPHBOMAXCOM 13,95	0	DL HELPHBOMAXCOM 13,95	0
2022-01	EBANX SPOTIFY 34,90	EBANX SPOTIFY 34,90	0	JUROS DE MORA 34,90	12
2024-01	UBER TRIP 19,99	UBER TRIP 19,99	0	UBER* TRIP VALORES EM REAIS 19,99	18
2025-08	IFOOD *IFD*MR DELIVE 51,97	IFOOD *IFD*MR DELIVE 51,97	0	IFOOD IFD MR DELIVE 51,97	3

Fonte: Elaborado pelo autor (2026). Embora as colunas de distância de Levenshtein sejam numéricas, o elemento é apresentado como quadro, e não como tabela, porque seu conteúdo predominante é textual (amostras de transcrição lado a lado) e os números cumprem função ilustrativa, não estatística – mesmo critério da Seção 3.7.

descrições limpas e fidedignas para o agente inteligente.

5.6 Resultados comparativos da classificação de transações

Para responder às questões de pesquisa Q1 e Q2, cinco arquiteturas foram implementadas e avaliadas sobre **o mesmo conjunto de teste cego de 334 transações**, cujos estabelecimentos são **disjuntos** dos utilizados em treino e no povoamento da base vetorial (particionamento por estabelecimento; Seção 5.3). Todas as métricas e artefatos foram registrados no MLflow. A Tabela 7 sumariza os resultados globais; a Figura 6 ilustra o desempenho preditivo e a Figura 7, a latência de cada arquitetura.


Tabela 7 – Comparativo global de desempenho preditivo e tempo médio de inferência (teste cego de 334 transações, estabelecimentos disjuntos).

Modelo / Arquitetura	Norm. léxica	Acurácia	Precisão	Revocação	F1-Macro	Latência
Linha de Base 1: TF-IDF + Naive Bayes	não	88,3%	69,8%	61,7%	63,6%	0,03 ms
Linha de Base 2: TF-IDF + Random Forest	não	84,7%	74,1%	66,5%	69,3%	0,28 ms
Modelo neural em nível de byte: ByT5 (byt5-small)	não	65,9%	52,0%	53,0%	48,3%	65,47 ms
Busca vetorial densa: pgvector + MiniLM	não	82,6%	57,9%	55,4%	56,2%	1,42 ms
Agente Híbrido Completo (LangGraph)	sim	61,4%	68,4%	62,9%	60,0%	6.529,97 ms

Fonte: Elaborada pelo autor (2026). A coluna “Norm. léxica” indica se a arquitetura consumiu a descrição após a rotina de normalização léxica de *gateways* (Apêndice E); as quatro primeiras operaram sobre a descrição bruta (a busca vetorial, sobre uma chave de casamento com apenas minúsculas e remoção de acentos). No agente, o ramo vetorial consultou a base com o texto integralmente normalizado, ao passo que o ramo LLM recebeu a descrição bruta na mensagem de usuário (Seção 4.7); a marcação “sim” refere-se ao ramo que decide o roteamento. O efeito dessa etapa sobre cada família de representação é medido na Seção 5.6.5. Latência em milissegundos para todas as arquiteturas, para comparação direta; a do agente é a média sobre as 334 transações ($\approx 6,5$ s) e é dominada pelo ramo LLM (gemma-4-e4b local), cuja latência condicional média é de $\approx 13,7$ s.


Aplicando o procedimento da Seção 5.4.3, a Tabela 8 apresenta os intervalos de confiança de 95% do F1-Macro de cada arquitetura. A tabela inclui, além das cinco configurações da Tabela 7, a busca vetorial densa *com* normalização léxica (66,8%, Seção 5.6.5): como a normalização tem efeito oposto sobre as duas famílias de representação,

Figura 6 – Acurácia e F1-Macro por arquitetura no teste cego (eixo vertical linear, em %).



Fonte: Elaborada pelo autor (2026). A linha tracejada indica o limiar de 85% da hipótese central.

Figura 7 – Latência média de inferência por transação e por arquitetura no teste cego (eixo vertical em escala logarítmica, em ms).



Fonte: Elaborada pelo autor (2026). As cores apenas distinguem as arquiteturas; o valor anotado sobre cada barra é a latência média em milissegundos. A latência do agente inclui o tempo de rede entre as duas máquinas (Seção 5.2).

a comparação justa entre representação esparsa e densa exige confrontar cada uma em sua melhor configuração, e não a melhor de uma com a pior da outra.

Os intervalos de confiança do TF-IDF com Random Forest e do TF-IDF com Naive Bayes – as duas arquiteturas de maior F1-Macro pontual entre as configurações da Tabela 7 – sobrepõem-se substancialmente, sugerindo que a diferença entre elas pode não

Tabela 8 – Intervalos de confiança de 95% (*bootstrap*, $B = 2.000$) para o F1-Macro.

Modelo / Arquitetura	Norm. léxica	F1-Macro (pontual)	IC 95%
TF-IDF + Random Forest	não	69,3%	[60,2%; 73,1%]
Busca vetorial densa (pgvector + MiniLM)	sim	66,8%	[58,6%; 71,3%]
TF-IDF + Naive Bayes	não	63,6%	[56,3%; 67,0%]
Agente Híbrido (LangGraph)	sim	60,0%	[50,8%; 65,9%]
Busca vetorial densa (pgvector + MiniLM)	não	56,2%	[51,2%; 60,2%]
ByT5 com ajuste fino	não	48,3%	[41,7%; 53,4%]

Fonte: Elaborada pelo autor (2026), a partir de `notebooks/experimentos/09_rag_norm_significancia.py` (reamostragem com semente fixa sobre `resultados/predicoes_*.csv`).

ser estatisticamente robusta. Aplicando o teste de McNemar pareado entre as duas: de 334 transações, ambas acertam em 272, ambas erram em 28, apenas o Random Forest acerta em 11, e apenas o Naive Bayes acerta em 23; a estatística resultante é $\chi^2 = 3,56$ (com correção de continuidade), correspondendo a $p = 0,059$ – **não significativo** ao nível $\alpha = 0,05$. Não há, portanto, evidência estatística suficiente para afirmar que o Random Forest classifica de forma mais eficaz que o Naive Bayes neste acervo, apesar de seu F1-Macro pontual ser superior.

O mesmo teste aplicado entre as melhores configurações de cada família de representação – TF-IDF com Random Forest sem normalização (69,3%) e busca vetorial densa com normalização (66,8%) – é ainda mais conclusivo quanto à equivalência: ambas acertam em 266 transações, ambas erram em 34, e cada uma acerta sozinha em exatamente 17 casos, resultando em $\chi^2 = 0,03$ e $p = 0,86$. As duas configurações têm, ainda, acurácia global idêntica (84,7%). **Em sua melhor configuração, a representação densa não é estatisticamente distinguível da esparsa neste acervo**; a diferença de 13,1 pontos percentuais entre 69,3% e 56,2% que a Tabela 7 exhibe é, em sua maior parte, efeito da configuração de pré-processamento, e não da representação. O que separa as duas famílias, neste regime, é o custo: 0,28 ms de inferência sem dependência de modelo de *embedding* nem de banco vetorial, contra 1,4 ms de consulta ao índice mais a geração do *embedding* e a manutenção da base vetorial.

A análise revela um quadro **distinto da expectativa corrente na literatura de PLN apoiada em grandes corpora**, segundo a qual representações densas e arquiteturas mais sofisticadas tendem a superar métodos esparsos clássicos – aqui, no máximo, os igualam –, atribuível às características do acervo pessoal disponível (volume reduzido, 11 categorias efetivamente povoadas e forte desbalanceamento):

1. **As linhas de base esparsas dominaram os resultados pontuais, sem diferença estatisticamente significativa entre si.** O TF-IDF com Random Forest

obteve o melhor F1-Macro (69,3%) e o TF-IDF com Naive Bayes a melhor acurácia global (88,3%), ambos com latência inferior a 0,3 ms – embora, como discutido acima, o teste de McNemar não rejeite a hipótese de desempenho equivalente entre os dois ($p = 0,059$). A vetorização por n -gramas de caractere (`char_wb`, 2–4) capturou a morfologia recorrente das descrições brasileiras (“UBER”, “IFD*”, “DROGA-”) mesmo em estabelecimentos inéditos. Ressalva: esse F1-Macro de 69,3% corresponde à configuração *sem* a etapa de normalização léxica (coluna “Norm. léxica” da Tabela 7); o efeito dessa etapa, oposto entre as duas famílias de representação, é medido na Seção 5.6.5. Pela mesma razão, a dominância das linhas de base esparsas vale para as configurações da Tabela 7, mas não se sustenta quando a busca vetorial densa é avaliada em sua melhor configuração (66,8% com normalização; Tabela 8), estatisticamente indistinguível do Random Forest ($p = 0,86$);

2. **A diferença entre validação cruzada e teste cego foi acentuada.** Sob validação cruzada 5-fold (com repetição de estabelecimentos entre folds), o Random Forest atingiu F1-Macro de 92,7%; no teste cego por estabelecimento o valor caiu para 69,3% – uma diferença de ≈ 23 pontos percentuais. O mesmo padrão se repete no Naive Bayes (Tabela 9): 88,5% sob validação cruzada contra 63,6% no teste cego, uma diferença de ≈ 25 pontos percentuais. Essa queda consistente nas duas arquiteturas em que a comparação foi medida quantifica o quanto o desempenho aparente de um classificador de transações depende da memorização de comércios já observados, e não apenas de um efeito isolado do Random Forest;
3. **O ByT5 ajustado sofreu sobreajuste.** Com 1.326 exemplos de treino (conjuntos de treino e validação unificados, Seção 5.4), o `byt5-small` convergiu a uma função de perda no treinamento inferior a 0,02 mas generalizou mal (F1-Macro 48,3%), colapsando a predição da classe majoritária *Lazer e Entretenimento*. Modelos no nível de byte exigem *corpora* de ordem de grandeza superior;
4. **A busca vetorial densa ficou limitada pela base fria.** Com 488 estabelecimentos vetorizados por `paraphrase-multilingual-MiniLM-L12-v2` (384-d), apenas 57,5% das transações de teste obtiveram vizinho com similaridade de cosseno $\geq 0,85$; nas demais o vizinho foi semanticamente fraco, resultando em F1-Macro de 56,2% sobre a descrição bruta – e de 66,8% quando a consulta e a base são normalizadas lexicalmente (Seção 5.6.5), configuração em que a busca densa iguala o Random Forest. A latência real de consulta no pgvector foi de 1,4 ms¹;

¹ Tempo isolado da instrução SQL de busca por similaridade no índice, sem incluir a geração do *embedding* da consulta, medida separadamente sobre um lote pré-codificado; a Seção 5.7 esclarece a diferença frente à latência de ponta a ponta do agente.

5. **O Agente Híbrido combinou os dois ramos, ao custo de latência.** O agente roteou 52% das transações para a busca vetorial (mediana de 40 ms de ponta a ponta²) e 48% para o ramo LLM local (dezenas de segundos); as transações encaminhadas à confirmação humana (4,5%) constituem um subconjunto desse ramo LLM, pois a interrupção ocorre após a inferência do modelo, e foram resolvidas nesta avaliação em lote por aceitação automática da própria sugestão do LLM (protocolo na Seção 5.7). A proporção de 52% difere dos 57,5% de cobertura de alta confiança do item anterior porque as duas medições usam pré-processamentos distintos da consulta³. O agente atingiu acurácia de 61,4% e F1-Macro de 60,0% (latência média de 6,5 s sobre as 334 transações; 35 ms em média no ramo vetorial e 13,7 s em média no ramo LLM). Seu F1-Macro supera o da busca vetorial isolada (56,2%) – o ramo LLM recupera parte das classes de cauda –, mas sua acurácia global é a mais baixa entre os modelos, pelo comportamento de abstenção do ramo LLM analisado na Seção 5.6.5. Cabe lembrar que o ramo LLM decidiu em regime *zero-shot*: os três vizinhos recuperados pelo ramo vetorial não lhe foram apresentados como exemplos (Seção 4.7), e o histórico de *marketplace* não foi injetado no *prompt*.

A Tabela 9 torna explícito, lado a lado, o contraste entre validação cruzada 5-fold e teste cego por estabelecimento disjunto discutido acima.

Tabela 9 – Validação cruzada 5-fold versus teste cego por estabelecimento disjunto (F1-Macro).

Modelo / Arquitetura	CV 5-fold (média ± dp)	Teste Cego	Diferen
TF-IDF + Random Forest	92,7% ± 2,6%	69,3%	−23,4 p
TF-IDF + Naive Bayes	88,5% ± 2,7%	63,6%	−24,9 p
ByT5 com ajuste fino	N/D	48,3%	N/D
Busca vetorial densa (pgvector + MiniLM)	N/D	56,2%	N/D
Agente Híbrido (LangGraph)	N/D	60,0%	N/D

Fonte: Elaborada pelo autor (2026), a partir de `notebooks/experimentos/resultados/consolidado_modelos.csv`.

Ressalva de escopo: a validação cruzada 5-fold (`StratifiedKFold`, `notebooks/experimentos/02_baselines.py`) foi implementada apenas para as duas linhas de base

² Latência do caminho vetorial completo dentro do grafo – geração do *embedding* da consulta, ida e volta assíncrona ao PostgreSQL e demais nós do LangGraph percorridos –, e não apenas a instrução SQL isolada de 1,4 ms do item anterior.

³ A cobertura do item anterior consulta a base com o texto levemente normalizado (`chave_estabelecimento`, o mesmo usado para construí-la) via similaridade de cosseno bruta; o roteamento do agente consulta com o texto integralmente normalizado pela rotina léxica (`nome_normalizado`, Apêndice E) via o invólucro (*wrapper*) de relevância do LangChain. Essa diferença entre consulta e indexação também contribui para o ganho atribuído à normalização léxica na busca densa (Seção 5.6.5).

esparsas (TF-IDF); não há um procedimento de validação cruzada análogo para o ByT5, a busca vetorial densa ou o agente híbrido nesta pesquisa (linhas “N/D” na tabela), o que é registrado como limitação na Seção 6.4. O achado de ≈ 23 –25 pontos percentuais de diferença está, portanto, empiricamente ancorado nas duas arquiteturas esparsas – que coincidem com as de melhor desempenho pontual no teste cego –, e não foi verificado nas demais três.

5.6.1 Acurácia global versus F1-Macro

Todos os modelos apresentam acurácia global consideravelmente superior ao F1-Macro (o Naive Bayes, por exemplo: 88,3% de acurácia contra 63,6% de F1-Macro). Isso decorre de dois fatores do acervo pessoal: (i) o forte desbalanceamento — *Alimentação e Lazer e Entretenimento* respondem por cerca de metade do teste; e (ii) o tamanho reduzido das classes de cauda — *Moradia, Tecnologia, Vestuário e Educação* contam com 4 a 5 estabelecimentos distintos cada, além das categorias agregadas por amostragem insuficiente (Seção 5.3.2). Diante desse cenário, o F1-Macro (justificativa de adoção na Seção 5.4.2) mostra-se conservador. O F1-Ponderado (Equação 2.8), que pesa cada categoria pelo seu suporte, situa-se sistematicamente entre as duas métricas e confirma empiricamente essa leitura: 86,2% para o Naive Bayes, 83,8% para o Random Forest, 83,9% para a busca vetorial, 69,0% para o agente híbrido e 63,3% para o ByT5 (`notebooks/experimentos/resultados/consolidado_modelos.csv`) – valores próximos da acurácia global, porque as categorias majoritárias dominam a ponderação, e distantes do F1-Macro, que atribui peso igual às classes de cauda. Os resultados devem ser lidos como **diagnóstico sobre um acervo pessoal real de porte reduzido**, não como estimativa de desempenho populacional.

5.6.2 Desempenho discriminado por instituição emissora

O C6 Bank e o Nubank são citados ao longo deste trabalho como as duas fontes do acervo pessoal (Seção 5.3.2), mas os resultados apresentados até aqui agregam as duas instituições. A Tabela 10 recalcula a acurácia e o F1-Macro de cada arquitetura separadamente sobre os dois subconjuntos do teste cego (234 transações do C6 Bank, 100 do Nubank).

A coincidência exata de acurácia e F1-Macro (98,0% e 36,2%) entre quatro arquiteturas de fundamentos matemáticos distintos no subconjunto do Nubank foi verificada diretamente nos arquivos de predição, transação a transação, para excluir a hipótese de erro de cruzamento entre os arquivos de predição e a coluna de origem. A coincidência é genuína e tem explicação simples, visível na Tabela 11: as quatro arquiteturas acertam as mesmas 98 transações e erram exatamente as mesmas 2 – as duas ocorrências do estabelecimento “Cinepolis Itaquaquecet” (rótulo *Lazer e Entretenimento*), ambas classificadas como

Tabela 10 – Acurácia e F1-Macro por arquitetura, discriminados por instituição emissora (teste cego).

Modelo / Arquitetura	C6 Bank ($n = 234$)		Nubank ($n = 100$)	
	Acurácia	F1-Macro	Acurácia	F1-Macro
TF-IDF + Random Forest	79,1%	66,8%	98,0%	36,2%
TF-IDF + Naive Bayes	84,2%	61,6%	98,0%	36,2%
ByT5 com ajuste fino	52,1%	45,7%	98,0%	36,2%
Busca vetorial densa (pgvector + MiniLM)	76,1%	54,7%	98,0%	36,2%
Agente Híbrido (LangGraph)	62,8%	60,5%	58,0%	31,3%

Fonte: Elaborada pelo autor (2026), a partir de `notebooks/experimentos/resultados/predicoes_*.csv` cruzados com a coluna `fonte_dataset` de `data/processed/split_teste.csv`.

Alimentação, a classe majoritária do recorte. Trata-se de um estabelecimento não observado no treinamento (consequência do particionamento por estabelecimento), cuja descrição não contém nenhum indício léxico das categorias conhecidas; na ausência de evidência, todos os modelos convergem para a classe mais frequente. As demais 98 transações do recorte distribuem-se por poucas descrições recorrentes de *Alimentação* e *Saúde* com padrões léxicos fortes (“Ifd*”, “Drogaria”, “Supermercado”, “Uber*”), que todas as arquiteturas resolvem sem dificuldade. Como o F1-Macro é uma função determinística da matriz de confusão, matrizes idênticas produzem métricas idênticas até a última casa decimal. O Agente Híbrido, único a não compartilhar essa matriz, é também o único com valores distintos.

Tabela 11 – Matriz de confusão do subconjunto do Nubank no teste cego ($n = 100$), comum às quatro arquiteturas com métricas idênticas na Tabela 10.

Categoria real	n	Acertos	Erros (predição atribuída)
Alimentação	53	53	–
Saúde	40	40	–
Transporte	3	3	–
Lazer e Entretenimento	2	0	2 (<i>Alimentação</i>)
Marketplace / E-commerce	2	2	–
Total	100	98	2

Fonte: Elaborada pelo autor (2026), a partir de `notebooks/experimentos/resultados/predicoes_*.csv`. Somente as 5 categorias presentes no recorte são listadas; as 6 ausentes entram com $F1 = 0$ na média macro sobre 11 categorias.

Dois pontos exigem leitura cuidadosa, sob pena de conclusão equivocada:

- **A acurácia do Nubank é sistematicamente alta (98,0%) para quatro das cinco arquiteturas – mas isso reflete a concentração de categorias**

do subconjunto, não superioridade de generalização. Como reportado na Seção 5.3.2, o recorte do Nubank no teste cego cobre apenas 5 das 11 categorias, com 93% das transações concentradas em *Alimentação* e *Saúde* – um problema de classificação bem mais fácil que o do C6 Bank, que cobre as 11 categorias em proporções mais equilibradas. O F1-Macro do Nubank, calculado sobre o mesmo universo de 11 categorias usado no restante do capítulo (para permitir comparação direta com as demais tabelas), penaliza estruturalmente esse recorte: as 6 categorias ausentes do subconjunto do Nubank contam como falha total ($F1 = 0$) na média macro, mesmo sem nenhuma transação desse rótulo para o modelo errar. Por isso o F1-Macro do Nubank (31–36%) é inferior ao do C6 Bank (46–67%) apesar da acurácia superior – o par de métricas mede propriedades diferentes do mesmo recorte, e nenhuma das duas isoladamente permite concluir se a solução generaliza melhor para um leiaute de fatura que para o outro;

- **O Agente Híbrido é a única arquitetura com desempenho pior no Nubank em ambas as métricas.** A proporção de roteamento entre os ramos vetorial e LLM é semelhante nos dois emissores: 52,6% vetorial, 41,5% LLM e 6,0% humano no C6 Bank; 52,0%, 47,0% e 1,0% no Nubank. Nessa contagem, a parcela “humano” é o recorte do ramo LLM que passou pela confirmação simulada; somadas, “LLM” e “humano” correspondem aos 48% do ramo LLM reportados na Seção 5.6.5. A diferença concentra-se no próprio ramo LLM, cuja acurácia condicional cai de 22,7% no C6 Bank para 12,8% no Nubank, enquanto o ramo vetorial se mantém equivalente ou superior (96,7% e 100,0%, respectivamente). Há, ainda, um confundidor não controlado: como o metadado de origem esteve fixado em “C6 Bank” para todo o teste cego (Seção 5.2), o ramo LLM recebeu informação de origem incorreta em todas as 100 transações do Nubank. Não foi possível, com os dados disponíveis, isolar se a queda decorre de diferenças de leiaute textual entre os emissores, da distribuição de categorias já discutida ou desse metadado incorreto; fica como investigação futura, de custo baixo (reexecução apenas do ramo LLM com o metadado correto).

Em suma, o acervo não permite concluir que a solução generaliza igualmente bem entre os dois leiautes de fatura: a comparação direta é confundida pela distribuição desigual de categorias entre os emissores no recorte de teste, um efeito do porte reduzido do subconjunto do Nubank (272 de 1.660 transações rotuladas) e não uma medição controlada de robustez entre instituições.

5.6.3 Risco de circularidade entre rotulagem e desempenho

O conjunto de teste cego foi rotulado por dois métodos de proveniência distinta e conhecida transação a transação (Seção 5.3.2). O primeiro, **regra_lexical**, é o dicionário

de alta precisão e cobre 271 das 334 transações (81,1%). O segundo, **categoria_emissor**, é o mapeamento da categoria nativa do C6 Bank e cobre as 63 restantes (18,9%). O dicionário léxico reconhece exatamente os mesmos padrões de superfície (“UBER”, “IFD*”, “DROGA-”) que a vetorização por n -gramas de caractere explora. Há, portanto, risco de que os classificadores esparsos estejam, em parte, reaprendendo a regra de rotulagem em vez da semântica da categoria, o que inflaria artificialmente seu desempenho relativo. Para investigar essa hipótese, a Tabela 12 recalcula o F1-Macro de cada arquitetura separadamente nos dois subconjuntos.

Tabela 12 – F1-Macro por arquitetura, segmentado pela proveniência do rótulo de referência.

Arquitetura	Geral	regra_lexical (n=271)	categoria_emissor (n=63)
TF-IDF + Random Forest	69,3%	82,4%	39,4%
TF-IDF + Naive Bayes	63,6%	85,6%	27,6%
Busca vetorial densa (pgvector + MiniLM)	56,2%	63,7%	28,1%
Agente Híbrido (LangGraph)	60,0%	74,6%	11,1%
ByT5 com ajuste fino	48,3%	53,6%	16,5%

Fonte: Elaborada pelo autor (2026), a partir de `data/processed/split_teste.csv` (coluna `metodo_rotulo`) cruzado com `notebooks/experimentos/resultados/predicoes_*.csv`.

A queda é substancial e sistemática em **todas as cinco arquiteturas**, não apenas nas de vetorização esparsa: o agente híbrido – que não emprega n -gramas de caractere, apoiando-se em busca vetorial densa e raciocínio via LLM – sofre a maior queda relativa (de 74,6% para 11,1%). Esse padrão uniforme entre famílias de modelo tão distintas admite duas leituras não mutuamente excludentes, e esta monografia não dispõe de evidência suficiente para decidir entre elas:


1. **Circularidade específica dos classificadores esparsos:** para o TF-IDF, a hipótese original permanece plausível – os n -gramas de caractere podem estar parcialmente memorizando os mesmos padrões de superfície usados pelo dicionário de rotulagem, inflando seu desempenho no subconjunto `regra_lexical`;
2. **Dificuldade ou ruído intrínseco do subconjunto categoria_emissor:** por definição, essas 63 transações são precisamente os casos que o dicionário de alta precisão **não conseguiu resolver**, herdando o rótulo do código MCC do emissor – reconhecidamente impreciso (Seção 5.3.2). A queda uniforme em modelos que não compartilham nenhuma característica com a regra de rotulagem (o agente híbrido, em especial) sugere que ao menos parte do efeito decorre de um **acervo mais difícil e de verdade de referência mais ruidosa** nesse subconjunto, não de circularidade propriamente dita.

Em qualquer uma das leituras, a conclusão prática é a mesma: o F1-Macro de 69,3% reportado como resultado principal desta pesquisa **não é uniformemente sustentado** entre as fontes de rotulagem, e deve ser interpretado com essa ressalva. Reproduzir esta análise com um subconjunto adicional validado manualmente, independente de ambos os métodos de rotulagem, é indicado como trabalho futuro imediato (Seção 6.5). Uma alternativa complementar, de menor custo, seria aplicar *Confident Learning* (Northcutt; Jiang; Chuang, 2021) sobre a base rotulada: por estimar a distribuição conjunta entre rótulos observados e rótulos verdadeiros a partir das probabilidades preditas fora da amostra, o método permitiria identificar os lançamentos cujo rótulo semiautomático é provavelmente incorreto – em especial no subconjunto **categoria_emissor**, em que a categorização por código MCC do emissor é reconhecidamente imprecisa – e priorizá-los para revisão humana, tratando o risco de circularidade como o problema de ruído de rótulo que ele de fato é.

5.6.4 Desempenho detalhado por categoria de despesa

A Tabela 13 detalha o comportamento do TF-IDF + Random Forest nas categorias efetivamente avaliadas.

Figura 8 – F1-Score por categoria de despesa (melhor modelo).



Fonte: Elaborada pelo autor (2026). A linha tracejada vertical indica o limiar de 85% da hipótese central; o suporte (volume de teste) de cada categoria, determinante para a leitura das barras nulas, consta da Tabela 13.

A Figura 8 exhibe, em ordem crescente, o F1-Score por categoria do TF-IDF + Random Forest da Tabela 13: categorias com padrões léxicos fortes e volume adequado — *Alimentação*, *Transporte*, *Saúde* e *Marketplace / E-commerce* — alcançaram F1-Score

Tabela 13 – Desempenho do TF-IDF + Random Forest discriminado por categoria de despesa efetivamente avaliada.


Categoria de Despesa	Precisão (%)	Revocação (%)	F1-Score (%)	Volume de Teste
Alimentação	69,4%	100,0%	82,0%	100
Transporte	100,0%	61,5%	76,2%	39
Saúde	100,0%	88,5%	93,9%	61
Moradia	100,0%	75,0%	85,7%	4
Lazer e Entretenimento	100,0%	86,6%	92,8%	67
Tecnologia	0,0%	0,0%	0,0%	4
Marketplace / E-commerce	100,0%	96,8%	98,4%	31
Vestuário	0,0%	0,0%	0,0%	5
Beleza e Cuidados Pessoais	100,0%	80,0%	88,9%	5
Educação	100,0%	100,0%	100,0%	4
Despesas Diversas / Outros	46,2%	42,9%	44,4%	14
Média Macro	74,1%	66,5%	69,3%	334

Fonte: Elaborada pelo autor (2026).

entre 90% e 100%. As classes de cauda (*Tecnologia*, *Vestuário*, *Moradia*) obtiveram F1 nulo ou próximo de zero em quase todos os modelos: com 4 a 5 exemplos no teste, um único erro derruba a métrica. Esse é o principal fator limitante do F1-Macro.

A Figura 9 apresenta a matriz de confusão do Agente Híbrido e torna visível a natureza dos seus erros, que não se distribuem de forma difusa: concentram-se quase inteiramente na coluna *Despesas Diversas / Outros*. Das 334 transações, 64 de *Alimentação* (de 100), 32 de *Lazer e Entretenimento* (de 67) e 10 de *Saúde* (de 61) foram absorvidas por essa classe residual, além da totalidade das 5 transações de *Vestuário*. Trata-se do padrão de abstenção do ramo LLM discutido na Seção 5.6.5: diante de um nome que não reconhece, o modelo local prefere a classe “sem categoria” a inferir pela pista léxica. Como a esteira aplica dois ancoramentos de rótulo que também desembocam nessa classe residual (Seção 4.7), verificou-se, a partir do registro bruto da execução (`resultados/agente_teste_bruto.csv`, etapa `11_ic_acuracia.py`), se a concentração poderia ser um artefato do ancoramento: das 132 predições de *Despesas Diversas / Outros*

Figura 9 – Matriz de confusão do Agente Híbrido no teste cego (334 transações).



Fonte: Elaborada pelo autor (2026).

emitidas pelo agente, todas as 132 já saíram do grafo com esse rótulo – o ancoramento externo por casamento aproximado não alterou nenhuma delas (113 do ramo LLM, 13 do ramo de confirmação simulada e 6 do ramo vetorial, estas últimas por vizinhos rotulados nessa classe). O ancoramento interno ao nó de estruturação, contudo, não é distinguível a posteriori, pois o rótulo bruto do modelo não foi persistido; a atribuição da abstenção ao modelo permanece, nessa medida, uma inferência, registrada como limitação (Seção 6.4). Fora dessa coluna, as confusões são raras e semanticamente plausíveis (5 transações de *Transporte* atribuídas a *Moradia*; 2 de *Marketplace / E-commerce* a *Tecnologia*), e a diagonal das classes com padrão léxico forte (*Saúde*, *Transporte*, *Marketplace / E-commerce*) permanece dominante. A matriz sustenta, portanto, a Resposta a Q3 (Seção 5.8): o erro típico do agente não é a troca entre categorias afins, mas a recusa em classificar.

5.6.5 Estudo de ablação

O estudo de ablação isolou os componentes mensuráveis sem novo custo de inferência do LLM (Tabela 14). O ramo vetorial do agente respondeu por 52% das transações (acurácia

condicional 98%) e o ramo LLM por 48% (acurácia 21%).

Tabela 14 – Ablação da normalização léxica sobre o teste cego (variação de F1-Macro) e desempenho por ramo do agente (acurácia condicional).

<i>Ablação de componente – F1-Macro no teste cego</i>			
Componente removido	Com	Sem	Δ F1 (p.p.)
Normalização léxica (TF-IDF + Random Forest)	67,4%	69,3%	-1,9
Normalização léxica (busca vetorial densa, MiniLM)	66,8%	56,2%	+10,6
<i>Desempenho por ramo do agente – acurácia condicional (não é ablação)</i>			
Ramo	Vetorial	LLM	Diferença (p.p.)
Acurácia condicional sobre as transações rotadas a cada ramo	97,7%	21,4%	+76,3

Fonte: Elaborada pelo autor (2026). O bloco inferior não é uma ablação: compara a acurácia condicional dos dois ramos do agente, ambos presentes na configuração avaliada; a diferença de 76,3 p.p. não corresponde a uma variação de F1-Macro.

A ablação revela um efeito **dependente da representação**. Para os classificadores esparsos (TF-IDF + Random Forest), a normalização léxica agressiva de *gateways* foi neutra ou levemente prejudicial (Δ F1 ≈ -2 p.p.): a vetorização por *n*-gramas de caractere já é robusta a prefixos como “PAG*” e “MP*”, que por vezes carregam sinal útil. Para a busca vetorial densa, ao contrário, a normalização foi **decisiva** (Δ F1 $\approx +11$ p.p.): sem ela, o *embedding* multilíngue se confunde com o ruído dos intermediadores. O componente que sustenta o desempenho do agente é a **busca vetorial**: seu ramo respondeu corretamente a 98% das transações que resolveu, enquanto o ramo LLM local (*gemma-4-e4b*) acertou apenas 21% — tendendo, sob a diretriz antialucinação, a rotular como *Despesas Diversas* nomes cuja categoria era lexicalmente evidente (“SAPPORO RESTAURANTE”, “Drogaria Paulista”). Na configuração avaliada, o ramo LLM operou sem a ferramenta de busca na web, sem os vizinhos recuperados como exemplos no *prompt* e com metadado de origem fixo (Seção 5.2); a execução complementar com a ferramenta habilitada, prejudicada por falhas de conexão, não melhorou o resultado (acurácia de 57,2%).

5.7 Avaliação de MLOps, latência e observabilidade

A infraestrutura de MLOps gerenciada pelo MLflow (Zaharia *et al.*, 2018) registrou integralmente os 5 experimentos de classificação (parâmetros, métricas, relatórios por categoria, previsões e figuras) no experimento `experimento_faturas`, assegurando a rastreabilidade dos resultados:

- **HITL**: no teste cego, 4,5% das transações (aproximadamente 15, sobre 334) aciona-

ram a interrupção programada para confirmação humana (`requer_confirmacao`), correspondendo a nomes ambíguos roteados ao LLM com baixa confiança. **Protocolo de resolução:** por se tratar de uma execução em lote não assistida (sem operador humano disponível durante a avaliação), essas interrupções foram resolvidas **automaticamente aceitando a própria sugestão do LLM** como confirmada (`confirmado=True` programático na retomada do grafo, Seção 4.7), sendo então contabilizadas na acurácia e no F1-Macro do agente exatamente como emitidas pelo ramo LLM – sem qualquer correção ou informação adicional de um revisor humano real. A rotulagem interna dessas transações como `fonte="humano"` e confiança 1,0 reflete apenas o rótulo de status do mecanismo de *checkpoint* do LangGraph, não uma validação humana efetiva; nenhuma das cinco arquiteturas recebeu, portanto, vantagem de revisão humana real nesta avaliação. No modo de gravação (`notebooks/experimentos/05_agente.py`, função `rodar_gravar`), a interrupção também é retomada de imediato pelo próprio processo, com `confirmado=False`: a sugestão do LLM é mantida e a transação é persistida com *status sugerida* e `requer_confirmacao` verdadeiro, ficando a revisão humana a cargo de uma etapa posterior sobre o banco de dados. Em nenhuma das duas modalidades o grafo aguarda um revisor em tempo real, pois o *checkpointer* em memória não permite a retomada por outro processo (Seção 4.7); a espera efetiva é trabalho futuro;

- **Latência por arquitetura:** a instrução SQL isolada de busca por similaridade no pgvector custou 1,4 ms (sem incluir a geração do *embedding* da consulta); já a mediana de ponta a ponta do caminho vetorial completo do agente – que inclui essa geração de *embedding*, a ida e volta assíncrona ao banco e os demais nós do grafo percorridos – foi de 40 ms (Seção 5.6, item 5). O ramo LLM local (`gemma-4-e4b`, modelo de raciocínio no LM Studio) custou em média 13,7 s por transação a ele roteada (mediana de 12,8 s), o que resulta na média global de 6,5 s sobre as 334 transações, evidenciando o principal gargalo operacional para processamento em lote sem GPU dedicada de maior porte;
- **Aprendizado ativo:** as classificações do ramo LLM com confiança autoavaliada superior a 0,85 e as validadas por humano alimentam a base vetorial (`salvar_vectorstore`), reduzindo progressivamente o acionamento do LLM em compras recorrentes. Ressalva-se que a etapa de povoamento inicial da base (`04_rag_pgvector.py`, opção de persistência) reconstrói a coleção a partir do zero, descartando as retroalimentações acumuladas; em produção, essa etapa deve ser executada uma única vez, ou substituída por uma carga incremental;
- **Registro por inferência:** o MLflow registra os experimentos no nível de arquitetura (parâmetros, métricas, predições, relatórios e figuras). O registro por inferência – *prompt* enviado, resposta bruta do modelo e tempo por transação –, previsto na tabela

`log_classificacoes`, não foi implementado nesta versão, de modo que a auditoria de uma decisão individual do ramo LLM depende do arquivo bruto da execução (`agente_teste_bruto.csv`), que guarda categoria, confiança, fonte e latência, mas não o texto da resposta.

5.8 Respostas às questões de pesquisa e verificação da hipótese

- **Resposta a Q1:** sob teste cego com estabelecimentos disjuntos, e comparando cada família de representação em sua melhor configuração, as representações **esparsas** (TF-IDF com n -gramas de caractere) e as **densas** (busca vetorial por *embeddings* multilíngues) mostraram-se **estatisticamente equivalentes** neste acervo de porte reduzido: o TF-IDF + Random Forest (69,3% de F1-Macro, sem normalização) e a busca vetorial densa com normalização léxica (66,8%) têm intervalos de confiança sobrepostos, acurácia global idêntica (84,7%) e discordância perfeitamente simétrica no teste de McNemar ($p = 0,86$; Tabela 8). Ambas superaram com folga o ajuste fino do ByT5 (48,3%) e o agente com LLM local (60,0%). A diferença de 13,1 pontos percentuais entre 69,3% e 56,2% visível na Tabela 7 decorre de as duas famílias exigirem pré-processamentos opostos (Q4), não de superioridade intrínseca da representação esparsa. O que distingue as duas famílias neste regime é o custo: a representação esparsa entrega o mesmo desempenho a uma fração do custo computacional e sem dependência de modelo de *embedding* nem de base vetorial povoada;
- **Resposta a Q2:** o melhor F1-Macro alcançado foi de 69,3% (acurácia global de até 88,3%) sobre as 11 categorias efetivamente povoadas – recorte estritamente mais favorável que as 14 da taxonomia original (ressalva da Seção 5.3.2), o que reforça o veredito de não confirmação a seguir. O limiar de 85% de F1-Macro **não foi atingido** por nenhuma arquitetura neste protocolo; o limiar de 85% de acurácia global foi superado apenas por uma arquitetura de referência (TF-IDF com Naive Bayes), de forma marginal, e não pela esteira híbrida objeto da hipótese (veredito a seguir);
- **Resposta a Q3:** os erros concentraram-se em (i) categorias de cauda com 4–5 exemplos de teste (F1 nulo para quase todos os modelos) e (ii) nomes opacos de intermediadores (“PAYPAL *BOSS LIFE”, “DIVIPAYPAYMENTS”). No agente, a matriz de confusão (Figura 9) mostra que o erro dominante não é a troca entre categorias afins, mas a absorção de transações com pista léxica clara pela classe residual *Despesas Diversas / Outros*. O ramo LLM local, sob diretriz antialucinação, mostrou-se **contraproducente**, rotulando como *Despesas Diversas* até nomes com pista de categoria explícita. A busca na web, que mitigaria nomes informais, foi exercitada apenas em execução complementar comprometida por falhas de conexão dos *backends* de busca (Seção 5.2), sem ganho mensurável; a cadeia de pensamento foi exigida pelo *prompt*, mas seu efeito isolado não foi medido;

- **Resposta a Q4:** dos três metadados contextuais enunciados na questão, apenas o **descarte de prefixos de *gateways*** (normalização léxica) foi efetivamente avaliado, e sua contribuição é **dependente da representação**: neutra a levemente negativa para o TF-IDF e decisiva para a busca vetorial densa (Tabela 14). A **origem do arquivo** não foi variada na avaliação, pois o metadado permaneceu fixo para todo o teste cego (Seção 5.2). O **histórico de compras do usuário** não pôde ser avaliado: além da ausência de compras confirmadas na base, a versão avaliada do agente não injeta o histórico recuperado no *prompt* e não roteia o *marketplace* mais frequente do acervo pelo ramo de histórico (Seção 4.7). A resposta à Q4 é, portanto, parcial;
- **Resposta a Q5:** o ciclo de MLOps com MLflow e aprendizado ativo mostrou-se viável e auditável; as limitações práticas são a **latência** e a **baixa acurácia** do ramo LLM local (Seções 5.6.5 e 5.7), que o tornam, neste acervo, menos eficaz que a busca vetorial isolada. A caracterização empírica de *Data Drift* e *Concept Drift* ao longo do tempo não foi conduzida, embora o acervo do C6 Bank, temporalmente ordenado, o permitisse (Seção 6.4).

Veredito sobre as Subhipóteses e a Hipótese Central: conforme a decomposição formalizada na Seção 4.2, cada subhipótese é verificada de forma independente, sob o protocolo de teste cego por estabelecimento, **sobre o objeto da hipótese** – a esteira híbrida, isto é, o agente em grafo de estados:

- **H1a (Acurácia > 85%): REFUTADA.** A esteira híbrida atinge 61,4% de acurácia global (IC 95% de Wilson [56,1%; 66,4%]), abaixo do limiar;
- **H1b (F1-Macro > 85%): REFUTADA.** A esteira híbrida atinge 60,0% de F1-Macro (IC 95% *bootstrap* [50,8%; 65,9%], Tabela 8), abaixo do limiar.

A hipótese central é, portanto, **refutada** em suas duas subhipóteses. O resultado permanece o mesmo se a verificação for estendida a qualquer das arquiteturas de referência avaliadas no mesmo protocolo (Tabela 15): nenhuma delas alcança 85% de F1-Macro (o melhor valor, 69,3% do TF-IDF com Random Forest, tem IC 95% [60,2%; 73,1%]); e apenas uma, o TF-IDF com Naive Bayes, supera o limiar de acurácia global – de forma **marginal**: 88,3%, com IC 95% de Wilson [84,4%; 91,3%], que inclui o limiar, e teste binomial exato unilateral com $p = 0,049$, no limiar da significância. Sob validação cruzada convencional – que admite a repetição de estabelecimentos entre treino e teste, e não corresponde ao protocolo primário desta pesquisa – o F1-Macro do Random Forest chega a 92,7%; esse resultado é reportado para evidenciar o efeito de memorização de comércios (Seção 5.6), mas não sustenta H1b nas condições rigorosas adotadas como critério de verificação.

As causas da refutação são discutidas na Seção 6.4: porte e cobertura do acervo rotulado, cauda longa de categorias com pouquíssimos exemplos, rotulagem de referência

Tabela 15 – Acurácia global por arquitetura no teste cego, com intervalo de confiança de 95% (Wilson) e teste binomial exato unilateral contra o limiar de 85%.

Modelo / Arquitetura	Acertos	Acurácia	IC 95% (Wilson)	p (binomial)
TF-IDF + Naive Bayes	295 / 334	88,3%	[84,4%; 91,3%]	0,049
TF-IDF + Random Forest	283 / 334	84,7%	[80,5%; 88,2%]	0,59
Busca vetorial densa (com norm. léxica)	283 / 334	84,7%	[80,5%; 88,2%]	0,59
Busca vetorial densa (sem norm. léxica)	276 / 334	82,6%	[78,2%; 86,3%]	0,90
ByT5 com ajuste fino	220 / 334	65,9%	[60,6%; 70,7%]	≈ 1
Agente Híbrido (LangGraph) – objeto da hipótese	205 / 334	61,4%	[56,1%; 66,4%]	≈ 1

Fonte: Elaborada pelo autor (2026), a partir de `notebooks/experimentos/11_ic_acuracia.py` sobre `resultados/predicoes_*.csv`. O valor p refere-se ao teste binomial exato unilateral da hipótese nula de acurácia populacional menor ou igual a 85%.

semiautomática e, no caso específico da esteira híbrida, a baixa acurácia condicional do ramo de raciocínio. A esteira técnica (extração, normalização, busca vetorial, agente em grafo, HITL, MLOps) foi implementada e validada do ponto de vista funcional, com as ressalvas de integração registradas no Capítulo 4.

5.9 Considerações finais do capítulo

Este capítulo apresentou a avaliação experimental da solução proposta, cobrindo desde a camada primária de ingestão óptica até a tomada de decisão semântica e observabilidade contínua em MLOps.

A primeira frente de validação mostrou quantitativamente que, **em faturas nativas digitais, a extração com preservação de leiaute supera a rasterização seguida de OCR** no processamento de faturas de cartão de crédito (com a ressalva de escopo da Seção 5.5). A redução do CER e o ganho na taxa de casamento exato, quantificados na Seção 5.5 (Tabela 5), confirmam que a preservação das fronteiras estruturais das tabelas foi determinante para impedir o vazamento de parcelas e valores para o campo de descrição do estabelecimento.

Na etapa subsequente de classificação semântica, cinco arquiteturas foram avaliadas sobre um conjunto rotulado de 1.660 transações reais em teste cego por estabelecimento (Tabela 7). O classificador esparsa clássico (TF-IDF + Random Forest) obteve o maior F1-Macro do protocolo (**69,3%**), estatisticamente indistinguível da busca vetorial densa em sua melhor configuração (66,8%, com normalização léxica; $p = 0,86$) e a uma fração do custo computacional desta – limiar de 85% de F1-Macro não atingido por nenhum modelo, e o de acurácia global superado apenas marginalmente pelo Naive Bayes (88,3%; IC 95% [84,4%; 91,3%]). A ablação (Seção 5.6.5) evidenciou que a busca vetorial é o componente determinante do agente e que o efeito da normalização léxica depende da representação – razão pela qual a comparação entre as duas famílias de representação só é justa quando cada uma é tomada em sua melhor configuração. O HITL foi acionado em

4,5% das transações, com a ressalva de simulação da Seção 5.7.

Tais constatações sustentam a viabilidade funcional da esteira (extração, normalização, busca vetorial, agente em grafo, HITL e MLOps auditável). A hipótese central é **refutada** em suas duas subhipóteses para a esteira híbrida que a enuncia (acurácia de 61,4% e F1-Macro de 60,0% sob avaliação por estabelecimento); entre as arquiteturas de referência, apenas o Naive Bayes supera o limiar de acurácia global, e de forma marginal (Seção 5.8). As causas da refutação — porte e cobertura do acervo rotulado, cauda longa de categorias com pouquíssimos exemplos, rotulagem semiautomática e capacidade limitada do LLM local — bem como as perspectivas de superação são discutidas no Capítulo 6.

6 CONCLUSÕES E TRABALHOS FUTUROS

6.1 Considerações iniciais

Este capítulo encerra a monografia apresentando uma síntese analítica do trabalho desenvolvido, a avaliação crítica do cumprimento dos objetivos estipulados, o reconhecimento das limitações identificadas durante a pesquisa e a proposição de direcionamentos para trabalhos futuros.

6.2 Síntese do trabalho, contribuições e objetivos atingidos

O presente Trabalho de Conclusão de Curso concebeu, implementou e avaliou experimentalmente uma solução computacional de ponta a ponta para a extração, saneamento e classificação automática de transações financeiras em faturas de cartão de crédito no contexto brasileiro. Suas contribuições, confrontadas com os objetivos específicos estabelecidos na Introdução, são as seguintes:

1. **Esteira de extração com preservação de leiaute** (objetivo 1): serviço de extração baseado em IBM Docling V2 que, em faturas nativas digitais, reduz a taxa de erro de caracteres de 52,82% para 5,72% frente à rasterização seguida de OCR (Tabela 5). O componente de reconhecimento óptico local (Tesseract com filtro de confiança) foi implementado e exercitado na comparação, mas não acoplado ao serviço (Seção 4.6) – objetivo atendido para documentos nativos digitais e parcialmente para documentos ópticos;
2. **Saneamento léxico** (objetivo 2): rotina determinística de normalização de prefixos de intermediadores, ruídos alfanuméricos e aliases, cujo efeito mostrou-se **condicional à representação**: decisivo para a busca vetorial densa e neutro a levemente prejudicial para os classificadores esparsos (Seção 5.6.5) – objetivo atendido;
3. **Linhas de base, representações densas e modelo no nível de byte** (objetivos 3 e 4): TF-IDF com Naive Bayes e Random Forest, busca vetorial densa sobre pgvector e ajuste fino do ByT5, todos calculados, comparados e documentados sob o mesmo teste cego – objetivos atendidos;
4. **Agente em grafo de estados** (objetivo 5): agente LangGraph que articula busca vetorial, raciocínio com LLM local, ferramenta de busca na web e interrupção para confirmação humana. O grafo foi construído e avaliado; dentro dele, o ramo vetorial foi o componente determinante e o ramo LLM, o gargalo de latência e de acurácia (Seção 5.6.5). Três mecanismos previstos não chegaram a influenciar a

decisão na versão avaliada – a busca na web (exercitada em execução complementar comprometida por falhas de conexão), o histórico de *marketplace* (recuperado, mas não injetado no *prompt*) e a confirmação humana em tempo real (simulada, por limitação do *checkpoint*) – objetivo atendido em sua arquitetura e parcialmente em sua operação;

5. **Infraestrutura em camadas e MLOps local** (objetivo 6): esteira containerizada de baixo custo apoiada em MinIO, Apache Kafka, PostgreSQL/pgvector, MLflow e Logto, com rastreamento de experimentos no nível de arquitetura e verificação empírica de necessidade de dados sob a LGPD. O registro por inferência, o controle de acesso por papéis nas APIs e a camada de consumo analítico permanecem como evolução (Seção 6.4) – objetivo atendido no essencial;
6. **Validação sob protocolo rigoroso** (objetivo 7): cinco arquiteturas avaliadas sobre 1.660 transações reais em 11 categorias, com teste cego de 334 transações por estabelecimento disjunto, validação cruzada nas duas linhas de base esparsas, ablação, intervalos de confiança por *bootstrap* e de Wilson, testes de McNemar e binomial, e rastreamento no MLflow – objetivo atendido. A hipótese central foi **refutada** em suas duas subhipóteses para a esteira híbrida que a enuncia (acurácia de 61,4% e F1-Macro de 60,0%); entre as arquiteturas de referência, apenas o Naive Bayes supera o limiar de acurácia global, de forma marginal, e nenhuma supera o de F1-Macro (Seção 5.8);
7. **Achado metodológico transferível**: a quantificação do efeito de memorização de estabelecimentos sob validação cruzada convencional (Seção 5.6), desenvolvida na conclusão 2 da Seção 6.3;
8. **Publicação e reprodutibilidade**: todo o código-fonte – microsserviços, processos trabalhadores, agente e a esteira experimental numerada que reproduz os resultados do Capítulo 5 – está publicado em repositório Git público (Apêndice C), com o acervo de faturas reais excluído da distribuição em observância à LGPD. A revisão final do código frente ao texto, incorporada a esta versão, explicitou as divergências entre o que foi projetado e o que foi efetivamente exercitado, registradas nos capítulos correspondentes.

6.3 Principais conclusões da pesquisa

Da evidência apresentada no Capítulo 5, destacam-se as seguintes conclusões, cada uma remetida à questão de pesquisa que a origina (Seção 4.2):

1. **Em faturas nativas digitais, preservar a topologia tabular na ingestão é condição necessária para a qualidade da classificação subsequente** (Q3,

quanto ao erro de leitura óptica). Descartar a camada de texto do PDF e rasterizá-lo para reconhecimento óptico faz mais da metade dos caracteres da descrição chegar corrompida ao classificador (CER de 52,82% contra 5,72%; casamento exato de 3,3% contra 86,2%), e nenhum saneamento posterior recupera essa perda. A decisão de projeto mais consequente da esteira está na ingestão, não na modelagem;

2. **O protocolo de avaliação é determinante para a leitura dos resultados – a contribuição metodológica mais relevante desta pesquisa (Q2).** Para as duas arquiteturas em que a comparação foi mensurada, a diferença entre validação cruzada convencional e teste cego por estabelecimentos disjuntos foi de 23 a 25 pontos percentuais de F1-Macro, evidenciando que parcela substancial do desempenho usualmente reportado pode ser memorização de comércios já observados, e não generalização;
3. **Em regime de baixo volume rotulado, uma representação esparsa por n -gramas de caractere com classificador clássico iguala o desempenho de *embeddings* densos multilíngues a uma fração do custo, e supera com folga o ajuste fino de um modelo no nível de byte e um agente apoiado em LLM local – a contribuição empírica mais relevante do trabalho (Q1 e Q4).** Comparadas em sua melhor configuração, as duas famílias de representação são estatisticamente indistinguíveis (69,3% contra 66,8% de F1-Macro; McNemar com $p = 0,86$), ao passo que o ByT5 (48,3%) e o agente (60,0%) ficam claramente abaixo. Sofisticação arquitetural não compensa escassez de dados rotulados; o que separa as duas primeiras abordagens neste regime é o custo, e o benefício do saneamento léxico é condicional à representação, não uma boa prática universal (Tabela 14);
4. **No agente híbrido, o gargalo está no raciocínio, não na recuperação – e a configuração avaliada do ramo de raciocínio não o testou em condições favoráveis (Q3 e Q5).** O ramo vetorial resolveu 98% das transações que recebeu, em dezenas de milissegundos; o ramo LLM local acertou 21% delas, a cerca de 14 segundos por transação, sob uma diretriz antialucinação que se converteu em abstenção sistemática para a classe residual. Quatro fatores confundem a atribuição dessa diferença ao modelo: o *prompt* não calibrado (Apêndice D), a ausência dos vizinhos recuperados como exemplos no *prompt* (o ramo operou em *zero-shot*, e não como geração aumentada por recuperação), o metadado de origem fixo e a indisponibilidade efetiva da ferramenta de busca. Nenhum deles foi isolado experimentalmente; a leitura mais alinhada à literatura de agentes é que um modelo de 4 bilhões de parâmetros efetivos, sem evidência recuperada no *prompt*, é insuficiente como cérebro do agente;
5. **A proveniência do rótulo é um fator de desempenho e deve ser tratada como variável de estratificação obrigatória (Q2).** O F1-Macro do melhor modelo

cai de 82,4% para 39,4% quando se passa do subconjunto rotulado por dicionário léxico para o rotulado pela categoria nativa do emissor, e a queda ocorre nas cinco arquiteturas (Tabela 12). Reportar uma métrica agregada sobre acervos de rotulagem heterogênea oculta variação dessa magnitude;

6. **Em taxonomias de despesa com cauda longa, acurácia global e F1-Macro medem propriedades distintas e podem apontar em direções opostas sobre o mesmo recorte** (Q2). No subconjunto do Nubank, quatro arquiteturas atingem 98,0% de acurácia e 36,2% de F1-Macro simultaneamente (Seção 5.6.2). A métrica primária deve ser declarada e justificada antes da avaliação, como feito na Seção 5.4; e a verificação de uma hipótese sobre acurácia deve vir acompanhada de intervalo de confiança, sem o qual o resultado marginal do Naive Bayes (88,3%, IC 95% [84,4%; 91,3%]) seria lido como sustentação inequívoca.

Recomendação prática. Para quem precise categorizar faturas de cartão em um acervo pessoal de porte semelhante, a evidência deste trabalho recomenda: um classificador esparso (TF-IDF com n -gramas de caractere e Random Forest) como primeira linha, pelo desempenho e pelo custo desprezível; busca vetorial densa para estabelecimentos já observados, em que sua acurácia condicional é próxima de 100%; modelo de linguagem restrito aos casos residuais, com evidência recuperada no *prompt* e confirmação humana obrigatória; e ajuste fino de modelos no nível de byte apenas com acervos rotulados uma ordem de grandeza maiores.

Em síntese, esta monografia entregou uma esteira completa, reproduzível e executável em infraestrutura local, submeteu-a a um protocolo de avaliação mais severo que o usual na área e documentou, com a mesma precisão, o que foi demonstrado, o que foi apenas projetado e o que resta investigar.

6.4 Limitações do trabalho

Além da refutação da hipótese de desempenho preditivo, apontam-se as seguintes limitações, cada uma discutida na seção indicada:

1. **Ferramenta de busca na web:** exercitada apenas em execução complementar em que os *backends* de busca falharam por conexão em 14% das transações; o resultado principal não a inclui (Seção 5.2);
2. **Metadado de origem fixo no teste cego:** o LLM recebeu origem incorreta para todo o subconjunto do Nubank, e a componente “origem do arquivo” da Q4 não foi variada (Seções 5.2 e 5.8);

3. **Histórico de *marketplace* e detecção de Mercado Livre:** o histórico recuperado não é injetado no *prompt*, e um defeito de chave impede o roteamento do *marketplace* mais frequente pelo ramo de histórico (Seção 4.7; Apêndice E);
4. **HITL simulado nas duas modalidades:** a interrupção do grafo é retomada programaticamente tanto no teste cego quanto no modo de gravação; a espera por um revisor em tempo real exige um *checkpoint* persistente e uma interface de revisão não implementadas (Seções 4.7 e 5.7);
5. **Ramo de raciocínio sem evidência recuperada:** o LLM decide em *zero-shot*; a ausência dos vizinhos no *prompt* é uma causa candidata, não isolada, da acurácia condicional de 21% (Seção 5.6.5);
6. **Ancoramento de rótulos:** o ancoramento interno ao nó de estruturação não é distinguível a posteriori do rótulo bruto do modelo, pois este não foi persistido; o ancoramento externo, verificável, não alterou nenhuma predição (Seção 5.6);
7. **Extração óptica não acoplada nem validada:** o componente Tesseract não está integrado ao serviço de extração, e a comparação de OCR foi conduzida sobre PDFs nativos rasterizados, não sobre documentos genuinamente escaneados (Seções 4.6 e 5.5);
8. **Porte, rotulagem e circularidade do acervo:** 1.660 transações de dois portadores, rotuladas semiautomaticamente, com 11 das 14 categorias povoadas e classes de cauda com 4 a 5 estabelecimentos; o F1-Macro cai sistematicamente no subconjunto rotulado pelo emissor, sem que se possa distinguir circularidade de ruído de rótulo (Seções 5.3.2 e 5.6.3);
9. **Validação cruzada restrita e não agrupada:** a diferença entre validação cruzada e teste cego foi medida apenas para as duas linhas de base esparsas, e a validação cruzada empregada não agrupa por estabelecimento; uma validação cruzada agrupada (**StratifiedGroupKFold**) confirmaria o achado dentro do próprio treino, com cinco estimativas (Seção 5.6);
10. **Desbalanceamento sem tratamento sistemático:** apenas o Random Forest recebeu ponderação de classes; a variante Complementar do Naive Bayes e técnicas de reamostragem não foram avaliadas (Seção 2.2.5);
11. **Hiperparâmetros e limiares não sintonizados:** o conjunto de validação foi incorporado ao treino; hiperparâmetros e os três limiares de roteamento foram fixados *a priori* (Seções 5.4 e 4.7);
12. **Reprodutibilidade do ramo LLM:** a configuração do modelo e do servidor foi documentada retroativamente a partir dos registros do LM Studio, e não pela esteira

experimental no momento da execução; a reprodutibilidade bit a bit permanece sujeita a efeitos numéricos do motor de inferência (Seção 5.2);

13. **Rastreabilidade, controle de acesso e testes:** o registro por inferência (`log_classificacoes`), a validação de *tokens* nas APIs, o isolamento multi-inquilino e a suíte de testes unitários não foram implementados; a aplicação *web* é um protótipo sem painel orçamentário nem tela de confirmação (Seções 4.5, 4.8 e 4.9);
14. **Modelo de *embeddings* genérico:** o modelo multilíngue de paráfrase foi usado sem ajuste fino ao domínio de nomes de estabelecimento (Seção 5.6);
15. **Levantamento bibliográfico:** cobertura mais rasa da string terciária, triada pelos 50 registros mais citados de cada base (Apêndice A);
16. **Desvio estatístico não mensurado:** *Data Drift* e *Concept Drift* motivam o ciclo de MLOps, mas não foram caracterizados, embora o acervo temporalmente ordenado o permitisse (Seção 5.8).

6.5 Trabalhos futuros

Os desdobramentos organizam-se em dois blocos. O primeiro, de **consolidação dos resultados atuais**, reúne execuções de baixo custo sobre a esteira existente, cada uma respondendo a uma limitação da Seção 6.4:

1. **Validação com rótulos independentes** (limitação 8, de maior prioridade): constituir um subconjunto de teste validado manualmente, sem acesso ao dicionário léxico nem à categoria do emissor, para quantificar e descontar o efeito de circularidade; complementarmente, aplicar *Confident Learning* para priorizar rótulos suspeitos à revisão;
2. **Reexecução do ramo LLM em condições controladas** (limitações 1 a 5): sobre as mesmas transações roteadas ao LLM no teste cego, reexecutar o ramo com (a) os três vizinhos recuperados injetados no *prompt* como exemplos rotulados – convertendo o ramo em geração aumentada por recuperação –, (b) o metadado de origem correto, (c) o *prompt* corrigido (regra 5 restaurada, campos revisados), (d) a ferramenta de busca com *backend* estável e (e) um modelo local de maior porte (12 a 27 bilhões de parâmetros), isolando o efeito de cada fator na acurácia condicional de 21%. Persistir o rótulo bruto do modelo para tornar o ancoramento auditável;
3. **Validação cruzada agrupada, balanceamento e sintonia** (limitações 9 a 11): repetir a validação cruzada com `StratifiedGroupKFold` por estabelecimento; avaliar *Complement Naive Bayes*, ponderação de classes e reamostragem; e empregar o conjunto de validação para sintonizar hiperparâmetros e os três limiares de roteamento;

4. **Ajuste fino contrastivo do modelo de *embeddings*** (limitação 14): treinar o codificador de sentenças com pares de descrições do mesmo estabelecimento ou categoria a partir do conjunto de treino;
5. **Correções de integração** (limitações 3, 4, 7 e 13): corrigir a chave de detecção de *marketplace* e injetar o histórico no *prompt*; adotar um *checkpoint* persistente e uma tela de confirmação na aplicação *web*; acoplar o Tesseract ao serviço de extração como *fallback*; alimentar `log_classificacoes`; validar os *tokens* do Logto nas APIs; e escrever a suíte de testes unitários das funções determinísticas;
6. **Bateria de OCR sobre documentos genuinamente escaneados** (limitação 7), estendendo-a também às 49 competências pareadas do acervo.

O segundo bloco, de **expansão**, reúne desenvolvimentos de maior alcance: integração com as APIs do Open Finance Brasil para ingestão contínua de extratos; arquitetura multiagente com especialistas em conciliação orçamentária, detecção de fraudes e consultoria tributária; modelos de visão e linguagem ultracompactos em dispositivo móvel para extração e categorização em borda; aprendizado federado para compartilhar, com preservação de privacidade, o conhecimento sobre novos estabelecimentos entre usuários; materialização das camadas Silver e Gold em formato de tabela aberto com transações ACID, conectadas a um motor SQL distribuído, a painéis gerenciais e a um orquestrador de fluxos, completando as propriedades de *lakehouse*; e caracterização empírica de desvios de dados e de conceito sobre o acervo temporalmente ordenado.

REFERÊNCIAS

- ABECS. **Panorama do Setor de Meios Eletrônicos de Pagamento: Balanço Anual 2024**. São Paulo: Associação Brasileira das Empresas de Cartões de Crédito e Serviços, 2024. Relatório institucional. Disponível em: <https://abecs.org.br/balanco-do-setor-de-meios-de-pagamento>. Acesso em: 15 jan. 2026.
- ARAÚJO, S. S. de; BEZERRA, B. L. D.; SOUZA NETO, A. F. de. A proposal of post-OCR spelling correction using monolingual byte-level language models. *In: Proceedings of the 25th ACM Symposium on Document Engineering (DocEng '25)*. New York, NY, USA: Association for Computing Machinery, 2025. p. 1–4. Artigo 14. DOI: <https://doi.org/10.1145/3704268.3748673>. Acesso em: 08 set. 2026.
- ARMBRUST, M. *et al.* Lakehouse: A new generation of open platforms that unify data warehousing and advanced analytics. *In: Proceedings of the 11th Conference on Innovative Data Systems Research (CIDR 2021)*. [S.l.]: CIDR, 2021. Disponível em: https://www.cidrdb.org/cidr2021/papers/cidr2021_paper17.pdf. Acesso em: 21 set. 2026.
- AUER, C.; DOLFI, M.; STAAR, P. W. J. Docling: A fast, modular document parsing tool for multimodal Document AI. **arXiv preprint arXiv:2408.09869**, 2024. DOI: <https://doi.org/10.48550/arXiv.2408.09869>. Acesso em: 11 set. 2026.
- BINMAKHASHEN, G. M.; MAHMOUD, S. A. Document layout analysis: A comprehensive survey. **ACM Computing Surveys**, v. 52, n. 6, p. 109:1–109:36, 2019. DOI: <https://doi.org/10.1145/3355610>. Acesso em: 08 set. 2026.
- BRASIL. **Lei nº 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais (LGPD)**. Brasília, DF: Diário Oficial da União, 2018. Legislação Federal. Disponível em: http://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/l13709.htm. Acesso em: 18 set. 2026.
- BRASIL. **Controladoria-Geral da União. Portal da Transparência: gastos por meio do Cartão de Pagamento do Governo Federal (CPGF)**. 2024. Conjunto de dados abertos governamentais. Disponível em: <https://portaldatransparencia.gov.br/download-de-dados/cpgf>. Acesso em: 20 jan. 2026.
- BREIMAN, L. Random forests. **Machine Learning**, v. 45, n. 1, p. 5–32, 2001. DOI: <https://doi.org/10.1023/A:1010933404324>. Acesso em: 15 set. 2026.
- BROWN, T. B. *et al.* Language models are few-shot learners. *In: Advances in Neural Information Processing Systems (NeurIPS)*. [S.l.: s.n.], 2020. v. 33, p. 1877–1901. DOI: <https://doi.org/10.48550/arXiv.2005.14165>. Acesso em: 20 set. 2026.
- CASELI, H. de M.; NUNES, M. das G. V. (ed.). **Processamento de linguagem natural: conceitos, técnicas e aplicações em português**. 2. ed. São Carlos, SP: BPLN, 2024. ISBN 978-65-00-95750-1. Disponível em: <https://brasileiraspln.com/livro-pln/2a-edicao/>. Acesso em: 18 set. 2026.

CHAPMAN, P. *et al.* **CRISP-DM 1.0: Step-by-Step Data Mining Guide**. [S.l.], 2000. Disponível em: <https://public.dhe.ibm.com/software/analytics/spss/documentation/modeler/14.2/es/CRISP-DM.pdf>. Acesso em: 21 set. 2026.

CHO, K. *et al.* Learning phrase representations using RNN encoder–decoder for statistical machine translation. *In: Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. Doha, Catar: Association for Computational Linguistics, 2014. p. 1724–1734. DOI: <https://doi.org/10.3115/v1/D14-1179>. Acesso em: 09 set. 2026.

CHOWDHURY, G. G. Natural language processing. **Annual Review of Information Science and Technology**, v. 37, n. 1, p. 51–89, 2003. DOI: <https://doi.org/10.1002/aris.1440370103>. Acesso em: 16 set. 2026.

CURCIO, V.; GALFRÉ, M.; LE VAN, O. Safe invoice data extraction: FPR-constrained validation with VLM denoising. *In: Proceedings of the 2026 ACM Symposium on Document Engineering (DocEng '26)*. Fribourg: Association for Computing Machinery, 2026. p. 1–10. DOI: <https://doi.org/10.1145/3820755.3821480>. Acesso em: 16 set. 2026.

DEVLIN, J. *et al.* BERT: Pre-training of deep bidirectional transformers for language understanding. *In: Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT)*. Minneapolis, MN: Association for Computational Linguistics, 2019. p. 4171–4186. DOI: <https://doi.org/10.18653/v1/N19-1423>. Acesso em: 20 set. 2026.

DHINGRA, B. *et al.* Tweet2vec: Character-based distributed representations for social media. *In: Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers)*. Berlin, Alemanha: Association for Computational Linguistics, 2016. p. 269–274. DOI: <https://doi.org/10.48550/arXiv.1605.03481>. Acesso em: 18 set. 2026.

EFRON, B. Bootstrap methods: Another look at the jackknife. **The Annals of Statistics**, v. 7, n. 1, p. 1–26, 1979. DOI: <https://doi.org/10.1214/aos/1176344552>. Acesso em: 11 set. 2026.

FARIAS, T. P.; MENDES, T. S.; CONCEIÇÃO, R. S. da. Nota Conforme: sistema integrado para classificação automatizada de serviços em NFS-e com machine learning. *In: Anais Estendidos do XL Simpósio Brasileiro de Banco de Dados (SBBDD 2025)*. Fortaleza: Sociedade Brasileira de Computação, 2025. p. 123–128. DOI: https://doi.org/10.5753/sbbd_estendido.2025.247676. Acesso em: 18 set. 2026.

GANDIKOTA, L. R. *et al.* Spatial-aware financial document understanding: A region-segmented OCR-LLM pipeline with layout-encoded prompting for key-value extraction. *In: 2026 IEEE International Conference on Electro Information Technology (eIT)*. La Crosse, WI: IEEE, 2026. p. 144–149. DOI: <https://doi.org/10.1109/eIT68936.2026.11670412>. Acesso em: 17 set. 2026.

GEMMA TEAM. **Gemma 4 Technical Report**. 2026. ArXiv:2607.02770. DOI: <https://doi.org/10.48550/arXiv.2607.02770>. Acesso em: 13 set. 2026.

- GERHARDT, T. E.; SILVEIRA, D. T. **Métodos de pesquisa**. Porto Alegre, RS: Editora da UFRGS, 2009. Disponível em: <https://lume.ufrgs.br/handle/10183/52806>. Acesso em: 18 set. 2026.
- GIL, A. C. **Métodos e técnicas de pesquisa social**. 7. ed. São Paulo, SP: Atlas, 2019. Disponível em: <https://www.grupogen.com.br/livro-metodos-e-tecnicas-de-pesquisa-social-antonio-carlos-gil-9786559778560>. Acesso em: 18 set. 2026.
- HAREL, D. Statecharts: A visual formalism for complex systems. **Science of Computer Programming**, v. 8, n. 3, p. 231–274, 1987. DOI: [https://doi.org/10.1016/0167-6423\(87\)90035-9](https://doi.org/10.1016/0167-6423(87)90035-9). Acesso em: 12 set. 2026.
- HOCHREITER, S.; SCHMIDHUBER, J. Long short-term memory. **Neural Computation**, v. 9, n. 8, p. 1735–1780, 1997. DOI: <https://doi.org/10.1162/neco.1997.9.8.1735>. Acesso em: 08 set. 2026.
- HUANG, Z. *et al.* ICDAR2019 competition on scanned receipt OCR and information extraction. *In: 2019 International Conference on Document Analysis and Recognition (ICDAR)*. Sydney: IEEE, 2019. p. 1516–1520. DOI: <https://doi.org/10.1109/ICDAR.2019.00244>. Acesso em: 10 set. 2026.
- JÉGOU, H.; DOUZE, M.; SCHMID, C. Product quantization for nearest neighbor search. **IEEE Transactions on Pattern Analysis and Machine Intelligence**, v. 33, n. 1, p. 117–128, 2011. DOI: <https://doi.org/10.1109/TPAMI.2010.57>. Acesso em: 10 set. 2026.
- KREUZBERGER, D.; KÜHL, N.; HIRSCHL, S. Machine learning operations (MLOps): Overview, definition, and architecture. **IEEE Access**, IEEE, v. 10, p. 31866–31879, 2022. DOI: <https://doi.org/10.1109/ACCESS.2022.3160450>. Acesso em: 12 set. 2026.
- LANGCHAIN. **LangGraph: Building resilient language agents as graphs**. 2024. Documento eletrônico corporativo, blog institucional LangChain. Disponível em: <https://blog.langchain.dev/langgraph/>. Acesso em: 18 set. 2026.
- LEVENSHTIN, V. I. Binary codes capable of correcting deletions, insertions, and reversals. **Soviet Physics Doklady**, v. 10, n. 8, p. 707–710, 1966. Disponível em: <https://nymity.ch/sybilhunting/pdf/Levenshtein1966a.pdf>. Acesso em: 21 set. 2026.
- LEWIS, D. D.; GALE, W. A. A sequential algorithm for training text classifiers. *In: Proceedings of the 17th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval*. [S.l.: s.n.]: Springer, 1994. p. 3–12. DOI: https://doi.org/10.1007/978-1-4471-2099-5_1. Acesso em: 10 set. 2026.
- LEWIS, P. *et al.* Retrieval-augmented generation for knowledge-intensive NLP tasks. *In: Advances in Neural Information Processing Systems (NeurIPS 2020)*. Red Hook, NY: Curran Associates, 2020. v. 33, p. 9459–9474. DOI: <https://doi.org/10.48550/arXiv.2005.11401>. Acesso em: 14 set. 2026.
- LU, J. *et al.* Learning under concept drift: A review. **IEEE Transactions on Knowledge and Data Engineering**, v. 31, n. 12, p. 2346–2363, 2019. DOI: <https://doi.org/10.1109/TKDE.2018.2876857>. Acesso em: 15 set. 2026.

MATOS, P. F.; CIFERRI, R. R.; PARDO, T. A. S. Metodologia de pré-processamento textual para extração de informação sobre efeitos de doenças em artigos científicos do domínio biomédico. *In: Workshop de Teses e Dissertações em Banco de Dados (WTDBD), XXIV Simpósio Brasileiro de Banco de Dados (SBBD)*. São Carlos, SP: Sociedade Brasileira de Computação, 2009. p. 7–12. Disponível em: <https://sites.icmc.usp.br/taspardo/WTDBD09-MatosEtAl.pdf>. Acesso em: 18 set. 2026.

MCCALLUM, A.; NIGAM, K. A comparison of event models for naive Bayes text classification. *In: AAAI-98 Workshop on Learning for Text Categorization*. Madison, WI: AAAI Press, 1998. v. 752, p. 41–48. Disponível em: <https://cdn.aaai.org/Workshops/1998/WS-98-05/WS98-05-007.pdf>. Acesso em: 21 set. 2026.

MCNEMAR, Q. Note on the sampling error of the difference between correlated proportions or percentages. *Psychometrika*, v. 12, n. 2, p. 153–157, 1947. DOI: <https://doi.org/10.1007/BF02295996>. Acesso em: 12 set. 2026.

MIKOLOV, T. *et al.* Efficient estimation of word representations in vector space. *In: Proceedings of the International Conference on Learning Representations (ICLR), Workshop Track*. [S.l.: s.n.], 2013. DOI: <https://doi.org/10.48550/arXiv.1301.3781>. Acesso em: 09 set. 2026.

NORTHCUTT, C. G.; JIANG, L.; CHUANG, I. L. Confident learning: Estimating uncertainty in dataset labels. *Journal of Artificial Intelligence Research*, v. 70, p. 1373–1411, 2021. DOI: <https://doi.org/10.1613/jair.1.12125>. Acesso em: 14 set. 2026.

PODER360. **Gastos com cartão de crédito sobem 8% no fim de 2024, aponta Elo**. 2025. Portal de Notícias. Disponível em: <https://www.poder360.com.br/economia/gastos-com-cartao-de-credito-sobem-8-no-fim-de-2024-aponta-elo/>. Acesso em: 12 fev. 2026.

PYDANTIC. **Pydantic: data validation using Python type hints – documentation, version 2**. 2025. Documentação eletrônica do projeto. Disponível em: <https://docs.pydantic.dev/latest/>. Acesso em: 20 set. 2026.

QUIÑONERO-CANDELA, J. *et al.* **Dataset Shift in Machine Learning**. Cambridge, MA: The MIT Press, 2008. DOI: <https://doi.org/10.7551/mitpress/9780262170055.001.0001>. Acesso em: 11 set. 2026.

RAJARAMAN, A.; ULLMAN, J. D. **Mining of Massive Datasets**. Cambridge, UK: Cambridge University Press, 2011. DOI: <https://doi.org/10.1017/CBO9781139058452>. Acesso em: 17 set. 2026.

REIMERS, N.; GUREVYCH, I. Sentence-BERT: Sentence embeddings using siamese BERT-networks. *In: Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*. Hong Kong, China: Association for Computational Linguistics, 2019. p. 3982–3992. DOI: <https://doi.org/10.18653/v1/D19-1410>. Acesso em: 19 set. 2026.

REN, P. *et al.* A survey of deep active learning. *ACM Computing Surveys*, v. 54, n. 9, p. 1–40, 2021. DOI: <https://doi.org/10.1145/3472291>. Acesso em: 13 set. 2026.

RENNIE, J. D. M. *et al.* Tackling the poor assumptions of naive Bayes text classifiers. *In: Proceedings of the 20th International Conference on Machine Learning (ICML 2003)*. Washington, DC: AAAI Press, 2003. p. 616–623. Disponível em: <https://dl.acm.org/doi/10.5555/3041838.3041916>. Acesso em: 21 set. 2026.

SALTON, G.; BUCKLEY, C. Term-weighting approaches in automatic text retrieval. **Information Processing & Management**, v. 24, n. 5, p. 513–523, 1988. DOI: [https://doi.org/10.1016/0306-4573\(88\)90021-0](https://doi.org/10.1016/0306-4573(88)90021-0). Acesso em: 15 set. 2026.

SANTOS, M. T. M. dos. **Classificação de produtos em Notas Fiscais Eletrônicas usando Descrições Textuais não estruturadas**. 2022. 39 f. Monografia (Trabalho de Conclusão de Curso (Engenharia de Computação)) — Universidade Federal de Alagoas (UFAL), Instituto de Computação, Maceió, AL, 2022. Disponível em: <https://www.repositorio.ufal.br/handle/123456789/11641>. Acesso em: 18 set. 2026.

SERASA EXPERIAN. **Mapa da Inadimplência e Renegociação de Dívidas no Brasil**. São Paulo: Serasa Experian, 2024. Relatório estatístico. Disponível em: <https://www.serasa.com.br/limpa-nome-online/estatisticas-inadimplencia/>. Acesso em: 10 fev. 2026.

SMITH, R. An overview of the Tesseract OCR engine. *In: Ninth International Conference on Document Analysis and Recognition (ICDAR 2007)*. Curitiba, Brasil: IEEE, 2007. v. 2, p. 629–633. DOI: <https://doi.org/10.1109/ICDAR.2007.4378789>. Acesso em: 20 set. 2026.

SOKOLOVA, M.; LAPALME, G. A systematic analysis of performance measures for classification tasks. **Information Processing & Management**, v. 45, n. 4, p. 427–437, 2009. DOI: <https://doi.org/10.1016/j.ipm.2009.03.002>. Acesso em: 19 set. 2026.

SOUZA, M. F. de. **Extração automática de informações em imagens de notas fiscais**. 2025. 69 f. Dissertação (Mestrado em Ciência da Computação) — Universidade Federal de Viçosa (UFV), Departamento de Informática, Viçosa, MG, 2025. DOI: <https://doi.org/10.47328/ufvbbt.2025.430>. Acesso em: 17 set. 2026.

SPÄRCK JONES, K. A statistical interpretation of term specificity and its application in retrieval. **Journal of Documentation**, v. 28, n. 1, p. 11–21, 1972. DOI: <https://doi.org/10.1108/eb026526>. Acesso em: 14 set. 2026.

SPC BRASIL. **Pesquisa de Educação Financeira e Gestão do Orçamento Doméstico no Brasil**. Brasília: Serviço de Proteção ao Crédito, 2024. Relatório de pesquisa. Disponível em: <https://www.spcbrasil.org.br>. Acesso em: 20 jan. 2026.

TA, D.-T.; SAAD, W. B.; OH, J.-Y. Specialized text classification: An approach to classifying Open Banking transactions. *In: 2023 IEEE 18th International Conference on Computer Science and Information Technologies (CSIT)*. Lviv: IEEE, 2023. DOI: <https://doi.org/10.1109/CSIT61576.2023.10324203>. Acesso em: 16 set. 2026.

TREVEIL, M. *et al.* **Introducing MLOps: How to Scale Machine Learning in the Enterprise**. Sebastopol, CA: O'Reilly Media, 2020. Disponível em: <https://www.oreilly.com/library/view/introducing-mlops/9781492083283/>. Acesso em: 18 set. 2026.

VASWANI, A. *et al.* Attention is all you need. *In: Advances in Neural Information Processing Systems (NeurIPS 2017)*. Red Hook, NY: Curran Associates, 2017. v. 30, p. 5998–6008. DOI: <https://doi.org/10.48550/arXiv.1706.03762>. Acesso em: 19 set. 2026.

WEI, J. *et al.* Chain-of-thought prompting elicits reasoning in large language models. *In: Advances in Neural Information Processing Systems (NeurIPS 2022)*. Red Hook, NY: Curran Associates, 2022. v. 35, p. 24824–24837. DOI: <https://doi.org/10.48550/arXiv.2201.11903>. Acesso em: 08 set. 2026.

WIRTH, R.; HIPPI, J. CRISP-DM: Towards a standard process model for data mining. *In: Proceedings of the 4th International Conference on the Practical Applications of Knowledge Discovery and Data Mining*. Manchester: Practical Application Company, 2000. p. 29–39. Disponível em: <https://cs.unibo.it/~danilo.montesi/CBD/Beatriz/10.1.1.198.5133.pdf>. Acesso em: 21 set. 2026.

WOHLIN, C. Guidelines for snowballing in systematic literature studies and a replication in software engineering. *In: Proceedings of the 18th International Conference on Evaluation and Assessment in Software Engineering (EASE '14)*. New York, NY, USA: Association for Computing Machinery, 2014. p. 1–10. DOI: <https://doi.org/10.1145/2601248.2601268>. Acesso em: 13 set. 2026.

XUE, L. *et al.* ByT5: Towards a token-free future with pre-trained byte-to-byte models. *Transactions of the Association for Computational Linguistics*, v. 10, p. 291–306, 2022. DOI: https://doi.org/10.1162/tacl_a_00461. Acesso em: 18 set. 2026.

YAO, S. *et al.* ReAct: Synergizing reasoning and acting in language models. *In: Proceedings of the 11th International Conference on Learning Representations (ICLR 2023)*. Kigali: OpenReview, 2023. DOI: <https://doi.org/10.48550/arXiv.2210.03629>. Acesso em: 09 set. 2026.

ZAHARIA, M. *et al.* Accelerating the machine learning lifecycle with MLflow. *IEEE Data Engineering Bulletin*, v. 41, n. 4, p. 39–45, 2018. Disponível em: <http://sites.computer.org/debull/A18dec/p39.pdf>. Acesso em: 18 set. 2026.

ZHANG, X.; ZHAO, J.; LECUN, Y. Character-level convolutional networks for text classification. *In: Advances in Neural Information Processing Systems (NeurIPS)*. Red Hook, NY: Curran Associates, 2015. v. 28, p. 649–657. DOI: <https://doi.org/10.48550/arXiv.1509.01626>. Acesso em: 09 set. 2026.

APÊNDICES

APÊNDICE A – PROTOCOLO DO LEVANTAMENTO BIBLIOGRÁFICO

Este apêndice documenta formalmente o protocolo do levantamento estruturado da literatura adotado no Capítulo 3, com vistas à reprodutibilidade metodológica do levantamento bibliográfico.

A.1 Bases de dados consultadas

As consultas foram executadas entre janeiro e maio de 2026, com reexecução das três strings em setembro de 2026 para reconstrução das contagens e incorporação de trabalhos publicados no intervalo (Seção A.5), nas seguintes bases de dados indexadas de relevância internacional e nacional:

- **Scopus** (Elsevier);
- **IEEE Xplore Digital Library**;
- **Google Scholar** e repositórios institucionais (para literatura cinzenta e teses nacionais).

A.2 Strings de busca aplicadas

As sintaxes de busca foram construídas com operadores booleanos AND e OR em múltiplos níveis de especificidade:

- **String Primária (Intersecção Central do Tema):**

```
("financial transaction*"OR "credit card"OR invoice* OR receipt* OR "nota fiscal") AND (classification OR categorization) AND (OCR) AND ("natural language processing"OR transformer* OR LLM*)
```

- **String Secundária (Saneamento e Correção Pós-OCR):**

```
("post-OCR"OR "OCR error correction") AND ("language model*"OR transformer* OR LLM* OR "byte-level")
```

- **String Terciária (Mineração em Textos Curtos Ruidosos):**

```
("short text*"OR "noisy text*"OR "noisy short text*") AND (classification OR categorization) AND (embeddings OR transformer* OR "deep learning")
```

A String Primária e a String Secundária, por delimitarem de forma mais restrita a interseção com o domínio de aplicação (faturas/transações financeiras e correção pós-OCR, respectivamente), retornaram um volume de registros compatível com triagem manual integral em todas as bases consultadas. A String Terciária, por abranger o campo mais amplo de classificação de textos curtos/ruidosos em geral – sem o recorte de domínio financeiro –, retornou um volume de registros (centenas a milhares por base) inviável de ser triado exaustivamente dentro do prazo do trabalho. Para essa string, adotou-se um critério de corte explícito: os **50 registros mais citados** (ordenação por número de citações, decrescente) de cada base foram selecionados para a etapa de triagem por título/resumo, descartando-se os demais. Esse critério prioriza os estudos de maior influência e consolidação na área, à custa de uma cobertura mais rasa da literatura mais recente ainda pouco citada – limitação reconhecida explicitamente na Seção 6.4 do Capítulo 6.

A.3 Critérios de inclusão e exclusão

- **Critérios de Inclusão (CI):**

1. Artigos publicados em periódicos científicos revisados por pares, anais de conferências internacionais indexadas (ICDAR, ACL, EMNLP, NeurIPS) ou dissertações/teses de excelência;
2. Estudos que apresentam métricas quantitativas formais de avaliação (Acurácia, F1-Score, CER, WER);
3. Trabalhos que detalham o tratamento de textos informais, abreviações, saneamento de OCR ou limitações de infraestrutura de hardware.

- **Critérios de Exclusão (CE):**

1. Trabalhos que utilizam LLMs generativos de forma puramente teórica sem mensuração empírica de custos e latência;
2. Artigos focados exclusivamente em reconhecimento de caracteres em placas veiculares ou caligrafia manuscrita sem relação com documentos comerciais;
3. Cursos *online*, postagens informais de blogs ou documentos sem afiliação institucional verificável.

A.4 Técnica de snowballing (citação em cascata)

Complementarmente à busca direta nas três bases de dados listadas na Seção A.1 com as strings da Seção A.2, adotou-se também a técnica de *snowballing* (citação em

cascata) descrita por Wohlin (2014): a partir dos estudos já recuperados pela busca formal, as listas de referências desses trabalhos foram inspecionadas em busca de estudos adicionais pertinentes não capturados pelas strings de busca, mas relevantes ao escopo do levantamento.

Foi por meio dessa técnica – e não da busca direta nas bases – que três dos dez estudos incluídos no levantamento (Seção 3.6) foram identificados: Zhang, Zhao e LeCun (2015), citados em trabalhos de revisão sobre redes neurais convolucionais em nível de caractere; Dhingra et al. (2016), citados nas referências bibliográficas de Santos (2022); e a competição ICDAR2019/SROIE de Huang *et al.* (2019), referenciada em trabalhos correlatos de extração de dados de faturas. Três estudos – Araújo, Bezerra e Souza Neto (2025), Curcio, Galfré e Le Van (2026) e Gandikota *et al.* (2026) – foram recuperados pela busca direta nas bases (String Primária e Secundária); três – Santos (2022), Souza (2025) e Farias, Mendes e Conceição (2025) – em repositórios institucionais nacionais e na biblioteca digital da SBC; e o décimo, Ta, Saad e Oh (2023), por busca direcionada complementar (Seção A.5).

A.5 Registros recuperados e seleção dos estudos

A Tabela 16 apresenta o número de registros recuperados por string e por base na busca direta em Scopus e IEEE Xplore, reconstruído retrospectivamente em setembro de 2026 a partir de reexecução ao vivo das três strings da Seção A.2 (contagens conferidas contra o contador oficial de resultados de cada base; para a String Terciária, aplicou-se o corte de relevância descrito na mesma seção). Após a remoção de 25 duplicados (na mesma base e entre bases), os 205 registros únicos foram triados por título e resumo, com decisões e justificativas individuais registradas em `docs/RSL/TRIAGEM_DECISOES.csv` no repositório do projeto.

Tabela 16 – Registros recuperados por busca direta, por string de busca e base (Scopus e IEEE Xplore).

String de busca	Scopus	IEEE Xplore	Total
Primária (interseção central do tema)	26	18	44
Secundária (saneamento e correção pós-OCR)	61	25	86
Terciária (textos curtos ruidosos; corte por citação)	50	50	100
Total recuperado	137	93	230
Duplicados removidos (na mesma base e entre bases)			25
Registros únicos triados por título/resumo			205

Fonte: Elaborada pelo autor (2026). Google Scholar não está contemplada nesta tabela por ter sido empregada como busca direcionada a repositórios institucionais e teses nacionais (Seção A.1), não como aplicação literal das três strings.

Deve-se declarar com clareza o que este levantamento é e o que não é. **Não se trata**

de uma revisão sistemática em sentido estrito: não houve triagem em duas etapas com leitura integral registrada e decisão de inclusão documentada estudo a estudo sobre a totalidade dos candidatos aprovados por título e resumo. A triagem por título e resumo foi, na prática, pouco seletiva (a maior parte dos 205 registros atende aos critérios de inclusão da Seção A.3, que são amplos), e reportar a partir dela um funil com “candidatos aptos” e “excluídos após leitura integral” equivaleria a estimar uma etapa que não foi de fato conduzida. O que se realizou foi um **levantamento estruturado da literatura:** as strings, bases e critérios acima delimitaram o universo de candidatos, e a seleção dos estudos efetivamente analisados em profundidade na Seção 3.6 do Capítulo 3 seguiu um julgamento de **centralidade em relação às questões da revisão** (QR-1 a QR-4, Seção 3.2), prática usual em revisões de escopo quando o volume de literatura correlata é amplo. Os dez estudos incluídos originam-se de quatro canais distintos e complementares, já documentados nas seções anteriores deste apêndice:

- **Busca direta nas bases** (dentre os 205 registros da Tabela 16): Araújo, Bezerra e Souza Neto (2025), pela String Secundária; Curcio, Galfré e Le Van (2026) e Gandikota et al. (2026), pela String Primária (Scopus e IEEE Xplore, respectivamente);
- **Busca direcionada a repositórios institucionais/teses nacionais e à biblioteca digital da SBC** (Seção A.1): Santos (2022), Souza (2025) e Farias, Mendes e Conceição (2025);
- ***Snowballing*** (Seção A.4): Zhang, Zhao e LeCun (2015), Dhingra et al. (2016) e a competição ICDAR2019/SROIE (2019);
- **Busca direcionada complementar sobre classificação de transações bancárias**, fora das três strings formais – a String Primária exige o termo OCR e, por isso, não captura trabalhos que classificam descrições de transação já digitais: Ta, Saad e Oh (2023), localizado por busca direcionada ao longo da redação do trabalho, sem registro do canal exato de recuperação, e incorporado ao levantamento por ser o estudo de problema mais próximo ao desta pesquisa.

APÊNDICE B – ESQUEMA DO BANCO DE DADOS RELACIONAL E VETORIAL

Este apêndice apresenta o esquema físico relacional e vetorial implementado no PostgreSQL 16 com a extensão pgvector, tal como criado pelos *scripts* `infra/scripts/base.sql` (esquema inicial) e `basev2.sql` (extensões para *marketplaces*, sugestões, alocações e aliases). O mapeamento objeto-relacional (`notebooks/modules/model.py`) declara as mesmas tabelas com tipos ligeiramente mais estritos (`NUMERIC(4,3)` em vez de `REAL` para confianças), sem efeito sobre os resultados.

B.1 Tabela de estabelecimentos (base de conhecimento relacional)

```
CREATE TABLE estabelecimentos (
  id SERIAL PRIMARY KEY,
  nome_original TEXT NOT NULL,
  nome_normalizado TEXT NOT NULL,
  categoria_id INTEGER REFERENCES categorias(id),
  subcategoria_id INTEGER REFERENCES subcategorias(id),
  tipo_estabelecimento_id INTEGER REFERENCES tipos_estabelecimento(id), -- basev2
  eh_marketplace BOOLEAN NOT NULL DEFAULT FALSE, -- basev2
  confianca REAL DEFAULT 0.0 CHECK (confianca BETWEEN 0 AND 1),
  fonte TEXT, -- 'llm', 'manual', 'usuario', 'importacao'
  metadados JSONB DEFAULT '{}',
  embedding VECTOR(384), -- embedding semantico do nome normalizado
  qtd_transacoes INTEGER DEFAULT 1,
  ultima_atualizacao TIMESTAMP DEFAULT NOW(),
  criado_em TIMESTAMP DEFAULT NOW()
);

CREATE INDEX idx_estab_nome_trgm ON estabelecimentos
  USING GIN (nome_normalizado gin_trgm_ops);
CREATE INDEX idx_estab_embedding_hnsw ON estabelecimentos
  USING hnsw (embedding vector_cosine_ops)
  WITH (m = 16, ef_construction = 64);
```

B.2 Coleção vetorial consultada pelo agente

A busca por similaridade do agente (nó `buscar_por_similaridade`) e a retroalimentação da base (nó `salvar_vectorstore`) operam sobre a coleção `baseconhecimento`, mantida pela integração `langchain-postgres` em duas tabelas próprias, criadas pela

biblioteca e povoadas pela etapa `04_rag_pgvector.py` com um documento por estabelecimento único do conjunto de treino (texto: chave do estabelecimento; metadados: categoria e identificador da categoria):

```
langchain_pg_collection (uuid UUID PRIMARY KEY, name VARCHAR, cmetadata JSON)
langchain_pg_embedding (id VARCHAR PRIMARY KEY, collection_id UUID REFERENCES
                        langchain_pg_collection(uuid), embedding VECTOR,
                        document VARCHAR, cmetadata JSONB)
```

Essa coleção não recebe índice aproximado de vizinhos mais próximos: a busca é exaustiva, adequada à escala do acervo (488 vetores) e responsável pela latência de 1,4 ms medida na Seção 5.7. A tabela `estabelecimentos` guarda cópia do mesmo *embedding* e da categoria para consulta relacional e para o *cache* por nome exato, mas não é a fonte da busca vetorial do agente.

B.3 Tabela de transações financeiras

```
CREATE TABLE transacoes (
  id SERIAL PRIMARY KEY,
  fatura_id INTEGER NOT NULL REFERENCES faturas(id) ON DELETE CASCADE,
  nome_original TEXT NOT NULL,
  nome_normalizado TEXT,
  valor NUMERIC(12, 2) NOT NULL,
  data_transacao DATE NOT NULL,
  categoria_id INTEGER REFERENCES categorias(id),
  subcategoria_id INTEGER REFERENCES subcategorias(id),
  estabelecimento_id INTEGER REFERENCES estabelecimentos(id),
  confianca REAL CHECK (confianca BETWEEN 0 AND 1),
  metodo_classificacao TEXT,          -- 'vetorial', 'llm', 'humano'
  revisado_usuario BOOLEAN DEFAULT FALSE,
  criado_em TIMESTAMP DEFAULT NOW(),
  -- colunas acrescentadas por basev2.sql:
  categoria_sugerida_id INTEGER REFERENCES categorias(id),
  subcategoria_sugerida_id INTEGER REFERENCES subcategorias(id),
  confianca_sugestao REAL CHECK (confianca_sugestao BETWEEN 0 AND 1),
  requer_confirmacao BOOLEAN NOT NULL DEFAULT FALSE,
  status_classificacao TEXT NOT NULL DEFAULT 'pendente'
    CHECK (status_classificacao IN ('pendente', 'classificada', 'sugerida',
    'confirmada_usuario', 'rejeitada_usuario', 'sem_evidencia')),
  origem_detalhamento TEXT
);
```

A tabela `log_classificacoes` (`nome_entrada`, `categoria_sugerida`, `confianca`, `metodo`, `prompt_usado`, `resposta_llm`, `similaridade`, `tempo_ms`) e as tabelas `feedbacks`, `transacao_alocacoes_categoria` e `confirmacoes_categoria_marketplace` constam do esquema, mas não são alimentadas pela versão do agente avaliada nesta monografia (Seção 4.7). Observa-se ainda que o *script* inicial semeia a tabela `categorias` com nove categorias de uma taxonomia anterior; a taxonomia canônica de 14 categorias empregada pelo agente e pela esteira experimental (lista em `notebooks/experimentos/common.py`) deve ser carregada nessa tabela antes da execução, passo documentado no Apêndice C.

APÊNDICE C – REPOSITÓRIO DE CÓDIGO-FONTE E REPRODUTIBILIDADE

Todo o código-fonte desenvolvido nesta monografia — *microserviços*, processos trabalhadores assíncronos, *notebooks* de experimentação, definições de infraestrutura e *scripts* de banco de dados — está publicado, sob controle de versão, no seguinte repositório público:

https://github.com/luizhslima/classificador_faturas_v1

A aplicação *web* (protótipo, Seção 4.5) é referenciada pelo repositório como submódulo Git, mas seu repositório próprio não foi publicado; o diretório *web/* aparece vazio após a clonagem e a aplicação está disponível apenas na cópia local do autor. Sua publicação, junto com o registro do arquivo *.gitmodules*, fica como pendência de depósito. A organização de diretórios é resumida a seguir:

- *infra/* — arquivos Docker Compose (*docker-compose-externalinfra.yml* é o utilizado nesta pesquisa) e *scripts* de inicialização (*setup_minio.sh*, *init.py*, *base.sql*, *basev2.sql*) que provisionam o MinIO, o Apache Kafka, o MLflow, o Logto e o PostgreSQL 16 com a extensão *pgvector*. Antes de executar o agente, a tabela *categorias* deve ser carregada com as 14 categorias canônicas listadas em *notebooks/experimentos/common.py*, e o *bucket mlflow-artifacts* deve ser criado (Apêndice B);
- *service-ingestao/* — API reativa de ingestão em Java (Spring WebFlux), organizada em arquitetura hexagonal, responsável por persistir os arquivos brutos no MinIO e publicar os eventos de ingestão no barramento Kafka;
- *worker-prata/* — serviço consumidor de extração em Python que consome os eventos do Kafka, executa a conversão documental com IBM Docling V2 e persiste faturas e transações no PostgreSQL;
- *notebooks/modules/* — implementação do agente de classificação em grafo de estados (LangGraph): nós, roteadores, contratos Pydantic, serviços de banco de dados, integração com o *vector store* e a rotina autônoma de OCR com Tesseract (*utils.py*);
- *notebooks/experimentos/* — **esteira experimental reprodutível** (*common.py* e as etapas 01 a 11) que gera os resultados de classificação do Capítulo 5: construção da base rotulada e dos conjuntos, treino e teste cego das linhas de base clássicas,

ajuste do ByT5, busca vetorial densa, execução do agente híbrido, estudo de ablação, consolidação das tabelas e figuras em L^AT_EX, intervalos de confiança e testes de significância para o F1-Macro (etapa 09) e para a acurácia (etapa 11), e verificação empírica de conformidade com a LGPD (etapa 10). A bateria comparativa de extração (Docling V2 versus Tesseract, Seção 5.5) é gerada pelo *notebook* `notebooks/data_analysis.ipynb`;

- **service-classification/** — protótipo de API de classificação *zero-shot* por similaridade de *embeddings*, não integrado ao agente nem avaliado nesta monografia;
- **web/** — protótipo de aplicação *web* (Next.js) com autenticação via Logto e interface de envio de faturas; a visualização orçamentária e a tela de confirmação humana (HITL) são trabalho futuro (submódulo);
- **requirements*.txt** — conjuntos de dependências Python (núcleo da solução, agentes e ambiente de redação da monografia).

Os experimentos de classificação foram rastreados em um servidor MLflow sob o experimento `experimento_faturas`, registrando parâmetros, métricas, relatórios por categoria, predições e artefatos gráficos. Em razão do caráter estritamente pessoal e sensível dos dados financeiros utilizados (Seção 4.8), o acervo de faturas reais e os respectivos arquivos de verdade de referência não são distribuídos no repositório. As credenciais de serviço da infraestrutura local constam em claro nos arquivos de configuração e devem ser substituídas em qualquer implantação fora do ambiente experimental.

APÊNDICE D – *SYSTEM PROMPT* E CONTRATO PYDANTIC DO RAMO LLM

Este apêndice reproduz, na íntegra e sem correções editoriais, o *System Prompt* dinâmico efetivamente enviado ao modelo de linguagem no nó `classificar_com_llm` do agente (Seção 4.7), extraído diretamente do código-fonte (`notebooks/modules/nodes.py`), e o esquema Pydantic `ClassificacaoLLM` (`notebooks/modules/structures.py`) que valida a saída estruturada correspondente, tornando o experimento auditável. Os dois artefatos são reproduzidos **na versão que gerou os resultados do Capítulo 5**; após os experimentos, a versão publicada no repositório recebeu as correções editoriais recomendadas na Seção D.3 (renumeração sequencial das regras e ortografia das descrições dos campos), sem alteração de conteúdo, de modo que o código-fonte atual difere do texto abaixo apenas nesses pontos.

D.1 *System prompt* dinâmico

Os trechos entre chaves (`{}`) são preenchidos em tempo de execução: `dtlk.get('source')` e `dtlk['extensao']` vêm dos metadados do caminho do arquivo no *data lakehouse*; a regra de origem do dado alterna entre uma instrução de saneamento de OCR ou uma instrução de não presumir erros ópticos, conforme o arquivo seja nativo digital ou óptico; e a lista de categorias permitidas é montada dinamicamente a partir da tabela `categorias` do banco de dados. A numeração das regras (1 a 4, seguida de 6 a 9, sem a regra 5) é reproduzida exatamente como consta no código-fonte.

Você é um assistente financeiro especialista em classificar transações de faturas de cartão de crédito no Brasil.

CONTEXTO DA EXTRAÇÃO:

- Banco Origem: `{dtlk.get('source')}`
- Formato do Dado: `{dtlk['extensao']}`

Você tem acesso a ferramentas. Sempre que usar uma ferramenta, certifique-se de preencher os parâmetros com um JSON estrito, utilizando os tipos corretos (ex: booleanos não devem ter aspas).

REGRAS DE ANÁLISE:

1. PROCESSADORES DE PAGAMENTO: Prefixos como "PG*", "PAG*", "MP*", "ZOOP*", "SUMUP*", "IFD*", "EBN*", "HNA*" indicam apenas a maquininha/gateway. Descodifique siglas comuns (IFD/IFOOD=comida, UBR/UBER=transporte, AMZN=marketplace, DROGA=farmácia).
2. SUA TAREFA É A CATEGORIA, NÃO A MARCA: mesmo sem reconhecer o estabelecimento específico, use pistas genéricas do texto para inferir

a categoria. Palavras como "RESTAURANTE", "LANCHONETE", "PIZZA", "ACAI", "PADARIA", "MERCADO", "HORTIFRUTI" => Alimentação; "DROGARIA", "DROGA", "FARMACIA", "OTICA", "CLINICA" => Saúde; "POSTO", "AUTO POSTO", "UBER", "99" => Transporte; "INGRESSE", "INGRESSO", "CINEMA", "STEAM", "PLAYSTATION", "JOGOS", "GAMES" => Lazer e Entretenimento; "MERCADOLIVRE", "AMAZON", "SHOPEE", "MAGALU" => Marketplace / E-commerce. Só use "Despesas Diversas / Outros" quando NENHUMA pista de categoria estiver presente.

3. COMBATE A ALUCINAÇÕES: não invente a identidade da marca; mas inferir a categoria a partir de pistas genéricas NÃO é alucinação.
4. REGRA DE ORIGEM DO DADO: {instrucao_ocr}
6. ESTABELECIMENTOS TOTALMENTE OPACOS: apenas quando o nome for um gateway genérico sem pista (ex.: "DIVIPAYPAYMENTS", "PAYPAL *XXXX") ou um nome próprio informal sem contexto, defina 'requer_confirmacao=true' e confiança <= 0.70.
7. CADEIA DE PENSAMENTO: Pense passo a passo (raciocínio curto) ANTES de decidir a categoria.
8. Se houver a ferramenta 'duckduckgo_search', use-a no máximo UMA vez, sem aspas na busca, para nomes obscuros.
9. SAÍDA FINAL: termine sua resposta com um bloco JSON em uma única linha, no formato exato:

```
{
  "categoria": "<um rótulo EXATO da lista abaixo>",
  "subcategoria": null,
  "confianca": <0..1>,
  "requer_confirmacao": <true|false>,
  "justificativa": "<curta>",
  "possiveis_categorias": ["...", "...", "..."],
  "raciocinio": "<resumo>"}

```

CATEGORIAS PERMITIDAS (Você DEVE escolher apenas uma desta lista):

```
{';'.join([f'Nome:{tipo.nome} - descrição: {tipo.descricao}' for tipo in tipos])}
```

D.2 Contrato Pydantic ClassificacaoLLM

O esquema a seguir valida e tipa a saída estruturada do ramo LLM, empregado pelo nó estruturar_saida_llm (Seção 4.7):

```
class ClassificacaoLLM(BaseModel):
    categoria: str = Field(
        description="Categoria principal sugerida para a transação."
    )
    subcategoria: str | None = Field(
        default=None,
        description="Subcategoria sugerida, caso seja possível identificar."
    )
    confianca: float = Field(
        ge=0.0,
        le=1.0,
```



```

        description="Confiança da classificação, entre 0 e 1.",
    )
    justificativa: str = Field(
        description="Justificativa curta baseada exclusivamente no nome da transação."
    )
    requer_confirmacao: bool = Field(
        description="True quando a evidência for insuficiente ou houver ambiguidade."
    )
    possiveis_categorias: list[str] = Field(
        default=[],
        description="Lista de categoria sugeridas de possiveis categorias no minimo 3"
    )
    raciocinio: str = Field(
        description="Raciocinio usado para categorizar a transação"
    )

```

D.3 Análise crítica do artefato

A reprodução literal acima expõe três defeitos do artefato efetivamente avaliado, que não foram corrigidos antes da execução dos experimentos e que, portanto, integram a configuração cujos resultados o Capítulo 5 reporta:

1. **Regra ausente:** a numeração salta da regra 4 para a regra 6. As versões anteriores do *prompt*, preservadas em `specs/prompts.md`, indicam que a lacuna decorre de renumeração incompleta ao longo da evolução do artefato (a cadeia de pensamento, regra 5 na primeira versão, tornou-se a regra 7 na versão final). Para o modelo, o efeito prático é apenas uma numeração inconsistente, mas o fato revela que o *prompt* não passou por revisão sistemática antes do experimento;
2. **Erros ortográficos nos campos de saída:** as descrições dos campos `possiveis_categorias` (“Lista de categoria sugeridas de possiveis categorias no minimo 3”) e `raciocinio` (“Raciocinio usado para categorizar a transação”) contêm erros de ortografia e de concordância. Como essas descrições são expostas ao modelo pelo mecanismo de saída estruturada, podem degradar marginalmente a compreensão do contrato de saída;
3. **Tensão entre as regras 2 e 3:** a regra 2 instrui a inferir a categoria por pistas genéricas mesmo sem reconhecer o estabelecimento, ao passo que a regra 3 combate alucinações; a ressalva “inferir a categoria a partir de pistas genéricas NÃO é alucinação” é uma tentativa, dentro do próprio *prompt*, de resolver essa tensão. O comportamento observado no experimento – o ramo LLM rotulou como *Despesas Diversas* nomes com pista de categoria explícita, como “SAPPORO RESTAURANTE” e “Drogaria Paulista” (Seção 5.6.5) – é compatível com a hipótese de que o modelo compacto resolveu a tensão em favor da regra 3.

Esses defeitos importam para a leitura dos resultados: a acurácia condicional de apenas 21% do ramo LLM foi atribuída, no Capítulo 5, à capacidade do modelo local compacto. Essa atribuição pode estar correta, mas a evidência disponível não a isola de explicações concorrentes e mais simples – um *prompt* com regra faltante, instruções em tensão e campos de saída descritos com erro; e um *prompt* que não apresenta ao modelo os vizinhos rotulados que o ramo vetorial já recuperou, deixando-o decidir em *zero-shot* (Seção 4.7). A separação entre limitação do modelo e limitação do *prompt* não foi verificada experimentalmente; o experimento de baixo custo que a isolaria (reexecutar o ramo LLM sobre as mesmas transações com o *prompt* corrigido) é indicado como trabalho futuro na Seção 6.5. A correção da numeração e da ortografia foi aplicada ao código-fonte do repositório após os experimentos, independentemente da reexecução; a reprodução acima preserva a versão avaliada.

APÊNDICE E – REGRAS DE NORMALIZAÇÃO LÉXICA E LISTAS DE MARKETPLACES

Este apêndice reproduz, na íntegra e sem correções editoriais, a rotina de normalização léxica executada pelo nó `normalizar` do agente (Seção 4.7): as expressões regulares de saneamento (`notebooks/modules/utils.py`), a lista de *marketplaces* ambíguos e o dicionário de aliases de estabelecimento (ambos em `notebooks/modules/nodes.py`).

E.1 Expressões regulares de saneamento

A função `normalizar_nome` aplica, em sequência, as cinco transformações a seguir sobre a descrição em caixa baixa:

```
# 1. Remove repetições exatas em volta de um asterisco (ex: "tim*tim" -> "tim")
texto = re.sub(r"\b([a-z]+)\*\1\b", r"\1", texto)
```

```
# 2. Remove termos comuns de pagamentos e naturezas jurídicas
texto = re.sub(r"\b(pag|pix|compra|debito|credito)\b\*?", "", texto)
texto = re.sub(r"\b(ltda|me|epp|sa|s/a|eireli)\b", " ", texto)
```

```
# 3. Mantém apenas letras, números e espaços (o * que sobrou vira espaço)
texto = re.sub(r"[^a-z0-9\s]", " ", texto)
```

```
# 4. Remove números com 4 ou mais dígitos (ex.: códigos de autorização)
texto = re.sub(r"\b\d{4,}\b", " ", texto)
```

```
# 5. Remove espaços extras
texto = re.sub(r"\s+", " ", texto).strip()
```

E.2 Lista de *marketplaces* ambíguos

O dicionário `MARKETPLACES_AMBIGUOS` reúne os padrões, como aparecem na fatura em caixa alta (sufixo `*` indica correspondência por prefixo), destinados a sinalizar transações cuja categoria depende do histórico de compras do usuário (`eh_marketplace`, Seção 4.7). A função `detectar_marketplace`, que percorre esses padrões, está implementada mas não é invocada pelo grafo: o nó `normalizar` decide `eh_marketplace` testando se o nome canônico devolvido pela resolução de aliases (Seção seguinte) é uma **chave** deste dicionário (ver Seção E.4):

```
MARKETPLACES_AMBIGUOS = {
```

```

"mercado_livre": ["MERCADOLIVRE", "MERCADO LIVRE", "ML*", "MELI*",
                  "MERCADOPAGO", "MERCADO PAGO"],
"amazon":        ["AMAZON", "AMZN", "AMZN MKTPLACE", "AMZ*",
                  "AMAZON MKTPLACE"],
"shopee":        ["SHOPEE", "SHOPEE*", "SPE*"],
"magalu":        ["MAGALU", "MAGAZINE LUIZA", "MAG*", "MAGALUETC"],
"americanas":    ["AMERICANAS", "LOJAS AMERICANAS", "AMER*", "B2W"],
"aliexpress":    ["ALIEXPRESS", "ALI*", "ALIBABA"],
"shein":         ["SHEIN", "SHEIN*"],
"ifood":         ["IFOOD", "IFOOD*", "IF*"],
"rappi":         ["RAPPI", "RAPPI*", "RPP*"],
}

```

E.3 Dicionário de aliases de estabelecimento

Independentemente da lista de *marketplaces* acima, a função `detectar_estabelecimento` resolve aliases sobre a descrição já normalizada (caixa baixa), canonicalizando o nome do estabelecimento antes da busca vetorial:

```

aliases = {
    "mercado livre": ["mercado livre", "mercadolivre", "mercado pago", "mlb"],
    "amazon":        ["amazon", "amzn", "amzn mktplace"],
    "shopee":        ["shopee"],
    "magalu":        ["magalu", "magazine luiza"],
    "americanas":    ["americanas", "americanas com"],
    "aliexpress":    ["aliexpress", "ali express"],
    "shein":         ["shein"],
}

```

Observa-se que este dicionário de aliases cobre um subconjunto dos *marketplaces* da Seção E.2 (não inclui *ifood* nem *rappi*), refletindo fielmente o estado atual do código-fonte.

E.4 Análise crítica do artefato

A reprodução literal acima, confrontada com o uso que o grafo faz de cada função, expõe quatro defeitos do artefato efetivamente avaliado, identificados na revisão final do código e não corrigidos antes da execução dos experimentos:

1. **Chave de *marketplace* não casada:** o nó `normalizar` define `eh_marketplace` verificando se o nome canônico devolvido por `detectar_estabelecimento` pertence às chaves de `MARKETPLACES_AMBIGUOS`. Para Amazon, Shopee, Magalu, Americanas, AliExpress e Shein os dois identificadores coincidem; para o Mercado Livre, o alias

canônico é "mercado livre" (com espaço) e a chave é "mercado_livre" (com sublinhado). Transações do Mercado Livre e do Mercado Pago – o *marketplace* mais frequente do acervo – nunca foram, portanto, roteadas pelo ramo de histórico;

2. **Função de detecção não utilizada:** `detectar_marketplace`, que aplica os padrões com curinga (ML*, MELI*, AMZ* etc.) sobre a descrição original em caixa alta, não é invocada em nenhum nó. Os padrões com curinga do dicionário são, na prática, inertes; só os nomes presentes no dicionário de aliases (sobre a descrição já normalizada) surtem efeito;
3. **Histórico recuperado e não consumido:** o nó `buscar_historico_marketplace` grava o histórico na chave `historico_marketplace` do estado, mas a função que o consumiria (`classificar_marketplace_por_historico`) lê a chave `historico_marketplaces` (com “s”) e não está ligada ao grafo; o nó `classificar_com_llm` tampouco injeta o histórico no *prompt*. O efeito líquido é que o ramo de histórico, quando acionado, não altera a decisão;
4. **Duas rotinas de normalização:** o serviço de extração (`worker-prata/modules/parsers.py`) preenche `transacoes.nome_normalizado` com uma versão da rotina que não contém a regra 1 (repetições em torno de asterisco); o agente recomputa a normalização com a rotina completa (`notebooks/modules/utils.py`); e a base de conhecimento indexa os estabelecimentos por uma terceira chave (apenas caixa baixa e remoção de acentos). A coexistência de três chaves para o mesmo estabelecimento explica por que a consulta por nome exato à tabela `estabelecimentos` raramente resolve o identificador do estabelecimento ao salvar o resultado, e contribui para a diferença entre consulta e indexação discutida na Seção 5.6.

Esses defeitos não afetam as linhas de base nem a busca vetorial isolada, e afetam o agente apenas no ramo de histórico de *marketplace*, que – por não influenciar a decisão – não altera as métricas reportadas. Eles importam para a resposta à Q4 (Seção 5.8), que fica parcial, e são corrigíveis com poucas linhas de código, o que se recomenda antes de qualquer reexecução (Seção 6.5).

ANEXOS

ANEXO A – DECLARAÇÃO DE USO DE INTELIGÊNCIA ARTIFICIAL

Declaração de uso de INTELIGÊNCIA ARTIFICIAL, cuidados éticos e adequação à LGPD no TCC

MBA em Inteligência Artificial e Big Data – ICMC/USP

Aluno(a): Luiz Henrique Monteiro Silva de Lima

Título do TCC: Extração e classificação automática de transações em faturas de cartão de crédito com preservação de leiaute e agentes de linguagem em infraestrutura local

Declaro que, na elaboração deste Trabalho de Conclusão de Curso:

☐ Não utilizei ferramentas de Inteligência Artificial Generativa como apoio à elaboração do TCC.

☒ Utilizei ferramentas de Inteligência Artificial Generativa como apoio à elaboração do TCC,
conforme indicado abaixo.

1. **Como utilizei IA:** Marque as opções aplicáveis:

- ☒ Revisão, aprimoramento ou tradução de textos ☒ Busca, síntese ou organização de informações e literatura ☒ Geração, revisão ou depuração de código ☒ Análise, tratamento ou interpretação de dados ☒ Apoio à estruturação de ideias, metodologia ou solução ☒ Geração ou aprimoramento de imagens, gráficos ou outros conteúdos
- ☐ Outro: _____

Ferramenta utilizada: Claude (Anthropic), via Claude Code

2. Nível de utilização

Marque a opção que melhor representa o uso de IA na elaboração do TCC:

☐ **Nível 1 – Apoio pontual** Uso em atividades específicas, como revisão de texto, tradução, esclarecimento de dúvidas ou sugestões pontuais.

☐ **Nível 2 – Apoio significativo** Uso recorrente em algumas etapas, como estruturação de conteúdo, programação, análise de dados ou desenvolvimento da solução.

☒ **Nível 3 – Apoio substancial** Uso relevante na geração ou desenvolvimento de conteúdos, códigos, análises ou outros elementos que integram o TCC.

3. Declaração sobre cuidados Éticos e atendimento à LGPD

Cuidados éticos: quais foram os procedimentos éticos adotados em pesquisas envolvendo seres humanos, conforme as Normas e Diretrizes Regulamentadoras da Pesquisa Envolvendo Seres Humanos – Resolução C N S N° 466/2012, Norma Operacional 001/2013, Resolução C N S N° 510/2016 e Resolução C N S N° 674/2022 (para pesquisas nacionais). Em trabalhos nos quais pesquisas com seres humanos não foram realizadas, a seção deve ser preenchida com “Não se aplica” ou “Atende à Resolução C N S N° 510/2016”.

☒ Não se aplica ☐ Cuidados adotados: _____

Quando o estudo envolver **coleta, uso ou análise de dados pessoais**, ainda que disponíveis publicamente, as pessoas autoras devem também indicar as medidas adotadas para proteção de dados pessoais, em conformidade com a **Lei Geral de Proteção de Dados Pessoais – LGPD** (Lei N° 13.709/2018), descrevendo, quando pertinente, os cuidados adotados no tratamento desses dados, tais como procedimentos de anonimização ou pseudonimização e medidas relacionadas ao armazenamento, acesso e segurança das informações. Imagens de pessoas menores de idade ou vulneráveis devem ser suprimidas ou devidamente anonimizadas no texto.

☐ Não se aplica ☒ **Medidas adotadas:** minimização de dados sensíveis (números

completos de cartão, CVV e senhas expurgados na ingestão), ausência de CPF ou documento do titular na base (verificada empiricamente por consulta à base de produção) e processamento integralmente local, sem envio a APIs de terceiros (Seção 4.8); o acervo de faturas reais e os respectivos arquivos de verdade de referência foram deliberadamente excluídos da distribuição pública do repositório (Apêndice C).

4. Declaração de responsabilidade

Declaro que revisei, validei criticamente e assumo a responsabilidade pelos conteúdos produzidos com o auxílio de ferramentas de Inteligência Artificial.

Declaro, ainda, que compreendo plenamente, sou capaz de explicar e defender todo o conteúdo apresentado neste TCC, bem como que observei os princípios éticos e os requisitos de proteção de dados aplicáveis

Data: ____ / ____ / ____

Assinatura do(a) aluno(a): _____