

UNIVERSIDADE DE SÃO PAULO

Instituto de Ciências Matemáticas e de Computação

**SOLUÇÃO PARA EXTRAÇÃO E CLASSIFICAÇÃO
EM FATURAS DE CARTÃO DE CRÉDITO
UTILIZANDO FERRAMENTAS DE INTELIGÊNCIA
ARTIFICIAL**

Luiz Henrique Monteiro Silva de Lima

Monografia - MBA em Inteligência Artificial e Big Data

SERVIÇO DE PÓS-GRADUAÇÃO DO ICMC-USP

Data de Depósito:

Assinatura: _____

Luiz Henrique Monteiro Silva de Lima

SOLUÇÃO PARA EXTRAÇÃO E CLASSIFICAÇÃO EM FATURAS DE CARTÃO DE CRÉDITO UTILIZANDO FERRAMENTAS DE INTELIGÊNCIA ARTIFICIAL

Monografia apresentada ao Departamento de Ciências de Computação do Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo - ICMC/USP, como parte dos requisitos para obtenção do título de Especialista em Inteligência Artificial e Big Data.

Área de concentração: Inteligência Artificial

Orientador: Prof. Dr. Ricardo Rodrigues Ciferri

Versão original

São Carlos

2026

AUTORIZO A REPRODUÇÃO E DIVULGAÇÃO TOTAL OU PARCIAL DESTE TRABALHO, POR QUALQUER MEIO CONVENCIONAL OU ELETRÔNICO PARA FINS DE ESTUDO E PESQUISA, DESDE QUE CITADA A FONTE.

Ficha catalográfica elaborada pela Biblioteca Prof. Achille Bassi, ICMC/USP, com os dados fornecidos pelo(a) autor(a)

S856m	Lima, Luiz SOLUÇÃO PARA EXTRAÇÃO E CLASSIFICAÇÃO EM FATURAS DE CARTÃO DE CRÉDITO UTILIZANDO FERRAMENTAS DE INTELIGÊNCIA ARTIFICIAL / Luiz Henrique Monteiro Silva de Lima ; orientador Ricardo Rodrigues Ciferri. – São Carlos, 2026. 83 p. : il. (algumas color.) ; 30 cm. Monografia (MBA em Inteligência Artificial e Big Data) – Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, 2026. Classificação de Transações Financeiras. Processamento de Linguagem Natural. Agentes Inteligentes. Geração Aumentada por Recuperação (RAG). Reconhecimento Óptico de Caracteres. MLOps. I. Ciferri, Ricardo Rodrigues, orient. II. Título.
-------	--

Luiz Henrique Monteiro Silva de Lima

Solution for Credit Card Statement Extraction and Classification Using Artificial Intelligence Tools

Monograph presented to the Departamento de Ciências de Computação do Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo - ICMC/USP, as part of the requirements for obtaining the title of Specialist in Artificial Intelligence and Big Data.

Concentration area: Artificial Intelligence

Advisor: Prof. Dr. Ricardo Rodrigues Ciferri

Original version

São Carlos

2026

Dedico este trabalho aos meus pais e à minha família, pelo apoio incondicional, amor e paciência durante todas as etapas desta jornada acadêmica.

AGRADECIMENTOS

Agradeço primeiramente a Deus, por me conceder força, sabedoria e guiar os meus passos ao longo de toda essa jornada.

À minha família, por todo amor, dedicação e pelos valores que me transmitiram ao longo da vida, me apoiando em tudo, incondicionalmente.

Aos professores e tutores do curso, que compartilharam seus conhecimentos e experiências, contribuindo imensamente para a minha evolução e para a construção de meu futuro profissional.

Ao meu orientador, Prof. Dr. Ricardo Rodrigues Ciferri, por todo o apoio, disponibilidade e, sobretudo, pela orientação precisa e enriquecedora, fundamentais para o desenvolvimento desse trabalho com qualidade e profundidade.

À coordenadora Solange, pelos valiosos conselhos e presença atenta, bem como a todo o quadro de coordenadores, sempre prontos a esclarecer dúvidas, acolher sugestões e incentivar os alunos em cada etapa dessa trajetória.

Por fim, expresso minha profunda gratidão a todas as pessoas que, direta ou indiretamente, fizeram parte deste ciclo. Esta conquista é também de vocês, e o sucesso desta jornada não seria possível sem o apoio e o incentivo de cada um.

“A inteligência artificial é a ferramenta mais poderosa que já criamos para ampliar a capacidade humana, não para substituí-la.”
Satya Nadella (CEO da Microsoft)

RESUMO

Lima, L. **SOLUÇÃO PARA EXTRAÇÃO E CLASSIFICAÇÃO EM FATURAS DE CARTÃO DE CRÉDITO UTILIZANDO FERRAMENTAS DE INTELIGÊNCIA ARTIFICIAL**. 2026. 83 p. Monografia (MBA em Inteligência Artificial e Big Data) - Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos, 2026.

O gerenciamento financeiro pessoal enfrenta barreiras críticas decorrentes da despadronização e dos ruídos textuais presentes em descrições de faturas de cartão de crédito, tais como abreviações truncadas, prefixos de intermediadores de pagamento e erros de leitura óptica (OCR). Este trabalho apresenta uma solução computacional de ponta a ponta para a extração, higienização e classificação automática de despesas financeiras no contexto brasileiro, fundamentada em ferramentas de Inteligência Artificial, Processamento de Linguagem Natural (PLN) e engenharia de dados. A metodologia proposta combina um *pipeline* de extração híbrida com análise de *layout* estruturado (IBM Docling V2) e OCR local (Tesseract), rotinas algorítmicas de saneamento léxico e uma arquitetura de agente inteligente orquestrada em grafos de estado (LangGraph). O sistema integra busca vetorial densa em milissegundos via PostgreSQL com extensão pgvector (RAG), raciocínio semântico contextual com modelos de linguagem (LLMs), ferramentas autônomas de enriquecimento via busca na *web* e mecanismo de intervenção humana (*Human-in-the-Loop*) para casos de alta incerteza, suportado por uma infraestrutura containerizada de *Data Lakehouse* e esteira de MLOps com MLflow, MinIO e Apache Kafka em estrita conformidade com a LGPD. A validação experimental utilizou o acervo governamental do Cartão de Pagamento do Governo Federal (mais de 470 mil transações) para caracterização do ruído textual e um conjunto rotulado de 1.660 transações reais de faturas do C6 Bank e do Nubank para a mensuração preditiva, sob protocolo de teste-cego por estabelecimento. Os resultados demonstraram que o extrator estruturado (IBM Docling V2) reduziu a taxa de erro de caracteres (CER) de 52,8% do OCR clássico para **5,72%**, elevando o casamento exato de 3,3% para 86,2%. Na classificação semântica, os *baselines* clássicos (TF-IDF com Random Forest) foram os mais robustos, com F1-Score Macro de **69,3%** e acurácia de 84,7%, à frente da busca vetorial densa (56,2%), do agente híbrido LangGraph (60,0% de F1-Macro / 61,4% de acurácia, com *Human-in-the-Loop* em 4,5% dos casos) e do ajuste fino do ByT5 (48,3%). Observou-se ainda uma diferença de cerca de 23 pontos percentuais entre a validação cruzada convencional e o teste-cego por estabelecimento, evidenciando o peso da memorização de comércios já vistos. Nenhum modelo atingiu o limiar de 85% de F1-Score Macro nesse protocolo — resultado atribuído ao porte reduzido do acervo pessoal rotulado e à cauda longa de categorias — ainda que a acurácia global o supere. Conclui-se que a solução comprova a **viabilidade funcional integral** de *pipelines*

modulares, reativos e auditáveis sob restrições de *hardware* local, e delimita as condições (volume de dados rotulados e capacidade do modelo local) para sua eficácia preditiva em escala.

Palavras-chave: Classificação de Transações Financeiras. Processamento de Linguagem Natural. Agentes Inteligentes. Geração Aumentada por Recuperação. Reconhecimento Óptico de Caracteres. MLOps.

ABSTRACT

Lima, L. **Solution for Credit Card Statement Extraction and Classification Using Artificial Intelligence Tools**. 2026. 83 p. Monograph (MBA in Artificial Intelligence and Big Data) - Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos, 2026.

Personal financial management faces critical barriers due to the lack of standardization and textual noise present in credit card statement descriptions, such as truncated abbreviations, payment gateway prefixes, and optical character recognition (OCR) errors. This work presents an end-to-end computational solution for the extraction, sanitation, and automatic classification of financial expenses in the Brazilian context, based on Artificial Intelligence, Natural Language Processing (NLP), and data engineering. The proposed methodology combines a hybrid extraction pipeline with structured layout analysis (IBM Docling V2) and local OCR (Tesseract), lexical sanitation routines, and an intelligent agent architecture orchestrated in state graphs (LangGraph). The system integrates dense vector search in milliseconds via PostgreSQL with the pgvector extension (RAG), contextual semantic reasoning with Large Language Models (LLMs), autonomous web search enrichment tools, and a Human-in-the-Loop mechanism for ambiguous transactions, supported by a containerized Data Lakehouse infrastructure and an MLOps pipeline with MLflow, MinIO, and Apache Kafka in strict compliance with the LGPD. Experimental validation used the Federal Government Payment Card dataset (over 470,000 real transactions) for textual-noise characterization and a labeled set of 1,660 real C6 Bank and Nubank statement transactions for predictive measurement, under a strict merchant-disjoint blind-test protocol. The structured extractor (IBM Docling V2) reduced the character error rate (CER) from 52.8% (classical OCR) to **5.72%**, raising the exact-match rate from 3.3% to 86.2%. For semantic classification, the classical sparse baselines (TF-IDF with Random Forest) were the most robust, with a Macro F1-Score of **69.3%** and 84.7% accuracy, ahead of dense vector retrieval (56.2%), the hybrid LangGraph agent (60.0% Macro-F1 / 61.4% accuracy, with Human-in-the-Loop on 4.5% of cases) and ByT5 fine-tuning (48.3%). A gap of about 23 percentage points was observed between conventional cross-validation and the merchant-disjoint blind test, highlighting the weight of memorizing previously seen merchants. No model reached the 85% Macro F1-Score threshold under this protocol — attributed to the small size of the labeled personal dataset and its long category tail — although global accuracy exceeds it. The solution proves the full functional feasibility of modular, reactive and auditable AI pipelines under local hardware constraints, and delimits the conditions (labeled-data volume and local-model capacity) required for predictive effectiveness at scale.

Keywords:Financial Transaction Classification. Natural Language Processing. Intelligent Agents. Retrieval-Augmented Generation. Optical Character Recognition. MLOps.

LISTA DE FIGURAS

Figura 1 – Exemplo ilustrativo de despadronização e ruídos em extrato de cartão de crédito.	30
Figura 2 – Arquitetura de Data Lakehouse orientada a eventos com MLOps e agentes de IA.	49
Figura 3 – Grafo do agente	54
Figura 4 – Distribuição comparativa de CER e WER entre Docling V2 e Tesseract OCR.	61
Figura 5 – Taxa de Erro de Caracteres (CER %) por competência de fatura (C6 Bank 2022–2026).	61
Figura 6 – Taxa de Casamento Exato (%) e Distância Média de Levenshtein por fatura.	62
Figura 7 – Acurácia, F1-Macro e latência (escala logarítmica) por arquitetura no teste-cego.	63
Figura 8 – Matriz de confusão do Agente Híbrido no teste-cego (334 transações). .	66
Figura 9 – F1-Score por categoria de despesa (melhor modelo).	67

LISTA DE TABELAS

Tabela 1 – Comparativo dos trabalhos relacionados frente à solução proposta. . . .	44
Tabela 2 – Distribuição do acervo de faturas do C6 Bank com pareamento PDF e CSV.	57
Tabela 3 – Desempenho comparativo global entre Docling V2 e Tesseract OCR. .	60
Tabela 4 – Detalhamento de CER, WER, Casamento Exato e Latência por fatura do C6 Bank.	60
Tabela 5 – Comparativo global de desempenho preditivo e tempo médio de inferência (teste-cego de 334 transações, estabelecimentos disjuntos). . . .	63
Tabela 6 – Desempenho do TF-IDF + Random Forest discriminado por categoria de despesa efetivamente avaliada.	65
Tabela 7 – Ablação de componentes sobre o teste-cego (variação de F1-Macro). . .	66

LISTA DE QUADROS

Quadro 1 – Amostra comparativa de transações reais: <i>Ground Truth</i> vs. Docling vs. Tesseract.	62
---	----

LISTA DE ABREVIATURAS E SIGLAS

ABECS	Associação Brasileira das Empresas de Cartões de Crédito e Serviços
ABNT	Associação Brasileira de Normas Técnicas
API	Application Programming Interface
BERT	Bidirectional Encoder Representations from Transformers
BI	Business Intelligence
ByT5	Byte-level T5
CER	Character Error Rate (Taxa de Erro de Caracteres)
CNN	Convolutional Neural Network (Rede Neural Convolucional)
CPGF	Cartão de Pagamento do Governo Federal
CRISP-DM	Cross-Industry Standard Process for Data Mining
DLA	Document Layout Analysis (Análise de Layout de Documentos)
GPU	Graphics Processing Unit
GRU	Gated Recurrent Unit
IAM	Identity and Access Management
IEEE	Institute of Electrical and Electronics Engineers
JSON	JavaScript Object Notation
LGPD	Lei Geral de Proteção de Dados Pessoais (Lei nº 13.709/2018)
LLM	Large Language Model (Grande Modelo de Linguagem)
LSTM	Long Short-Term Memory
MCC	Merchant Category Code (Código de Categoria do Estabelecimento)
MLflow	Machine Learning Flow (Plataforma de MLOps)
MLOps	Machine Learning Operations
NFE	Nota Fiscal Eletrônica
OCR	Optical Character Recognition (Reconhecimento Óptico de Caracteres)

OFX	Open Financial Exchange
OIDC	OpenID Connect
OOV	Out-Of-Vocabulary (Fora do Vocabulário)
PDF	Portable Document Format
PGVector	PostgreSQL Vector Extension
PLN	Processamento de Linguagem Natural
RAG	Retrieval-Augmented Generation
RAM	Random Access Memory
RBAC	Role-Based Access Control
Regex	Regular Expressions (Expressões Regulares)
RNN	Recurrent Neural Network (Rede Neural Recorrente)
S3	Simple Storage Service
SBERT	Sentence-BERT
SOTA	State-of-the-Art (Estado da Arte)
SPC	Serviço de Proteção ao Crédito
SQL	Structured Query Language
TF-IDF	Term Frequency-Inverse Document Frequency
TP	Verdadeiro Positivo
USP	Universidade de São Paulo
VRAM	Video Random Access Memory
WER	Word Error Rate (Taxa de Erro de Palavras)

SUMÁRIO

1	INTRODUÇÃO	29
1.1	Considerações Iniciais	29
1.2	Contextualização e Formulação do Problema	29
1.3	Motivação e Justificativa	31
1.4	Objetivos	31
1.5	Organização da Monografia	33
2	FUNDAMENTAÇÃO TEÓRICA	35
2.1	Considerações Iniciais	35
2.2	Mineração de Textos e Processamento de Linguagem Natural	35
2.2.1	Pré-processamento Léxico e Morfológico	35
2.2.2	Estratégias de Tokenização: Da Palavra ao Nível de Byte	35
2.2.3	Vetorização Estatística versus Representações Densas (Embeddings)	36
2.2.3.1	TF-IDF (Term Frequency-Inverse Document Frequency)	36
2.2.3.2	Embeddings Densos e Bancos de Dados Vetoriais	36
2.3	Visão Computacional e Inteligência de Documentos	37
2.3.1	Análise de Layout de Documentos (DLA) e Caixas Delimitadoras	37
2.3.2	Motores de OCR e Ferramentas de Conversão Estruturada	37
2.3.3	Métricas Formais de Avaliação de OCR: CER e WER	38
2.4	Arquiteturas Neurais e Agentes Inteligentes	38
2.4.1	Mecanismos de Autoatenção e Arquiteturas Transformer	38
2.4.2	Grandes Modelos de Linguagem (LLMs) e Raciocínio Estruturado	38
2.4.3	Orquestração Baseada em Grafos de Estado: LangGraph	39
2.5	Engenharia de Dados, MLOps e Sustentabilidade de Modelos	39
2.5.1	Desvios Estatísticos: Data Drift e Concept Drift	39
2.5.2	Aprendizado Ativo (Active Learning) e Confident Learning	40
2.5.3	Arquitetura de Data Lakehouse e Rastreamento com MLflow	40
2.6	Considerações Finais do Capítulo	40
3	TRABALHOS RELACIONADOS	41
3.1	Considerações Iniciais	41
3.2	Levantamento Bibliográfico e Categorização dos Estudos	41
3.3	Análise Crítica dos Estudos Selecionados	41
3.3.1	Zhang et al. (2015) e Dhingra et al. (2016)	41
3.3.2	Competição ICDAR 2019 (SROIE)	42
3.3.3	Santos (2022)	42

3.3.4	Araújo et al. (2025)	43
3.3.5	Souza (2025)	43
3.4	Quadro Comparativo e Posicionamento desta Pesquisa	44
3.5	Conclusão do Capítulo	45
4	SOLUÇÃO PROPOSTA	47
4.1	Considerações Iniciais	47
4.2	Questões de Pesquisa e Hipótese Central	47
4.3	Metodologia da Pesquisa e Framework CRISP-DM Adaptado	48
4.4	Arquitetura Geral da Solução e Ecossistema Data Lakehouse	49
4.5	Pipeline de Ingestão e Extração Híbrida de Documentos	50
4.6	Engenharia do Agente de Classificação Inteligente	51
4.7	Conformidade com a LGPD e Segurança da Informação Financeira	52
4.8	Estratégia de Garantia de Qualidade e Testes	53
4.9	Considerações Finais do Capítulo	53
5	VALIDAÇÃO EXPERIMENTAL E RESULTADOS	55
5.1	Considerações Iniciais	55
5.2	Ambiente Computacional e Configuração Experimental	55
5.3	Caracterização dos Conjuntos de Dados (Datasets)	56
5.3.1	Conjunto Rotulado de Referência para a Classificação	57
5.4	Protocolo Experimental e Métricas de Avaliação	58
5.4.1	Métricas para Extração Óptica e Reconhecimento de Texto	58
5.4.2	Métricas para Classificação Semântica de Transações	58
5.5	Resultados da Extração e Pré-Processamento Óptico	59
5.5.1	Desempenho Quantitativo Global: Docling versus Tesseract	59
5.5.2	Análise Visual das Métricas e Dispersão de Erros	59
5.5.3	Análise Qualitativa de Erros e Preservação Estrutural de Tabelas	60
5.6	Resultados Comparativos da Classificação de Transações	63
5.6.1	Acurácia global versus F1-Macro	64
5.6.2	Desempenho Detalhado por Categoria de Despesa	65
5.6.3	Estudo de Ablação	65
5.7	Avaliação de MLOps, Latência e Observabilidade	67
5.8	Respostas às Questões de Pesquisa e Verificação da Hipótese	67
5.9	Considerações Finais do Capítulo	68
6	CONCLUSÕES E TRABALHOS FUTUROS	71
6.1	Considerações Iniciais	71
6.2	Síntese do Trabalho e Principais Contribuições	71
6.3	Avaliação dos Objetivos Atingidos	72

6.4	Limitações do Trabalho	72
6.5	Trabalhos Futuros	73
6.6	Considerações Finais	74
	APÊNDICE A – PROTOCOLO DO LEVANTAMENTO BIBLIO- GRÁFICO	75
A.1	Bases de Dados Consultadas	75
A.2	Strings de Busca Aplicadas	75
A.3	Critérios de Inclusão e Exclusão	76
	APÊNDICE B – ESQUEMA DO BANCO DE DADOS RELACIO- NAL E VETORIAL	77
B.1	Tabela de Estabelecimentos (Base de Conhecimento e Embeddings)	77
B.2	Tabela de Transações Financeiras	77
	APÊNDICE C – REPOSITÓRIO DE CÓDIGO-FONTE E REPRO- DUTIBILIDADE	79
	REFERÊNCIAS	81

1 INTRODUÇÃO

1.1 Considerações Iniciais

O gerenciamento financeiro pessoal constitui uma das competências mais críticas e desafiadoras para os cidadãos no cenário econômico contemporâneo. Com a digitalização em massa dos meios de pagamento e a consequente substituição do dinheiro em espécie por instrumentos eletrônicos, o volume de dados transacionais gerados cotidianamente atingiu patamares sem precedentes. No entanto, o aumento na facilidade de transacionar não foi acompanhado por ferramentas automáticas eficazes de organização e inteligência orçamentária, gerando um descompasso estrutural entre o consumo e a visibilidade financeira dos indivíduos. Este capítulo contextualiza a problemática da despadroneização de descrições em faturas de cartão de crédito, formaliza o problema de pesquisa, apresenta as motivações e justificativas deste trabalho, define os objetivos gerais e específicos, e detalha a organização estrutural desta monografia.

1.2 Contextualização e Formulação do Problema

A popularização do cartão de crédito como o principal meio de pagamento no Brasil trouxe consigo um desafio crescente: a dificuldade de compreender e organizar os próprios gastos de forma autônoma e tempestiva. Segundo dados consolidados pela Associação Brasileira das Empresas de Cartões de Crédito e Serviços (ABECS, 2024), as compras realizadas com cartões de crédito, débito e pré-pagos movimentaram aproximadamente 4,1 trilhões de reais em 2024, evidenciando o papel central desses instrumentos na economia nacional. Paralelamente, dados divulgados pela Serasa Experian (SERASA EXPERIAN, 2024) indicam a existência de mais de 200 milhões de cartões de crédito ativos no país, sendo que cerca de 29,37% dos consumidores brasileiros inadimplentes possuíam dívidas diretamente vinculadas ao crédito rotativo ou ao parcelamento de faturas.

O crescimento no volume transacional é impulsionado tanto pelas compras em estabelecimentos físicos quanto pelo comércio eletrônico (*e-commerce*). Relatórios de hábitos de consumo demonstram que os gastos digitais apresentaram expansão superior a 15% ao final de 2024 (PODER360, 2025). Não obstante a conveniência proporcionada por essa digitalização, a falta de padronização nas informações repassadas aos usuários nas faturas mensais impede o planejamento consciente. Conforme apontado pelo Serviço de Proteção ao Crédito (SPC BRASIL, 2024), a grande maioria dos consumidores não possui um controle sistemático de seu orçamento mensal, recorrendo frequentemente a anotações manuais em planilhas ou cadernos — práticas propensas a erros e com altas taxas de abandono ao longo do tempo.

Figura 1 – Exemplo ilustrativo de despadronização e ruídos em extrato de cartão de crédito.

MARIA OLIVEIRA COSTA				R\$ 2.450,15
05 FEB	1234	Livraria Cultura - São Paulo		R\$ 145,50
08 FEB	5678	Academia SmartFit - Parcela 3/12		R\$ 99,90
11 FEB	9012	Netshoes - Parcela 2/3		R\$ 110,33
14 FEB	3456	Café Do Ponto - Ipanema		R\$ 22,80
16 FEB	7890	Papelaria Grafite - Curitiba		R\$ 48,20
18 FEB	1122	Padaria Pão de Queijo - Belo Horizonte		R\$ 15,90
21 FEB	4455	Supermercado Pão de Açúcar - Recife		R\$ 299,75
24 FEB	6677	Farmácia Drogasil - Salvador		R\$ 81,10
26 FEB	8899	Restaurante Mocotó - São Paulo		R\$ 195,40
28 FEB	1010	Cinema Kinoplex - Shopping Morumbi		R\$ 68,00
02 MAR	2020	Gasolina Posto Shell		R\$ 210,00
05 MAR	3030	Petshop Cão Fiel		R\$ 74,50
08 MAR	4040	Loja Zara - Parcela 1/2		R\$ 125,00
11 MAR	5050	Uber - Viagem Local		R\$ 18,90
14 MAR	6060	Mercado Livre		R\$ 89,90
19 MAR	8080	Padaria Dona Deôla		R\$ 12,50
21 MAR	9090	Barbearia Corleone		R\$ 55,00
23 MAR	1133	Restaurante Bráz Pizzaria		R\$ 138,00
25 MAR	2244	Assinatura Netflix		R\$ 44,90

Fonte: Elaborado pelo autor (2026).

O problema central investigado nesta pesquisa reside na categorização automática, precisa e escalável de transações financeiras de cartão de crédito a partir de descrições textuais curtas, heterogêneas, ruidosas e altamente despadronizadas. Conforme ilustrado na Figura 1, as linhas de extrato apresentam obstáculos multidimensionais:

- 1. Abreviações e Siglas Crípticas:** Nomes de fornecedores frequentemente aparecem severamente truncados, concatenados ou representados por razões sociais obsoletas (ex.: “AMZN MKTPLACE”, “PAG*RestSaoPaulo”, “DL*GOOGLE”);
- 2. Prefixos de Processadores e Gateways de Pagamento:** Transações intermediadas por terminais eletrônicos (maquininhas) e facilitadores digitais inserem códigos e prefixos alfanuméricos espúrios (ex.: “PG*”, “MP*”, “ZOO*”, “SUMUP*”) que ocultam a identidade real do estabelecimento;
- 3. Ruídos Decorrentes de Leitura Óptica (OCR):** Em documentos digitalizados, escaneados ou fotografados por câmeras móveis, motores de Reconhecimento Óptico de Caracteres introduzem erros de substituição, deleção e inserção de caracteres (ex.: letras trocadas por números semelhantes), gerando palavras fora do vocabulário padrão (*Out-Of-Vocabulary* – OOV);

4. **Ambiguidade de Marketplaces e Multicategorias:** Grandes plataformas de comércio eletrônico (como Mercado Livre, Amazon e Shopee) transacionam mercadorias de naturezas diametralmente opostas (eletrônicos, vestuário, alimentação, medicamentos) sob uma mesma fatura corporativa genérica, tornando a inferência categórica impossível apenas pelo texto bruto do canal;
5. **Privacidade e Soberania dos Dados Financeiros:** O tratamento de dados transacionais bancários envolve informações de alta sensibilidade pessoal, exigindo estrita conformidade com a Lei Geral de Proteção de Dados Pessoais (LGPD – Lei nº 13.709/2018) (BRASIL, 2018), o que restringe o envio indiscriminado de extratos a serviços terceirizados e APIs proprietárias em nuvem pública.

1.3 Motivação e Justificativa

A motivação deste trabalho apoia-se em duas perspectivas complementares: o avanço técnico-científico na área de Ciência da Computação e o impacto socioeconômico direto na gestão orçamentária dos cidadãos.

No âmbito da **Ciência da Computação**, o problema integra de maneira transdisciplinar a Visão Computacional/OCR, o Processamento de Linguagem Natural (PLN), os Sistemas de Recuperação de Informação Vetorial (RAG), a Engenharia de Agentes Inteligentes baseados em Grafos de Estado e as práticas de Operações de Aprendizado de Máquina (MLOps). Desenvolver e avaliar criticamente uma arquitetura que opere sob restrições severas de hardware local (sem demandar clusters de GPU de alto custo) contribui para a literatura de Inteligência Artificial aplicada, evidenciando as possibilidades e os limites de pipelines modulares, reativos e energeticamente eficientes.

Sob o ponto de vista **aplicado e socioeconômico**, automatizar o processo de saneamento e classificação de despesas elimina o esforço cognitivo e a sobrecarga de tempo associados à gestão financeira pessoal. Ao fornecer categorias precisas, justificativas semânticas inteligíveis e mecanismos de aprendizado contínuo com intervenção humana (*Human-in-the-Loop*), o sistema capacita os usuários a compreender seus reais padrões de consumo, auxiliando na prevenção do endividamento precoce e promovendo a sustentabilidade orçamentária das famílias.

1.4 Objetivos

O **objetivo geral** desta monografia é conceber, implementar e avaliar experimentalmente uma solução computacional de ponta a ponta baseada em ferramentas de Inteligência Artificial para a extração, normalização e classificação automática de transações financeiras em faturas de cartão de crédito, caracterizando a acurácia preditiva

alcançável e a resiliência a ruídos textuais e ópticos sob restrições de privacidade dos dados e de sustentabilidade operacional em *hardware* local.

Para concretizar o objetivo geral, definiram-se os seguintes **objetivos específicos**:

1. **Ingestão e Extração Híbrida de Documentos:** Desenvolver um módulo capaz de ingerir faturas em formatos digitais nativos (CSV, OFX, JSON) e documentos ópticos (PDFs digitalizados e imagens), combinando conversores avançados com análise de layout (*Docling*) e motores de OCR locais (*Tesseract*) com filtragem de confiança;
2. **Pipeline de Normalização e Saneamento Léxico:** Projetar rotinas algorítmicas de pré-processamento para eliminação de prefixos de gateways de pagamento, supressão de ruídos alfanuméricos e resolução de sinônimos/alias comerciais;
3. **Estabelecimento de Linhas de Base Científicas (*Baselines*):** Implementar e mensurar o desempenho de algoritmos de aprendizado de máquina clássico (Naive Bayes e Random Forest) acoplados à vetorização estatística TF-IDF, estabelecendo referências quantitativas de comparação;
4. **Modelagem com Transformers e Recuperação Vetorial (RAG):** Construir uma base de conhecimento densa em banco de dados relacional e vetorial (*PostgreSQL* com extensão *pgvector*), permitindo buscas semânticas em milissegundos via embeddings multilíngues e investigando modelos no nível de byte/caractere (*ByT5*);
5. **Arquitetura de Agente Inteligente com Grafos de Estado:** Orquestrar a tomada de decisão preditiva através de um grafo de estados (*LangGraph*), integrando prompts dinâmicos conscientes da origem do dado, ferramentas autônomas de busca na web (*DuckDuckGo*), estruturas Pydantic com cadeias de pensamento (*Chain-of-Thought*) e pausas programadas para confirmação humana (*Human-in-the-Loop*) em casos ambíguos;
6. **Estruturação de Data Lakehouse e Esteira MLOps:** Desenvolver a infraestrutura containerizada da solução apoiada em armazenamento em camadas (MinIO Bronze/Silver), mensageria por eventos (Apache Kafka), rastreamento experimental e versionamento de modelos (MLflow);
7. **Validação Experimental e Diagnóstico Comparativo:** Avaliar quantitativamente a acurácia, precisão, recall, F1-Score Macro, matriz de confusão e latência sobre faturas reais — com um acervo governamental de mais de 470 mil transações para caracterização do ruído textual e um conjunto rotulado de faturas pessoais para a mensuração preditiva, sob protocolo de teste-cego por estabelecimento — confrontando formalmente as hipóteses de pesquisa com as evidências obtidas.

1.5 Organização da Monografia

O presente documento está estruturado em seis capítulos e dois apêndices, organizados de forma sequencial e lógica conforme descrito a seguir:

- **Capítulo 1 – Introdução:** Apresenta as considerações iniciais, a contextualização da pesquisa, a formalização do problema de faturas despadronizadas, as motivações técnica e socioeconômica, os objetivos geral e específicos, e a visão geral da estrutura do trabalho;
- **Capítulo 2 – Fundamentação Teórica:** Discute os conceitos teóricos essenciais que sustentam a solução, abrangendo Processamento de Linguagem Natural, tokenização em subpalavras/bytes, modelos densos de embeddings, bancos de dados vetoriais, visão computacional e OCR, arquiteturas neurais Transformer, agentes inteligentes em grafos e práticas contemporâneas de MLOps e Data Lakehouse;
- **Capítulo 3 – Trabalhos Relacionados:** Analisa o estado da arte por meio de uma revisão estruturada da literatura, confrontando estudos sobre saneamento pós-OCR, mineração de textos informais e extração em notas fiscais, sintetizados em um quadro comparativo que explicita as lacunas abordadas por esta pesquisa;
- **Capítulo 4 – Solução Proposta:** Detalha a engenharia do sistema, formalizando as questões de pesquisa e a hipótese central, o framework metodológico CRISP-DM adaptado, a arquitetura de Data Lakehouse containerizada, o fluxo de extração híbrida, o grafo de estados do agente inteligente (LangGraph), as salvaguardas de privacidade e LGPD, e a estratégia de garantia de qualidade;
- **Capítulo 5 – Validação Experimental e Resultados:** Expõe o ambiente computacional, a caracterização dos datasets utilizados (CPGF, faturas reais de bancos digitais e dados com ruídos sintéticos), o protocolo de avaliação, as métricas obtidas nos baselines clássicos versus agente híbrido, as análises de ablação e a verificação formal das hipóteses;
- **Capítulo 6 – Conclusões e Trabalhos Futuros:** Sintetiza as principais contribuições técnicas alcançadas, avalia o cumprimento dos objetivos, discute as limitações identificadas e aponta direções para continuidade e evolução da pesquisa em cenários como Open Finance e aprendizado federado;
- **Apêndices:** O Apêndice A apresenta o protocolo detalhado do levantamento bibliográfico (strings booleanas, bases de dados e critérios de triagem), e o Apêndice B expõe o esquema do banco de dados relacional e vetorial implementado.

2 FUNDAMENTAÇÃO TEÓRICA

2.1 Considerações Iniciais

A concepção de uma ferramenta robusta para a interpretação e categorização de faturas financeiras requer o domínio integrado de fundamentos oriundos de múltiplas subáreas da Inteligência Artificial e da Engenharia de Software. Este capítulo estabelece as bases conceituais estritamente instrumentais ao projeto, organizando-se em quatro pilares fundamentais: (i) Mineração de Textos e Processamento de Linguagem Natural; (ii) Visão Computacional, Análise de Layout e Reconhecimento Óptico de Caracteres (OCR); (iii) Arquiteturas Neurais Profundas e Agentes Inteligentes baseados em Grafos; e (iv) Engenharia de Dados, MLOps e Sustentabilidade de Modelos em Produção.

2.2 Mineração de Textos e Processamento de Linguagem Natural

O Processamento de Linguagem Natural (PLN) constitui o ramo da Inteligência Artificial dedicado a capacitar sistemas computacionais a compreender, interpretar, manipular e gerar linguagens humanas (Caseli; Nunes, 2024; Chowdhury, 2003). No domínio financeiro, o desafio central da mineração textual reside na natureza não estruturada e altamente degenerada das descrições de compras em cartões de crédito (Santos, 2022).

2.2.1 Pré-processamento Léxico e Morfológico

A primeira barreira técnica na modelagem de textos curtos é a dispersão léxica. A padronização morfológica atua reduzindo a alta dimensionalidade do vocabulário através de operações determinísticas (Caseli; Nunes, 2024): conversão para caixa baixa (*lowercasing*), normalização de caracteres acentuados via codificação Unicode e aplicação de Expressões Regulares (Regex) para supressão de pontuações, caracteres de controle e símbolos especiais.

Adicionalmente, a literatura enfatiza a remoção de *stopwords* — palavras de alta frequência sem valor semântico discriminativo (artigos, preposições, conjunções) (Matos; Ciferri; Pardo, 2009). Contudo, listas genéricas universais mostram-se insuficientes no domínio financeiro. É mandatório injetar heurísticas específicas do negócio para remover sufixos de naturezas jurídicas e corporativas (como “LTDA”, “S/A”, “ME”, “EPP”, “EIRELI”) e prefixos de liquidação financeira (“COMPRA”, “PARCELA”, “DEBITO”), os quais atuam como ruídos que distorcem as distribuições estatísticas (Santos, 2022).

2.2.2 Estratégias de Tokenização: Da Palavra ao Nível de Byte

A tokenização segmenta a cadeia textual contínua em unidades atômicas de processamento denominadas *tokens* (Caseli; Nunes, 2024). Modelos tradicionais baseados em

palavras inteiras (*word-level*) dependem de vocabulários fechados predefinidos. Diante de faturas financeiras, onde erros de digitação, truncamentos e aglutinações são onipresentes, essa abordagem falha sistematicamente devido à explosão de termos fora do vocabulário (*Out-Of-Vocabulary* – OOV).

Para superar essa fragilidade, o estado da arte avançou para a tokenização em subpalavras (*subwords*, como Byte-Pair Encoding e WordPiece) e, no limite da granularidade, para a tokenização no nível de caractere ou byte (Zhang; Zhao; LeCun, 2015; Xue *et al.*, 2022). Modelos que operam diretamente sobre sequências de bytes UTF-8, a exemplo do ByT5 (Xue *et al.*, 2022), eliminam completamente o vocabulário fixo. Essa característica confere ao sistema imunidade contra erros ortográficos e capacidade inata de generalizar sobre siglas desconhecidas e nomes comerciais aglutinados (ex.: “MERCADO-PAG*LOJA123”).

2.2.3 Vetorização Estatística versus Representações Densas (Embeddings)

Para que algoritmos computacionais processem dados textuais, é imperativo convertê-los em representações numéricas vetoriais.

2.2.3.1 TF-IDF (Term Frequency-Inverse Document Frequency)

A técnica clássica de TF-IDF quantifica a importância de um termo t em um documento d pertencente a um corpus D , calculada pelo produto da frequência do termo (TF) pelo inverso da frequência no documento (IDF) (Rajaraman; Ullman, 2011):

$$\text{TF-IDF}(t, d, D) = \text{TF}(t, d) \times \log \left(\frac{|D|}{1 + |\{d \in D : t \in d\}|} \right) \quad (2.1)$$

Embora gere matrizes esparsas de alta dimensionalidade que desconsideram o contexto e a ordem sintagmática das palavras, o TF-IDF permanece relevante como uma linha de base científica (*baseline*) de referência rápida, interpretável e de baixo custo computacional (Santos, 2022).

2.2.3.2 Embeddings Densos e Bancos de Dados Vetoriais

A superação das limitações esparsas consolidou-se com a semântica distribucional profunda. Modelos como o Sentence-BERT (SBERT) (Reimers; Gurevych, 2019), implementados através de arquiteturas siamesas de Sentence Transformers (ex.: **paraphrase-multilingual-MiniLM-L12-v2**), mapeiam sentenças inteiras em vetores densos e contínuos de dimensionalidade fixa (ex.: 384 dimensões).

Nesse espaço vetorial contínuo, a proximidade semântica entre duas transações u e v é mensurada diretamente pela similaridade de cosseno:

$$\text{Simil}(u, v) = \frac{u \cdot v}{\|u\|_2 \|v\|_2} = \frac{\sum_{i=1}^n u_i v_i}{\sqrt{\sum_{i=1}^n u_i^2} \sqrt{\sum_{i=1}^n v_i^2}} \quad (2.2)$$

Para viabilizar consultas em milissegundos sobre milhões de registros históricos, utilizam-se extensões vetoriais integradas ao banco de dados relacional, destacando-se a extensão *pgvector* para PostgreSQL. Essa infraestrutura permite implementar mecanismos de Geração Aumentada por Recuperação (*Retrieval-Augmented Generation* – RAG), onde exemplos canônicos rotulados são recuperados dinamicamente para subsidiar a tomada de decisão do classificador.

2.3 Visão Computacional e Inteligência de Documentos

A Inteligência de Documentos (*Document AI*) integra Visão Computacional e PLN para extrair informações estruturadas de imagens e documentos não nativos (Auer; Dolfi; Staar, 2024).

2.3.1 Análise de Layout de Documentos (DLA) e Caixas Delimitadoras

A Análise de Layout de Documentos (DLA) é a etapa encarregada de segmentar a imagem da página, identificando blocos lógicos como tabelas, colunas, parágrafos e cabeçalhos. Cada entidade visual é mapeada por coordenadas espaciais denominadas caixas delimitadoras (*bounding boxes*): $[x_{\min}, y_{\min}, x_{\max}, y_{\max}]$.

Em faturas de cartão de crédito, a preservação da topologia e da ordem de leitura é mandatória: a relação espacial de alinhamento horizontal entre o nome do estabelecimento comercial e o seu respectivo valor monetário em reais (R\$) carrega a semântica relacional necessária para isolar a transação e evitar a fusão indevida de dados entre colunas paralelas (Auer; Dolfi; Staar, 2024).

2.3.2 Motores de OCR e Ferramentas de Conversão Estruturada

- **Tesseract OCR:** Mecanismo de reconhecimento óptico de código aberto amplamente utilizado (Smith, 2007). Baseia-se em redes neurais LSTM para converter matrizes de pixels em caracteres. O Tesseract opera localmente garantindo total privacidade, mas exige imagens rigorosamente limpas para evitar quedas acentuadas de precisão diante de ruídos visuais;
- **IBM Docling:** Ferramenta moderna de processamento documental (*Document Parsing*) especializada na extração estruturada de PDFs complexos (Auer; Dolfi; Staar, 2024). Ao combinar modelos de visão para segmentação de tabelas com exportação nativa em Markdown estruturado, o Docling preserva as linhas de transações tabulares sem depender de heurísticas frágeis de coordenadas manuais.

2.3.3 Métricas Formais de Avaliação de OCR: CER e WER

A qualidade da extração óptica é avaliada formalmente pela distância de edição de Levenshtein entre o texto predito pelo OCR e o texto de referência (*ground truth*). Definem-se três tipos fundamentais de erro: Substituição (S), Deleção (D) e Inserção (I).

A **Taxa de Erro de Caracteres** (CER – *Character Error Rate*) é calculada sobre o total de caracteres de referência N_c :

$$\text{CER} = \frac{S_c + D_c + I_c}{N_c} \quad (2.3)$$

A **Taxa de Erro de Palavras** (WER – *Word Error Rate*) opera de forma idêntica, porém adotando palavras inteiras como unidade amostral sobre o total de palavras N_w :

$$\text{WER} = \frac{S_w + D_w + I_w}{N_w} \quad (2.4)$$

Um único caractere lido incorretamente invalida a palavra inteira no cálculo do WER, tornando esta métrica estritamente mais rigorosa que o CER (Araújo; Bezerra; Neto, 2025).

2.4 Arquiteturas Neurais e Agentes Inteligentes

2.4.1 Mecanismos de Autoatenção e Arquiteturas Transformer

A introdução do mecanismo de autoatenção (*self-attention*) na arquitetura Transformer por Vaswani et al. (Vaswani *et al.*, 2017) superou as limitações de paralelização das redes recorrentes tradicionais (LSTM e GRU) (Hochreiter; Schmidhuber, 1997; Cho *et al.*, 2014). A atenção escalada por produto escalar calcula o alinhamento contextual entre matrizes de Consulta (Q), Chave (K) e Valor (V):

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V \quad (2.5)$$

Essa formulação permite que cada token pondere dinamicamente todos os demais elementos da sequência de entrada, capturando dependências semânticas não locais em textos curtos e informais.

2.4.2 Grandes Modelos de Linguagem (LLMs) e Raciocínio Estruturado

Os Grandes Modelos de Linguagem (*Large Language Models* – LLMs) pré-treinados em escala massiva demonstraram notável capacidade de inferência semântica e raciocínio contextual. Para mitigar o risco de alucinações e garantir o determinismo necessário a sistemas financeiros, duas técnicas são essenciais:

- **Cadeia de Pensamento (*Chain-of-Thought* – CoT):** Induz o modelo a explicitar seus passos intermediários de raciocínio antes de emitir o veredito final, elevando comprovadamente a precisão lógica;

- **Chamada de Ferramentas (*Tool Calling*):** Capacidade do modelo de suspender temporariamente a geração de texto para invocar funções externas (como motores de busca na web) a fim de obter evidências factuais em tempo real;
- **Saída Estruturada com Validação de Tipos:** Utilização de bibliotecas de validação de esquemas (como Pydantic) para forçar o modelo a responder exclusivamente em formatos JSON estritos e tipados.

2.4.3 Orquestração Baseada em Grafos de Estado: LangGraph

Enquanto cadeias lineares simples (*chains*) são rígidas, aplicações complexas demandam arquiteturas cíclicas e com controle fino de fluxo. O *LangGraph* (Chase; LangChain Team, 2024) estrutura a aplicação como um Grafo Direcionado de Estados (*StateGraph*), onde cada nó executa uma função atômica (normalização, consulta vetorial, inferência LLM, persistência) e as arestas condicionais determinam o próximo passo baseando-se no estado tipado (*AgentState*). O framework suporta nativamente persistência de memória (*checkpoints*) e o padrão *Human-in-the-Loop*, permitindo interromper o grafo de forma transparente para aguardar a confirmação humana e retomá-lo posteriormente.

2.5 Engenharia de Dados, MLOps e Sustentabilidade de Modelos

A sustentabilidade de uma solução de IA em ambientes de produção exige a incorporação de práticas de Engenharia de Dados e Operações de Aprendizado de Máquina (*Machine Learning Operations* – MLOps) (Kreuzberger; Kühn; Hirschl, 2022; Treveil *et al.*, 2020).

2.5.1 Desvios Estatísticos: Data Drift e Concept Drift

Modelos de machine learning operando sobre dados financeiros sofrem inevitável degradação temporal decorrente de dois fenômenos (Quiñonero-Candela *et al.*, 2008; Lu *et al.*, 2019):

- **Data Drift (Desvio de Covariáveis):** Ocorre quando a distribuição das variáveis de entrada $P(X)$ se altera ao longo do tempo (ex.: novos nomes de estabelecimentos no mercado, atualização de gateways ou mudanças de formatação no OCR), embora a relação mapeada $P(Y|X)$ permaneça estável;
- **Concept Drift (Desvio de Conceito):** Manifesta-se quando a probabilidade condicional real $P(Y|X)$ muda (ex.: uma grande rede de postos de combustível que passa a atuar predominantemente como loja de conveniência/alimentação, alterando a categoria esperada para uma mesma descrição textual).

2.5.2 Aprendizado Ativo (Active Learning) e Confident Learning

Para contornar o custo proibitivo da rotulação manual exaustiva diante do surgimento contínuo de novas empresas, a literatura preconiza o Aprendizado Ativo (*Active Learning*) (Ren *et al.*, 2021). Ao invés de amostrar dados aleatoriamente, o sistema calcula a incerteza estatística de suas inferências. Transações com escore de confiança inferior a um limiar seguro (ex.: confiança ≤ 0.70) são isoladas e encaminhadas para curadoria humana (*Human-in-the-Loop*) (Northcutt; Jiang; Chuang, 2021). Os dados confirmados expandem a base de conhecimento de forma cirúrgica e de alto valor agregado.

2.5.3 Arquitetura de Data Lakehouse e Rastreamento com MLflow

A infraestrutura de suporte a dados moderna adota o paradigma de Data Lakehouse, combinando a flexibilidade e o baixo custo de armazenamento de objetos compatíveis com S3 (como o MinIO) com as garantias transacionais e a organização em camadas (*Medallion Architecture*) (Treveil *et al.*, 2020):

- **Camada Bronze:** Armazena os dados brutos e imutáveis exatamente como foram ingeridos (PDFs originais, extratos bancários em CSV, textos ruidosos extraídos);
- **Camada Silver:** Contém os dados limpos, saneados, normalizados e enriquecidos, organizados em esquemas analíticos;
- **Camada Gold:** Tabelas agregadas e visões analíticas prontas para consumo por motores de consulta e ferramentas de inteligência de negócios.

O ciclo de vida experimental e operacional é unificado pelo *MLflow* (Treveil *et al.*, 2020). A plataforma atua como repositório centralizado de parâmetros, métricas e artefatos, suportando execuções aninhadas (*nested runs*) que viabilizam o rastreamento em dois níveis de granularidade: a corrida global correspondente à fatura completa e corridas filhas isoladas para cada transação individualmente classificada.

2.6 Considerações Finais do Capítulo

Os conceitos apresentados neste capítulo constituem a fundamentação técnica indispensável para a construção da solução proposta. A integração entre normalização morfológica, embeddings densos no PostgreSQL com pgvector, análise de layout com Docling, orquestração em grafos com LangGraph e práticas contínuas de MLOps no Data Lakehouse estabelece um arcabouço metodológico sólido para solucionar o desafio de classificar faturas de cartão de crédito com alto desempenho e sobriedade computacional.

3 TRABALHOS RELACIONADOS

3.1 Considerações Iniciais

A identificação das lacunas de pesquisa e o delineamento das escolhas arquiteturais deste trabalho exigem uma análise rigorosa do estado da arte. Este capítulo sintetiza a literatura recente referente à extração, saneamento de erros ópticos e classificação de documentos comerciais e textos informais. O protocolo metodológico completo do levantamento bibliográfico (strings de busca booleanas, bases científicas consultadas e critérios de triagem) encontra-se formalizado no Apêndice A. Nas seções seguintes, apresentam-se a discussão crítica dos estudos selecionados, o quadro comparativo e o posicionamento distintivo da presente monografia.

3.2 Levantamento Bibliográfico e Categorização dos Estudos

O levantamento bibliográfico foi conduzido nas principais bases indexadoras internacionais e nacionais (Scopus, IEEE Xplore, Web of Science e Google Scholar), cobrindo publicações entre 2016 e 2025. Os trabalhos recuperados dividem-se em duas categorias conceituais:

- **Trabalhos Fortemente Relacionados:** Pesquisas dedicadas especificamente ao processamento de notas fiscais, faturas comerciais e saneamento de textos financeiros curtos oriundos de OCR;
- **Trabalhos Fracamente Relacionados:** Estudos focados em problemas afins, como mineração de textos informais em redes sociais, arquiteturas teóricas de autoatenção e classificação de layout baseada exclusivamente em visão computacional.

3.3 Análise Crítica dos Estudos Selecionados

A seguir, examinam-se individualmente os trabalhos que compõem o núcleo do estado da arte, padronizados conforme seus objetivos, abordagem metodológica, validação experimental e principais conclusões.

3.3.1 Zhang et al. (2015) e Dhingra et al. (2016)

Objetivo: Investigar métodos de representação vetorial e classificação profunda em textos curtos, informais e ruidosos, operando diretamente no nível de caractere para dispensar vocabulários fechados.

Abordagem: Zhang, Zhao e LeCun (Zhang; Zhao; LeCun, 2015) propuseram redes convolucionais profundas (*character-level ConvNets*) que classificam texto lendo a sequência bruta de caracteres, comparando-as a *bag-of-words*, *n*-gramas, TF-IDF e modelos baseados em palavras. Dhingra et al. (Dhingra *et al.*, 2016), com o modelo *tweet2vec*, adotaram uma Rede Neural Recorrente bidirecional (Bi-GRU) no nível de caractere para gerar *embeddings* de mensagens curtas. Ambas as linhas constroem representações semânticas densas a partir de sequências de letras adjacentes.

Validação e Resultados: A validação foi conduzida em grandes coleções de textos curtos (*datasets* de classificação de Zhang et al. e *tweets* anotados por *hashtags* em Dhingra et al.). Os resultados demonstraram a competitividade da modelagem por caractere frente a métodos tradicionais, com ganho expressivo diante de palavras fora do vocabulário (*Out-Of-Vocabulary*).

Relação com esta Pesquisa: Fundamenta teoricamente a necessidade de decompor termos financeiros em subpalavras e caracteres para reconhecer descrições truncadas (ex.: “IFD*RESTAUR”) que não constam em dicionários formais.

3.3.2 Competição ICDAR 2019 (SROIE)

Objetivo: Promover o avanço de técnicas automatizadas para localização de texto, reconhecimento óptico (OCR) e extração de informação-chave em recibos comerciais digitalizados (*scanned receipts*), por meio de um conjunto de dados público com mil imagens anotadas (Huang *et al.*, 2019).

Abordagem: A competição estruturou-se em três tarefas (localização de texto, OCR e extração de campos-chave). As equipes de melhor desempenho combinaram detecção de texto baseada em redes convolucionais com módulos de reconhecimento sequencial e, na etapa de extração, codificadores contextuais do tipo *Transformer* (Devlin *et al.*, 2019).

Validação e Resultados: A avaliação sobre recibos reais com distorções físicas evidenciou que abordagens neurais de ponta a ponta superam consistentemente heurísticas determinísticas de substituição, embora ao custo de maior demanda computacional.

Relação com esta Pesquisa: Consolida o cupom/recibo como um problema de leitura estruturada em que a preservação do *layout* tabular e a correção contextual são decisivas, motivando a extração híbrida e o saneamento adotados nesta monografia; a demanda de *hardware* das arquiteturas vencedoras justifica a investigação de modelos compactos e locais.

3.3.3 Santos (2022)

Objetivo: Avaliar a viabilidade de algoritmos de aprendizado de máquina para classificar produtos em Notas Fiscais Eletrônicas (NFE) a partir de descrições textuais

desestruturadas e curtas (Santos, 2022).

Abordagem: O autor comparou um classificador clássico baseado em vetorização TF-IDF associada a algoritmos tradicionais contra uma Rede Neural Recorrente (LSTM) no nível de caracteres, treinadas para categorizar itens mercadológicos.

Validação e Resultados: A validação em dados reais de notas fiscais confirmou que a abordagem no nível de caracteres obteve ganhos expressivos de acurácia sobre o baseline clássico. Todavia, o estudo reportou dificuldades computacionais no treinamento sequencial de RNNs em máquinas convencionais e severa degradação preditiva nas classes minoritárias devido ao desbalanceamento extremo da base.

Relação com esta Pesquisa: Reforça a importância do processamento granular e demonstra a necessidade de adotar métricas robustas (como o F1-Score Macro) e arquiteturas baseadas em Transformers paralelizáveis e RAG para contornar o gargalo das classes desbalanceadas.

3.3.4 Araújo et al. (2025)

Objetivo: Avaliar a eficácia de modelos de linguagem monolíngues no nível de *byte* para a correção ortográfica Pós-OCR de textos ruidosos produzidos por sistemas de reconhecimento de escrita (Araújo; Bezerra; Neto, 2025).

Abordagem: Os autores treinaram três modelos *Monobyte* — baseados no ByT5 do Google (Xue *et al.*, 2022) — de forma independente para inglês, francês e português do Brasil, aplicando-os como etapa de pós-processamento sobre saídas de reconhecimento textual.

Validação e Resultados: A avaliação sobre três conjuntos de manuscritos contemporâneos (IAM, RIMES e BRESSAY) mostrou reduções consistentes das taxas de erro: no IAM, 2,24% de CER e 26,37% de WER; no RIMES, 13,48% e 33,34%; e no BRESSAY, 12,78% e 40,62%. Os resultados evidenciam a eficácia da tokenização no nível de *byte* em texto ruidoso e o potencial de modelos monolíngues computacionalmente eficientes.

Relação com esta Pesquisa: Sustenta a escolha de representações no nível de *byte*/caractere para tratar descrições truncadas e aglutinadas de faturas, além de reforçar a viabilidade de modelos compactos e locais em vez de LLMs massivos na etapa de saneamento.

3.3.5 Souza (2025)

Objetivo: Desenvolver um sistema automatizado para extração e estruturação de informações em imagens de faturas de energia elétrica e notas de serviços (Souza, 2025).

Abordagem: O autor utilizou Redes Neurais Convolucionais profundas (família

EfficientNet) para classificação visual de layout, seguidas pela invocação da API comercial em nuvem Amazon Textract para extração das tabelas de consumo.

Validação e Resultados: A solução demonstrou alta precisão em modelos de faturas conhecidos. No entanto, o sistema revelou-se incapaz de generalizar diante de novos layouts não catalogados, exigindo a reconstrução de adaptadores manuais a cada mudança estética promovida pelas concessionárias, além de depender de custos recorrentes de APIs externas.

Relação com esta Pesquisa: Evidencia os riscos e limitações da dependência rígida de layouts visuais e APIs proprietárias em nuvem, justificando a opção do presente trabalho por uma arquitetura independente de layout visual estático, processada localmente e focada na semântica textual das transações.

3.4 Quadro Comparativo e Posicionamento desta Pesquisa

A Tabela 1 confronta as características fundamentais dos estudos correlatos com a proposta desenvolvida nesta monografia.

Tabela 1 – Comparativo dos trabalhos relacionados frente à solução proposta.

Trabalho (Ref)	Objetivo	Abordagem	Limitações Identificadas	Lacuna Abordada nesta Pesquisa
Araújo et al. (2025)	Correção Pós-OCR de textos ruidosos.	Modelos monolíngues no nível de <i>byte</i> (<i>Mo- nobyte</i> /ByT5).	Foco estrito em correção ortográfica; não executa categorização semântica nem RAG.	Integração de busca vetorial (PGVector), inferência semântica e orquestração em grafo.
Santos (2022)	Classificação de produtos em NFE.	TF-IDF vs. LSTM no nível de caracteres.	Treinamento lento de RNNs; alta degradação em classes minoritárias desbalanceadas.	Uso de embeddings densos multilíngues, aprendizado ativo e validação via F1-Score Macro.

Continua na próxima página...

Tabela 1 – continuação da página anterior

Trabalho (Ref)	Objetivo	Abordagem	Limitações Identificadas	Lacuna Abordada nesta Pesquisa
Souza (2025)	Extração em faturas de concessionárias.	CNNs (EfficientNet) + OCR Amazon Textract.	Dependência de layout rígido e custos com APIs pagas em nuvem.	Independência de layout geométrico; extração local híbrida (Docling/Tesseract) sem custo de API.
Zhang et al. (2015); Dhingra et al. (2016)	Classificação e mineração de textos curtos e informais.	ConvNets e Bi-GRU no nível de caractere.	Não trata o ciclo de vida MLOps, Data Drift nem desambiguação de marketplaces.	Resolução de aliases, histórico de marketplaces por usuário e monitoramento via MLflow.
Competição ICDAR 2019 (SROIE)	OCR e extração de campos em recibos digitalizados.	Detecção convolucional + reconhecimento sequencial + codificadores Transformer.	Custo de inferência elevado; sem mecanismos de Human-in-the-Loop.	Agente LangGraph com interrupções programadas e ferramentas autônomas de busca web.
Esta Pesquisa (Proposta)	Extração, saneamento e classificação de faturas de cartão de crédito.	Agente Reativo Híbrido: Docling/OCR + PGVector + LLM Dinâmico + LangGraph + MLOps.	Demanda bootstrap inicial de exemplos vetoriais e conectividade opcional para web search.	Solução de ponta a ponta local, aderente à LGPD, com esteira de Data Lakehouse e observabilidade total.

Fonte: Elaborado pelo autor (2026).

3.5 Conclusão do Capítulo

A revisão da literatura demonstra que, embora existam contribuições expressivas em tarefas isoladas (correção pós-OCR com Transformers ou extração visual de notas fiscais), persiste uma lacuna quanto a soluções completas, locais e integradas para o tratamento de

faturas de cartão de crédito. Ao combinar a extração tabular estruturada, normalização léxica, banco vetorial PGVector, agente inteligente em grafo (LangGraph) com suporte a Human-in-the-Loop e governança MLOps no Data Lakehouse, este trabalho posiciona-se de forma inovadora para oferecer alta assertividade e sustentabilidade operacional no controle financeiro pessoal.

4 SOLUÇÃO PROPOSTA

4.1 Considerações Iniciais

Este capítulo detalha a concepção arquitetural, os modelos matemáticos e a implementação prática da solução desenvolvida para a extração e classificação de faturas de cartão de crédito. Afastando-se de abstrações puramente teóricas, a seção formaliza as questões de pesquisa e as hipóteses norteadoras, descreve a metodologia baseada no CRISP-DM adaptado, especifica os microsserviços do ecossistema Data Lakehouse, pormenoriza a engenharia do agente inteligente em grafo (LangGraph), estabelece as salvaguardas de conformidade com a LGPD e delineia a estratégia de garantia de qualidade e testes de software.

4.2 Questões de Pesquisa e Hipótese Central

A formulação e a avaliação experimental deste trabalho são guiadas por cinco Questões de Pesquisa (Q1 a Q5) fundamentadas na literatura:

- **Q1:** Quais técnicas de representação textual (esparsas vs. densas) e algoritmos de aprendizado (estatísticos clássicos vs. modelos neurais baseados em subpalavras e agentes LLM) apresentam maior eficácia para categorizar transações a partir de descrições ruidosas e despadronizadas?
- **Q2:** Qual é o nível de acurácia global e F1-Score Macro alcançável por um classificador automático de gastos operando sobre faturas reais e ruidosas, considerando uma taxonomia de 10 a 20 categorias de despesas?
- **Q3:** Quais são as principais naturezas de erro cometidas pelos classificadores automatizados (ambiguidades de marketplace, erros de leitura de OCR, nomes informais de lojistas) e de que forma mecanismos como *Chain-of-Thought* e busca na web podem mitigá-los?
- **Q4:** Em que medida a injeção de metadados contextuais (origem do arquivo digital versus óptico, histórico de compras do usuário e descarte de prefixos de gateways) contribui para o incremento do desempenho preditivo?
- **Q5:** Qual é a viabilidade prática e a sustentabilidade computacional de manter e atualizar o sistema continuamente ao longo do tempo diante de fenômenos de *Data Drift* e *Concept Drift*, utilizando MLOps e Aprendizado Ativo com intervenção humana (*Human-in-the-Loop*)?

A **hipótese central** submetida a teste nesta pesquisa estabelece que:

“Um pipeline híbrido que integra normalização léxica de gateways, busca por similaridade semântica em banco vetorial (PGVector), raciocínio dinâmico via agente LLM com acesso a ferramentas de busca e intervenção humana programada (Human-in-the-Loop) é capaz de classificar transações de cartão de crédito com acurácia global e F1-Score Macro superiores a 85% em uma taxonomia de 14 categorias, garantindo conformidade rigorosa com a LGPD e viabilidade de execução em infraestrutura local.”

4.3 Metodologia da Pesquisa e Framework CRISP-DM Adaptado

A pesquisa classifica-se, quanto à sua natureza, como **aplicada**, voltada à resolução do problema prático de gestão financeira pessoal (Gerhardt; Silveira, 2009). Quanto à abordagem e procedimentos, define-se como uma pesquisa **experimental e quantitativa** (Gil, 2019), estruturada no controle de variáveis em ambiente simulado e na mensuração estatística rigorosa de métricas preditivas.


O ciclo metodológico adotou o framework padrão da indústria *Cross-Industry Standard Process for Data Mining* (CRISP-DM), estendido com diretrizes contemporâneas de MLOps (Kreuzberger; Kühl; Hirschl, 2022) conforme as seis etapas sequenciais:

1. **Compreensão do Negócio:** Mapeamento das regras de faturas de cartão de crédito no Brasil, identificação de intermediadores de pagamento e taxonomia de categorias orçamentárias;
2. **Compreensão dos Dados:** Coleta e exploração de datasets públicos oficiais (CPGF), faturas reais anonimizadas e geração de datasets sintéticos com ruídos de maquininhas de cartão;
3. **Preparação dos Dados:** Engenharia de extração híbrida (Docling e Tesseract OCR), normalização léxica com Regex, descarte de jargões corporativos e cálculo de embeddings vetoriais;
4. **Modelagem:** Desenvolvimento comparativo englobando baselines clássicos (TF-IDF + Random Forest / Naive Bayes), ajuste fino do ByT5 e construção do agente inteligente em grafo de estados (LangGraph com PGVector e LLM);
5. **Avaliação:** Mensuração de métricas estatísticas (Acurácia, Precisão, Recall, F1-Score Macro e Matriz de Confusão), estudos de ablação e auditoria de latência;
6. **Implantação e Ciclo de Vida:** Containerização em microsserviços via Docker, orquestração de Data Lakehouse com MinIO e Kafka, rastreamento de experimentos com MLflow e governança de acessos via Logto.

4.4 Arquitetura Geral da Solução e Ecosistema Data Lakehouse

A arquitetura geral do sistema foi concebida sob o paradigma orientado a eventos e microsserviços desacoplados, implementada com tecnologias de código aberto (*Open Source*) orquestradas via *Docker Compose*. A Figura 2 ilustra a topologia da infraestrutura efetivamente implementada e exercitada neste trabalho.

Figura 2 – Arquitetura de Data Lakehouse orientada a eventos com MLOps e agentes de IA.



Fonte: Elaborado pelo autor (2026).

O ecossistema divide-se nos seguintes serviços especializados:

- **MinIO (Object Storage S3):** Provedor de armazenamento em nuvem local compatível com a API AWS S3. Organiza o Data Lakehouse em três buckets particionados por fonte e data: (i) **bronze-raw** para preservação imutável dos arquivos brutos (PDFs, CSVs); (ii) **bronze-txt** para dados textuais extraídos; e (iii) **mlflow-artifacts** para armazenamento de pesos e rastreios de modelos;
- **Apache Kafka:** Barramento de mensageria distribuído que garante o desacoplamento temporal e a resiliência volumétrica entre a camada de ingestão e os workers assíncronos através dos tópicos **test-topic**, **events-topic** e **datalake-bronze-ingestao-topic**;
- **PostgreSQL 16 com extensão PGVector:** Banco de dados relacional e vetorial encarregado de armazenar a base de conhecimento de estabelecimentos, usuários, faturas, alocações de transações e vetores de características densas de 384 dimensões gerados pelo modelo **paraphrase-multilingual-MiniLM-L12-v2**;

- **Servidor MLflow:** Servidor centralizado de MLOps apoiado por backend relacional PostgreSQL (`mlops_db`) e bucket S3. Realiza o autologging de experimentos LangChain/LangGraph, registrando parâmetros de prompt, latência de inferência, tokens consumidos, tags de rastreamento e arquivos de cadeia de pensamento em formato texto (`results/raciocinio.txt`);
- **Logto IAM:** Servidor de autenticação e controle de acesso baseado em OpenID Connect (OIDC) e OAuth 2.0, garantindo o isolamento multi-inquilino (*multi-tenant*) e a segurança de acesso aos dados financeiros.

A camada de consumo analítico dedicada (motor SQL distribuído e *dashboards* gerenciais de *Business Intelligence*) e a orquestração de pipelines em lote não integram o escopo implementado e avaliado nesta monografia, sendo apontadas como evolução natural da solução no Capítulo 6. A visualização orçamentária ao usuário é atendida diretamente pela aplicação *web* sobre o PostgreSQL.

4.5 Pipeline de Ingestão e Extração Híbrida de Documentos

A camada de extração foi arquitetada para processar indistintamente documentos digitais nativos e arquivos ópticos escaneados, operando através de um fluxo em três etapas:

1. **Identificação de Metadados no Data Lakehouse:** A função determinística `extrair_metadados_datalake` inspeciona o caminho do arquivo (ex.: `bronze/source=nubank/.../original.csv`) e extrai o banco de origem, partições temporais e a flag `is_digital_nativo`. Caso a extensão seja `.csv`, `.ofx` ou `.json`, o sistema desativa hipóteses de erro de OCR; caso seja imagem ou PDF escaneado, ativa heurísticas de correção óptica;
2. **Conversão com Docling V2 (Layout Tabular):** Em faturas em formato PDF (como Nubank e C6 Bank), utiliza-se o *DocumentConverter* da biblioteca IBM Docling com backend PyPdfium acelerado por GPU CUDA. O conversor mapeia itens de tabela com caixas delimitadoras e exporta o conteúdo estruturado em Markdown delimitado por pipes (`|`), preservando a correspondência exata entre data, final do cartão de crédito, descrição do estabelecimento e valor em reais (R\$);
3. **Extração com Tesseract OCR e Filtro de Confiança:** Para recibos em imagem estrita ou páginas onde o conversor não identifica tabelas, aciona-se o Tesseract OCR configurado em modo OEM 3 (redes LSTM) e PSM 6 (bloco uniforme de texto). Aplica-se a função `image_to_data` com um **filtro de confiança** > 40%, descartando fragmentos visuais irrecuperáveis antes do envio à camada semântica.

4.6 Engenharia do Agente de Classificação Inteligente

O núcleo de tomada de decisão do sistema foi codificado como um grafo de estados direcionado (3)

(*StateGraph*) no framework *LangGraph*, suportado pelo estado tipado *AgentState*. O fluxo operacional do agente é estruturado nas seguintes etapas coordenadas:

1. **Nó normalizar:** Executa a limpeza léxica da descrição da transação com Regex, eliminando duplicações em torno de asteriscos (ex.: “TIM*TIM” → “TIM”), descartando termos de pagamento (“PAG*”, “PIX”, “COMPRA”) e sufixos societários (“LTDA”, “ME”). Realiza a resolução de aliases de marcas e verifica se a compra pertence à lista de marketplaces ambíguos (*eh_marketplace*);
2. **Roteamento Pós-Normalização (*rota_apos_normalizar*):** Se a transação for detectada como marketplace (Mercado Livre, Amazon, Shopee), encaminha o fluxo para o nó *buscar_historico_marketplace*; caso contrário, direciona para o nó de busca vetorial *buscar_por_similaridade*;
3. **Nó *buscar_historico_marketplace*:** Consulta o histórico consolidado do usuário no banco PostgreSQL (*sugestoes_categoria_marketplace*), recuperando as preferências de compras confirmadas anteriormente no mesmo marketplace;
4. **Nó *buscar_por_similaridade*:** Executa a busca por similaridade de cosseno na extensão PGVector utilizando os embeddings gerados pelo modelo *paraphrase-multilingual-MiniLM-L12-v2*. Se a melhor correspondência apresentar escore de similaridade ≥ 0.85 , a transação é considerada classificada com alta certeza, sendo roteada diretamente para o nó *salvar_resultado*;
5. **Nó *classificar_com_llm*:** Caso a busca vetorial resulte em confiança inferior a 0.85, aciona-se o modelo de linguagem (LLM). O nó injeta um System Prompt dinâmico contendo: (i) metadados da origem do arquivo; (ii) regras de decodificação de maquininhas de pagamento; (iii) diretrizes anti-alucinação; (iv) cadeia de pensamento obrigatória gerando o campo *raciocinio* antes da categoria; e (v) acesso à ferramenta *duckduckgo_search* para pesquisar nomes comerciais obscuros;
6. **Roteador Unificado e Nó *tools*:** Se o LLM emitir uma chamada de ferramenta (*tool call*), o fluxo executa a pesquisa autônoma na web pelo *ToolNode* e retorna as evidências para o classificador;
7. **Nó *estruturar_saida_llm*:** Utiliza o método *with_structured_output* com validação Pydantic (*ClassificacaoLLM*) para garantir que a resposta do LLM respeite

o contrato de tipos com categoria, subcategoria, escore de confiança de 0 a 1, justificativa, lista de categorias alternativas e cadeia de raciocínio;

8. **Nó aguardar_confirmacao (Human-in-the-Loop):** Se o escore de confiança for ≤ 0.80 ou se houver ambiguidade severa de marketplace, o grafo executa o comando `interrupt`, pausando o processamento da thread e aguardando a validação ou correção do usuário. A execução é retomada assincronamente via `Command(resume=resposta)`;
9. **Nó salvar_vectorstore:** Transações classificadas com alta confiança (≥ 0.85) ou validadas por humanos têm sua descrição normalizada e metadados persistidos no PGVector, retroalimentando a base de conhecimento de forma contínua;
10. **Nó salvar_resultado:** Persiste a transação definitiva no PostgreSQL com integridade referencial completa, registrando o método de classificação utilizado (`vetorial`, `llm`, `humano`), escores de confiança, logs de auditoria e status de revisão.

4.7 Conformidade com a LGPD e Segurança da Informação Financeira

O processamento de dados transacionais bancários envolve informações estritamente sensíveis que revelam hábitos de vida, localização geográfica, saúde e patrimônio dos cidadãos. A arquitetura proposta foi desenhada em estrita observância à Lei Geral de Proteção de Dados Pessoais (LGPD – Lei nº 13.709/2018) (BRASIL, 2018), estruturando-se sobre quatro princípios fundamentais:

1. **Princípio da Minimização de Dados (Art. 6º, III):** O pipeline descarta sistematicamente quaisquer dados que não sejam estritamente necessários para a finalidade de categorização orçamentária. Números completos de cartões de crédito, códigos de segurança (CVV), endereços residenciais e senhas são expurgados no estágio de ingestão, preservando-se apenas a descrição textual, data e valor da compra;
2. **Anonimização e Pseudonimização (Art. 13):** Os identificadores pessoais dos titulares (como CPF e nome completo) são pseudonimizados através de identificadores únicos universais (UIDs) e funções hash criptográficas unidirecionais antes do armazenamento na camada de dados;
3. **Soberania de Processamento On-Premise (Privacidade por Design):** Ao adotar o motor Tesseract, modelos locais de embeddings e containers executados na infraestrutura do próprio usuário, a solução impede o vazamento de extratos bancários para servidores de terceiros ou provedores comerciais proprietários de IA;

4. **Autenticação e Rastreabilidade de Acesso (Art. 46):** O acesso às interfaces gerenciais e endpoints de API é protegido pelo servidor Logto via protocolo OpenID Connect (OIDC), com controle de acesso baseado em papéis (RBAC). Ademais, a tabela `log_classificacoes` mantém registro temporal auditável de todas as inferências, métodos e revisões humanas realizadas.

4.8 Estratégia de Garantia de Qualidade e Testes

Para um sistema distribuído e poliglota de natureza exploratória, a garantia de qualidade apoiou-se em três frentes complementares:


- **Testes Unitários:** Verificação isolada das funções determinísticas de pré-processamento — saneamento léxico com *Regex*, *parsers* de datas e valores monetários, resolução de *aliases* comerciais e contratos Pydantic — por meio de *pytest* (com suporte a execução assíncrona) no núcleo Python. O serviço de ingestão reativa em Java conta com verificação de carga do contexto da aplicação *Spring Boot* via *JUnit 5*;
- **Testes de Regressão de Modelo:** O pipeline experimental reproduzível (`notebooks/experimentos/`, etapas 01 a 08) fixa a semente aleatória e um conjunto de teste-cego particionado por estabelecimento (sem vazamento de *merchant*), permitindo detectar regressões nas métricas preditivas a cada alteração de código, *prompt* ou hiperparâmetro, com os resultados versionados no MLflow;
- **Validação de Integração Assistida:** A comunicação de ponta a ponta entre a API de ingestão, o barramento Kafka, o *Object Storage* MinIO e o *worker* de extração foi exercitada de forma assistida em ambiente *Docker Compose*, confirmando a publicação e o consumo de eventos e a persistência dos artefatos nas camadas do Data Lakehouse.

A automação plena da esteira de testes (integração com *Testcontainers* e testes de carga do barramento) é registrada como trabalho futuro no Capítulo 6.

4.9 Considerações Finais do Capítulo

A arquitetura da solução proposta materializa uma abordagem pragmática, moderna e escalável para o desafio da classificação de faturas financeiras. Ao articular a extração híbrida, busca vetorial densa em banco PostgreSQL, agente em grafo LangGraph com Human-in-the-Loop, salvaguardas rigorosas de privacidade e governança MLOps no Data Lakehouse, o sistema estabelece as bases técnicas necessárias para a validação empírica detalhada no capítulo seguinte.

Figura 3 – Grafo do agente



5 VALIDAÇÃO EXPERIMENTAL E RESULTADOS

5.1 Considerações Iniciais

A validação empírica constitui a etapa decisiva para comprovar a eficácia prática da solução proposta e responder formalmente às questões de pesquisa estabelecidas. Este capítulo apresenta o ambiente computacional dos experimentos, a caracterização detalhada dos conjuntos de dados utilizados (com ênfase no acervo de faturas do C6 Bank e seus respectivos arquivos de *Ground Truth*), o protocolo formal de mensuração adotado (incluindo as definições matemáticas da Distância de Edição de Levenshtein, CER e WER), os resultados comparativos detalhados de extração óptica entre o IBM Docling e o Tesseract OCR, o desempenho dos classificadores (baselines clássicos versus agente inteligente híbrido), a análise de ablações, a avaliação de MLOps e observabilidade, e a verificação conclusiva da hipótese central da monografia.

5.2 Ambiente Computacional e Configuração Experimental

Todos os experimentos foram conduzidos em um ambiente computacional controlado, representativo de estações de trabalho de desenvolvimento comuns, com as seguintes especificações de hardware e software:

- **Hardware:** Processador Intel Core i7 / AMD Ryzen de 8 núcleos e 16 threads, 32 GB de memória RAM DDR4, GPU dedicada NVIDIA GeForce RTX com 16 GB de VRAM (suporte a aceleração CUDA 12.x) e armazenamento SSD NVMe de alta velocidade;
- **Software e Bibliotecas:** Sistema Operacional Windows 11 / Linux Ubuntu 22.04 LTS, Docker Engine v26.1, Python v3.11.15, PyTorch v2.3.1, Transformers v4.41, LangChain v0.2, LangGraph v0.1, Sentence-Transformers v3.0, Scikit-Learn v1.5, PostgreSQL v16.3 com extensão pgvector v0.7, MLflow v2.14, IBM Docling v2.0, PyTesseract v0.3.13 (motor Tesseract 5.3 com modelos em português), PyPDFium2 v4.30, RapidFuzz v3.14 e JiWER v4.0.

O código-fonte completo da solução e o *pipeline* experimental reproduzível que gera os resultados apresentados neste capítulo estão disponíveis no repositório público descrito no Apêndice C.

5.3 Caracterização dos Conjuntos de Dados (Datasets)

A experimentação foi estruturada sobre conjuntos de dados complementares, abrangendo dados governamentais e faturas reais de instituições financeiras. O acervo governamental (mais de 470 mil transações) foi empregado para a **caracterização exploratória** do ruído textual; a **mensuração preditiva** da classificação apoiou-se em um subconjunto rotulado das faturas pessoais reais (detalhado ao final desta seção):

1. **Dataset Governamental CPGF (Cartão de Pagamento do Governo Federal):** Acervo público oficial obtido no Portal da Transparência do Governo Federal (BRASIL. Controladoria-Geral da União, 2024). O conjunto reúne 44 arquivos CSV mensais consolidados, totalizando **477.740 transações financeiras reais** contendo campos como nome do favorecido comercial, CNPJ, órgão responsável, data e valor monetário transacionado;
2. **Acervo Real de Faturas Bancárias C6 Bank e Nubank:** Extratos de cartões de crédito pessoais obtidos junto a instituições financeiras brasileiras em formatos digitais nativos (CSV) e documentos ópticos protegidos (PDFs com layout tabular multicolumnar). No caso do C6 Bank, reuniu-se um acervo abrangendo o período contínuo de janeiro de 2022 a agosto de 2026, composto por **49 faturas em PDF** (totalizando 357 páginas protegidas por senha) e os respectivos **49 arquivos CSV oficiais**, os quais foram utilizados como *Ground Truth* de alta fidelidade para a mensuração de erros de OCR;
3. **Ruído Real de Intermediadores de Pagamento:** As próprias faturas do C6 Bank e do Nubank já contêm, de forma nativa, os fenômenos de ruído que se deseja estressar — truncamentos de descrição, prefixos de adquirentes (“PAG*”, “MP*”, “IFD*”), sufixos numéricos de autorização e nomes informais aglutinados de pequenos negócios (ex.: “jhoonymorango”). Optou-se por avaliar os modelos diretamente sobre esse ruído real, em vez de gerá-lo sinteticamente.

Para a avaliação de extração óptica, estabeleceu-se um procedimento determinístico de pareamento temporal entre os documentos em PDF e os arquivos CSV do C6 Bank. Por meio da leitura dos metadados das primeiras páginas dos PDFs, identificou-se a data de corte (fechamento por volta do dia 8 de cada mês) e o vencimento (fixado no dia 15), mapeando-se com exatidão 1 : 1 cada uma das 49 faturas ao seu respectivo arquivo `Fatura_AAAA-MM-15.csv`. A Tabela 2 resume a distribuição do acervo de faturas do C6 Bank por ano de competência.

As transações foram rotuladas em uma taxonomia de **14 categorias canônicas de despesas**: Alimentação, Transporte, Moradia, Saúde, Educação, Vestuário, Lazer

Tabela 2 – Distribuição do acervo de faturas do C6 Bank com pareamento PDF e CSV.

Ano de Competência	Faturas (PDF)	CSVs (<i>Ground Truth</i>)	Páginas
2022	12	12	74
2023	12	12	80
2024	11	11	73
2025	12	12	112
2026	2	2	18
Total	49	49	357

Fonte: Elaborado pelo autor (2026).

e Entretenimento, Tecnologia, Beleza e Cuidados Pessoais, Pets, Serviços Financeiros, Marketplace / E-commerce, Doações / Presentes e Despesas Diversas.

5.3.1 Conjunto Rotulado de Referência para a Classificação

Como as faturas do Nubank não trazem rótulo de categoria e a categorização nativa do emissor C6 Bank é derivada de códigos MCC — frequentemente imprecisa (por exemplo, serviços de nuvem rotulados como “Elétrico” e plataformas de ingressos como “Serviços Profissionais”) — adotou-se um procedimento de rotulagem de referência em duas camadas: (i) um **dicionário léxico de alta precisão** com dezenas de padrões de estabelecimentos consolidados (“UBER”→Transporte, “IFD*”→Alimentação, “DROGA-”→Saúde, “NETFLIX/STEAM”→Lazer etc.), validado manualmente sobre amostra; e (ii) o **mapeamento da categoria nativa do emissor** para a taxonomia canônica nos casos não cobertos pelo dicionário.

Após deduplicação e limitação a no máximo 12 lançamentos por estabelecimento — para que o *benchmark* meça a amplitude de comércios e não a frequência de um único *merchant* dominante (ex.: “UBER* TRIP”) — o conjunto totalizou **1.660 transações rotuladas**, das quais 74% pelo dicionário léxico. As categorias *Pets*, *Serviços Financeiros* e *Doações e Presentes* não apresentaram amostragem suficiente no acervo pessoal disponível e foram agregadas a *Despesas Diversas / Outros*, restando **11 categorias efetivamente avaliadas**.

O particionamento foi feito **por estabelecimento** (todas as ocorrências de uma mesma descrição pertencem a um único conjunto), impedindo o vazamento de comércios entre treino e teste: 1.150 transações para treino e povoamento vetorial, 176 para validação e **334 para o teste-cego congelado**. Esse protocolo é deliberadamente mais severo que o holdout aleatório: mede a capacidade de generalizar para *estabelecimentos inéditos*, não a de reconhecer comércios já vistos. Ressalta-se que a rotulagem semiautomática e o porte reduzido do acervo constituem limitações discutidas no Capítulo 6.

5.4 Protocolo Experimental e Métricas de Avaliação

Para garantir rigor estatístico e reprodutibilidade, a avaliação foi dividida em duas frentes complementares: avaliação da extração de texto (OCR) e avaliação da classificação semântica.

5.4.1 Métricas para Extração Óptica e Reconhecimento de Texto

Para avaliar a qualidade da transcrição em relação ao *Ground Truth* fornecido pelos CSVs bancários oficiais, adotaram-se as métricas fundamentadas na Distância de Edição de Levenshtein $L(s_1, s_2)$, definida como o número mínimo de operações de inserção, remoção ou substituição de caracteres necessárias para transformar a cadeia s_1 na cadeia s_2 :

1. **Character Error Rate (CER):** Proporção de caracteres incorretos em relação ao comprimento da cadeia de referência:

$$\text{CER} = \frac{\sum_{i=1}^N L(\text{ref}_i, \text{hyp}_i)}{\sum_{i=1}^N \text{len}(\text{ref}_i)} \quad (5.1)$$

onde ref_i representa o texto oficial no CSV (verdade-terrestre) e hyp_i representa a transcrição obtida pelo motor de OCR;

2. **Word Error Rate (WER):** Taxa de erro calculada no nível de palavras tokenizadas, mensurando inserções, deleções e substituições de palavras completas:

$$\text{WER} = \frac{\sum_{i=1}^N L_{\text{palavras}}(\text{ref}_i, \text{hyp}_i)}{\sum_{i=1}^N \text{len}_{\text{palavras}}(\text{ref}_i)} \quad (5.2)$$

3. **Taxa de Casamento Exato (*Exact Match Rate*):** Fração percentual de transações transcritas com exatidão perfeita ($L(\text{ref}_i, \text{hyp}_i) = 0$):

$$\text{EMR} = \frac{1}{N} \sum_{i=1}^N \mathbb{I}[L(\text{ref}_i, \text{hyp}_i) = 0] \quad (5.3)$$

5.4.2 Métricas para Classificação Semântica de Transações

Para a classificação de categorias, adotou-se o particionamento **por estabelecimento** (Seção 5.3.1): 69% para treinamento e povoamento da base de conhecimento vetorial, 11% para validação e sintonia de hiperparâmetros, e 20% (334 transações) mantidos estritamente congelados para teste-cego, com todas as ocorrências de um mesmo comércio confinadas a um único conjunto. Complementarmente, computou-se validação cruzada 5-fold (*5-fold cross-validation*) sobre treino+validação, cuja comparação com o teste-cego quantifica o efeito de memorização de comércios.

O desempenho preditivo foi mensurado através da Matriz de Confusão e das métricas clássicas de classificação multiclasse ponderadas: Acurácia Global, Precisão Macro, Recall Macro e F1-Score Macro:

$$\text{Acurácia} = \frac{\sum_{k=1}^K TP_k}{\text{Total de Amostras}}, \quad \text{F1-Score Macro} = \frac{1}{K} \sum_{k=1}^K \frac{2 \cdot \text{Precisão}_k \cdot \text{Recall}_k}{\text{Precisão}_k + \text{Recall}_k} \quad (5.4)$$

onde K representa o total de categorias efetivamente avaliadas ($K = 11$ no acervo disponível). A adoção primordial do F1-Score Macro justifica-se pela sua capacidade de avaliar a assertividade de forma equitativa em classes minoritárias desbalanceadas (como Educação e Moradia), impedindo que o modelo mascare erros através de acertos concentrados nas classes majoritárias (como Alimentação).

5.5 Resultados da Extração e Pré-Processamento Óptico

A primeira bateria experimental comparou rigorosamente dois paradigmas de ingestão documental aplicados sobre o acervo de faturas do C6 Bank:

1. **Tesseract OCR (versão 5.3):** Paradigma convencional baseado em visão computacional e OCR óptico rasterizado, processando as páginas convertidas em imagens de alta resolução (300 DPI) com modelos de idioma para português (**por**);
2. **IBM Docling V2:** Paradigma moderno de compreensão de leiaute de documentos (*Document Layout Analysis*), integrando o backend digital PyPdfium2 com modelos neurais de detecção e segmentação de tabelas (*Table Transformer*), gerando como saída texto estruturado em tabelas Markdown.

A avaliação englobou **1.398 transações individuais auditadas** extraídas de faturas representativas cobrindo todos os anos do conjunto de dados (2022 a 2026). Para cada transação da verdade-terrestre contida no arquivo CSV oficial da instituição financeira, avaliou-se tanto a cadeia completa da transação (*Descrição do Estabelecimento + Valor Monetário*) quanto o campo isolado da descrição comercial.

5.5.1 Desempenho Quantitativo Global: Docling versus Tesseract

Os resultados médios consolidados de todas as faturas avaliadas são apresentados na Tabela 3.

A Tabela 4 detalha o comportamento dos dois motores por competência mensal ao longo dos cinco anos do acervo histórico analisado.

5.5.2 Análise Visual das Métricas e Dispersão de Erros

A distribuição das taxas de erro de caracteres (CER) e de palavras (WER) é ilustrada no gráfico *boxplot* da Figura 4. Observa-se que a distribuição do Docling se

Tabela 3 – Desempenho comparativo global entre Docling V2 e Tesseract OCR.

Métrica de Avaliação	Docling V2	Tesseract OCR	Vantagem / Impacto
CER (Transação Completa)	5,72% (± 6,75%)	52,82% (± 9,84%)	Docling erra 9,2x menos caracteres
WER (Transação Completa)	10,14% (± 12,47%)	85,36% (± 12,43%)	Docling erra 8,4x menos palavras
CER (Apenas Descrição)	6,42% (± 8,20%)	54,60% (± 12,54%)	Docling erra 8,5x menos na descrição
WER (Apenas Descrição)	10,26% (± 13,67%)	93,34% (± 14,67%)	Docling é 9,1x mais preciso
Distância de Levenshtein Média	1,30 caracteres	10,72 caracteres	Tesseract erra +9,4 caracteres por linha
Taxa de Casamento Exato (<i>Exact Match</i>)	86,2%	3,3%	Docling acerta +82,9 pontos percentuais
Tempo Médio de Processamento / Fatura	5,56 segundos	8,76 segundos	Docling é 1,6x mais rápido

Fonte: Elaborado pelo autor (2026).

Tabela 4 – Detalhamento de CER, WER, Casamento Exato e Latência por fatura do C6 Bank.

Competência	Págs.	Qtd. GT	CER Completo (%)		WER Completo (%)		Casamento Exato (%)		Tempo de Extração (s)	
			Docling	Tesseract	Docling	Tesseract	Docling	Tesseract	Docling	Tesseract
2022-01	6	25	15,1%	60,9%	21,3%	89,0%	76,0%	0,0%	3,35 s	6,80 s
2022-02	6	34	4,0%	67,4%	7,6%	106,3%	79,4%	0,0%	8,01 s	6,91 s
2022-04	7	51	13,1%	63,5%	24,3%	90,1%	41,2%	0,0%	5,95 s	7,93 s
2023-01	7	57	1,8%	50,9%	4,8%	79,8%	96,5%	1,8%	5,45 s	8,24 s
2023-02	7	45	24,6%	39,1%	46,1%	63,3%	57,8%	33,3%	4,69 s	8,06 s
2023-03	6	33	1,6%	60,0%	5,3%	91,7%	97,0%	3,0%	4,18 s	7,05 s
2024-01	7	51	2,0%	50,7%	4,7%	85,6%	96,1%	2,0%	5,23 s	8,36 s
2024-02	7	41	4,8%	57,4%	10,0%	96,3%	90,2%	2,4%	4,79 s	8,09 s
2024-05	6	28	2,8%	46,6%	3,3%	83,6%	92,9%	3,6%	2,94 s	7,32 s
2025-01	10	91	2,0%	50,6%	2,7%	87,1%	96,7%	0,0%	8,35 s	11,70 s
2025-04	9	74	2,2%	60,3%	4,6%	95,3%	95,9%	0,0%	7,21 s	10,48 s
2025-08	9	70	1,5%	53,7%	2,0%	93,2%	97,1%	0,0%	6,68 s	10,42 s
2026-02	9	43	2,3%	41,0%	2,7%	68,2%	95,3%	0,0%	5,51 s	10,54 s
2026-08	9	56	2,0%	38,1%	2,4%	65,5%	94,6%	0,0%	5,57 s	10,74 s
Média	7,5	49,9	5,7%	52,8%	10,1%	85,4%	86,2%	3,3%	5,56 s	8,76 s

Fonte: Elaborado pelo autor (2026).

concentra quase na totalidade próxima de zero (mediana de CER inferior a 2,5%), enquanto o Tesseract exhibe dispersão ampla e média superior a 50% de erro por transação.


A evolução temporal do CER ao longo das diferentes faturas bancárias é exibida na Figura 5. Com exceção de competências específicas com variações na diagramação do cabeçalho da fatura em 2022 e 2023, o Docling manteve estabilidade expressiva com CER abaixo de 2,5% em todas as faturas modernas (2024 a 2026). Em contraste, o Tesseract sustentou taxas elevadas de erro em todo o período histórico decorrentes da fragmentação linear das tabelas.

Na Figura 6, analisa-se a Taxa de Casamento Exato (*Exact Match Rate*) e a Distância Média de Levenshtein por fatura. O Docling alcançou entre 90% e 97% de casamentos exatos na grande maioria dos extratos, com distância de Levenshtein média de apenas 1,30 caracteres contra mais de 10 caracteres no Tesseract.

5.5.3 Análise Qualitativa de Erros e Preservação Estrutural de Tabelas


A discrepância acentuada entre o Docling e o Tesseract decorre fundamentalmente da diferença arquitetural na forma de interpretar a informação presente nos documentos:

Figura 4 – Distribuição comparativa de CER e WER entre Docling V2 e Tesseract OCR.



Fonte: Elaborado pelo autor (2026).


Figura 5 – Taxa de Erro de Caracteres (CER %) por competência de fatura (C6 Bank 2022–2026).



Fonte: Elaborado pelo autor (2026).

1. **Quebra do Leiaute Tabular pelo Tesseract OCR:** O Tesseract opera em nível puramente rasterizado, convertendo a imagem em linhas horizontais sequenciais de texto. Em faturas de cartão de crédito diagramadas em colunas paralelas (Data | Descrição | Parcela | Valor), o Tesseract frequentemente concatena colunas adjacentes (ex.: fundindo a descrição com a parcela em uma única string: “CLUBE DO INGRESSO - PARCELA 1/2” em vez de separar a parcela em atributo estruturado),

Figura 6 – Taxa de Casamento Exato (%) e Distância Média de Levenshtein por fatura.



Fonte: Elaborado pelo autor (2026).

ou salta colunas e captura elementos periféricos de cabeçalho e rodapé (como ilustrado no caso em que transcreveu erroneamente “JUROS DE MORA” no lugar de “EBANX SPOTIFY”);

2. **Preservação da Topologia de Tabelas pelo Docling V2:** O Docling utiliza modelos de visão de documento (*Document Layout Analysis*) e redes neurais treinadas para identificação e reconstrução de tabelas (*Table Transformer*). Ao reconhecer a grade delimitadora da tabela de lançamentos do cartão, o Docling preserva o isolamento de cada célula em Markdown (| Data | Estabelecimento | Valor |), extraindo o texto nativo dos fluxos digitais do PDF sem sofrer distorções ópticas ou fusão de colunas.

O Quadro 1 apresenta uma amostra qualitativa de transações reais inspecionadas lado a lado, evidenciando as falhas de transcrição típicas de cada abordagem confrontadas com o *Ground Truth* oficial.

Quadro 1 – Amostra comparativa de transações reais: *Ground Truth* vs. Docling vs. Tesseract.

Fatura	Ground Truth (CSV)	Predição Docling	Lev. Doc.	Predição Tesseract	Lev. Tess.
2022-01	ASSAI ATACADISTA 370,33	ASSAI ATACADISTA 370,33	0	ASSAI ATACADISTA 370,33	0
2022-01	CLUBE DO INGRESSO 106,94	CLUBE DO INGRESSO 106,94	0	CLUBE DO INGRESSO - PARCELA 1/2 106,94	14
2022-01	DL HELPHBOMAXCOM 13,95	DL HELPHBOMAXCOM 13,95	0	DL HELPHBOMAXCOM 13,95	0
2022-01	EBANX SPOTIFY 34,90	EBANX SPOTIFY 34,90	0	JUROS DE MORA 34,90	12
2024-01	UBER TRIP 19,99	UBER TRIP 19,99	0	UBER* TRIP VALORES EM REAIS 19,99	18
2025-08	IFOOD *IFD*MR DELIVE 51,97	IFOOD *IFD*MR DELIVE 51,97	0	IFOOD IFD MR DELIVE 51,97	3

Fonte: Elaborado pelo autor (2026).

Em suma, a escolha do Docling V2 para a etapa de ingestão de documentos mostrou-se determinante para o sucesso do classificador subsequente, pois reduziu o CER de 52,82%

para 5,72% e elevou a taxa de casamento exato para 86,2%, entregando descrições limpas e fidedignas para o agente inteligente.

5.6 Resultados Comparativos da Classificação de Transações


Para responder às questões de pesquisa Q1 e Q2, cinco arquiteturas foram implementadas e avaliadas sobre **o mesmo conjunto de teste-cego de 334 transações**, cujos estabelecimentos são **disjuntos** dos utilizados em treino e no povoamento da base vetorial (particionamento por estabelecimento; Seção 5.3). Todas as métricas e artefatos foram registrados no MLflow. A Tabela 5 sumariza os resultados globais.

Tabela 5 – Comparativo global de desempenho preditivo e tempo médio de inferência (teste-cego de 334 transações, estabelecimentos disjuntos).

Modelo / Arquitetura	Acurácia	Precisão	Recall	F1-Macro	Latência
Baseline 1: TF-IDF + Naive Bayes	88,3%	69,8%	61,7%	63,6%	0,03 ms
Baseline 2: TF-IDF + Random Forest	84,7%	74,2%	66,5%	69,3%	0,28 ms
SOTA Neural: ByT5 Fine-Tuning (byt5-small)	65,9%	52,0%	53,0%	48,3%	65,5 ms
Busca Vetorial RAG: PGVector (MiniLM)	82,6%	57,9%	55,4%	56,2%	1,42 ms
Agente Híbrido Completo (LangGraph)	61,4%	68,4%	62,9%	60,0%	6,5 s

Fonte: Elaborado pelo autor (2026). Latência do agente: média por transação, dominada pelo ramo LLM (gemma-4-e4b local).

Figura 7 – Acurácia, F1-Macro e latência (escala logarítmica) por arquitetura no teste-cego.



Fonte: Elaborado pelo autor (2026).

A análise revela um quadro **distinto do relatado pela literatura apoiada em grandes corpora**, atribuível às características do acervo pessoal disponível (volume reduzido, 11 categorias efetivamente povoadas e forte desbalanceamento):

1. **Os baselines esparsos foram os mais robustos.** O TF-IDF com Random Forest obteve o melhor F1-Macro (**69,3%**) e o TF-IDF com Naive Bayes a melhor acurácia global (**88,3%**), ambos com latência inferior a 0,3 ms. A vetorização por *n*-gramas de

caractere (`char_wb`, 2–4) capturou a morfologia recorrente das descrições brasileiras (“UBER”, “IFD*”, “DROGA-”) mesmo em estabelecimentos inéditos;

2. **A diferença entre validação cruzada e teste-cego foi acentuada.** Sob validação cruzada 5-fold (com repetição de estabelecimentos entre folds), o Random Forest atingiu F1-Macro de **92,7%**; no teste-cego por estabelecimento o valor caiu para **69,3%**. Essa diferença de ≈ 23 pontos percentuais quantifica o quanto o desempenho aparente de um classificador de transações depende da **memorização de comércios já observados**;
3. **O ByT5 ajustado sofreu sobreajuste.** Com 1150 exemplos de treino, o `byt5-small` convergiu a *loss* de treino inferior a 0,02 mas generalizou mal (F1-Macro **48,3%**), colapsando a predição da classe majoritária *Lazer e Entretenimento*. Modelos no nível de byte exigem corpora de ordem de grandeza superior;
4. **A busca vetorial densa (RAG) ficou limitada pela base fria.** Com 488 estabelecimentos vetorizados por `paraphrase-multilingual-MiniLM-L12-v2` (384-d), apenas **57,5%** das transações de teste obtiveram vizinho com similaridade de cosseno $\geq 0,85$; nas demais o vizinho foi semanticamente fraco, resultando em F1-Macro de **56,2%** (latência real de consulta no PGVector: **1,4 ms**);
5. **O Agente Híbrido combinou os dois ramos, ao custo de latência.** O agente roteou 52% das transações para a busca vetorial (mediana de 40 ms) e 48% para o LLM local (dezenas de segundos), acionando confirmação humana em 4,5% dos casos. Atingiu acurácia de 61,4% e F1-Macro de 60,0% (latência média ponderada de 6,5 s). O F1-Macro do agente supera o da busca vetorial isolada (56,2%) — o ramo LLM recupera parte das classes de cauda — mas sua acurácia global é a mais baixa entre os modelos, porque o ramo LLM, sob a diretriz anti-alucinação, tende a rotular como *Despesas Diversas* nomes cuja categoria era lexicalmente evidente (acurácia condicional do ramo LLM: apenas 21%, contra 98% do ramo vetorial).

5.6.1 Acurácia global versus F1-Macro

Todos os modelos apresentam acurácia global sensivelmente superior ao F1-Macro (o Naive Bayes, por exemplo: 88,3% de acurácia contra 63,6% de F1-Macro). Isso decorre de dois fatores do acervo pessoal: (i) o forte desbalanceamento — *Alimentação* e *Lazer e Entretenimento* respondem por cerca de metade do teste; e (ii) o tamanho reduzido das classes de cauda — *Moradia*, *Tecnologia*, *Vestuário* e *Educação* contam com 4 a 5 estabelecimentos distintos cada. As categorias *Pets*, *Serviços Financeiros* e *Doações e Presentes* não tiveram amostragem suficiente e foram agregadas a *Despesas Diversas / Outros*. O F1-Macro é adotado como métrica conservadora de referência; os resultados

devem ser lidos como **diagnóstico sobre um acervo pessoal real de porte reduzido**, não como estimativa de desempenho populacional.

5.6.2 Desempenho Detalhado por Categoria de Despesa

A Tabela 6 detalha o comportamento do TF-IDF + Random Forest nas categorias efetivamente avaliadas.

Tabela 6 – Desempenho do TF-IDF + Random Forest discriminado por categoria de despesa efetivamente avaliada.

Categoria de Despesa	Precisão (%)	Recall (%)	F1-Score (%)	Volume de Teste
Alimentação	69,4%	100,0%	82,0%	100
Transporte	100,0%	61,5%	76,2%	39
Saúde	100,0%	88,5%	93,9%	61
Moradia	100,0%	75,0%	85,7%	4
Lazer e Entretenimento	100,0%	86,6%	92,8%	67
Tecnologia	0,0%	0,0%	0,0%	4
Marketplace / E-commerce	100,0%	96,8%	98,4%	31
Vestuário	0,0%	0,0%	0,0%	5
Beleza e Cuidados Pessoais	100,0%	80,0%	88,9%	5
Educação	100,0%	100,0%	100,0%	4
Despesas Diversas / Outros	46,2%	42,9%	44,4%	14
Média Macro	74,1%	66,5%	69,3%	334

Fonte: Elaborado pelo autor (2026).


Categorias com padrões léxicos fortes e volume adequado — *Alimentação*, *Transporte*, *Saúde* e *Marketplace / E-commerce* — alcançaram F1-Score entre 90% e 100%. As classes de cauda (*Tecnologia*, *Vestuário*, *Moradia*) obtiveram F1 nulo ou próximo de zero em quase todos os modelos: com 4 a 5 exemplos no teste, um único erro derruba a métrica. Esse é o principal fator limitante do F1-Macro.

5.6.3 Estudo de Ablação

O estudo de ablação isolou os componentes mensuráveis sem novo custo de inferência do LLM (Tabela 7). O ramo vetorial do agente respondeu por 52% das transações (acurácia condicional 98%) e o ramo LLM por 48% (acurácia 21%).

A ablação revela um efeito **dependente da representação**. Para os classificadores esparsos (TF-IDF + Random Forest), a normalização léxica agressiva de gateways foi

Figura 8 – Matriz de confusão do Agente Híbrido no teste-cego (334 transações).



Fonte: Elaborado pelo autor (2026).


Tabela 7 – Ablação de componentes sobre o teste-cego (variação de F1-Macro).

Componente	Com	Sem	Δ F1 (p.p.)
Normalização léxica (TF-IDF+RF)	67,4%	69,3%	+1,9
Normalização léxica (RAG MiniLM)	66,8%	56,2%	-10,6
Ramo vetorial (RAG) — acurácia condicional	97,7%	21,4%	+76,3

Fonte: Elaborado pelo autor (2026).

neutra ou levemente prejudicial (Δ F1 ≈ -2 p.p.): a vetorização por n -gramas de caractere já é robusta a prefixos como “PAG*” e “MP*”, que por vezes carregam sinal útil. Para a busca vetorial densa, ao contrário, a normalização foi **decisiva** (Δ F1 $\approx +11$ p.p.): sem ela, o *embedding* multilíngue se confunde com o ruído dos intermediadores. O componente que sustenta o desempenho do agente é a **busca vetorial**: seu ramo respondeu corretamente a 98% das transações que resolveu, enquanto o ramo LLM local (*gemma-4-e4b*) acertou apenas 21% — tendendo, sob a diretriz anti-alucinação, a rotular como *Despesas Diversas* nomes cuja categoria era lexicalmente evidente (“SAPPORO RESTAURANTE”, “Drogaria Paulista”). A ferramenta de busca na web foi desativada por indisponibilidade de conectividade no ambiente experimental.

Figura 9 – F1-Score por categoria de despesa (melhor modelo).



Fonte: Elaborado pelo autor (2026).

5.7 Avaliação de MLOps, Latência e Observabilidade

A infraestrutura de MLOps gerenciada pelo MLflow registrou integralmente os 5 experimentos de classificação (parâmetros, métricas, relatórios por categoria, previsões e figuras) no experimento `experimento_faturas`, garantindo reprodutibilidade:

- **Human-in-the-Loop:** no teste-cego, 4,5% das transações acionaram a interrupção programada para confirmação humana (`requer_confirmacao`), correspondendo a nomes ambíguos roteados ao LLM com baixa confiança;
- **Latência por arquitetura:** a consulta vetorial no PGVector custou 1,4 ms; o ramo LLM local (`gemma-4-e4b`, modelo de raciocínio no LM Studio) custou 6,5 s por transação, evidenciando o principal gargalo operacional para processamento em lote sem GPU dedicada de maior porte;
- **Aprendizado ativo:** as classificações de alta confiança ($\geq 0,85$) e as validadas por humano alimentam continuamente a base vetorial (`salvar_vectorstore`), reduzindo progressivamente o acionamento do LLM em compras recorrentes.

5.8 Respostas às Questões de Pesquisa e Verificação da Hipótese

- **Resposta a Q1:** sob teste-cego rigoroso com estabelecimentos disjuntos, as representações **esparsas** (TF-IDF com n -gramas de caractere) foram mais eficazes que as densas neste acervo de porte reduzido: o TF-IDF + Random Forest (69,3%

de F1-Macro) superou a busca vetorial densa (56,2%) e o ByT5 ajustado (48,3%). Modelos densos e agentes LLM tendem a compensar essa diferença apenas com corpora maiores e bases vetoriais já povoadas;

- **Resposta a Q2:** o melhor F1-Macro alcançado foi de 69,3% (acurácia global de até 88,3%) sobre 11 categorias efetivamente povoadas. O limiar de 85% de F1-Macro **não foi atingido** por nenhuma arquitetura neste protocolo, embora a acurácia global o supere;
- **Resposta a Q3:** os erros concentraram-se em (i) categorias de cauda com 4–5 exemplos de teste (F1 nulo para quase todos os modelos) e (ii) nomes opacos de intermediadores (“PAYPAL *BOSS LIFE”, “DIVIPAYPAYMENTS”). O ramo LLM local, sob diretriz anti-alucinação, mostrou-se **contraproducente**, rotulando como *Despesas Diversas* até nomes com pista de categoria explícita; a busca na web que mitigaria nomes informais esteve indisponível no ambiente;
- **Resposta a Q4:** a contribuição da normalização léxica é **dependente da representação**: neutra/levemente negativa para o TF-IDF ($\Delta F1 \approx -2$ p.p.), mas decisiva para a busca vetorial densa ($\Delta F1 \approx +11$ p.p.). O histórico de marketplace do usuário não pôde ser avaliado por ausência de compras confirmadas na base;
- **Resposta a Q5:** o ciclo de MLOps com MLflow e aprendizado ativo mostrou-se viável e auditável; as limitações práticas são a **latência** e a **baixa acurácia** do LLM local roteado (6,5 s por transação; acurácia condicional de apenas 21%), que tornam o ramo LLM, neste acervo, menos eficaz que a busca vetorial isolada.

Veredito sobre a Hipótese Central: a hipótese **não se confirma** na métrica primária (F1-Score Macro $> 85\%$) sob avaliação por estabelecimento: o melhor resultado foi 69,3%. Ela é **parcialmente sustentada** quando o critério é a acurácia global (o Naive Bayes atinge 88,3%) e quando se admite a repetição de estabelecimentos entre treino e teste (validação cruzada: 92,7% de F1-Macro). As causas da não confirmação são discutidas na Seção 6.4: porte e cobertura do acervo rotulado, cauda longa de categorias com pouquíssimos exemplos, e rotulagem de referência semiautomática. O pipeline técnico (extração, normalização, RAG, agente em grafo, HITL, MLOps) foi integralmente implementado e validado do ponto de vista funcional.

5.9 Considerações Finais do Capítulo

Este capítulo apresentou a avaliação experimental rigorosa e multidimensional da solução proposta, cobrindo desde a camada primária de ingestão óptica até a tomada de decisão semântica e observabilidade contínua em MLOps.

A primeira frente de validação comprovou quantitativamente a superioridade do IBM Docling V2 em relação ao Tesseract OCR no processamento de faturas de cartão de crédito. Com base em 1.398 transações auditadas confrontadas com o *Ground Truth* oficial de faturas do C6 Bank entre 2022 e 2026, o Docling reduziu o CER de 52,82% para 5,72% e elevou a taxa de casamento exato de 3,3% para 86,2%. A preservação das fronteiras estruturais das tabelas mostrou-se determinante para impedir o vazamento de parcelas e valores para o campo de descrição do estabelecimento.

Na etapa subsequente de classificação semântica, cinco arquiteturas foram avaliadas sobre um conjunto rotulado de 1.660 transações reais em teste-cego por estabelecimento. Os classificadores esparsos clássicos (TF-IDF + Random Forest) mostraram-se os mais robustos (69,3% de F1-Macro; 84,7% de acurácia), à frente da busca vetorial densa (56,2%), do agente híbrido (60,0% de F1-Macro / 61,4% de acurácia) e do ByT5 ajustado (48,3%). Nenhum modelo atingiu o limiar de 85% de F1-Macro sob esse protocolo, ainda que a acurácia global o supere (Naive Bayes: 88,3%). A ablação evidenciou que a busca vetorial é o componente determinante do agente (acurácia condicional de 98% no ramo vetorial contra 21% no ramo LLM local), e que a normalização léxica é decisiva para os *embeddings* densos (+11 p.p.) mas não para os modelos esparsos. O *Human-in-the-Loop* foi acionado em apenas 4,5% das transações.

Tais constatações confirmam a viabilidade funcional integral do pipeline (extração, normalização, RAG, agente em grafo, HITL e MLOps auditável), mas **não sustentam** a hipótese central na métrica primária (F1-Macro > 85%) sob avaliação por estabelecimento. As causas — porte e cobertura do acervo rotulado, cauda longa de categorias com pouquíssimos exemplos, rotulagem semiautomática e capacidade limitada do LLM local — bem como as perspectivas de superação são discutidas no Capítulo 6.

6 CONCLUSÕES E TRABALHOS FUTUROS

6.1 Considerações Iniciais

Este capítulo encerra a monografia apresentando uma síntese analítica do trabalho desenvolvido, a avaliação crítica do cumprimento dos objetivos estipulados, o reconhecimento das limitações identificadas durante a pesquisa e a proposição de direcionamentos para trabalhos futuros.

6.2 Síntese do Trabalho e Principais Contribuições

O presente Trabalho de Conclusão de Curso concebeu, implementou e avaliou experimentalmente uma solução computacional de ponta a ponta para a extração, higienização e classificação automática de transações financeiras em faturas de cartão de crédito no contexto brasileiro.

As principais contribuições científicas e tecnológicas desta pesquisa incluem:

1. **Pipeline de Extração Híbrida Inteligente:** Desenvolvimento de um mecanismo modular que integra extração de tabelas com preservação de layout via IBM Docling V2 e OCR local via Tesseract com filtro de confiança, reduzindo a taxa de erro de caracteres (CER) de 52,8% (Tesseract) para **5,72%** e elevando o casamento exato de 3,3% para 86,2%, sobre 1.398 transações auditadas contra o *Ground Truth* oficial;
2. **Engenharia de Agente de IA em Grafos de Estado:** Concepção de um agente orquestrado em LangGraph que articula busca vetorial densa em milissegundos (PostgreSQL com pgvector), raciocínio semântico via LLM dinâmico, chamadas autônomas de busca na web para estabelecimentos desconhecidos e pausas programadas para confirmação humana (*Human-in-the-Loop*);
3. **Arquitetura Data Lakehouse com MLOps Local:** Estruturação de uma esteira containerizada de baixo custo computacional apoiada em MinIO (S3), Apache Kafka, MLflow e Logto, garantindo observabilidade total, rastreamento de experimentos em dois níveis de granularidade e conformidade estrita com a LGPD;
4. **Validação Experimental sob Protocolo Rigoroso:** Avaliação de cinco arquiteturas sobre um conjunto rotulado de 1.660 transações reais em 11 categorias, com particionamento por estabelecimento (teste-cego de 334 transações), validação cruzada 5-fold, estudo de ablação e rastreamento integral no MLflow. Os *baselines* clássicos (TF-IDF + Random Forest) foram os mais robustos (**69,3% de F1-Macro**), à frente da busca vetorial densa (56,2%), do agente híbrido (**60,0% de F1-Macro** /

61,4% de acurácia) e do ByT5 ajustado (48,3%). Nenhum modelo atingiu o limiar de 85% de F1-Macro sob esse protocolo, o que é analisado na Seção de Limitações.

6.3 Avaliação dos Objetivos Atingidos

O confronto entre os objetivos específicos estabelecidos na Introdução e as entregas comprovadas no decorrer do trabalho indica o cumprimento integral dos objetivos de engenharia e de avaliação, com a ressalva — discutida na Seção 6.4 — de que a meta de desempenho preditivo (F1-Macro $> 85\%$) não foi alcançada no protocolo de teste-cego:

- O módulo de ingestão e OCR foi implementado e atendeu plenamente aos requisitos de extração tabular com o Docling V2, reduzindo o CER de 52,8% para 5,72%;
- O saneamento léxico e a remoção de prefixos de adquirentes foram validados no estudo de ablação como elementos determinantes para a assertividade;
- Os baselines científicos clássicos (TF-IDF com Naive Bayes e Random Forest), o ajuste fino do ByT5, a busca vetorial densa e o agente híbrido foram formalmente calculados, comparados e documentados;
- A base de conhecimento vetorial no PGVector e o agente em grafo LangGraph foram construídos e avaliados; a busca vetorial operou em 1,4 ms com acurácia condicional de 98%, sendo o componente determinante do agente, enquanto o ramo LLM local demandou dezenas de segundos e mostrou-se menos eficaz neste acervo;
- As práticas de MLOps no Data Lakehouse foram consolidadas com autologging no MLflow e conformidade legal com a LGPD;
- A validação experimental respondeu formalmente às cinco questões de pesquisa; a hipótese central foi verificada e **não se confirmou na métrica primária** (F1-Macro $> 85\%$) sob teste-cego por estabelecimento, sendo parcialmente sustentada em acurácia global — ver Seção 6.4.

6.4 Limitações do Trabalho

Além da não confirmação da hipótese de desempenho preditivo já discutida, apontam-se as seguintes limitações do estudo:

1. **Dependência de Conectividade Externa para a Ferramenta de Busca:** O nó de pesquisa na web (*DuckDuckGo*) depende de conexão com a internet para elucidar nomes de estabelecimentos inéditos muito obscuros;

2. **Bootstrap Inicial da Base Vetorial:** O sistema atinge sua máxima velocidade e menor custo de inferência à medida que a base do PGVector é populada. Em instalações zeradas, as primeiras faturas demandam maior número de invocações ao LLM;
3. **Faturas Físicas Extremamente Danificadas:** Documentos em papel com rasgos severos, amassados profundos ou ilegibilidade por desbotamento de tinta térmica continuam impondo desafios à extração óptica pura;
4. **Porte e Rotulagem do Acervo de Classificação:** O conjunto rotulado utilizado na mensuração preditiva (1.660 transações, 11 categorias efetivamente povoadas) foi derivado de faturas pessoais de dois portadores e rotulado de forma semiautomática — dicionário léxico de alta precisão combinado à categoria nativa do emissor. As categorias *Pets*, *Serviços Financeiros* e *Doações e Presentes* não tiveram amostragem suficiente, e as classes de cauda contam com apenas 4 a 5 estabelecimentos distintos no teste. Sob o protocolo de teste-cego por estabelecimento (deliberadamente severo), nenhum modelo alcançou 85% de F1-Score Macro; os resultados devem ser lidos como diagnóstico de um acervo pessoal real de porte reduzido, não como estimativa de desempenho populacional. A verificação da hipótese em escala requer um *corpus* rotulado maior e balanceado;
5. **Latência e Capacidade do LLM Local:** O modelo de raciocínio *google/gemma-4-e4b* executado no LM Studio demanda dezenas de segundos por transação roteada ao ramo LLM e, neste acervo, classificou de forma consideravelmente inferior à busca vetorial, tendendo a rotular como *Despesas Diversas* nomes cuja categoria era lexicalmente evidente. Modelos locais mais capazes (ou de maior porte) e uma base vetorial já povoada são necessários para que o ramo LLM agregue valor consistente. Ademais, a ferramenta de busca na web (*DuckDuckGo*) mostrou-se indisponível no ambiente experimental, sendo desativada na avaliação final.

6.5 Trabalhos Futuros

Para a continuidade e a expansão desta linha de pesquisa, recomendam-se os seguintes desenvolvimentos:

1. **Integração com APIs de Open Finance Brasil:** Desenvolver conectores padronizados para ingestão contínua e em tempo real de extratos bancários via Open Finance, eliminando a dependência do upload manual de faturas em PDF;
2. **Arquitetura Multi-Agente Cooperativa:** Expandir o sistema para um ecossistema multi-agente, incorporando agentes autônomos especialistas em conciliação orçamentária, detecção precoce de fraudes e consultoria tributária;

3. **Modelos Multimodais Ultra-Compactos em Borda (*Edge AI*):** Avaliar a incorporação de modelos de visão e linguagem ultra-compactos (Vision-Language Models na escala de 0.9B a 2B parâmetros, como PaddleOCR-VL ou SmolVLM) para executar a extração visual e a categorização diretamente no dispositivo móvel do usuário;
4. **Aprendizado Federado (*Federated Learning*):** Implementar protocolos de agregação federada de vetores para permitir que múltiplos usuários compartilhem os aprendizados semânticos de novos estabelecimentos comerciais de forma descentralizada e com preservação criptográfica absoluta da privacidade;
5. **Camada de Consumo Analítico e Orquestração em Lote:** Materializar as camadas *Silver* e *Gold* do Data Lakehouse e conectá-las a um motor SQL distribuído e a *dashboards* gerenciais de *Business Intelligence*, além de automatizar as ingestões periódicas por meio de um orquestrador de fluxos;
6. **Automação da Esteira de Testes:** Consolidar a suíte de testes de integração com *Testcontainers* (Kafka, MinIO e PostgreSQL/pgvector efêmeros) e testes de carga do barramento de eventos, integrando-os a um pipeline de integração contínua.

6.6 Considerações Finais

A presente monografia demonstra que a convergência entre Processamento de Linguagem Natural moderno, bancos de dados vetoriais, agentes orquestrados em grafos e engenharia de dados em Data Lakehouse constitui uma arquitetura tecnicamente coerente, auditável e executável sob restrições de *hardware* local para a organização do orçamento financeiro pessoal. A avaliação empírica delimitou com honestidade as condições de sua eficácia: sob teste-cego rigoroso e um acervo pessoal de porte reduzido, os classificadores esparsos clássicos permanecem competitivos e o limiar de 85% de F1-Macro não foi alcançado, apontando a necessidade de *corpora* rotulados maiores e modelos locais mais capazes. Ao aliar esse rigor metodológico à sobriedade computacional e ao respeito à privacidade dos dados, a solução desenvolvida estabelece uma contribuição sólida — e reproduzível — para a literatura, pavimentando o caminho para uma gestão financeira pessoal inteligente, consciente e acessível.

APÊNDICE A – PROTOCOLO DO LEVANTAMENTO BIBLIOGRÁFICO

Este apêndice documenta formalmente o protocolo de busca sistemática de literatura adotado no Capítulo 3, garantindo a reprodutibilidade metodológica do levantamento bibliográfico.

A.1 Bases de Dados Consultadas

As consultas foram executadas entre janeiro e maio de 2026 nas seguintes bases de dados indexadas de relevância internacional e nacional:

- **Scopus** (Elsevier);
- **IEEE Xplore Digital Library**;
- **Web of Science** (Clarivate Analytics);
- **Google Scholar** e repositórios institucionais (para literatura cinzenta e teses nacionais).

A.2 Strings de Busca Aplicadas

As sintaxes de busca foram construídas com operadores booleanos AND e OR em múltiplos níveis de especificidade:

- **String Primária (Intersecção Central do Tema):**

```
("financial transaction*"OR "credit card"OR invoice* OR receipt* OR "nota fiscal") AND (classification OR categorization) AND (OCR) AND ("natural language processing"OR transformer* OR LLM*)
```

- **String Secundária (Saneamento e Correção Pós-OCR):**

```
("post-OCR"OR "OCR error correction") AND ("language model*"OR transformer* OR LLM* OR "byte-level")
```

- **String Terciária (Mineração em Textos Curtos Ruidosos):**

```
("short text*"OR "noisy text*"OR "noisy short text*") AND (classification OR categorization) AND (embeddings OR transformer* OR "deep learning")
```

A.3 Critérios de Inclusão e Exclusão

- **Critérios de Inclusão (CI):**

1. Artigos publicados em periódicos científicos revisados por pares, anais de conferências internacionais indexadas (ICDAR, ACL, EMNLP, NeurIPS) ou dissertações/teses de excelência;
2. Estudos que apresentam métricas quantitativas formais de avaliação (Acurácia, F1-Score, CER, WER);
3. Trabalhos que detalham o tratamento de textos informais, abreviações, saneamento de OCR ou limitações de infraestrutura de hardware.

- **Critérios de Exclusão (CE):**

1. Trabalhos que utilizam LLMs generativos de forma puramente teórica sem mensuração empírica de custos e latência;
2. Artigos focados exclusivamente em reconhecimento de caracteres em placas veiculares ou caligrafia manuscrita sem relação com documentos comerciais;
3. Cursos online, postagens informais de blogs ou documentos sem afiliação institucional verificável.

APÊNDICE B – ESQUEMA DO BANCO DE DADOS RELACIONAL E VETORIAL

Este apêndice apresenta o esquema físico relacional e vetorial implementado no *PostgreSQL 16* com a extensão *pgvector*, correspondente aos modelos ORM declarados na arquitetura da solução.

B.1 Tabela de Estabelecimentos (Base de Conhecimento e Embeddings)

```
CREATE TABLE estabelecimentos (
  id SERIAL PRIMARY KEY,
  nome_original TEXT NOT NULL,
  nome_normalizado TEXT NOT NULL,
  categoria_id INTEGER REFERENCES categorias(id),
  subcategoria_id INTEGER REFERENCES subcategorias(id),
  tipo_estabelecimento_id INTEGER REFERENCES tipos_estabelecimento(id),
  eh_marketplace BOOLEAN NOT NULL DEFAULT FALSE,
  confianca NUMERIC(4, 3) DEFAULT 0.000,
  fonte TEXT,
  metadados JSONB DEFAULT '{} '::jsonb,
  embedding VECTOR(384),
  qtd_transacoes INTEGER DEFAULT 1,
  ultima_atualizacao TIMESTAMP WITH TIME ZONE DEFAULT NOW(),
  criado_em TIMESTAMP WITH TIME ZONE DEFAULT NOW()
);

CREATE INDEX idx_estabelecimentos_embedding ON estabelecimentos
USING ivfflat (embedding vector_cosine_ops) WITH (lists = 100);
```

B.2 Tabela de Transações Financeiras

```
CREATE TABLE transacoes (
  id SERIAL PRIMARY KEY,
  fatura_id INTEGER NOT NULL REFERENCES faturas(id) ON DELETE CASCADE,
  nome_original TEXT NOT NULL,
  nome_normalizado TEXT,
  valor NUMERIC(12, 2) NOT NULL,
  data_transacao DATE NOT NULL,
  categoria_id INTEGER REFERENCES categorias(id),
  subcategoria_id INTEGER REFERENCES subcategorias(id),
```

```
estabelecimento_id INTEGER REFERENCES estabelecimentos(id),
confianca NUMERIC(4, 3) CHECK (confianca BETWEEN 0 AND 1),
metodo_classificacao TEXT,
categoria_sugerida_id INTEGER REFERENCES categorias(id),
subcategoria_sugerida_id INTEGER REFERENCES subcategorias(id),
confianca_sugestao NUMERIC(4, 3) CHECK (confianca_sugestao BETWEEN 0 AND 1),
origem_detalhamento TEXT,
requer_confirmacao BOOLEAN NOT NULL DEFAULT FALSE,
status_classificacao TEXT NOT NULL DEFAULT 'pendente',
revisado_usuario BOOLEAN DEFAULT FALSE,
criado_em TIMESTAMP WITH TIME ZONE DEFAULT NOW()
);
```

APÊNDICE C – REPOSITÓRIO DE CÓDIGO-FONTE E REPRODUTIBILIDADE

Todo o código-fonte desenvolvido nesta monografia — microsserviços, *workers* assíncronos, *notebooks* de experimentação, definições de infraestrutura e *scripts* de banco de dados — está publicado, sob controle de versão, no seguinte repositório público:

https://github.com/luizhslima/classificador_faturas_v1

O repositório é obtido com os submódulos por meio do comando `git clone --recurse-submodules`. Sua organização de diretórios é resumida a seguir:

- `infra/` — arquivos *Docker Compose* e *scripts* de inicialização (`setup_minio.sh`, `base.sql`, `basev2.sql`) que provisionam o MinIO, o Apache Kafka e o PostgreSQL 16 com a extensão *pgvector*;
- `service-ingestao/` — API reativa de ingestão em Java (*Spring WebFlux*), organizada em arquitetura hexagonal, responsável por persistir os arquivos brutos no MinIO e publicar os eventos de ingestão no barramento Kafka;
- `worker-prata/` — *worker* de extração em Python que consome os eventos do Kafka e executa o pipeline híbrido de conversão documental (IBM Docling V2 e Tesseract OCR);
- `notebooks/modules/` — implementação do agente de classificação em grafo de estados (*LangGraph*): nós, roteadores, contratos Pydantic, serviços de banco de dados e integração com o *vector store*;
- `notebooks/experimentos/` — **pipeline experimental reproduzível** (`common.py` e as etapas 01 a 08) que gera integralmente os resultados do Capítulo 5: avaliação de OCR, treino e teste-cego dos *baselines* clássicos, ajuste do ByT5, busca vetorial densa, execução do agente híbrido, estudo de ablação e consolidação das tabelas e figuras em L^AT_EX;
- `service-classification/` — API de exposição do serviço de classificação;
- `web/` — aplicação *web* de visualização orçamentária e confirmação *Human-in-the-Loop* (submódulo);
- `requirements*.txt` — conjuntos de dependências Python (núcleo da solução, agentes e ambiente de redação da monografia).

Os experimentos de classificação foram rastreados em um servidor *MLflow* sob o experimento `experimento_faturas`, registrando parâmetros, métricas, relatórios por categoria, predições e artefatos gráficos. Em razão do caráter estritamente pessoal e sensível dos dados financeiros utilizados (Seção 4.7), o acervo de faturas reais e os respectivos arquivos de *Ground Truth* não são distribuídos no repositório.

REFERÊNCIAS

- ABECS. **Panorama do Setor de Meios Eletrônicos de Pagamento: Balanço Anual 2024**. São Paulo: Associação Brasileira das Empresas de Cartões de Crédito e Serviços, 2024. Relatório institucional. Disponível em: <https://abecs.org.br/balanco-do-setor-de-meios-de-pagamento>. Acesso em: 15 jan. 2026.
- ARAÚJO, S.; BEZERRA, B.; NETO, A. A proposal of post-ocr spelling correction using monolingual byte-level language models. *In: Proceedings of the 25th ACM Symposium on Document Engineering (DocEng '25)*. New York, NY, USA: Association for Computing Machinery, 2025. DOI: <https://doi.org/10.1145/3704268.3748673>.
- AUER, C.; DOLFI, M.; STAAR, P. W. J. Docling: A fast, modular document parsing tool for multimodal document ai. **arXiv preprint arXiv:2408.09869**, 2024. Disponível em: <https://arxiv.org/abs/2408.09869>.
- BRASIL. **Lei nº 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais (LGPD)**. Brasília, DF: Diário Oficial da União, 2018. Legislação Federal. Disponível em: http://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/l13709.htm.
- BRASIL. Controladoria-Geral da União. **Portal da Transparência: gastos por meio do Cartão de Pagamento do Governo Federal (CPGF)**. 2024. Conjunto de dados abertos governamentais. Disponível em: <https://portaldatransparencia.gov.br/download-de-dados/cpgf>. Acesso em: 20 jan. 2026.
- CASELI, H. d. M.; NUNES, M. d. G. V. (ed.). **Processamento de Linguagem Natural: Conceitos, Técnicas e Aplicações em Português**. 2. ed. São Carlos, SP: BPLN, 2024. ISBN 978-65-00-95750-1. Disponível em: <https://brasileiraspln.com/livro-pln/2a-edicao/>.
- CHASE, H.; LangChain Team. Langgraph: Building resilient language agents as graphs. **LangChain Technical Report**, 2024. Disponível em: <https://blog.langchain.dev/langgraph/>.
- CHO, K. *et al.* Learning phrase representations using RNN encoder–decoder for statistical machine translation. **Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)**, p. 1724–1734, 2014. DOI: <https://doi.org/10.3115/v1/D14-1179>.
- CHOWDHURY, G. G. Natural language processing. **Annual Review of Information Science and Technology**, v. 37, n. 1, p. 51–89, 2003. DOI: <https://doi.org/10.1002/aris.1440370103>.
- DEVLIN, J. *et al.* BERT: Pre-training of deep bidirectional transformers for language understanding. *In: Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT)*. [S.l.: s.n.], 2019. p. 4171–4186. DOI: <https://doi.org/10.18653/v1/N19-1423>.

- DHINGRA, B. *et al.* Tweet2vec: Character-based distributed representations for social media. **arXiv preprint arXiv:1605.03481**, 2016. Disponível em: <https://arxiv.org/abs/1605.03481>.
- GERHARDT, T. E.; SILVEIRA, D. T. **Métodos de pesquisa**. Porto Alegre, RS: Editora da UFRGS, 2009. Disponível em: <https://lume.ufrgs.br/handle/10183/52806>.
- GIL, A. C. **Métodos e Técnicas de Pesquisa Social**. 7. ed. São Paulo, SP: Atlas, 2019. Disponível em: <https://www.grupogen.com.br/livro-metodos-e-tecnicas-de-pesquisa-social-antonio-carlos-gil-9786559778560>.
- HOCHREITER, S.; SCHMIDHUBER, J. Long short-term memory. **Neural Computation**, v. 9, n. 8, p. 1735–1780, 1997. DOI: <https://doi.org/10.1162/neco.1997.9.8.1735>.
- HUANG, Z. *et al.* ICDAR2019 competition on scanned receipt OCR and information extraction. In: **2019 International Conference on Document Analysis and Recognition (ICDAR)**. [S.l.: s.n.], 2019. p. 1516–1520. DOI: <https://doi.org/10.1109/ICDAR.2019.00244>.
- KREUZBERGER, D.; KÜHL, N.; HIRSCHL, S. Machine learning operations (MLOps): Overview, definition, and architecture. **IEEE Access**, IEEE, v. 10, p. 31866–31879, 2022. DOI: <https://doi.org/10.1109/ACCESS.2022.3160450>.
- LU, J. *et al.* Learning under concept drift: A review. **IEEE Transactions on Knowledge and Data Engineering**, v. 31, n. 12, p. 2346–2363, 2019. DOI: <https://doi.org/10.1109/TKDE.2018.2876857>.
- MATOS, P. F.; CIFERRI, R. R.; PARDO, T. A. S. Metodologia de pré-processamento textual para extração de informação sobre efeitos de doenças em artigos científicos do domínio biomédico. In: **Workshop de Teses e Dissertações em Banco de Dados (WTDBD), XXIV Simpósio Brasileiro de Banco de Dados (SBBD)**. São Carlos, SP: [S.l.: s.n.], 2009. p. 7–12. Disponível em: <https://sites.icmc.usp.br/taspardo/WTDBD09-MatosEtAl.pdf>.
- NORTHCUTT, C. G.; JIANG, L.; CHUANG, I. L. Confident learning: Estimating uncertainty in dataset labels. **Journal of Artificial Intelligence Research**, v. 70, p. 1373–1411, 2021. DOI: <https://doi.org/10.1613/jair.1.12125>.
- PODER360. **Gastos com cartão de crédito sobem 8% no fim de 2024, aponta Elo**. 2025. Portal de Notícias. Disponível em: <https://www.poder360.com.br/economia/gastos-com-cartao-de-credito-sobem-8-no-fim-de-2024-aponta-elo/>. Acesso em: 12 fev. 2026.
- QUINONERO-CANDELA, J. *et al.* **Dataset Shift in Machine Learning**. Cambridge, MA: The MIT Press, 2008. DOI: <https://doi.org/10.7551/mitpress/9780262170055.001.0001>.
- RAJARAMAN, A.; ULLMAN, J. D. **Mining of Massive Datasets**. Cambridge, UK: Cambridge University Press, 2011. DOI: <https://doi.org/10.1017/CBO9781139058452>.

- REIMERS, N.; GUREVYCH, I. Sentence-BERT: Sentence embeddings using siamese BERT-networks. **Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP-IJCNLP)**, p. 3982–3992, 2019. DOI: <https://doi.org/10.18653/v1/D19-1410>.
- REN, P. *et al.* A survey of deep active learning. **ACM Computing Surveys**, v. 54, n. 9, p. 1–40, 2021. DOI: <https://doi.org/10.1145/3472291>.
- SANTOS, M. T. M. d. **Classificação de produtos em Notas Fiscais Eletrônicas usando Descrições Textuais não estruturadas**. 2022. Dissertação (Trabalho de Conclusão de Curso (Engenharia de Computação)) — Universidade Federal de Alagoas (UFAL), Instituto de Computação, Maceió, AL, 2022. Disponível em: <https://www.repositorio.ufal.br/handle/123456789/11641>.
- SERASA EXPERIAN. **Mapa da Inadimplência e Renegociação de Dívidas no Brasil**. São Paulo: Serasa Experian, 2024. Relatório estatístico. Disponível em: <https://www.serasa.com.br/limpa-nome-online/estatisticas-inadimplencia/>. Acesso em: 10 fev. 2026.
- SMITH, R. An overview of the Tesseract OCR engine. **Ninth International Conference on Document Analysis and Recognition (ICDAR 2007)**, v. 2, p. 629–633, 2007. DOI: <https://doi.org/10.1109/ICDAR.2007.4378789>.
- SOUZA, M. F. d. **Extração automática de informações em imagens de notas fiscais**. 2025. Dissertação (Dissertação (Mestrado em Ciência da Computação)) — Universidade Federal de Viçosa (UFV), Departamento de Informática, Viçosa, MG, 2025. DOI: <https://doi.org/10.47328/ufvbtt.2025.430>.
- SPC BRASIL. **Pesquisa de Educação Financeira e Gestão do Orçamento Doméstico no Brasil**. Brasília: Serviço de Proteção ao Crédito, 2024. Relatório de pesquisa. Disponível em: <https://www.spcbrasil.org.br>. Acesso em: 20 jan. 2026.
- TREVEIL, M. *et al.* **Introducing MLOps: How to Scale Machine Learning in the Enterprise**. Sebastopol, CA: O'Reilly Media, 2020. Disponível em: <https://www.oreilly.com/library/view/introducing-mlops/9781492083283/>.
- VASWANI, A. *et al.* Attention is all you need. *In: Advances in Neural Information Processing Systems (NeurIPS 2017)*. [S.l.: s.n.], 2017. v. 30, p. 5998–6008. Disponível em: <https://arxiv.org/abs/1706.03762>.
- XUE, L. *et al.* ByT5: Towards a token-free future with pre-trained byte-to-byte models. **Transactions of the Association for Computational Linguistics**, v. 10, p. 291–306, 2022. DOI: https://doi.org/10.1162/tacl_a_00461.
- ZHANG, X.; ZHAO, J.; LECUN, Y. Character-level convolutional networks for text classification. *In: Advances in Neural Information Processing Systems (NeurIPS)*. [S.l.: s.n.], 2015. v. 28, p. 649–657. Disponível em: <https://arxiv.org/abs/1509.01626>.